

یادگیری ماشین: الگوریتم‌ها، کاربردها و تحقیقات در دنیای واقعی
مسیرها

ID اقبال اچ. سارکر 2.1

دریافت: ۲۷ ژانویه / ۲۰۲۱ پذیرش: ۱۲ مارس / ۲۰۲۱ انتشار آنلاین: ۲۲ مارس ۲۰۲۱
© نویسنده(گان)، تحت لایسنس انحصاری Springer Nature Singapore Pte Ltd 2021

چکیده

در عصر کنونی انقلاب صنعتی چهارم (4IR) یا (Industry 4.0) دنیای دیجیتال دارای انبوهی از داده‌ها، مانند داده‌های اینترنت اشیا (IoT)، داده‌های امنیت سایبری، داده‌های تلفن همراه، داده‌های تجاری، داده‌های رسانه‌های اجتماعی، داده‌های سلامت و غیره است. برای تجزیه و تحلیل هوشمندانه این داده‌ها و توسعه برنامه‌های هوشمند و خودکار مربوطه، دانش هوش مصنوعی (AI) به ویژه یادگیری عمیق، (ML) کلید اصلی است. انواع مختلفی از الگوریتم‌های یادگیری ماشین مانند یادگیری نظارت‌شده، بدون نظارت، نیمه‌نظارتی و تقویتی در این حوزه وجود دارد. علاوه بر این، یادگیری عمیق، که بخشی از خانواده وسیع‌تری از روش‌های یادگیری ماشین است، می‌تواند داده‌ها را در مقیاس بزرگ به صورت هوشمندانه تجزیه و تحلیل کند. در این مقاله، ما یک دیدگاه جامع در مورد این الگوریتم‌های یادگیری ماشین ارائه می‌دهیم که می‌توانند برای افزایش هوش و قابلیت‌های یک برنامه کاربردی اعمال شوند. بنابراین، سهم کلیدی این مطالعه توضیح اصول تکنیک‌های مختلف یادگیری ماشین و کاربرد آنها در حوزه‌های مختلف کاربردی دنیای واقعی، مانند سیستم‌های امنیت سایبری، شهرهای هوشمند، مراقبت‌های بهداشتی، تجارت الکترونیک، کشاورزی و بسیاری موارد دیگر است. ما همچنین چالش‌ها و جهت‌های تحقیقاتی بالقوه را برجسته می‌کنیم.

بر اساس مطالعه ما، در مجموع، هدف این مقاله ارائه یک نقطه مرجع برای متخصصان دانشگاهی و صنعتی و همچنین برای تصمیم‌گیرندگان در موقعیت‌های مختلف دنیای واقعی و حوزه‌های کاربردی، به ویژه از دیدگاه فنی، است.

کلمات کلیدی: یادگیری ماشین · یادگیری عمیق · هوش مصنوعی · علم داده · تصمیم‌گیری مبتنی بر داده · تحلیل‌های پیش‌بینی‌کننده · برنامه‌های هوشمند

مقدمه

ما در عصر داده‌ها زندگی می‌کنیم، جایی که همه چیز در اطراف ما به یک منبع داده متصل است و همه چیز در زندگی ما به صورت دیجیتالی ثبت می‌شود. [103، 21] به عنوان مثال، دنیای الکترونیک فعلی دارای انبوهی از انواع داده‌ها، مانند داده‌های اینترنت اشیا (IoT)، داده‌های امنیت سایبری، داده‌های شهر هوشمند، داده‌های تجاری، داده‌های گوشی‌های هوشمند، داده‌های رسانه‌های اجتماعی، داده‌های سلامت، داده‌های کووید-19 و بسیاری موارد دیگر است. این داده‌ها می‌توانند

ساختاریافته، نیمه‌ساختاریافته یا بدون ساختار باشد، که به طور خلاصه در بخش «انواع داده‌های دنیای واقعی و تکنیک‌های یادگیری ماشین» مورد بحث قرار گرفته است، که روز به روز در حال افزایش است.

استخراج بینش از این داده‌ها می‌تواند برای ساخت برنامه‌های هوشمند مختلف در حوزه‌های مربوطه مورد استفاده قرار گیرد. به عنوان مثال، برای ساخت یک سیستم امنیت سایبری خودکار و هوشمند مبتنی بر داده، می‌توان از داده‌های امنیت سایبری مربوطه استفاده کرد. [105] برای ساخت برنامه‌های کاربردی تلفن همراه هوشمند آگاه از زمینه شخصی‌سازی شده، می‌توان از داده‌های تلفن همراه مربوطه استفاده کرد [103] و غیره. بنابراین، ابزارها و تکنیک‌های مدیریت داده که قابلیت استخراج بینش یا دانش مفید از داده‌ها را به روشی به موقع و هوشمندانه دارند، به شدت مورد نیاز است، که برنامه‌های کاربردی دنیای واقعی بر اساس آن بنا شده‌اند.

این مقاله بخشی از مجموعه موضوعی «پیشرفت‌ها در رویکردهای محاسباتی برای هوش مصنوعی، پردازش تصویر، اینترنت اشیا و کاربردهای ابری» است که توسط بهانو پراکاش کی.ان. و ام. شیواکومار به عنوان همزمان ویرایش شده است.

* اقبال اچ. سارکر msarker@swin.edu.au

۱ دانشگاه فناوری سوئینرن، ملیورن، ویکتوریا ۳۱۲۲ استرالیا

۲ دانشکده علوم و مهندسی کامپیوتر،
دانشگاه مهندسی و فناوری چیتاگونگ،
۴۳۳۹ چاتوگرام، بنگلادش

هوش مصنوعی (AI) به ویژه یادگیری ماشین (ML) در سال‌های اخیر در زمینه تجزیه و تحلیل داده‌ها و محاسبات به سرعت رشد کرده‌اند که معمولاً به برنامه‌ها اجازه می‌دهد تا به شیوه‌ای هوشمندانه عمل کنند [95]. ML معمولاً به سیستم‌ها این امکان را می‌دهد که بدون نیاز به برنامه‌ریزی خاص، به طور خودکار از تجربه یاد بگیرند و بهبود یابند و عموماً به عنوان محبوب‌ترین ... شناخته می‌شود.

آخرین فناوری‌ها در انقلاب صنعتی چهارم (4IR)

یا صنعت [103, 105] ۴۰۰ «صنعت [114] ۴۰۰ معمولاً اتوماسیون مداوم شیوه‌های تولید و صنعتی مرسوم، از جمله پردازش داده‌های اکتشافی، با استفاده از فناوری‌های هوشمند جدید مانند اتوماسیون یادگیری ماشین است. بنابراین، برای تجزیه و تحلیل هوشمندانه این داده‌ها و توسعه برنامه‌های کاربردی مربوط به دنیای واقعی، الگوریتم‌های یادگیری ماشین کلید اصلی هستند. الگوریتم‌های یادگیری می‌توان به چهار نوع اصلی، مانند یادگیری تحت نظارت، بدون نظارت، نیمه نظارت و تقویتی در این حوزه [75] طبقه‌بندی کرد که به طور خلاصه در بخش «انواع داده‌های دنیای واقعی و تکنیک‌های یادگیری ماشین» مورد بحث قرار گرفته است. محبوبیت این رویکردها برای یادگیری روز به روز در حال افزایش است، که در شکل ۱، بر اساس داده‌های جمع‌آوری شده از [4] Google Trends در پنج سال گذشته نشان داده شده است. محور x شکل، تاریخ‌های خاص و امتیاز محبوبیت مربوطه را در محدوده ۰ (حداقل) نشان می‌دهد.

تا ۱۰۰ (حداکثر) در محور y نشان داده شده است. طبق شکل ۱، مقادیر نشانگر محبوبیت برای این نوع یادگیری در سال ۲۰۱۵ کم بوده و روز به روز در حال افزایش است. این آمار ما را بر آن می‌دارد تا در این مقاله به مطالعه یادگیری ماشین بپردازیم، که می‌تواند نقش مهمی در دنیای واقعی از طریق اتوماسیون صنعت ۴.۰ ایفا کند.

به طور کلی، اثربخشی و کارایی یک راه‌حل یادگیری ماشین به ماهیت و ویژگی‌های داده‌ها و عملکرد الگوریتم‌های یادگیری بستگی دارد. در حوزه الگوریتم‌های یادگیری ماشین، تحلیل طبقه‌بندی، رگرسیون، خوشه‌بندی داده‌ها، مهندسی ویژگی و کاهش ابعاد، یادگیری قانون وابستگی یا تکنیک‌های یادگیری تقویتی برای ساخت مؤثر سیستم‌های داده‌محور وجود دارند [125, 41].

علاوه بر این، یادگیری عمیق از شبکه عصبی مصنوعی سرچشمه گرفته است که می‌تواند برای تجزیه و تحلیل هوشمندانه داده‌ها مورد استفاده قرار گیرد، که به عنوان بخشی از خانواده وسیع‌تری از رویکردهای یادگیری ماشین شناخته می‌شود [96]. بنابراین، انتخاب یک الگوریتم یادگیری مناسب که برای کاربرد هدف مناسب باشد،

یک دامنه خاص چالش برانگیز است. دلیل آن این است که هدف الگوریتم‌های یادگیری مختلف متفاوت است، حتی نتیجه الگوریتم‌های یادگیری مختلف در یک دسته مشابه ممکن است بسته به ویژگی‌های داده متفاوت باشد [106]. بنابراین، درک اصول الگوریتم‌های مختلف یادگیری ماشین و قابلیت کاربرد آنها در حوزه‌های مختلف کاربردی در دنیای واقعی، مانند سیستم‌های اینترنت اشیا، خدمات امنیت سایبری، سیستم‌های تجاری و توصیه‌گر، شهرهای هوشمند، مراقبت‌های بهداشتی و کووید-19، سیستم‌های آگاه از زمینه، کشاورزی پایدار و بسیاری موارد دیگر که به طور خلاصه در بخش توضیح داده شده‌اند، مهم است.


«کاربردهای یادگیری ماشین».

بر اساس اهمیت و پتانسیل «یادگیری ماشین» برای تجزیه و تحلیل داده‌های ذکر شده در بالا، در این مقاله، ما یک دیدگاه جامع در مورد انواع مختلف الگوریتم‌های یادگیری ماشین که می‌توانند برای افزایش هوش و قابلیت‌های یک برنامه کاربردی به کار روند، ارائه می‌دهیم. بنابراین، سهم کلیدی این مطالعه، توضیح اصول و پتانسیل تکنیک‌های مختلف یادگیری ماشین و کاربرد آنها در حوزه‌های مختلف کاربردی دنیای واقعی است که قبلاً ذکر شد. بنابراین، هدف این مقاله ارائه یک راهنمای اولیه برای آن دسته از افراد دانشگاهی و صنعتی است که می‌خواهند سیستم‌های خودکار و هوشمند مبتنی بر داده را در حوزه‌های مرتبط مبتنی بر تکنیک‌های یادگیری ماشین مطالعه، تحقیق و توسعه دهند.

مشارکت‌های کلیدی این مقاله به شرح زیر فهرست شده‌اند:

-تعریف دامنه مطالعه ما با در نظر گرفتن ماهیت و ویژگی‌های انواع مختلف داده‌های دنیای واقعی و قابلیت‌های تکنیک‌های مختلف یادگیری.

-ارائه دیدگاهی جامع در مورد الگوریتم‌های یادگیری ماشین که می‌توانند برای افزایش هوش و قابلیت‌های یک برنامه کاربردی داده‌محور به کار گرفته شوند.



شکل 1. امتیاز محبوبیت جهانی انواع مختلف الگوریتم‌های یادگیری ماشین (نظارت‌شده، بدون نظارت، نیمه‌نظارت‌شده و تقویت‌شده) در محدوده 0 (حداقل) تا 100 (حداکثر) در طول زمان که در آن محور x نشان‌دهنده اطلاعات مهر زمانی و محور y نشان‌دهنده امتیاز مربوطه است.

انواع دیگر اسناد تجاری را می‌توان به عنوان داده‌های بدون ساختار در نظر گرفت.

-بحث در مورد کاربردپذیری راه‌حل‌های مبتنی بر یادگیری ماشین در حوزه‌های مختلف کاربردی دنیای واقعی.
-برجسته کردن و خلاصه کردن مسیرهای تحقیقاتی بالقوه در محدوده مطالعه ما برای تجزیه و تحلیل داده‌ها و خدمات هوشمند.

نیمه‌ساختاریافته : داده‌های نیمه‌ساختاریافته در ... ذخیره نمی‌شوند.

یک پایگاه داده رابط‌های مانند داده‌های ساختاریافته ذکر شده در بالا، اما دارای ویژگی‌های سازمانی خاصی است که تجزیه و تحلیل آن را آسان‌تر می‌کند. اسناد HTML، XML، JSON، پایگاه‌های داده NoSQL و غیره، نمونه‌هایی از داده‌های نیمه ساختاریافته هستند.

ادامه مقاله به شرح زیر سازماندهی شده است. بخش بعدی انواع داده‌ها و الگوریتم‌های یادگیری ماشین را به معنای وسیع‌تری ارائه می‌دهد و دامنه مطالعه ما را تعریف می‌کند.

در بخش بعدی، الگوریتم‌های مختلف یادگیری ماشین را به طور خلاصه مورد بحث و توضیح قرار می‌دهیم و پس از آن، حوزه‌های کاربردی مختلف دنیای واقعی مبتنی بر الگوریتم‌های یادگیری ماشین مورد بحث و خلاصه قرار می‌گیرند. در بخش ماقبل آخر، چندین موضوع تحقیقاتی و جهت‌گیری‌های بالقوه آینده را برجسته می‌کنیم و بخش پایانی، این مقاله را به پایان می‌رساند.

-فراداده: این شکل عادی داده‌ها نیست، بلکه «داده‌هایی درباره داده‌ها» است. تفاوت اصلی بین «داده» و «فراداده» این است که داده‌ها صرفاً مطالبی هستند که می‌توانند چیزی را نسبت به ویژگی‌های داده‌های یک سازمان طبقه‌بندی، اندازه‌گیری یا حتی مستند کنند. از سوی دیگر، فراداده اطلاعات مربوط به داده‌ها را توصیف می‌کند و به آن اهمیت بیشتری برای کاربران داده می‌دهد. یک مثال اساسی از فراداده یک سند می‌تواند نویسنده، اندازه فایل، تاریخ تولید شده توسط سند، کلمات کلیدی برای تعریف سند و غیره باشد.

انواع داده‌های دنیای واقعی و ماشین تکنیک‌های یادگیری

الگوریتم‌های یادگیری ماشین معمولاً داده‌ها را مصرف و پردازش می‌کنند تا الگوهای مرتبط با افراد، فرآیندهای تجاری، ترانکشن‌ها، رویدادها و غیره را بیاموزند. در ادامه، انواع مختلف داده‌های دنیای واقعی و همچنین دسته‌بندی‌های الگوریتم‌های یادگیری ماشین را مورد بحث قرار می‌دهیم.

در حوزه یادگیری ماشین و علم داده، محققان از مجموعه داده‌های پرکاربرد مختلفی برای اهداف مختلف استفاده می‌کنند.


به عنوان مثال، مجموعه داده‌های امنیت سایبری مانند [59] Bot-IoT، [2] CIC-DDoS2019، [1] ISCX'12، [76] UNSW-NB15، [119] NSL-KDD و غیره، مجموعه داده‌های گوشی‌های هوشمند مانند گزارش‌های تماس تلفنی، [84، 101] گزارش پیامک [29]، گزارش‌های استفاده از برنامه‌های تلفن همراه [117] [137] گزارش‌های اعلان تلفن همراه [73] و غیره، داده‌های اینترنت اشیا [62، 57، 16] داده‌های کشاورزی و تجارت الکترونیک [138، 120] داده‌های سلامت مانند بیماری‌های قلبی، [92] دیابت شیرین [134، 83] کووید-19 [74، 43] و غیره، و بسیاری دیگر در حوزه‌های مختلف کاربردی، داده‌ها می‌توانند از انواع مختلفی باشند که در بالا مورد بحث قرار گرفتند، که ممکن است از کاربردی به کاربرد دیگر در دنیای واقعی متفاوت باشند. برای تجزیه و تحلیل چنین داده‌هایی در یک حوزه مسئله خاص و استخراج بینش یا دانش مفید از داده‌ها برای ساخت برنامه‌های هوشمند دنیای واقعی، می‌توان از انواع مختلفی از تکنیک‌های یادگیری ماشین، ابزارهای برای تحلیل، یادگیری آنها، استفاده از یادگیری برای پاسخ به سوالات و غیره استفاده کرد. [41، 72]

علاوه بر این، «فراداده» نوع دیگری از داده‌ها است که معمولاً داده‌هایی درباره داده‌ها ارائه می‌دهد. در ادامه، به طور خلاصه این نوع داده‌ها را مورد بحث قرار می‌دهیم.

-ساختاریافته: ساختاری خالص تکنیک‌های یادگیری ماشین است که از یک نظم استاندارد پیروی می‌کند، بسیار سازمان‌یافته و به راحتی قابل دسترسی است و توسط یک نهاد یا یک برنامه کامپیوتری استفاده می‌شود. در طرح‌های خوش‌تعریف، مانند پایگاه‌های داده رابط‌های، داده‌های ساختاریافته معمولاً در قالب جدولی ذخیره می‌شوند. به عنوان مثال، نام‌ها، تاریخ‌ها، آدرس‌ها، شماره کارتهای اعتباری، اطلاعات الگوهای رفتاری، ویژگی‌های غیرتکراری، فرمت‌های مختلف، مدل‌های ساختاریافته، یادگیری بدون نظارت، یادگیری نیمه‌نظارتی و یادگیری تقویتی، [75] همانطور که در شکل 2 نشان داده شده است. در ادامه، به طور خلاصه هر نوع تکنیک یادگیری را با دامنه کاربرد آنها برای حل مسائل دنیای واقعی مورد بحث قرار می‌دهیم.

-بدون ساختار: از سوی دیگر، هیچ قالب یا سازماندهی از پیش تعریف‌شده‌ای برای داده‌های بدون ساختار وجود ندارد، که ثبت، پردازش و تجزیه و تحلیل آنها را بسیار دشوارتر می‌کند، زیرا عمدتاً حاوی متن و مطالب چندرسانه‌ای، فایل‌های صوتی، ویدیوها، تصاویر، ارائه‌ها، صفحات وب و بسیاری دیگر ورودی را به خروجی بر اساس جفت‌های ورودی-خروجی نمونه نگاشت می‌کند. [41] این روش از داده‌های آموزشی برچسب‌گذاری‌شده و مجموعه‌ای از مثال‌های آموزشی برای استخراج یک تابع استفاده می‌کند. یادگیری نظارت‌شده زمانی انجام می‌شود که اهداف خاصی برای دستیابی شناسایی شوند.

شکل ۲۰. انواع مختلف تکنیک‌های یادگیری ماشین



از مجموعه‌ای خاص از ورودی‌ها، [105] یعنی یک رویکرد وظیفه‌محور، استخراج می‌شود. رایج‌ترین وظایف تحت نظارت، «طبقه‌بندی» هستند که داده‌ها را جدا می‌کند و «رگرسیون» که داده‌ها را برازش می‌دهد. به عنوان مثال، پیش‌بینی برچسب کلاس یا احساسات یک متن، مانند یک توییت یا بررسی یک محصول، یعنی طبقه‌بندی متن، نمونه‌ای از یادگیری تحت نظارت است.

بدون نظارت: یادگیری بدون نظارت، مجموعه داده‌های بدون برچسب را بدون نیاز به دخالت انسان، یعنی یک فرآیند داده‌محور [41] تجزیه و تحلیل می‌کند. این روش به طور گسترده برای استخراج ویژگی‌های مولد، شناسایی روندها و ساختارهای معنادار، گروه‌بندی در نتایج و اهداف اکتشافی استفاده می‌شود. رایج‌ترین وظایف یادگیری بدون نظارت عبارتند از خوشه‌بندی، تخمین چگالی، یادگیری ویژگی، کاهش ابعاد، یافتن قوانین وابستگی، تشخیص ناهنجاری و غیره.

نیمه‌نظارتی: یادگیری نیمه‌نظارتی را می‌توان ترکیبی از روش‌های نظارت‌شده و بدون نظارت ذکر شده در بالا تعریف کرد، زیرا هم بر روی داده‌های برچسب‌گذاری‌شده و هم بدون برچسب عمل می‌کند. [105، 41] بنابراین، بین یادگیری «بدون نظارت» و یادگیری «با نظارت» قرار می‌گیرد. در دنیای واقعی، داده‌های برچسب‌گذاری‌شده می‌توانند در چندین زمینه نادر باشند و داده‌های بدون برچسب فراوان هستند، جایی که یادگیری نیمه‌نظارتی مفید است [75].

هدف نهایی یک مدل یادگیری نیمه‌نظارتی، ارائه نتیجه‌ای بهتر برای پیش‌بینی نسبت به نتایجی است که تنها با استفاده از داده‌های برچسب‌گذاری‌شده از مدل تولید می‌شوند.

برخی از حوزه‌های کاربردی که یادگیری نیمه‌نظارتی در آن‌ها مورد استفاده قرار می‌گیرد شامل ترجمه ماشینی، تشخیص تقلب، برچسب‌گذاری داده‌ها و طبقه‌بندی متن است.

تقویت: یادگیری تقویتی نوعی الگوریتم یادگیری ماشین است که به عامل‌های نرم‌افزاری و ماشین‌ها این امکان را می‌دهد که به طور خودکار رفتار بهینه را در یک زمینه یا محیط خاص ارزیابی کنند تا کارایی آن را بهبود بخشند. [52] یعنی یک رویکرد مبتنی بر محیط. این نوع یادگیری مبتنی بر پاداش یا جریمه است و هدف نهایی آن استفاده از بینش‌های به دست آمده از فعالان محیط زیست برای انجام اقداماتی جهت افزایش پاداش یا به حداقل رساندن ریسک است. [75] این یک ابزار قدرتمند برای آموزش مدل‌های هوش مصنوعی است که می‌تواند به افزایش اتوماسیون یا بهینه‌سازی کارایی عملیاتی سیستم‌های پیچیده مانند رباتیک، وظایف رانندگی خودکار، تولید و لجستیک زنجیره تأمین کمک کند. با این حال، استفاده از آن برای حل مشکلات اساسی یا ساده ترجیح داده نمی‌شود.

بنابراین، برای ساخت مدل‌های مؤثر در حوزه‌های کاربردی مختلف، انواع مختلف تکنیک‌های یادگیری ماشین می‌توانند بسته به قابلیت‌های یادگیری خود، بسته به ماهیت داده‌هایی که قبلاً مورد بحث قرار گرفتند و نتیجه مورد نظر، نقش مهمی ایفا کنند. در جدول 1، انواع مختلف تکنیک‌های یادگیری ماشین را با مثال‌هایی خلاصه می‌کنیم. در ادامه، دیدگاه جامعی از الگوریتم‌های یادگیری ماشین که می‌توانند برای افزایش هوش و قابلیت‌های یک برنامه کاربردی داده‌محور به کار روند، ارائه می‌دهیم.

جدول 1 انواع مختلف تکنیک‌های یادگیری ماشین به همراه مثال‌ها

مثال‌ها	نوع یادگیری
طبقه‌بندی، رگرسیون	الگوریتم‌ها یا مدل‌ها از داده‌های برچسب‌گذاری‌شده یاد می‌گیرند (رویکرد وظیفه‌محور)
خوشه‌بندی، وابستگی‌ها، کاهش ابعاد	الگوریتم‌ها یا مدل‌ها از داده‌های بدون برچسب یاد می‌گیرند (رویکرد داده‌محور)
طبقه‌بندی، خوشه‌بندی	مدل‌ها با استفاده از داده‌های ترکیبی (برچسب‌دار + بدون برچسب) ساخته می‌شوند.
طبقه‌بندی، کنترل	مدل‌ها مبتنی بر پاداش یا جریمه هستند (رویکرد مبتنی بر محیط)

وظایف و الگوریتم‌های یادگیری ماشین

در این بخش، الگوریتم‌های مختلف یادگیری ماشین از جمله تحلیل طبقه‌بندی، تحلیل رگرسیون، خوشه‌بندی داده‌ها، یادگیری قوانین وابستگی، مهندسی ویژگی برای کاهش ابعاد و همچنین روش‌های یادگیری عمیق را مورد بحث قرار می‌دهیم. ساختار کلی یک مدل پیش‌بینی مبتنی بر یادگیری ماشین در شکل 3 نشان داده شده است، که در آن مدل از داده‌های تاریخی در فاز 1 آموزش داده می‌شود و نتیجه در فاز 2 برای داده‌های آزمایشی جدید تولید می‌شود.

تحلیل طبقه‌بندی

طبقه‌بندی به عنوان یک روش یادگیری نظارت‌شده در یادگیری ماشین در نظر گرفته می‌شود و به مسئله‌ای در مدل‌سازی پیش‌بینی نیز اشاره دارد که در آن برچسب کلاس برای یک مثال معین پیش‌بینی می‌شود [41]. از نظر ریاضی، این روش یک تابع f را از متغیرهای ورودی X به متغیرهای خروجی Y (به عنوان هدف، برچسب یا دسته‌ها نگاشت می‌کند. برای پیش‌بینی کلاس نقاط داده معین، می‌توان آن را روی داده‌های ساختاریافته یا بدون ساختار انجام داد. به عنوان مثال، تشخیص هرزنامه مانند "هرزنامه" و "غیرهرزنامه" در ارائه دهندگان خدمات ایمیل می‌تواند یک مسئله طبقه‌بندی باشد. در ادامه، مسائل طبقه‌بندی رایج را خلاصه می‌کنیم.


• طبقه‌بندی دودویی: به وظایف طبقه‌بندی اشاره دارد که دارای دو برچسب کلاس مانند "درست و نادرست" یا "بله و خیر" هستند. [41] در چنین وظایف طبقه‌بندی دودویی، یک کلاس می‌تواند حالت عادی باشد، در حالی که حالت غیرعادی می‌تواند کلاس دیگری باشد. به عنوان مثال، "سرطان تشخیص داده نشد" حالت عادی یک وظیفه است که شامل ... الگوریتم‌های طبقه‌بندی زیادی در ادبیات یادگیری ماشین و علوم داده ارائه شده‌اند. [125، 41] در ادامه، رایج‌ترین و محبوب‌ترین روش‌هایی را که به طور گسترده در زمینه‌های کاربردی مختلف استفاده می‌شوند، خلاصه می‌کنیم.

آزمایش پزشکی و «سرطان تشخیص داده شد» می‌تواند به عنوان حالت غیرطبیعی در نظر گرفته شوند. به طور مشابه، «هرزنامه» و «غیرهرزنامه» در مثال بالا از ارائه دهندگان خدمات ایمیل به عنوان طبقه‌بندی دودویی در نظر گرفته می‌شود. [NB] الگوریتم بیز ساده بر اساس قضیه بیز یا فرض استقلال بین هر جفت از ویژگی‌ها [51] است. این الگوریتم به خوبی کار می‌کند و می‌تواند برای هر دو دسته دودویی و چند کلاسی در بسیاری از موقعیت‌های دنیای واقعی، مانند طبقه‌بندی سند یا متن، فیلتر کردن هرزنامه و غیره، مورد استفاده قرار گیرد. برای طبقه‌بندی مؤثر نمونه‌های نویزی در داده‌ها و ساخت یک مدل پیش‌بینی قوی، می‌توان از طبقه‌بندی‌کننده NB استفاده کرد. [94]


مزیت کلیدی این است که در مقایسه با رویکردهای پیچیده‌تر، به مقدار کمی از داده‌های آموزشی برای تخمین سریع پارامترهای لازم نیاز دارد. [82]

با این حال، عملکرد آن ممکن است به دلیل فرضیات قوی آن در مورد استقلال ویژگی‌ها تحت تأثیر قرار گیرد. گاوسی، چندجمله‌ای، مکمل، برنولی و دسته‌بندی، انواع رایج طبقه‌بندی‌کننده NB هستند [82].

-تحلیل تفکیک خطی (LDA): تحلیل تفکیک خطی (LDA) یک طبقه‌بندی‌کننده مرز تصمیم‌گیری خطی است که با برآزش چگالی‌های شرطی کلاس به داده‌ها و اعمال قانون بیز ایجاد می‌شود. [82، 51] این روش همچنین به عنوان تعمیمی از تفکیک خطی فیشر شناخته می‌شود که یک مجموعه داده معین را به فضای با ابعاد کمتر تصویر می‌کند، یعنی کاهش ابعادی که ... را به حداقل می‌رساند.



شکل 3. ساختار کلی یک مدل پیش‌بینی مبتنی بر یادگیری ماشین با در نظر گرفتن هر دو مرحله آموزش و آزمایش



شکل 5. مثالی از ساختار جنگل تصادفی با در نظر گرفتن چندین درخت تصمیم

«ترکیب موازی» که چندین طبقه‌بندی‌کننده درخت تصمیم‌گیری را به صورت موازی، همانطور که در شکل 5 نشان داده شده است، بر روی زیرمونه‌های مجموعه داده‌های مختلف برازش می‌دهد و از رأی اکثریت یا میانگین‌ها برای نتیجه یا خروجی نهایی استفاده می‌کند. بنابراین، مشکل بیش‌برازش را به حداقل می‌رساند و دقت پیش‌بینی و کنترل را افزایش می‌دهد. [82] بنابراین، مدل یادگیری RF با چندین درخت تصمیم‌گیری معمولاً دقیق‌تر از یک مدل مبتنی بر درخت تصمیم‌گیری واحد است [106].

برای ساخت مجموعه‌ای از درخت‌های تصمیم‌گیری با تغییرات کنترل‌شده، این روش، تجمیع بوت‌استرپ (بسته‌بندی) [18] و انتخاب ویژگی تصادفی [11] را ترکیب می‌کند. این روش با مسائل طبقه‌بندی و رگرسیون سازگار است و برای مقادیر دسته‌بندی‌شده و پیوسته به خوبی برازش دارد.

-تقویت تطبیقی: (AdaBoost) تقویت تطبیقی (AdaBoost) یک فرآیند یادگیری جمعی است که از یک رویکرد تکراری برای بهبود طبقه‌بندی‌کننده‌های ضعیف با یادگیری از خطاهای آنها استفاده می‌کند. این روش توسط یوآو فروند و همکارانش [35] توسعه داده شده و به عنوان «فرایادگیری» نیز شناخته می‌شود. برخلاف جنگل تصادفی که از ترکیب موازی استفاده می‌کند، AdaBoost از «ترکیب متوالی» استفاده می‌کند.

این روش با ترکیب بسیاری از طبقه‌بندی‌کننده‌های ضعیف، یک طبقه‌بندی‌کننده قدرتمند ایجاد می‌کند تا یک طبقه‌بندی‌کننده خوب با دقت بالا به دست آورد. از این نظر، AdaBoost با بهبود قابل توجه کارایی طبقه‌بندی‌کننده، یک طبقه‌بندی‌کننده تطبیقی نامیده می‌شود، اما در برخی موارد، می‌تواند باعث ایجاد بیش‌برازش شود. AdaBoost بهترین استفاده را برای افزایش عملکرد درخت‌های تصمیم‌گیری دارد، با این حال، تخمین‌گر پایه [82] در مسائل طبقه‌بندی دودویی به داده‌های نویزی و داده‌های پرت حساس است.

-تقویت گرادیان شدید: (XGBoost) تقویت گرادیان، مانند جنگل‌های تصادفی [19] در بالا، یک الگوریتم یادگیری گروهی است که یک مدل نهایی را بر اساس مجموعه‌ای از مدل‌های منفرد، معمولاً درختان تصمیم‌گیری، تولید می‌کند. گرادیان برای به حداقل رساندن تابع زیان استفاده می‌شود، مشابه نحوه استفاده شبکه‌های عصبی [41] از گرادیان نزولی برای بهینه‌سازی وزن‌ها. تقویت گرادیان شدید

(XGBoost) نوعی تقویت گرادیان است که هنگام تعیین بهترین مدل، تقریب‌های دقیق‌تری را در نظر می‌گیرد. [82] این روش گرادیان‌های مرتبه دوم تابع زیان را برای به حداقل رساندن زیان و منظم‌سازی پیشرفته (L1) و (L2) محاسبه می‌کند [82] که بیش‌برازش را کاهش می‌دهد و تعمیم‌پذیری و عملکرد مدل را بهبود می‌بخشد.

XGBoost به سرعت تفسیر می‌شود و می‌تواند مجموعه داده‌های بزرگ را به خوبی مدیریت کند.

-گرادیان نزولی تصادفی: (SGD) گرادیان نزولی تصادفی [41] (SGD) یک روش تکراری برای بهینه‌سازی یک تابع هدف با خواص هموارسازی مناسب است، که در آن کلمه «تصادفی» به احتمال تصادفی اشاره دارد. این روش، بار محاسباتی را، به ویژه در مسائل بهینه‌سازی با ابعاد بالا، کاهش می‌دهد و امکان تکرارهای سریع‌تر را در ازای نرخ همگرایی پایین‌تر فراهم می‌کند. گرادیان، شیب تابعی است که درجه تغییر یک متغیر را در پاسخ به تغییرات متغیر دیگر محاسبه می‌کند. از نظر ریاضی، گرادیان نزولی یک تابع محدب است که خروجی آن مشتق جزئی از مجموعه‌ای از پارامترهای ورودی آن است. فرض کنید، لانه یادگیری و الگوریتم نمونه آموزشی نام باشد، سپس معادله (4) روش به‌روزرسانی وزن گرادیان نزولی تصادفی را در نشان می‌دهد.

تکرار. در یادگیری ماشین در مقیاس بزرگ
و پراکنده، SGD با موفقیت در مسائلی که اغلب در طبقه‌بندی متن و پردازش زبان طبیعی با آن مواجه می‌شویم، اعمال شده است. [82] با این حال، SGD به مقیاس‌بندی ویژگی حساس است و به طیف وسیعی از فرآیندها، مانند پارامتر منظم‌سازی و تعداد تکرارها، نیاز دارد.

$$w_j^{(t+1)} = w_j^{(t)} - \eta \frac{\partial J}{\partial w_j} \quad (4)$$

-طبقه‌بندی مبتنی بر قانون: اصطلاح طبقه‌بندی مبتنی بر قانون می‌تواند برای اشاره به هر طرح طبقه‌بندی که از قوانین IF-THEN برای پیش‌بینی کلاس استفاده می‌کند، به کار رود.

چندین الگوریتم طبقه‌بندی مانند [47] One-R، [125] Zero-R درخت‌های تصمیم‌گیری [110] DTNB، [88]، [87] یادگیرنده قانون کاهش موجی، [125] (RIDOR) هرس افزایش مکرر برای تولید کاهش خطا [126] (RIPPER) با قابلیت تولید قانون وجود دارند. درخت تصمیم‌گیری یکی از رایج‌ترین روش‌های طبقه‌بندی مبتنی بر قانون است.

الگوریتم‌های چندمتغیره در میان این تکنیک‌ها به دلیل مزایای متعددی مانند تفسیر آسان‌تر؛ توانایی مدیریت داده‌های با ابعاد بالا؛ سادگی و سرعت؛ دقت خوب؛ و قابلیت تولید قوانین برای طبقه‌بندی واضح و قابل فهم توسط انسان [127] مورد توجه قرار گرفته‌اند.

[128] قوانین مبتنی بر درخت تصمیم همچنین دقت قابل توجهی را در یک مدل پیش‌بینی برای موارد آزمایشی دیده نشده ارائه می‌دهند. [106] از آنجایی که قوانین به راحتی قابل تفسیر هستند، این طبقه‌بندی‌کننده‌های مبتنی بر قانون اغلب برای تولید مدل‌های توصیفی استفاده می‌شوند که می‌توانند سیستمی شامل موجودیت‌ها و روابط آنها را توصیف کنند.

تحلیل رگرسیون


تحلیل رگرسیون شامل چندین روش یادگیری ماشین است که امکان پیش‌بینی یک متغیر نتیجه پیوسته (y) را بر اساس مقدار یک یا چند متغیر پیش‌بینی‌کننده (x) فراهم می‌کند [41]. مهم‌ترین تمایز بین طبقه‌بندی و رگرسیون این است که طبقه‌بندی برچسب‌های کلاس متمایز را پیش‌بینی می‌کند، در حالی که رگرسیون پیش‌بینی یک کمیت پیوسته را تسهیل می‌کند. شکل 6 مثالی از تفاوت طبقه‌بندی با مدل‌های رگرسیون را نشان می‌دهد. اغلب بین این دو نوع الگوریتم یادگیری ماشین همپوشانی‌هایی یافت می‌شود. مدل‌های رگرسیون اکنون به طور گسترده در زمینه‌های مختلفی از جمله پیش‌بینی یا پیش‌بینی مالی، تخمین هزینه، تحلیل روند، بازاریابی، تخمین سری‌های زمانی، مدل‌سازی پاسخ به دارو و بسیاری موارد دیگر استفاده می‌شوند. برخی از انواع آشنای الگوریتم‌های رگرسیون عبارتند از رگرسیون خطی، چندجمله‌ای، لاسو و ريج و غیره که در ادامه به طور خلاصه توضیح داده می‌شوند.

*رگرسیون خطی ساده و چندگانه: این یکی از محبوب‌ترین تکنیک‌های مدل‌سازی یادگیری ماشین و همچنین یک تکنیک رگرسیون شناخته شده است. در این تکنیک، متغیر وابسته پیوسته است، متغیر(های) مستقل می‌توانند پیوسته یا گسسته باشند و شکل خط رگرسیون خطی است. رگرسیون خطی با استفاده از بهترین خط مستقیم برازش، رابطه‌ای بین متغیر وابسته (y) و یک یا چند متغیر مستقل (x) (که به عنوان خط رگرسیون نیز شناخته می‌شود) ایجاد می‌کند. [41] این رگرسیون با معادلات زیر تعریف می‌شود:

$$y = a + bx + e \quad (5)$$

$$y = a + b_1x_1 + b_2x_2 + \dots + b_nx_n + e, \quad (6)$$

که در آن n نقطه تقاطع، b شیب خط و e است. عبارت خطا است. این معادله می‌تواند برای پیش‌بینی



شکل 6. طبقه‌بندی در مقابل رگرسیون. در طبقه‌بندی، خط نقطه‌چین نشان دهنده یک مرکز خطی است که دو کلاس را از هم جدا می‌کند؛ در رگرسیون، خط نقطه‌چین رابطه خطی بین دو متغیر را مدل‌سازی می‌کند.

مقدار متغیر هدف بر اساس متغیر(های) پیش‌بینی‌کننده داده شده. رگرسیون خطی چندگانه، بسطی از رگرسیون خطی ساده است که به دو یا چند متغیر پیش‌بینی‌کننده اجازه می‌دهد تا یک متغیر پاسخ، y، به عنوان یک تابع خطی [41] که در معادله 6 تعریف شده است، مدل‌سازی کنند، در حالی که رگرسیون خطی ساده فقط 1 متغیر مستقل دارد که در معادله 5 تعریف شده است.

*رگرسیون چندجمله‌ای: رگرسیون چندجمله‌ای شکلی از تحلیل رگرسیون است که در آن رابطه بین متغیر مستقل x و متغیر وابسته y

خطی نیست، بلکه درجه چندجمله‌ای n در x است. [82]

معادله رگرسیون چندجمله‌ای نیز از معادله رگرسیون خطی (رگرسیون چندجمله‌ای درجه 1) مشتق شده است که به صورت زیر تعریف می‌شود:

$$y = b_0 + b_1x + b_2x^2 + b_3x^3 + \dots + b_nx^n + e. \quad (7)$$

در اینجا، y خروجی پیش‌بینی‌شده/هدف، $b_0, b_1, \dots, b_n$ ضرایب رگرسیون و x یک متغیر مستقل/ورودی است. به عبارت ساده، می‌توان گفت که اگر داده‌ها به صورت خطی توزیع نشده باشند، بلکه از درجه n چندجمله‌ای باشند، از رگرسیون چندجمله‌ای برای بدست آوردن خروجی مطلوب استفاده می‌کنیم.

*رگرسیون لاسو و ريج: رگرسیون لاسو و ريج به عنوان تکنیک‌های قدرتمندی شناخته می‌شوند که معمولاً برای ساخت مدل‌های یادگیری در حضور تعداد زیادی از ویژگی‌ها استفاده می‌شوند، به دلیل توانایی آنها در جلوگیری از بیش‌برازش و کاهش پیچیدگی مدل. مدل رگرسیون لاسو (عملگر انقباض و انتخاب حداقل مطلق) از تکنیک منظم‌سازی [82] L1 استفاده می‌کند که از انقباض استفاده می‌کند و "مقدار مطلق بزرگی ضرایب" (جریمه L1) را جریمه می‌کند. در نتیجه، به نظر می‌رسد لاسو ضرایب را به صفر مطلق می‌رساند. بنابراین، رگرسیون لاسو با هدف یافتن زیرمجموعه‌ای از پیش‌بینی‌کننده‌ها که خطای پیش‌بینی را برای یک متغیر پاسخ کمی به حداقل می‌رساند، انجام می‌شود. از سوی دیگر، رگرسیون ريج از منظم‌سازی [82] L2 استفاده می‌کند که "مقدار مربع بزرگی ضرایب" (جریمه L2) است.

بنابراین، رگرسیون ريج وزن‌ها را مجبور به کوچک بودن می‌کند اما هرگز مقدار ضریب را صفر قرار نمی‌دهد و یک راه‌حل غیرتنگ انجام می‌دهد. به‌طورکلی، رگرسیون LASSO برای بدست آوردن زیرمجموعه‌ای از پیش‌بینی‌کننده‌ها با حذف ویژگی‌های کم‌اهمیت‌تر مفید است و رگرسیون ريج زمانی مفید است که یک مجموعه داده دارای «همبستگی چندگانه» باشد که به پیش‌بینی‌کننده‌هایی اشاره دارد که با سایر پیش‌بینی‌کننده‌ها همبستگی دارند.

تحلیل خوشه‌ای

تحلیل خوشه‌ای، که با نام خوشه‌بندی نیز شناخته می‌شود، یک تکنیک یادگیری ماشین بدون نظارت برای شناسایی و گروه‌بندی نقاط داده مرتبط در مجموعه داده‌های بزرگ بدون توجه به نتیجه خاص است. این تکنیک مجموعه‌ای از اشیاء را به گونه‌ای گروه‌بندی می‌کند که اشیاء در یک دسته، که خوشه نامیده می‌شوند، به نوعی بیشتر از اشیاء موجود در یک دسته، به یکدیگر شبیه باشند.

اشیاء در گروه‌های دیگر [41]. این اغلب به عنوان یک تکنیک تحلیل داده برای کشف روندها یا الگوهای جالب در داده‌ها، به عنوان مثال، گروه‌های مصرف‌کنندگان بر اساس رفتار آنها، استفاده می‌شود. در طیف گسترده‌ای از زمینه‌های کاربردی، مانند امنیت سایبری، تجارت الکترونیک، پردازش داده‌های تلفن همراه، تجزیه و تحلیل سلامت، مدل‌سازی کاربر و تجزیه و تحلیل رفتاری، می‌توان از خوشه‌بندی استفاده کرد.

در ادامه، به طور خلاصه انواع روش‌های خوشه‌بندی را مورد بحث و بررسی قرار می‌دهیم.

-روش‌های تقسیم‌بندی: بر اساس ویژگی‌ها و شباهت‌های موجود در داده‌ها، این رویکرد خوشه‌بندی، داده‌ها را به چندین گروه یا خوشه دسته‌بندی می‌کند. دانشمندان یا تحلیلگران داده معمولاً تعداد خوشه‌ها را به صورت پویا یا ایستا بسته به ماهیت برنامه‌های هدف تعیین می‌کنند تا روش‌های خوشه‌بندی را ایجاد کنند. رایج‌ترین الگوریتم‌های خوشه‌بندی مبتنی بر روش‌های تقسیم‌بندی عبارتند از [55] CLARA، [80] K-Medoids، [69] K-means و غیره.

-روش‌های مبتنی بر چگالی: برای شناسایی گروه‌ها یا خوشه‌های متمایز، از این مفهوم استفاده می‌کند که یک خوشه در فضای داده‌ها، ناحیه‌ای پیوسته با چگالی نقطه‌ای بالا است که توسط نواحی پیوسته با چگالی نقطه‌ای پایین از سایر خوشه‌های مشابه جدا شده است. نقاطی که جزئی از یک خوشه نیستند، به عنوان نویز در نظر گرفته می‌شوند. الگوریتم‌های خوشه‌بندی معمول مبتنی بر چگالی عبارتند از [12] OPTICS، [32] DBSCAN و غیره.


روش‌های مبتنی بر چگالی معمولاً با خوشه‌هایی با چگالی مشابه و داده‌های با ابعاد بالا مشکل دارند.

-روش‌های مبتنی بر سلسله مراتب: خوشه‌بندی سلسله مراتبی معمولاً به دنبال ساخت سلسله مراتبی از خوشه‌ها، یعنی ساختار درختی، است. استراتژی‌های خوشه‌بندی سلسله مراتبی عموماً به دو نوع تقسیم می‌شوند: (۱) تجمعی - رویکردی "پایین به بالا" که در آن هر مشاهده در خوشه خود شروع می‌شود و جفت خوشه‌ها به عنوان یک خوشه ترکیب می‌شوند و در سلسله مراتب به سمت بالا حرکت می‌کنند، و (۲) تقسیمی - رویکردی "بالا به پایین" که در آن همه مشاهدات در یک خوشه شروع می‌شوند و تقسیم‌ها به صورت بازگشتی انجام می‌شوند و در سلسله مراتب به سمت پایین حرکت می‌کنند، همانطور که در شکل ۷ نشان داده شده است. تکنیک BOTS پیشنهادی قبلی ما، سارکر و همکاران [102] نمونه‌ای از یک الگوریتم خوشه‌بندی سلسله مراتبی، به ویژه پایین به بالا است.

-روش‌های مبتنی بر شبکه: برای مقابله با مجموعه داده‌های عظیم، خوشه‌بندی مبتنی بر شبکه به ویژه مناسب است. برای به دست آوردن خوشه‌ها، اصل این است که ابتدا مجموعه داده‌ها را با یک نمایش شبکه‌ای خلاصه کنیم و سپس سلول‌های شبکه را ترکیب کنیم. [6] CLIQUE، [122] STING و غیره الگوریتم‌های استاندارد خوشه‌بندی مبتنی بر شبکه هستند.

-روش‌های مبتنی بر مدل: عمدتاً دو نوع الگوریتم خوشه‌بندی مبتنی بر مدل وجود دارد: یکی که از یادگیری آماری استفاده می‌کند و دیگری که مبتنی بر روشی از یادگیری شبکه عصبی است [130]. به عنوان مثال، [89] GMM نمونه‌ای از یک روش یادگیری آماری و [96] [22] SOM نمونه‌ای از یک روش یادگیری شبکه عصبی است.

روش‌های مبتنی بر محدودیت: خوشه‌بندی مبتنی بر محدودیت، یک رویکرد نیمه‌مظارتی برای خوشه‌بندی داده‌ها است که از ... استفاده می‌کند.



شکل 7. تفسیر گرافیکی از تکنیک خوشه‌بندی سلسله مراتبی (از پایین به بالا و از بالا به پایین) که به طور گسترده استفاده می‌شود

محدودیت‌هایی برای گنجاندن دانش دامنه، محدودیت‌های کاربردی یا کاربرمحور برای انجام خوشه‌بندی گنجانده می‌شوند. الگوریتم‌های معمول این نوع خوشه‌بندی عبارتند از [27] Means، [121] K-means، CMWK و غیره.

الگوریتم‌های خوشه‌بندی زیادی با قابلیت گروه‌بندی داده‌ها در ادبیات یادگیری ماشین و علوم داده پیشنهاد شده‌اند [41، 125]. در ادامه، روش‌های رایجی را که به طور گسترده در کاربردهای مختلف استفاده می‌شوند، خلاصه می‌کنیم.

مناطق.

-خوشه‌بندی K-means: خوشه‌بندی K-means [69] یک الگوریتم سریع، قوی و ساده است که وقتی مجموعه داده‌ها به خوبی از یکدیگر جدا شده‌اند، نتایج قابل اعتمادی ارائه می‌دهد. در این الگوریتم، نقاط داده به گونه‌ای به یک خوشه اختصاص داده می‌شوند که مقدار مربع فاصله بین نقاط داده و مرکز جرم تا حد امکان کوچک باشد. به عبارت دیگر، الگوریتم K-means تعداد k مرکز جرم را شناسایی می‌کند و سپس هر نقطه داده را به نزدیکترین خوشه اختصاص می‌دهد و در عین حال مراکز جرم را تا حد امکان کوچک نگه می‌دارد. از آنجایی که با انتخاب تصادفی از مراکز خوشه شروع می‌شود، نتایج می‌توانند متناقض باشند. از آنجایی که مقادیر شدید می‌توانند به راحتی بر میانگین تأثیر بگذارند، الگوریتم خوشه‌بندی K-means به داده‌های پرت حساس است. خوشه‌بندی [91] K-medoids نوعی از K-means است که در برابر نویزها و داده‌های پرت مقاوم‌تر است.

خوشه‌بندی تغییر میانگین: خوشه‌بندی تغییر میانگین [37] یک تکنیک خوشه‌بندی ناپارامتری است که نیازی به دانش قبلی از تعداد خوشه‌ها یا محدودیت‌های شکل خوشه ندارد. خوشه‌بندی تغییر میانگین با هدف کشف «جواب‌ها» در یک توزیع یا ... هموار انجام می‌شود.

چگالی تک‌موتنه‌ها [82] این یکساز و خوشه‌بندی می‌سازد که وظیفه‌ی طبقه‌بندی و دسته‌بندی داده‌ها را انجام می‌دهد. برای تشکیل مجموعه نهایی مراکز ثقل، این کاندیدها در مرحله پس‌پردازش فیلتر می‌شوند. علاوه بر این، در مواردی که تعداد خوشه‌ها به طور ناگهانی تغییر می‌کند، الگوریتم تغییر میانگین به خوبی کار نمی‌کند. در یادگیری ماشین و علم داده، پردازش داده‌های با ابعاد بالا، هم برای محققان و هم برای توسعه‌دهندگان برنامه‌ها، کاری چالش‌برانگیز است. بنابراین، کاهش ابعاد که یک تکنیک یادگیری بدون نظارت است، مهم است زیرا منجر به کاهش هزینه‌های محاسباتی و بهبود کارایی می‌شود. DBSCAN (Density-Based Spatial Clustering of Applications with Noise) یک الگوریتم برای دسته‌بندی داده‌ها است که به طور گسترده در داده‌کاوی و یادگیری ماشین استفاده می‌شود. این الگوریتم به عنوان یک تکنیک خوشه‌بندی غیر نظریه‌محور و غیر پارامتریک برای دسته‌بندی داده‌ها استفاده می‌شود. شناخته می‌شود. ایده اصلی DBSCAN این است که یک نقطه در صورتی به یک خوشه تعلق دارد که به اندازه کافی نزدیک به سایر نقاط خوشه‌ها باشد. این الگوریتم می‌تواند به خوبی با داده‌های با ابعاد بالا و داده‌های با ابعاد کم کار کند. به طور خلاصه، این تکنیک‌ها را مورد بحث قرار می‌دهیم.

کاهش ابعاد و یادگیری ویژگی

علاوه بر این، در مواردی که ابعاد بالا، که تعداد خوشه‌ها به طور ناگهانی تغییر می‌کند، الگوریتم تغییر میانگین به خوبی کار نمی‌کند. در یادگیری ماشین و علم داده، پردازش داده‌های با ابعاد بالا، هم برای محققان و هم برای توسعه‌دهندگان برنامه‌ها، کاری چالش‌برانگیز است. بنابراین، کاهش ابعاد که یک تکنیک یادگیری بدون نظارت است، مهم است زیرا منجر به کاهش هزینه‌های محاسباتی و بهبود کارایی می‌شود. DBSCAN (Density-Based Spatial Clustering of Applications with Noise) یک الگوریتم برای دسته‌بندی داده‌ها است که به طور گسترده در داده‌کاوی و یادگیری ماشین استفاده می‌شود. این الگوریتم به عنوان یک تکنیک خوشه‌بندی غیر نظریه‌محور و غیر پارامتریک برای دسته‌بندی داده‌ها استفاده می‌شود. شناخته می‌شود. ایده اصلی DBSCAN این است که یک نقطه در صورتی به یک خوشه تعلق دارد که به اندازه کافی نزدیک به سایر نقاط خوشه‌ها باشد. این الگوریتم می‌تواند به خوبی با داده‌های با ابعاد بالا و داده‌های با ابعاد کم کار کند. به طور خلاصه، این تکنیک‌ها را مورد بحث قرار می‌دهیم.

-انتخاب ویژگی: انتخاب ویژگی‌ها، که با عنوان انتخاب متغیرها یا ویژگی‌ها در داده‌ها نیز شناخته می‌شود، فرآیند انتخاب ویژگی‌ها را شامل می‌شود. این فرآیند با حذف ویژگی‌های نامربوط یا کم‌اهمیت، پیچیدگی مدل را کاهش می‌دهد و امکان آموزش سریع‌تر الگوریتم‌های یادگیری ماشین را فراهم می‌کند. خوشه‌بندی: GMM: مدل‌های مخلوط گاوسی (GMM) اغلب برای خوشه‌بندی داده‌ها استفاده می‌شوند که یک الگوریتم خوشه‌بندی مبتنی بر توزیع است. یک مدل مخلوط گاوسی یک مدل احتمالی است که در آن تمام نقاط داده توسط ترکیبی از تعداد محدودی از توزیع‌های گاوسی با پارامترهای ناشناخته تولید می‌شوند. [82] برای یافتن پارامترهای گاوسی برای هر خوشه، می‌توان از یک الگوریتم بهینه‌سازی به نام حداکثرسازی انتظار [EM] [82] استفاده کرد. EM یک روش تکراری است که از یک مدل آماری برای تخمین پارامترها استفاده می‌کند. برخلاف k-means، مدل‌های مخلوط گاوسی عدم قطعیت را در نظر می‌گیرند و احتمال تعلق یک نقطه داده به یکی از k خوشه را برمی‌گردانند. خوشه‌بندی GMM قوی‌تر از k-means است. یک مزیت دیگر این است که می‌تواند به خوبی با داده‌های با ابعاد بالا و داده‌های با ابعاد کم کار کند. به طور خلاصه، این تکنیک‌ها را مورد بحث قرار می‌دهیم.

-استخراج ویژگی: در یک مدل یا سیستم مبتنی بر یادگیری ماشین، تکنیک‌های استخراج ویژگی معمولاً درک بهتری از داده‌ها، راهی برای بهبود دقت پیش‌بینی و کاهش هزینه محاسباتی یا زمان آموزش ارائه می‌دهند. هدف از «استخراج ویژگی» [66, 99] کاهش تعداد ویژگی‌ها در یک مجموعه داده با تولید ویژگی‌های جدید از ویژگی‌های موجود و سپس حذف ویژگی‌های اصلی است. اکثر اطلاعات موجود در مجموعه ویژگی‌های اصلی را می‌توان با استفاده از این مجموعه جدید از ویژگی‌های کاهش‌یافته خلاصه کرد. به عنوان مثال، تجزیه و تحلیل مؤلفه‌های اصلی (PCA) اغلب به عنوان یک تکنیک کاهش ابعاد برای استخراج یک مجموعه با ابعاد کمتر استفاده می‌شود.

نتیجه یک دندروگرام است که نمایش درختی عناصر است. پیوند تک [115]، پیوند کامل [102]، BOTS [116] و غیره نمونه‌هایی از این موارد هستند.

فضای ابعادی که اجزای برند جدید را از ویژگی‌های موجود در یک مجموعه داده ایجاد می‌کند. [98]

الگوریتم‌های زیادی برای کاهش ابعاد داده‌ها در ادبیات یادگیری ماشین و علوم داده پیشنهاد شده‌اند. [41، 125] در ادامه، روش‌های رایجی را که به طور گسترده در حوزه‌های کاربردی مختلف استفاده می‌شوند، خلاصه می‌کنیم.


• آستانه واریانس: یک رویکرد ساده و اساسی برای انتخاب ویژگی، آستانه واریانس است. [82] این آستانه، تمام ویژگی‌های با واریانس کم، یعنی تمام ویژگی‌هایی که واریانس آنها از آستانه تجاوز نمی‌کند، را حذف می‌کند. این آستانه به طور پیش‌فرض تمام ویژگی‌های با واریانس صفر، یعنی ویژگی‌هایی که در تمام نمونه‌ها مقدار یکسانی دارند، را حذف می‌کند. این الگوریتم انتخاب ویژگی فقط به ویژگی‌های (X) نگاه می‌کند، نه به خروجی‌های (Y) مورد نیاز، و بنابراین می‌تواند برای یادگیری بدون نظارت استفاده شود.

• همبستگی پیرسون: همبستگی پیرسون روش دیگری برای درک رابطه یک ویژگی با متغیر پاسخ است و می‌تواند برای انتخاب ویژگی مورد استفاده قرار گیرد. [99] این روش همچنین برای یافتن ارتباط بین ویژگی‌ها در یک مجموعه داده استفاده می‌شود. مقدار حاصل [1، -1] است، که در آن -1 به معنای همبستگی منفی کامل، +1 به معنای همبستگی مثبت کامل و 0 به معنای عدم همبستگی خطی دو متغیر است. اگر دو متغیر تصادفی

متغیرها نشان دهنده X و Y هستند، سپس ضریب همبستگی بین X و Y به صورت [41] تعریف می‌شود.

$$r(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (8)$$

ANOVA: تحلیل واریانس (ANOVA) ابزاری آماری است که برای تأیید مقادیر میانگین دو یا چند گروه که تفاوت معناداری با یکدیگر دارند، استفاده می‌شود. ANOVA یک رابطه خطی بین متغیرها و هدف و توزیع نرمال متغیرها را فرض می‌کند. برای آزمون آماری برابری میانگین‌ها، از روش ANOVA استفاده می‌شود.



(a) An example of the original features in a 3D space.

از آزمون‌های F استفاده می‌کند. برای انتخاب ویژگی، می‌توان از «مقدار F آنالیز واریانس» [82] نتایج این آزمون استفاده کرد، در حالی که می‌توان ویژگی‌های خاصی را که مستقل از متغیر هدف هستند، حذف کرد.

• مجذور کای: آماره مجذور کای [82] یک تخمین است. همسر تفاوت بین اثرات یک سری از

رویدادها یا متغیرهای مشاهده شده و فراوانی‌های مورد انتظار.


بزرگی اختلاف بین مقادیر واقعی و مشاهده شده، درجات آزادی و اندازه نمونه به χ^2 بستگی دارد. کای اسکور χ^2 معمولاً برای آزمایش روابط بین متغیرهای دسته‌ای استفاده می‌شود. اگر O_i نشان دهنده مقدار مشاهده شده و E_i نشان دهنده مقدار مورد انتظار باشد، آنگاه

$$\chi^2 = \sum_{i=1}^n \frac{(O_i - E_i)^2}{E_i} \quad (9)$$

• حذف ویژگی بازگشتی (RFE): حذف ویژگی بازگشتی (RFE) یک رویکرد جستجوی فراگیر برای انتخاب ویژگی است. [82] RFE مدل را برآزش می‌دهد و ضعیف‌ترین ویژگی را قبل از اینکه به تعداد مشخصی از ویژگی‌ها برسد، حذف می‌کند. ویژگی‌ها بر اساس ضرایب یا اهمیت ویژگی مدل رتبه‌بندی می‌شوند. RFE قصد دارد وابستگی‌ها و هم‌خطی بودن را در مدل با حذف بازگشتی تعداد کمی از ویژگی‌ها در هر تکرار، حذف کند.

• انتخاب مبتنی بر مدل: برای کاهش ابعاد داده‌ها، می‌توان از مدل‌های خطی جریمه‌شده با منظم‌سازی L1 استفاده کرد. رگرسیون حداقل مطلق انقباض و عملگر انتخاب (لاسو) نوعی رگرسیون خطی است که خاصیت کاهش برخی از ضرایب به صفر را دارد. [82] بنابراین، می‌توان آن ویژگی را از مدل حذف کرد. بنابراین، روش رگرسیون لاسو جریمه‌شده، که اغلب در یادگیری ماشین برای انتخاب زیرمجموعه‌ای از متغیرها استفاده می‌شود. طبقه‌بندی‌کننده درختان اضافی [82] نمونه‌ای از یک تخمین‌گر مبتنی بر درخت است که می‌تواند برای محاسبه اهمیت تابع مبتنی بر ناخالصی استفاده شود، که سپس می‌تواند برای حذف ویژگی‌های نامربوط استفاده شود.

• تحلیل مؤلفه‌های اصلی (PCA): تحلیل مؤلفه‌های اصلی (PCA) یک روش یادگیری بدون نظارت شناخته شده است.



(b) Principal components in 2D and 1D space.

شکل ۸. نمونه‌ای از تحلیل مؤلفه‌های اصلی (PCA) و مؤلفه‌های اصلی ایجاد شده PC1 و PC2 در فضای ابعاد مختلف

رویکردی در زمینه یادگیری ماشین و علم داده. PCA یک تکنیک ریاضی است که مجموعه‌ای از متغیرهای همبسته را به مجموعه‌ای از متغیرهای غیرهمبسته تبدیل می‌کند.

متغیرهایی که به عنوان مؤلفه‌های اصلی شناخته می‌شوند. [81، 48] شکل 8 مثالی از تأثیر PCA بر فضای ابعاد مختلف را نشان می‌دهد، که در آن شکل 8a ویژگی‌های اصلی را در فضای سه‌بعدی نشان می‌دهد و شکل 8b مؤلفه‌های اصلی ایجاد شده PC2 و PC1 را به ترتیب روی یک صفحه دوبعدی و یک خط یک‌بعدی با مؤلفه اصلی PC1 نشان می‌دهد.

بنابراین، PCA می‌تواند به عنوان یک تکنیک استخراج ویژگی که ابعاد مجموعه داده‌ها را کاهش می‌دهد و برای ساخت یک مدل یادگیری ماشین مؤثر استفاده شود. [98] از نظر فنی، PCA داده‌های کاملاً تبدیل‌شده با بالاترین مقادیر ویژه یک ماتریس کوواریانس را شناسایی می‌کند و سپس از آنها برای تصویر کردن داده‌ها به یک زیرفضای جدید با ابعاد برابر یا کمتر استفاده می‌کند. [82]

یادگیری قانون انجمنی

یادگیری قوانین انجمنی یک رویکرد یادگیری ماشین مبتنی بر قوانین برای کشف روابط جالب، یعنی عبارات «اگر-آنگاه»، در مجموعه داده‌های بزرگ بین متغیرها است. [7] یک مثال این است که «اگر مشتری یک کامپیوتر با لپ‌تاپ (یک کالا) بخرد، احتمالاً همزمان نرم‌افزار آنتی‌ویروس (کالای دیگری) را نیز خواهد خرید». قوانین انجمنی امروزه در بسیاری از حوزه‌های کاربردی، از جمله خدمات اینترنت اشیا، تشخیص پزشکی، تجزیه و تحلیل رفتار استفاده، کاوش استفاده از وب، برنامه‌های کاربردی گوشی‌های هوشمند، برنامه‌های کاربردی امنیت سایبری و بیوانفورماتیک به کار گرفته می‌شوند. در مقایسه با کاوش توالی، یادگیری قوانین انجمنی معمولاً ترتیب چیزها را در داخل یا بین تراکنش‌ها در نظر نمی‌گیرد.

یک روش رایج برای اندازه‌گیری سودمندی قوانین انجمنی، استفاده از پارامترهای آن، یعنی «پشتیبانی» و «اطمینان» است که در [7] معرفی شده است.

در ادبیات داده‌کاوی، روش‌های یادگیری قوانین انجمنی زیادی پیشنهاد شده‌اند، مانند روش‌های وابسته به منطق، [34] مبتنی بر الگوهای مکرر [68، 49، 8] و مبتنی بر درخت. [42]

محبوب‌ترین الگوریتم‌های یادگیری قانون وابستگی در زیر خلاصه شده‌اند.

– AIS و SETM: اولین الگوریتمی است که توسط Agrawal و همکارانش [7] برای کاوش قوانین انجمنی ارائه شده است. عیب اصلی الگوریتم AIS این است که مجموعه اقلام کاندید بسیار زیادی تولید می‌شوند که به فضای بیشتری نیاز دارند و تلاش زیادی را هدر می‌دهند. این الگوریتم برای تولید قوانین، به تعداد زیادی گذر از کل مجموعه داده‌ها نیاز دارد. رویکرد دیگر، [49] SETM عملکرد خوب و رفتار پایداری را در زمان اجرا نشان می‌دهد؛ با این حال، از همان نقص الگوریتم AIS رنج می‌برد.

Apriori – برای تولید قوانین انجمنی برای یک مجموعه داده مشخص، آگروال و همکارانش [8] الگوریتم‌های Apriori-TID، Apriori-Hybrid و Apriori را پیشنهاد کردند. این الگوریتم‌های جدیدتر به دلایل زیر از AIS و SETM ذکر شده در بالا بهتر عمل می‌کنند:

ویژگی Apriori مجموعه اقلام پرترکر [8] اصطلاح «Apriori» معمولاً به داشتن دانش قبلی از ویژگی‌های مجموعه اقلام پرترکر اشاره دارد. Apriori از یک رویکرد «پایین به بالا» استفاده می‌کند، که در آن مجموعه اقلام کاندید را تولید می‌کند. برای کاهش فضای جستجو، Apriori از این ویژگی استفاده می‌کند که «همه زیرمجموعه‌های یک مجموعه اقلام پرترکر باید پرترکر باشند؛ و اگر یک مجموعه اقلام پرترکر باشد، همه ابرمجموعه‌های آن نیز باید پرترکر باشند». رویکرد پیش‌بینی‌کننده دیگر، [108] Apriori نیز می‌تواند قوانینی تولید کند. با این حال، با ترکیب پشتیبانی و اطمینان، نتایج غیرمنتظره‌ای دریافت می‌کند.

[8] Apriori تکنیک‌های پرکاربرد در کاوش قوانین وابستگی است.

ECLAT: این تکنیک توسط Zaki و همکارانش [131] پیشنهاد شده است و مخفف Class Clustering Equivalence و Bottom-Up Lattice Traversal است. ECLAT از جستجوی عمقی برای یافتن مجموعه اقلام مکرر استفاده می‌کند. برخلاف الگوریتم [8] Apriori که داده‌ها را در یک الگوی افقی نشان می‌دهد، این الگوریتم داده‌ها را به صورت عمودی نشان می‌دهد. از این رو، الگوریتم ECLAT در حوزه ارتباط، کارآمدتر و مقیاس‌پذیرتر است.

یادگیری قانون. این الگوریتم برای مجموعه داده‌های کوچک و متوسط مناسب‌تر است در حالی که الگوریتم Apriori برای مجموعه داده‌های بزرگ استفاده می‌شود.

– رشد سریع الگوریتم (FP-Growth): یکی دیگر از تکنیک‌های رایج یادگیری قوانین انجمنی مبتنی بر درخت الگوی پرترکر (FP-tree) که توسط هان و همکارانش [42] پیشنهاد شده است، رشد سریع الگوریتم است که با نام رشد سریع الگوریتم (FP-Growth) شناخته می‌شود. تفاوت کلیدی آن با Apriori این است که الگوریتم [8] Apriori هنگام تولید قوانین، مجموعه اقلام کاندید پرترکر را تولید می‌کند. از سوی دیگر، الگوریتم رشد سریع الگوریتم [42] (FP-growth) تولید کاندید جلوگیری می‌کند و بنابراین با استراتژی موفقیت‌آمیز رویکرد «تقسیم و غلبه»، یک درخت تولید می‌کند. با این حال، به دلیل پیچیدگی آن، استفاده از FP-Tree در یک محیط کاوش تعاملی چالش برانگیز است. [133] بنابراین، FP-Tree برای مجموعه داده‌های عظیم در حافظه جا نمی‌شود و پردازش داده‌های بزرگ را نیز چالش برانگیز می‌کند. راه حل دیگر JARM (کاوش سریع قوانین انجمنی) است که توسط داس و همکارانش [26] پیشنهاد شده است، اما با یک مشکل درخت FP مرتبط روبرو است. [133]

ABC-RuleMiner – یک روش یادگیری ماشین مبتنی بر قانون، که اخیراً در مقاله قبلی ما توسط سارکر و همکارانش [104] پیشنهاد شده است، برای کشف قوانین غیر تکراری جالب برای ارائه خدمات هوشمند در دنیای واقعی. این الگوریتم با در نظر گرفتن تأثیر یا تقدم ویژگی‌های زمینه‌ای مرتبط، افزونگی در انجمن‌ها را به طور مؤثر شناسایی می‌کند و مجموعه‌ای از قوانین ارتباطی غیر تکراری را کشف می‌کند. این الگوریتم ابتدا یک درخت تولید انجمن (AGT) یک رویکرد بالا به پایین، می‌سازد و سپس با پیمایش درخت، قوانین ارتباطی را استخراج می‌کند. بنابراین، RuleMiner ABC از نظر هر دو مورد، قوی‌تر از روش‌های سنتی مبتنی بر قانون است.

تولید قوانین غیر تکراری و تصمیم‌گیری هوشمند، به ویژه در یک محیط محاسباتی هوشمند آگاه از زمینه، که در آن ترجیحات انسانی یا کاربر دخیل است.

از این رویکرد، یادگیری تقویتی (RL) به عنوان یک روش یادگیری ماشین برای حل مسائل یادگیری در محیط‌های پویا و غیرقابل پیش‌بینی شناخته می‌شود. [133]

تطبیق، با انتقال‌ها و پاداش‌های تصادفی سروکار داشته باشد. «Q» در یادگیری Q

معمولاً به معنای کیفیت است، زیرا الگوریتم حداکثر پاداش مورد انتظار را برای یک

نقطه قوتی اصلی، تکلیف یا تابع هدف را می‌یابد. از آنجایی که تمام انجمن‌هایی را تولید می‌کند که محدودیت‌های مشخص شده توسط کاربر، مانند حداقل پشتیبانی و مقدار اطمینان

را برآورده می‌کنند. رویکرد [104] ABC-RuleMiner که قبلاً مورد بحث قرار گرفت، می‌تواند نتایج قابل توجهی را از نظر تولید قوانین غیر تکراری و تصمیم‌گیری هوشمند برای حوزه‌های

کاربرد یادگیری تقویتی (RL) را به نمایش درآورد. [52] این است که حالت اولیه به

شبکه عصبی داده می‌شود، که مقدار Q تمام اقدامات ممکن را به عنوان خروجی

برمی‌گرداند. با این حال، وقتی یک محیط نسبتاً ساده برای غلبه بر آن داریم، یادگیری Q به

خوبی کار می‌کند.

با این حال، وقتی تعداد حالت‌ها و اقدامات پیچیده‌تر می‌شود، یادگیری عمیق

می‌تواند به عنوان یک تقریب‌ساز تابع مورد استفاده قرار گیرد.

یادگیری تقویتی

یادگیری تقویتی (RL) یک تکنیک یادگیری ماشینی است که به یک عامل اجازه می‌دهد تا

با استفاده از ورودی از اقدامات و تجربیات خود، در یک محیط تعاملی با آزمون و خطا یاد

بگیرد. برخلاف یادگیری نظارت شده که مبتنی بر داده‌های نمونه یا مثال‌های داده شده

است، روش یادگیری تقویتی مبتنی بر تعامل با محیط است. مسئله‌ای که باید در یادگیری

تقویتی (RL) حل شود، به عنوان یک فرآیند تصمیم‌گیری مارکوف [86] (MDP) تعریف

می‌شود، یعنی همه چیز در مورد تصمیم‌گیری‌های متوالی است. یک مسئله یادگیری

تقویتی معمولاً شامل چهار عنصر مانند عامل، محیط، پاداش‌ها و سیاست است.

یادگیری تقویتی، همراه با یادگیری تحت نظارت و بدون نظارت، یکی از پارادایم‌های اساسی

یادگیری ماشین است. یادگیری تقویتی می‌تواند برای حل مسائل دنیای واقعی متعدد در

زمینه‌های مختلف مانند نظریه بازی‌ها، نظریه کنترل، تحلیل عملیات، نظریه اطلاعات،

بهینه‌سازی مبتنی بر شبیه‌سازی، تولید، لجستیک زنجیره تأمین، سیستم‌های چندعاملی،

هوش ازدحامی، کنترل هواپیما، کنترل حرکت ربات و بسیاری موارد دیگر مورد استفاده

قرار گیرد.

شبکه عصبی مصنوعی و یادگیری عمیق

یادگیری عمیق بخشی از خانواده وسیع‌تری از رویکردهای یادگیری ماشین مبتنی بر

شبکه‌های عصبی مصنوعی (ANN) با یادگیری بازنمایی است. یادگیری عمیق با ترکیب

چندین لایه پردازشی، مانند لایه‌های ورودی، پنهان و خروجی، یک معماری محاسباتی برای

یادگیری از داده‌ها فراهم می‌کند. [41] مزیت اصلی یادگیری عمیق نسبت به روش‌های

سنتی یادگیری ماشین، عملکرد بهتر آن در چندین مورد، به ویژه یادگیری از مجموعه

داده‌های بزرگ است. [105، 129] شکل 9 عملکرد کلی یادگیری عمیق نسبت به یادگیری

ماشین را با توجه به افزایش حجم داده‌ها نشان می‌دهد. با این حال، ممکن است بسته به

ویژگی‌های داده‌ها و تنظیمات آزمایشی متفاوت باشد.

یادگیری تقویتی (RL) را می‌توان تقریباً به تکنیک‌های مبتنی بر مدل و بدون مدل

تقسیم کرد. یادگیری تقویتی مبتنی بر مدل، فرآیند استنتاج رفتار بهینه از یک مدل از محیط

با انجام اقدامات و مشاهده نتایج است که شامل حالت بعدی و پاداش فوری می‌شود

[113] Alp-haZero، AlphaGo [85] نمونه‌هایی از رویکردهای مبتنی بر مدل هستند. از

سوی دیگر، یک رویکرد بدون مدل از توزیع احتمال انتقال و تابع پاداش مرتبط با MDP

استفاده نمی‌کند. یادگیری Q، شبکه Q عمیق، کنترل مونت کارلو، SARSA (حالت-عمل-

پاداش-حالت-عمل) و غیره نمونه‌هایی از الگوریتم‌های بدون مدل هستند. [52] شبکه


سیاست، که برای یادگیری تقویتی مبتنی بر مدل مورد نیاز است اما برای یادگیری بدون

مدل مورد نیاز نیست، تفاوت کلیدی بین یادگیری بدون مدل و مبتنی بر مدل است. در

ادامه، الگوریتم‌های محبوب یادگیری تقویتی را مورد بحث قرار می‌دهیم.

رایج‌ترین الگوریتم‌های یادگیری عمیق عبارتند از: پرسپترون چندلایه (MLP)، شبکه

عصبی کانولوشن



شکل 9: عملکرد کلی یادگیری ماشین و یادگیری عمیق با توجه به میزان داده‌ها

-روش‌های مونت کارلو: تکنیک‌های مونت کارلو یا آزمایش‌های مونت کارلو، دسته‌ای

گسترده‌ای از الگوریتم‌های محاسباتی هستند که برای دستیابی به نتایج عددی به نمونه‌گیری

تصادفی مکرر متکی هستند. [52] مفهوم اساسی، استفاده از تصادفی بودن برای حل

مسائلی است که در اصل قطعی هستند. بهینه‌سازی، انتگرال‌گیری عددی و ترسیم


نمودارها از توزیع احتمال، سه دسته از مسائلی هستند که تکنیک‌های مونت کارلو بیشتر

در آنها مورد استفاده قرار می‌گیرند.


-یادگیری Q: یادگیری Q یک الگوریتم یادگیری تقویتی بدون مدل برای یادگیری کیفیت

رفتارهایی است که به یک عامل می‌گوید تحت چه شرایطی چه اقدامی انجام دهد. [52] به

مدلی از محیط نیاز ندارد.



شکل 10. ساختاری از مدل‌سازی شبکه عصبی مصنوعی با چندین لایه پردازشی



شکل 11. نمونه‌ای از یک شبکه عصبی کانولوشن (CNN) یا (Con-vNet) شامل چندین لایه کانولوشن و pooling

(CNN) یا (ConvNet) شبکه عصبی بازگشتی با حافظه کوتاه مدت بلند [96] (LSTM-RNN) در ادامه، انواع مختلفی از روش‌های یادگیری عمیق را که می‌توانند برای ساخت مدل‌های داده‌محور مؤثر برای موارد مختلف استفاده شوند، مورد بحث قرار می‌دهیم.

اهداف.

MLP: معماری پایه یادگیری عمیق، که به عنوان شبکه عصبی مصنوعی پیش‌خور نیز شناخته می‌شود، پرسپترون چندلایه (MLP) نامیده می‌شود. [82] یک MLP معمولی، یک شبکه کاملاً متصل است که از یک لایه ورودی، یک یا چند لایه پنهان و یک لایه خروجی تشکیل شده است، همانطور که در شکل 10 نشان داده شده است. هر گره در یک لایه با وزن خاصی به هر گره در لایه بعدی متصل می‌شود.

IMLP از تکنیک «پس‌انتشار» [41] که اساسی‌ترین «بلوک سازنده» در یک شبکه عصبی است، برای تنظیم داخلی مقادیر وزن هنگام ساخت مدل استفاده می‌کند. MLP به ویژگی‌های مقیاس‌بندی حساس است و امکان تنظیم انواع فرایارامترها، مانند تعداد لایه‌های پنهان، نورون‌ها و تکرارها را فراهم می‌کند که می‌تواند منجر به یک مدل از نظر محاسباتی پرهزینه شود.

CNN - یا ConvNet: شبکه عصبی کانولوشن [65] (CNN) طراحی استاندارد را بهبود می‌بخشد، که شامل لایه‌های کانولوشن، لایه‌های pooling و همچنین لایه‌های کاملاً متصل است، همانطور که در شکل 11 نشان داده شده است.

از آنجایی که از ساختار دوبعدی (2D) داده‌های ورودی بهره می‌برد، معمولاً به طور گسترده در زمینه‌های مختلفی مانند تشخیص تصویر و ویدیو، پردازش و طبقه‌بندی تصویر، تجزیه و تحلیل تصاویر پزشکی، پردازش زبان طبیعی و غیره استفاده می‌شود. در حالی که CNN بار محاسباتی بیشتری دارد، بدون هیچ گونه مداخله دستی، از مزیت تشخیص خودکار ویژگی‌های مهم برخوردار است و از این رو CNN قدرتمندتر از ANN معمولی در نظر گرفته می‌شود. تعدادی از مدل‌های یادگیری عمیق پیشرفته مبتنی بر CNN می‌توانند در این زمینه استفاده شوند، مانند ResNet [45]، AlexNet [60]، Xception [24]، Inception [118]، Visual Geometry Group (VGG) [44]، و غیره.

LSTM-RNN: حافظه کوتاه‌مدت بلند (LSTM) یک معماری شبکه عصبی مصنوعی بازگشتی (RNN) است که در حوزه یادگیری عمیق مورد استفاده قرار می‌گیرد. LSTM [38] برخلاف شبکه‌های عصبی پیش‌خور معمولی، دارای پیوندهای بازخوردی است. شبکه‌های LSTM برای تجزیه و تحلیل و یادگیری داده‌های متوالی، مانند طبقه‌بندی، پردازش و پیش‌بینی داده‌ها بر اساس داده‌های سری زمانی، بسیار مناسب هستند که آن را از سایر شبکه‌های مرسوم متمایز می‌کند. بنابراین، LSTM می‌تواند زمانی که داده‌ها در قالب متوالی مانند زمان، جمله و غیره هستند، مورد استفاده قرار گیرد و معمولاً در حوزه تحلیل سری‌های زمانی، پردازش زبان طبیعی، تشخیص گفتار و غیره کاربرد دارد.

علاوه بر این رایج‌ترین روش‌های یادگیری عمیق که در بالا مورد بحث قرار گرفتند، چندین رویکرد یادگیری عمیق دیگر [96] در این حوزه برای اهداف مختلف وجود دارد. به عنوان مثال، نقشه خودسازمانده [58] (SOM) از یادگیری بدون نظارت برای نمایش داده‌های با ابعاد بالا توسط یک نقشه شبکه دوبعدی استفاده می‌کند و در نتیجه به کاهش ابعاد دست می‌یابد. رمزگذار خودکار [15] (AE) یکی دیگر از تکنیک‌های یادگیری است که به طور گسترده برای کاهش ابعاد و استخراج ویژگی در وظایف یادگیری بدون نظارت استفاده می‌شود.

ماشین‌های بولتزمن محدود [46] (RBM) می‌توانند برای کاهش ابعاد، طبقه‌بندی، رگرسیون، فیلترینگ مشارکتی، یادگیری ویژگی و مدل‌سازی موضوعی استفاده شوند. یک شبکه باور عمیق (DBN) معمولاً از شبکه‌های ساده و بدون نظارت مانند ماشین‌های بولتزمن محدود (RBM) یا خودرمزگذارها و یک شبکه عصبی انتشار معکوس [123] (BPNN) تشکیل شده است. یک شبکه رقیب مولد [39] (GAN) نوعی شبکه برای یادگیری عمیق است که می‌تواند داده‌هایی با ویژگی‌های نزدیک به ورودی داده واقعی تولید کند. یادگیری انتقالی در حال حاضر بسیار رایج است زیرا می‌تواند شبکه‌های عصبی عمیق را با داده‌های نسبتاً کم آموزش دهد، که معمولاً استفاده مجدد از یک مسئله جدید با یک مدل از پیش آموزش دیده است [124]. بحث مختصری در مورد این شبکه‌های عصبی مصنوعی (ANN) و مدل‌های یادگیری عمیق (DL) در مقاله قبلی ما، سارکر و همکاران، [96] خلاصه شده است.

در مجموع، بر اساس تکنیک‌های یادگیری مورد بحث در بالا، می‌توانیم نتیجه بگیریم که انواع مختلف ماشین

تکنیک‌های یادگیری، مانند تحلیل طبقه‌بندی، رگرسیون، خوشه‌بندی داده‌ها، انتخاب و استخراج ویژگی و کاهش ابعاد، یادگیری قانون وابستگی، یادگیری تقویتی یا تکنیک‌های یادگیری عمیق، می‌توانند بسته به قابلیت‌هایشان، نقش مهمی برای اهداف مختلف ایفا کنند. در بخش زیر، چندین حوزه کاربردی مبتنی بر الگوریتم‌های یادگیری ماشین را مورد بحث قرار می‌دهیم.

کاربردهای یادگیری ماشین

در عصر کنونی انقلاب صنعتی چهارم (4IR) یادگیری ماشینی به دلیل قابلیت‌های یادگیری از گذشته و تصمیم‌گیری‌های هوشمندانه، در حوزه‌های کاربردی مختلف محبوبیت پیدا می‌کند. در ادامه، ده حوزه کاربردی محبوب فناوری یادگیری ماشینی را خلاصه و مورد بحث قرار می‌دهیم.

-تجزیه و تحلیل پیش‌بینانه و تصمیم‌گیری هوشمند: یکی از زمینه‌های کاربردی اصلی یادگیری ماشین، تصمیم‌گیری هوشمند با استفاده از تجزیه و تحلیل‌های پیش‌بینانه مبتنی بر داده است. [70، 21] اساس تجزیه و تحلیل پیش‌بینانه، ثبت و بهره‌برداری از روابط بین متغیرهای توضیحی و متغیرهای پیش‌بینی‌شده از رویدادهای قبلی برای پیش‌بینی نتیجه ناشناخته است. [41] به عنوان مثال، شناسایی مظنونین یا مجرمان پس از ارتکاب جرم، یا تشخیص کلاهبرداری کارت اعتباری در حین وقوع، کاربرد دیگر، جایی است که الگوریتم‌های یادگیری ماشین می‌توانند به خرده‌فروشان در درک بهتر ترجیحات و رفتار مصرف‌کننده، مدیریت بهتر موجودی، جلوگیری از موقعیت‌های ناموجود و بهینه‌سازی لجستیک و انبارداری در تجارت الکترونیک کمک کنند. الگوریتم‌های مختلف یادگیری ماشین مانند درخت‌های تصمیم‌گیری، ماشین‌های بردار پشتیبان، شبکه‌های عصبی مصنوعی و غیره [125، 106] معمولاً در این حوزه استفاده می‌شوند. از آنجایی که پیش‌بینی‌های دقیق، بینشی نسبت به ناشناخته‌ها ارائه می‌دهند، می‌توانند تصمیمات صنایع، کسب‌وکارها و تقریباً هر سازمانی، از جمله سازمان‌های دولتی، تجارت الکترونیک، مخابرات، بانکداری و خدمات مالی، مراقبت‌های بهداشتی، فروش و بازاریابی، حمل و نقل، شبکه‌های اجتماعی و بسیاری دیگر را بهبود بخشند.

-امنیت سایبری و اطلاعات تهدید: امنیت سایبری یکی از اساسی‌ترین حوزه‌های صنعت ۴۰ است. [114] که معمولاً به محافظت از شبکه‌ها، سیستم‌ها، سخت‌افزار و داده‌ها در برابر حملات دیجیتال اطلاق می‌شود. [114]

یادگیری ماشینی به یک فناوری حیاتی در امنیت سایبری تبدیل شده است که دائماً با تجزیه و تحلیل داده‌ها، الگوها را شناسایی می‌کند، بدافزارها را در ترافیک رمزگذاری شده بهتر تشخیص می‌دهد، تهدیدات داخلی را پیدا می‌کند، پیش‌بینی می‌کند که محله‌های بد کجا آنلاین هستند، افراد را هنگام مرور ایمن نگه می‌دارد یا با کشف فعالیت‌های مشکوک، داده‌ها را در ابر ایمن می‌کند. به عنوان مثال، می‌توان از تکنیک‌های خوشه‌بندی برای شناسایی ناهنجاری‌های سایبری، نقض سیاست‌ها و غیره استفاده کرد.

برای تشخیص انواع مختلف حملات سایبری یا نفوذها، مدل‌های طبقه‌بندی یادگیری ماشین با در نظر گرفتن تأثیر ویژگی‌های امنیتی مفید هستند. [97]

مدل‌های امنیتی مختلف مبتنی بر یادگیری عمیق نیز می‌توانند در مقیاس بزرگ مجموعه داده‌های امنیتی مورد استفاده قرار گیرند. [129، 96] علاوه بر این، قوانین سیاست امنیتی تولید شده توسط تکنیک‌های یادگیری قوانین انجمنی می‌توانند نقش مهمی در ساخت یک سیستم امنیتی مبتنی بر قوانین ایفا کنند. [105] بنابراین، می‌توانیم بگوییم که تکنیک‌های مختلف یادگیری که در بخش وظایف و الگوریتم‌های یادگیری ماشین مورد بحث قرار گرفته‌اند، می‌توانند متخصصان امنیت سایبری را قادر سازند تا در جلوگیری از تهدیدات و حملات سایبری، پیشگیرانه‌تر عمل کنند.

-اینترنت اشیا (IoT) و شهرهای هوشمند: اینترنت اشیا (IoT) یکی دیگر از حوزه‌های ضروری صنعت ۴۰ است. [114] که با فراهم کردن امکان انتقال داده‌ها و خودکارسازی وظایف بدون نیاز به تعامل انسانی، اشیاء روزمره را به اشیاء هوشمند تبدیل می‌کند. بنابراین، اینترنت اشیا به عنوان مرز بزرگی در نظر گرفته می‌شود که می‌تواند تقریباً تمام فعالیت‌های زندگی ما، مانند حکومت هوشمند، خانه هوشمند، آموزش، ارتباطات، حمل و نقل، خرده فروشی، کشاورزی، مراقبت‌های بهداشتی، تجارت و بسیاری موارد دیگر را بهبود بخشد. [70]

شهر هوشمند یکی از زمینه‌های اصلی کاربرد اینترنت اشیا است که از فناوری‌ها برای بهبود خدمات شهری و تجربیات زندگی ساکنان استفاده می‌کند. [135، 132] از آنجایی که یادگیری ماشین از تجربه برای تشخیص روندها و ایجاد مدل‌هایی که به پیش‌بینی رفتار و رویدادهای آینده کمک می‌کنند، استفاده می‌کند، به یک فناوری حیاتی برای کاربردهای اینترنت اشیا تبدیل شده است. [103] به عنوان مثال، پیش‌بینی ترافیک در شهرهای هوشمند، پیش‌بینی در دسترس بودن پارکینگ، تخمین کل مصرف انرژی شهروندان برای یک دوره خاص، تصمیم‌گیری آگاهانه و به موقع برای مردم و غیره، برخی از کارهایی هستند که می‌توان با استفاده از تکنیک‌های یادگیری ماشین مطابق با نیازهای فعلی مردم حل کرد.

-پیش‌بینی ترافیک و حمل و نقل: سیستم‌های حمل و نقل به یک جزء حیاتی از توسعه اقتصادی هر کشور تبدیل شده‌اند. با این وجود، چندین شهر در سراسر جهان افزایش بیش از حد حجم ترافیک را تجربه می‌کنند که منجر به مسائل جدی مانند تأخیر، ازدحام ترافیک، افزایش قیمت سوخت، افزایش آلودگی، CO₂ تصادفات، موارد اضطراری و کاهش کیفیت زندگی جامعه مدرن می‌شود. [40] بنابراین، یک سیستم حمل و نقل هوشمند از طریق پیش‌بینی ترافیک آینده مهم است که بخش ضروری یک شهر هوشمند است. پیش‌بینی دقیق ترافیک مبتنی بر مدل‌سازی یادگیری ماشین و یادگیری عمیق می‌تواند به به حداقل رساندن مشکلات کمک کند. [31، 30، 17] به عنوان مثال، بر اساس سابقه سفر و روند سفر در مسیرهای مختلف، یادگیری ماشین می‌تواند به شرکت‌های حمل و نقل در پیش‌بینی مشکلات احتمالی که ممکن است در مسیرهای خاص رخ دهد و توصیه به مشتریان خود برای انتخاب مسیر متفاوت کمک کند.

در نهایت، این مدل‌های داده‌محور مبتنی بر یادگیری به بهبود جریان ترافیک، افزایش استفاده و کارایی ... کمک می‌کنند.

روش‌های پایدار حمل و نقل، و محدود کردن اختلالات در دنیای واقعی با مدل‌سازی و تجسم تغییرات آیند.

-مراقبت‌های بهداشتی و هم‌گیری کووید-۱۹: یادگیری ماشین می‌تواند به حل مشکلات تشخیصی و پیش‌آگهی در حوزه‌های مختلف پزشکی، مانند پیش‌بینی بیماری، استخراج دانش پزشکی، تشخیص نظم در داده‌ها، مدیریت بیمار و غیره کمک کند. [112، 77، 33] بیماری کرونا (کووید-۱۹) طبق گفته سازمان بهداشت جهانی (WHO) یک بیماری عفونی است که توسط یک ویروس کرونای تازه کشف شده ایجاد می‌شود. [3] اخیراً، تکنیک‌های یادگیری در مبارزه با کووید-۱۹ محبوب شده‌اند. [63، 61] برای هم‌گیری کووید-۱۹، از تکنیک‌های یادگیری برای طبقه‌بندی بیماران در معرض خطر بالا، میزان مرگ و میر آنها و سایر ناهنجاری‌ها استفاده می‌شود. [61] همچنین می‌توان از آن برای درک بهتر منشأ ویروس استفاده کرد.

جین، پیش‌بینی شیوع کووید-۱۹، و همچنین برای تشخیص و درمان بیماری. [50، 14] با کمک یادگیری ماشین، محققان می‌توانند پیش‌بینی کنند که کووید-۱۹ احتمالاً کجا و چه زمانی گسترش می‌یابد و به آن مناطق اطلاع دهند تا تمهیدات لازم را رعایت کنند. یادگیری عمیق همچنین راجه‌های هیجان‌انگیزی برای مشکلات پردازش تصاویر پزشکی ارائه می‌دهد و به عنوان یک تکنیک حیاتی برای کاربردهای بالقوه، و به ویژه برای هم‌گیری کووید-۱۹، در نظر گرفته می‌شود. [111، 78، 10] به طور کلی، تکنیک‌های یادگیری ماشین و عمیق می‌توانند به مبارزه با ویروس کووید-۱۹ و هم‌گیری و همچنین تصمیم‌گیری‌های بالینی هوشمند در حوزه مراقبت‌های بهداشتی کمک کنند.

-تجارت الکترونیک و توصیه‌های محصول: توصیه محصول یکی از شناخته‌شده‌ترین و پرکاربردترین کاربردهای یادگیری ماشین است و امروزه یکی از برجسته‌ترین ویژگی‌های تقریباً هر وب‌سایت تجارت الکترونیک است. فناوری یادگیری ماشین می‌تواند به کسب‌وکارها در تجزیه و تحلیل تاریخچه خرید مصرف‌کنندگان و ارائه پیشنهادات محصول سفارشی برای خرید بعدی آنها بر اساس رفتار و ترجیحاتشان کمک کند. به عنوان مثال، شرکت‌های تجارت الکترونیک می‌توانند به راحتی با تجزیه و تحلیل روندهای مرور و نرخ کلیک اقلام خاص، پیشنهادات و پیشنهادات محصول را در موقعیت مناسب قرار دهند.

با استفاده از مدل‌سازی پیش‌بینی مبتنی بر تکنیک‌های یادگیری ماشین، بسیاری از خرده‌فروشان آنلاین، مانند آمازون [71] می‌توانند موجودی را بهتر مدیریت کنند، از موقعیت‌های عدم موجودی جلوگیری کنند و لجستیک و انبارداری را بهینه کنند. آینده فروش و بازاریابی، توانایی ثبت، ارزیابی و استفاده از داده‌های مصرف‌کننده برای ارائه یک تجربه خرید سفارشی است. علاوه بر این، تکنیک‌های یادگیری ماشین، شرکت‌ها را قادر می‌سازد تا بسته‌ها و محتوایی متناسب با نیازهای مشتریان خود ایجاد کنند و به آنها امکان می‌دهد مشتریان فعلی را حفظ کرده و در عین حال مشتریان جدید جذب کنند.

-پردازش زبان طبیعی (NLP) و تحلیل احساسات: پردازش زبان طبیعی (NLP) شامل خواندن و درک زبان گفتاری یا نوشتاری از طریق واسطه یک کامپیوتر است. [103، 79] بنابراین، پردازش زبان طبیعی به کامپیوترها کمک می‌کند، به عنوان مثال، یک متن را بخوانند، گفتار را بشنوند، آن را تفسیر کنند، تجزیه و تحلیل کنند...

احساسات را تجزیه و تحلیل کنید و تصمیم بگیرید کدام جنبه‌ها مهم هستند، جایی که می‌توان از تکنیک‌های یادگیری ماشین استفاده کرد. دستیار شخصی مجازی، چت‌بات، تشخیص گفتار، توصیف سند، ترجمه زبان یا ماشین و غیره نمونه‌هایی از وظایف مرتبط با NLP هستند. تحلیل احساسات [90] (که به آن نظرکاوی یا هوش مصنوعی احساسات نیز گفته می‌شود) یک زیرشاخه NLP است که به دنبال شناسایی و استخراج خلق و خو و دیدگاه‌های عمومی در یک متن معین از طریق وبلاگ‌ها، بررسی‌ها، رسانه‌های اجتماعی، انجمن‌ها، اخبار و غیره است. به عنوان مثال، مشاغل و برندها از تحلیل احساسات برای درک احساسات اجتماعی برند، محصول یا خدمات خود از طریق پلتفرم‌های رسانه‌های اجتماعی یا وب به طور کلی استفاده می‌کنند. به طور کلی، تحلیل احساسات به عنوان یک وظیفه یادگیری ماشین در نظر گرفته می‌شود که متون را از نظر قطبیت، مانند "مثبت"، "منفی" یا "خنثی" همراه با احساسات شدیدتر مانند بسیار خوشحال، شاد، غمگین، بسیار غمگین، عصبانی، علاقه‌مند یا بی‌علاقه و غیره تجزیه و تحلیل می‌کند.

-تشخیص تصویر، گفتار و الگو: تشخیص تصویر [36] یک نمونه شناخته شده و گسترده از یادگیری ماشین در دنیای واقعی است که می‌تواند یک شیء را به عنوان یک تصویر دیجیتال شناسایی کند. به عنوان مثال، برچسب گذاری یک عکس اشعه ایکس به عنوان سرطانی یا غیر سرطانی، تشخیص کاراکتر یا تشخیص چهره در یک تصویر، پیشنهادهای برچسب گذاری در رسانه‌های اجتماعی، مانند فیس بوک، نمونه‌های رایجی از تشخیص تصویر هستند. تشخیص گفتار [23] نیز بسیار محبوب است که معمولاً از مدل‌های صوتی و زبانی استفاده می‌کند، مانند دستیار گوگل، کورتانا، سیری، الکسا و غیره. [67] که در آن از روش‌های یادگیری ماشین استفاده می‌شود. تشخیص الگو [13] به عنوان تشخیص خودکار الگوها و نظم در داده‌ها، مانند تجزیه و تحلیل تصویر تعریف می‌شود. چندین تکنیک یادگیری ماشین مانند طبقه‌بندی، انتخاب ویژگی، خوشه‌بندی یا روش‌های برچسب‌گذاری توالی در این زمینه استفاده می‌شوند.

-کشاورزی پایدار: کشاورزی برای بقای همه فعالیت‌های انسانی ضروری است. [109] شیوه‌های کشاورزی پایدار به بهبود بهره‌وری کشاورزی کمک می‌کنند و در عین حال تأثیرات منفی بر محیط زیست را نیز کاهش می‌دهند. [109، 25، 5] زنجیره‌های تأمین کشاورزی پایدار دانش‌محور و مبتنی بر اطلاعات، مهارت‌ها، فناوری‌ها و غیره هستند، که در آن انتقال دانش، کشاورزان را تشویق می‌کند تا تصمیمات خود را برای اتخاذ شیوه‌های کشاورزی پایدار با استفاده از حجم فزاینده داده‌های جمع‌آوری‌شده توسط فناوری‌های نوظهور، مانند اینترنت اشیا (IoT)، فناوری‌ها و دستگاه‌های تلفن همراه و غیره، بهبود بخشند. [54، 53، 5] یادگیری ماشینی را می‌توان در مراحل مختلف کشاورزی پایدار، مانند مرحله پیش از تولید -برای پیش‌بینی عملکرد محصول، خواص خاک، نیازهای آبیاری و غیره؛ در مرحله تولید -برای پیش‌بینی آب و هوا، تشخیص بیماری، تشخیص علف‌های هرز، مدیریت مواد مغذی خاک، مدیریت دام و غیره؛ در مرحله پردازش -برای تخمین تقاضا، برنامه‌ریزی تولید و غیره و در مرحله توزیع، به کار برد.

و تحلیل رفتارهای اکرایی و هزینه‌های کل، بیش از گروه هم‌اهای هوشمند آگاه از زمینه، آگاهی از زمینه، توانایی یک سیستم برای کسب دانش در مورد محیط اطراف خود در هر لحظه و اصلاح رفتارها بر اساس آن است. [28, 93]

[illegible]

است. ^{۱۱}

برای تجزیه و تحلیل داده‌ها و استخراج بینش، الگوریتم‌های یادگیری ماشین زیادی وجود دارد که در بخش «**وظایف و الگوریتم‌های یادگیری ماشین**» خلاصه شده‌اند. بنابراین، انتخاب یک الگوریتم یادگیری مناسب که برای کاربرد هدف مناسب باشد، چالش برانگیز است. دلیل آن این است که نتیجه الگوریتم‌های یادگیری مختلف ممکن است بسته به ویژگی‌های داده متفاوت باشد. [106] انتخاب یک الگوریتم یادگیری اشتباه منجر به تولید نتایج غیرمنتظره‌ای می‌شود که ممکن است منجر به از دست رفتن تلاش و همچنین اثربخشی و دقت مدل شود. از نظر ساخت مدل، تکنیک‌های مورد بحث در بخش «**وظایف و الگوریتم‌های یادگیری ماشین**» می‌توانند مستقیماً برای حل بسیاری از مسائل دنیای واقعی در حوزه‌های مختلف، مانند امنیت سایبری، شهرهای هوشمند و مراقبت‌های بهداشتی که در بخش «**کاربردهای یادگیری ماشین**» خلاصه شده‌اند، استفاده شوند.

با این حال، مدل یادگیری ترکیبی، مثلاً ترکیبی از روش‌ها، اصلاح یا بهبود تکنیک‌های یادگیری موجود یا طراحی روش‌های جدید یادگیری، می‌تواند یک کار بالقوه آینده در این حوزه باشد.

بنابراین، موفقیت نهایی یک راحل مبتنی بر یادگیری ماشین و برنامه‌های کاربردی مربوطه عمدتاً به داده‌ها و الگوریتم‌های یادگیری بستگی دارد. اگر داده‌ها برای یادگیری نامناسب باشند، مانند داده‌های غیرنماینده، بی‌کیفیت، دارای ویژگی‌های نامربوط یا دارای کمیت ناکافی برای آموزش، مدل‌های یادگیری ماشین ممکن است بی‌فایده شوند یا دقت کمتری تولید کنند. بنابراین، پردازش مؤثر داده‌ها و مدیریت الگوریتم‌های یادگیری متنوع برای یک راحل مبتنی بر یادگیری ماشین و در نهایت ساخت برنامه‌های کاربردی هوشمند مهم است.

نتیجه‌گیری

در این مقاله، ما مروری جامع بر الگوریتم‌های یادگیری ماشین برای تحلیل داده‌های هوشمند و کاربردهای آن داشته‌ایم. با توجه به هدفمان، به طور خلاصه در مورد چگونگی عملکرد انواع مختلف روش‌های یادگیری ماشین بحث کرده‌ایم.

علاوه بر این حوزه‌های کاربردی، مدل‌های مبتنی بر یادگیری ماشین می‌توانند در حوزه‌های دیگری مانند بیوانفورماتیک، شیمی‌انفورماتیک، شبکه‌های کامپیوتری، طبقه‌بندی توالی DNA، اقتصاد و بانکداری، رباتیک، مهندسی پیشرفته و بسیاری موارد دیگر نیز کاربرد داشته باشند.

چالش‌ها و مسیرهای تحقیقاتی

مطالعه ما در مورد الگوریتم‌های یادگیری ماشین برای تحلیل و کاربردهای هوشمند داده‌ها، چندین موضوع تحقیقاتی در این حوزه را مطرح می‌کند. بنابراین، در این بخش، چالش‌های پیش رو و فرصت‌های تحقیقاتی بالقوه و مسیرهای آینده را خلاصه و مورد بحث قرار می‌دهیم.

به طور کلی، اثربخشی و کارایی یک راحل مبتنی بر یادگیری ماشین به ماهیت و ویژگی‌های داده‌ها و عملکرد الگوریتم‌های یادگیری بستگی دارد. جمع‌آوری داده‌ها در حوزه‌های مرتبط، مانند امنیت سایبری، اینترنت اشیا، مراقبت‌های بهداشتی و کشاورزی که در بخش «کاربردهای یادگیری ماشین» مورد بحث قرار گرفته است، ساده نیست، اگرچه فضای مجازی فعلی این امکان را فراهم می‌کند

برای ارائه راه‌حل‌هایی برای مسائل مختلف دنیای واقعی استفاده شود.

یک مدل یادگیری ماشین موفق به داده‌ها و عملکرد الگوریتم‌های یادگیری بستگی دارد. الگوریتم‌های یادگیری پیچیده سپس باید از طریق داده‌ها و دانش جمع‌آوری‌شده از دنیای واقعی مربوط به کاربرد هدف آموزش داده شوند تا سیستم بتواند در تصمیم‌گیری هوشمند کمک کند. ما همچنین چندین حوزه کاربردی محبوب مبتنی بر تکنیک‌های یادگیری ماشین را مورد بحث قرار دادیم تا کاربرد آنها را در مسائل مختلف دنیای واقعی برجسته کنیم. در نهایت، چالش‌های پیش رو و فرصت‌های تحقیقاتی بالقوه و مسیرهای آینده در این حوزه را خلاصه و مورد بحث قرار داده‌ایم. بنابراین، چالش‌های شناسایی‌شده، فرصت‌های تحقیقاتی امیدوارکننده‌ای را در این زمینه ایجاد می‌کنند که باید با راه‌حل‌های مؤثر در حوزه‌های کاربردی مختلف مورد توجه قرار گیرند. در مجموع، ما معتقدیم که مطالعه ما در مورد راه‌حل‌های مبتنی بر یادگیری ماشین، مسیری امیدوارکننده را باز می‌کند و می‌تواند به عنوان یک راهنمای مرجع برای تحقیقات و کاربردهای بالقوه برای متخصصان دانشگاهی و صنعتی و همچنین برای تصمیم‌گیرندگان، از دیدگاه فنی، مورد استفاده قرار گیرد.

اعلامیه

تضاد منافع نویسنده هیچگونه تضاد منافع را اعلام نمی‌کند.

منابع

اموسسه کانادایی امنیت سایبری، دانشگاه نیوبرانزویک، مجموعه داده‌های cic/datasets/index.html، [iscx. http://www.unb.ca/](http://www.unb.ca/iscx) (دسترسی در ۲۰ اکتبر ۲۰۱۹).
Cic-ddos2019 [آنلاین]. موجود در: <https://www.unb.ca/cic/datas>
<https://www.unb.ca/cic/datas> (دسترسی در ۲۸ مارس ۲۰۲۰).
۳. سازمان بهداشت جهانی: <http://www.who.int/>.
۴. روندهای گوگل. در ۲۰۱۹. <https://trends.google.com/trends/>.
۵. عدنان ن. نوردین شهرینا، دکتر رحمان آی، نور ا. تأثیرات انتقال دانش بر تصمیم‌گیری کشاورزان در مورد شیوه‌های کشاورزی پایدار، مجله جهانی فناوری علمی و فناوری پایدار، ۲۰۱۸.
۶. آگراوال آر، گرک جی، گونوپولوس دی، راگاوای پی. خوشه‌بندی خودکار زیرفضای داده‌های با ابعاد بالا برای کاربردهای داده‌کاوی. در: مجموعه مقالات کنفرانس بین‌المللی مدیریت داده‌ها ACM SIGMOD 1998، 1998: 94-105
۷. آگراوال آر، ایمیلینسکی تی، سوامی آ. کاوش قوانین وابستگی بین مجموعه اقلام در پایگاه‌های داده بزرگ. در: رکورد ۲۱۶-۲۰۷-۲۲: ۱۹۹۳. ACM SIGMOD. ACM.
۸. آگراوال آر، گرک جی، گونوپولوس دی، راگاوای پی. الگوریتم‌های سریع برای کاوش قوانین انجمنی. در: مجموعه مقالات کنفرانس مشترک بین‌المللی پایگاه‌های داده بسیار بزرگ، سانتیاگو شیلی. ۴۸۷-۴۹۹. ۱۳۱۵: ۱۹۹۳.
۹. آها دی‌دلیو، کیلر دی، آلبرت ام. الگوریتم‌های یادگیری مبتنی بر نمونه. ماخ لرن. 1991:6(1):37-66.
۱۰. آلکوس تی‌بی، تورکوگلو آ. مقایسه رویکردهای یادگیری عمیق برای پیش‌بینی عفونت کووید-۱۹. Chaos Solit Fract. 2020;140:
۱۱. آمیت وای، گمن دی. کوانتیزاسیون و تشخیص شکل با درخت‌های تصادفی. محاسبات عصبی. 88، 1997:9(7):1545-

12. Ankerst M, Breunig MM, Kriegel HP, Sander J. 12. Ankerst M, Breunig MM, Kriegel HP, Sander J. نقاط مرتب‌سازی برای شناسایی ساختار خوشه‌بندی. ACM Sigmod Record. 1999;28(2):49-60.
۱۳. آنزای وای. تشخیص الگو و یادگیری ماشین. الزویر: ۲۰۱۲. (۱۳۹).
14. اردبیلی سی.ف.، موسوی ا.، قمیسی پ.، فردیناند ف.، وارکونی-کوچی ا.ر.، روتنر یو.، رایجوک ت.، انکینسون پ.م. پیش‌بینی شیوع کووید-۱۹ با یادگیری ماشین. الگوریتم‌ها. 2020;13(10):249.
۱۵. ابالدی پی. خودرمزگذارها، یادگیری بدون نظارت و معماری‌های عمیق. در: مجموعه مقالات کارگاه ICML در مورد یادگیری بدون نظارت و انتقال، ۲۰۱۲: ۳۷-۴۹.
16. Balducci F, Impedovo D, Pirlo G. 16. Balducci F, Impedovo D, Pirlo G. کاربردهای یادگیری ماشین در مجموعه داده‌های کشاورزی برای بهبود مزرعه هوشمند. Machines. 2018;6(3):38.
۱۷. بوکرچ ای، وانگ جی. مدل‌های پیش‌بینی ترافیک مبتنی بر یادگیری ماشین برای سیستم‌های حمل و نقل هوشمند. Comput Netw. 2020;181:
۱۸. بریمن ل. پیش‌بینی‌کننده‌های کیسه‌بندی. ماخ لیر ن. 1996;24(2):123-40.
19. بریمن ل. جنگل‌های تصادفی. ماخ لرن. 2001: 45(1):5-32.
۲۰. بریمن ال، فریدمن جی، استون سی جی، اولشن آر آی. طبقه بندی و درخت‌های رگرسیون. انتشارات. ۱۹۸۴. CRC:
21. ال‌کائو ال. علم داده: یک مرور جامع. ACM Comput Surv (CSUR). 2017;50(3):43.
22. کارپنتر جی.ای.، گراسبرگ اس. یک معماری کاملاً موازی برای یک ماشین تشخیص الگوی عصبی خودسازمانده. پردازش تصویر گراف محاسباتی. 1987;37(1):54-115.
۲۳. چپو سی سی، ساینات تی ان، وو وای، پرابوالکار آر، نگوین پی، چن زد، کائان ای، وایس آر جی، راثو کی، گوینیا ای و همکاران. تشخیص گفتار پیشرفته با مدل‌های توالی به توالی. در: کنفرانس بین‌المللی IEEE در مورد آکوستیک، پردازش گفتار و سیگنال 2018. (ICASSP) صفحات ۲۴. IEEE ۴۷۷۸-۴۷۷۴ چولت اف. استننا: یادگیری عمیق با کانولوشن‌های جادش‌نی عمقی. در: مجموعه مقالات کنفرانس IEEE در مورد بنیای کامپیوتر و تشخیص الگو، صفحات ۲۰۱۷. ۱۲۵۸-۱۲۵۱ کامپیوتر و تشخیص الگو، صفحات ۲۰۱۷.
25. کوبولوگلو اچ، بوبوکاتناکین آی ای. تحلیل تصمیم‌گیری چندمعیاره تصادفی برای انتخاب محصول زیست‌فوده پایدار. Expert Syst Appl. 2015;42(15-16):6065-74.
۲۶. داس ای، ان‌جی دبلیو کی، وون وای کی، کاوش سریع قوانین وابستگی. در: مجموعه مقالات دهمین کنفرانس بین‌المللی مدیریت اطلاعات و دانش، صفحات ۲۰۰۱. ACM، ۴۷۴-۴۸۱.
۲۷. de Amorim RC. خوشه‌بندی مقید با کمپانین‌های وزنی مینکوفسکی. در: سیزدهمین سمپوزیوم بین‌المللی IEEE در مورد هوش محاسباتی و انفورماتیک (CINTI)، صفحات ۱۱۳ تا ۱۷.
۲۰۱۲. IEEE.
۲۸. دی ای کی. درک و استفاده از زمینه. شخص، فراگیر، کام-
29. دیگلن ن، پنتلند ای. اس. کاوش واقعیت: سنجش سیستم‌های اجتماعی پیچیده. 2006;10(4):255-68.
30. Person Ubiquit Comput. اسین آ، پترونیاس آی، سامپایو پی، سامپایو اس. بهبود پیش‌بینی سرعت ترافیک شهری با استفاده از ترکیب منابع داده و یادگیری عمیق. در: کنفرانس بین‌المللی IEEE در مورد کلان داده و محاسبات هوشمند (BigComp) در سال 2019. IEEE. 2019: 1-8.
۳۱. اسین آ، پترونیاس آی، سامپایو پی، سامپایو اس. یک مدل یادگیری عمیق برای پیش‌بینی جریان ترافیک شهری با رویدادهای ترافیکی استخراج‌شده از توپیت. در: وب جهان‌گستر، ۲۳-۲۴ ا-۲۰: ۱۲-۱۲ استر ام، کریگل اچپی، ساندز جی، شیائووی ایکس و همکاران. یک الگوریتم مبتنی بر چگالی برای کشف خوشه‌ها در پایگاه‌های داده مکانی بزرگ با نویز. ۳۱-۲۴: ۱۹۹۶: ۹۶: Kdd.
33. فاطمه م، پاشا م، و همکاران. بررسی الگوریتم‌های یادگیری ماشین برای تشخیص بیماری. 2017;9(01):1.
34. فلچ پی‌ای.، لاچیچه ان. کشف هدایت‌شده با تأیید قوانین مرتبه اول با ترتیوس. ماخ لرن. 2001:42(1-34):
۳۵. فروند وای، شاپیر آر ای، و همکاران. آزمایش‌هایی با یک الگوریتم تقویت جدید. در: ۱۵۶-۱۵۵: ۱۴۸-۹۶: ۱۹۹۶. IcmI. Citeseer.

داده‌ها. در: چهارمین کنفرانس بین‌المللی محاسبات، کنترل و اتوماسیون ارتباطات 6-1: IEEE. 2018: 160-161 (ICCCBEA).

۵۸. کوهنوتن. نقشه خودسازمانده. مجموعه مقالات IEEE. 1990;78(9):1464-80.

۵۹. کورنیوتس ن، مصطفی ن، سیتیکووا ای، ترنبول ب. به سوی توسعه مجموعه داده‌های واقعی‌بینانه بات‌نت در اینترنت اشیا برای تجزیه و تحلیل پزشکی قانونی شبکه: مجموعه داده‌های ربات-اینترنت اشیا. 96. Fut Gen Comput Syst. 2019;100:779-791.

۶۰. کرزفوسکی آ، سانسکور آ، هینتون جی.ای. طبقه‌بندی شبکه تصویری با شبکه‌های عصبی کانولوشن عمیق. در: پیشرفت‌ها در سیستم‌های پردازش اطلاعات عصبی، ۱۱۰۵-۱۰۹۷: ۲۰۱۲.

61. کوشوها اس، بهل اس، باگا ای کی، پارمار کی اس، جاوید ام، حلیم ای، سینگ آر پی. کاربردهای مهم یادگیری ماشین برای همه‌گیری کووید-19. مجله مدیریت یکپارچه صنایع. 2020;5(4): 2020.

62. لید پی، گوش آر، سرینیواسان اس. تجزیه و تحلیل تولید و اینترنت اشیا صنعتی. Syst. 2017;32(3):74-9.

IEEE Intell ۲۳. لاموناوما اس، حسین جی، چکچاک ال. کاربردهای یادگیری ماشین و هوش مصنوعی برای همه‌گیری کووید-۱۹ (سارس-کوو-۲): یک بررسی. Chaos Sol Fract. 2020;110059.

64. LeCessie S, Van Houwelingen JC. 1992; 41 (1): 191-201. 65. لکان وای، بوتو ال، بنگو وای، هافنر پی. یادگیری مبتنی بر گرادیان اعمال شده برای تشخیص اسناد. 324. Proc IEEE. 1998;86(11):2278-2288.

۶۶. لیو اج، موتودا اج. استخراج ویژگی، ساخت و انتخاب: دیدگاه داده‌کاوی، جلد ۴۵۳. اشپرینگر ساینس اند بیزینس مدیا؛ ۱۹۹۸.

۶۷. لویز جی، کسدا ال، گوئرو ال‌ای، الکسا در مقابل سیری در مقابل کورتانا در مقابل دستیار گوگل: مقایسه رابط‌های کاربری طبیعی مبتنی بر گفتار. در: کنفرانس بین‌المللی عوامل انسانی کاربردی و ارگونومی، اشپرینگر. ۲۰۱۷: ۲۳۱-۲۵۰.

۶۸. لیو پی، هسو دلیو، ما وای. ادغام طبقه‌بندی و کاوش قوانین انجمنی. در: مجموعه مقالات چهارمین کنفرانس بین‌المللی کشف دانش و داده‌کاوی، ۱۹۹۸.

۹۰. مک‌کولین جی و همکاران. برخی روش‌ها برای طبقه‌بندی و تحلیل مشاهدات چند متغیره. در: مجموعه مقالات پنجمین سمپوزیوم برکلی در مورد آمار و احتمال ریاضی، ۱۹۶۷: ۲۹۷-۱۲۸۱. اصفحات ۹۷. کالیفرنیا، ایالات متحده آمریکا.

70. مهدوی‌نژاد، م.س.، رضوان، م.، برکتین، م.، ادیبی، پ.، بزاقی، پ.، شت، ای.پی. یادگیری ماشینی برای تحلیل داده‌های اینترنت اشیا: یک بررسی. Digit Commun Netw. 2018;4(3):161-75.

71. مارچند ای، مارکس پی. توصیه‌های خودکار محصول با توضیحات مبتنی بر ترجیحات. مجله خرده‌فروشی. 2020; 96(3):328-43.

72. مک‌کالوم ای. استخراج اطلاعات: استخراج داده‌های ساختار یافته از متن بدون ساختار. 2005;3(9):48-57. Queue.

۷۳. مهرورتا آ، هندلی آر، موسولسی ام. پری‌فامپنز: کاوش ترجیحات کاربر برای مدیریت هوشمند اعلان‌های موبایل. در: مجموعه مقالات کنفرانس مشترک بین‌المللی محاسبات فراگیر و فراگیر، هایدلبرگ، آلمان، ۱۲ تا ۱۶ سپتامبر ۲۰۱۶: ۱۲۳۴-۱۲۳۴. ACM، ۱۲۳۴. ایالات متحده آمریکا.

74. محمودی، هالیدو، آ. کاپن پی تی. مروری بر مدل‌سازی ریاضی، هوش مصنوعی و مجموعه داده‌های مورد استفاده در مطالعه، پیش‌بینی و مدیریت کووید-19. 2020;50(11):3913-25. Appl Intell.

۷۵. محمد م، خان م ب، بشیر محمد ب. یادگیری ماشین: الگوریتم‌ها و کاربردها. انتشارات CRC؛ ۲۰۱۶.

۷۶. مصطفی ن، اسلای جی. Unsw-nb15: یک مجموعه داده جامع برای سیستم‌های تشخیص نفوذ شبکه (مجموعه داده شبکه (unsw-nb15): کنفرانس سیستم‌های ارتباطات و اطلاعات نظامی ۲۰۱۵: ۱۰۶-۱۱۰ (MILCIS). صفحات IEEE ۱۰۶.

۷۷. نیلانی م، ابراهیم اوبی، احمدی ح، شاهمرادی ل. روشی تحلیلی برای پیش‌بینی بیماری‌ها با استفاده از تکنیک‌های یادگیری ماشین. مهندس شیمی محاسباتی. ۲۰۲۰: ۲۳-۱۱۲: ۲۰۱۷.

36. فوجیوشی اج. هیراکاوا تی، یاماشینا تی. تشخیص تصویر مبتنی بر یادگیری عمیق برای رانندگی خودرو. 52. IATSS Res. 2019;43(4):244-245.

37. فوکونگا ک، هاستنر ل. تخمین گرادیان یک تابع چگالی، با کاربردهایی در تشخیص الگو. 1975;21(1):32-40. IEEE Trans Form Theory.

۳۸. گودفلو آ، بنگو وای، کورویل ای، بنگو وای. یادگیری عمیق. کمبریج: انتشارات MIT؛ ۲۰۱۶.

۳۹. گودفلو آ، پوزه-آبادی جی، میرزا ام، خو بی، وارد-فارلی دی، اوزیر اس، کورویل ای، بنگو وای. شبکه‌های تخصصی مولد. در: پیشرفت‌ها در سیستم‌های پردازش اطلاعات عصبی. 2014: 2672-2680.

40. گوئرو-ایپانیز جی، زیدالی اس، کونتراس-کاستیلو جی. فناوری‌های حسگر برای سیستم‌های حمل و نقل هوشمند. حسگرها. 2018;18(4):1212.

۴۱. هان جی، پی جی، کامبر ام. داده‌کاوی: مفاهیم و تکنیک‌ها. آمستردام: الزویر؛ ۲۰۱۱.

۴۲. هان جی، پی جی، یین وای. کاوش الگوهای پرتکرار بدون تولید کاندیدا. در: 12-1. Record, ACM. 2000;29: 1-12. ACM Sigmod

۴۳. هارمون اس. ای. سفورد تی. ای.، شنگ ایکس. ترکیبی ای. بی.، راث اج. زیوله ایکس.، پانگ دی.، میرونکو ای.، اندرسون وی.، آمالو ای. و همکاران. هوش مصنوعی برای تشخیص ذات‌الریه کووید-19 در سی‌تی‌اسکن قفسه سینه با استفاده از مجموعه داده‌های چندملیتی. 7-1. Nat Commun. 2020;11(1):1-7.

44. He K, Zhang X, Ren S, Sun J. 144. ادغام هرمی فضایی در شبکه‌های کانولوشنی عمیق برای تشخیص بصری. IEEE Trans Pat-pattern Anal Mach Intell. 2015;37(9):1904-16.

۴۵. هه کی، ژانگ ایکس، رن اس، سان جی. یادگیری عمیق باقیمانده برای تشخیص تصویر. در: مجموعه مقالات کنفرانس IEEE در مورد بینایی کامپیوتر و تشخیص الگو، ۷۷۸-۷۷۷: ۲۰۱۶.

۴۶. هینتون جی.ای. راهنمای عملی برای آموزش ماشین‌های بولتزن محدود. در: شبکه‌های عصبی: ترفندهای تجارت. اشپرینگر. ۲۰۱۲: ۵۹۹-۶۱۹.

47. Holte RC. 47. قوانین طبقه‌بندی بسیار ساده روی اکثر مجموعه داده‌های رایج عملکرد خوبی دارند. 90. Mach Learn. 1993;11(1):63-74.

48. هنلیگ اج. تحلیل مجموعه‌ای از متغیرهای آماری به مؤلفه‌های اصلی. مجله روانشناسی آموزشی. 24(6):417. 1933:

۴۹. هاتسما ام، سومای ای. کاوش مجموعه‌گرا برای قوانین انجمنی در پایگاه‌های داده رابطه‌ای. در: مهندسی داده، ۱۹۹۵: ۳۳۰-۳۲۵. IEEE.

50. جمشیدی م، لالیشخ ع، تاج، پروتکا ز، حاجیلوی ف، لالیشخ ص، جمشیدی م، لا اسپادا ل. میرمظفری م، دهقانی م، و همکاران. هوش مصنوعی و کووید-19: رویکردهای یادگیری عمیق برای تشخیص و درمان دسترسی. IEEE. 2020; 8:109581-95.

۵۱. جان جی اج، لانگلی پی. تخمین توزیع‌های پیوسته در طبقه‌بندی‌کننده‌های بیزی. در: مجموعه مقالات یازدهمین کنفرانس عدم قطعیت در هوش مصنوعی، انتشارات مورگان کافمن، ۳۳۵-۳۳۸: ۱۹۹۵.

52. Kaebbling LP, Littman ML, Moore AW. 1996; 4: 237-85. J Artif Intell Res.

۵۳. کامیل اس‌اس، گونااسکاران ای، گواناکار اس‌ای. چارچوب صنعت پایدار: یک بررسی سیستماتیک از ادبیات که روندهای فعلی و چشم‌اندازهای آینده را شناسایی می‌کند. 25-2. Environ Protect. 2018;117:408-25. Process Saf

۵۴. کامیل اس‌اس، گونااسکاران ای، گواناکار اس‌ای. دستیابی به عملکرد پایدار در زنجیره تأمین کشاورزی مبتنی بر داده: مروری برای تحقیق و کاربردها. مجله بین‌المللی محصولات اقتصادی. ۲۰۲۰: ۹۴-۱۷۹: ۲۰۲۰.

۵۵. کافمن ال، روسیو پ‌جی. یافتن گروه‌ها در داده‌ها: مقدمه‌ای بر تحلیل خوشه‌ای، جلد ۳۴۴. جان وایلی و پسران؛ ۲۰۰۹.

56. Keerthi SS, Shevade SK, Bhattacharyya C, Radha Krishna MK. بهبودهایی در الگوریتم svm. مقالات برای طراحی طبقه‌بندی‌کننده. 2001; 13(3):637-49.

۵۷. خادسه وی، محله پان، بیراریس اس‌وی. مقایسه تجربی الگوریتم‌های یادگیری ماشین تحت نظارت برای اینترنت اشیا

دیابت از طریق پرونده‌های الکترونیکی سلامت. Int J Med Inform. 2017;97:120–7.

۱۳۵. ازنگ وای، راجسگارار اس، لکی سی. پیش‌بینی در دسترس بودن پارکینگ برای پارکینگ‌های مجهز به حسگر در شهرهای هوشمند. در: حسگرهای هوشمند، شبکه‌های حسگر و پردازش اطلاعات (ISSNIP)، دهمین کنفرانس بین‌المللی IEEE در سال ۲۰۱۵، IEEE، ۲۰۱۵، صفحات ۶ تا ۶.

۱۳۶. ازو اچ، چن ای، شیونگ اچ، تیان جی. بهره‌برداری از اطلاعات زمینه‌ای غنی‌شده برای طبقه‌بندی برنامه‌های تلفن همراه. در: مجموعه مقالات بیست و یکمین کنفرانس بین‌المللی ACM در مورد مدیریت اطلاعات و دانش، ۲۰۱۲، ACM، صفحات ۱۶۱۷–۱۶۲۱.

۱۳۷. ازو اچ، چن ای، شیونگ اچ، کویفی وای، کاوش ترجیحات کاربر موبایل برای ارائه توصیه‌های شخصی‌سازی‌شده و آگاه از زمینه. Trans Intell Syst Technol (TIST). 2014;5(4):58.

۱۳۸. زیکانگ اچ، یونگ وای، گوئوفنگ وای، شینیو زی. تحلیل احساسات داده‌های بررسی تجارت الکترونیک محصولات کشاورزی مبتنی بر یادگیری عمیق. در: کنفرانس بین‌المللی اینترنت اشیا و کاربردهای هوشمند ۲۰۲۰ (ITIA)، IEEE، ۲۰۲۰، صفحات ۷ تا ۷.

۱۳۹. زولکرزین اس، مادیراجو پی، احمد اس. آی. یک سیستم مدیریت وقفه آگاه از متن برای دستگاه‌های تلفن همراه. در: میان‌افزار، سیستم‌عامل‌ها و برنامه‌های کاربردی بی‌سیم تلفن همراه، اشپرینگر، ۲۰۱۰، صفحات ۲۳۴–۲۳۱.

140. زولکرزین اس، مادیراجو پی، احمد اس، استام کی. یک سیستم مدیریت هوشمند وقفه موبایل. مجله UCS. 2010;16(15):2060–80.

یادداشت ناشر: اشپرینگر نیچر در مورد ادعاهای مربوط به صلاحیت قضایی در نقشه‌های منتشر شده و وابستگی‌های سازمانی بی‌طرف باقی می‌ماند.

۱۴۱. اوگستاف کی، کاردی سی، راجرز اس، شرودل اس، و همکاران. خوشه‌بندی k-means محدود با دانش پس‌زمینه. IcmI. 2001;1:577–84.

۱۴۲. اوگ دلیو، یانگ جی، مونتز آر و همکاران. استینگ: رویکرد شبکه اطلاعات آماری به داده‌کاوی مکانی. VLDB. ۱۹۹۷;۹۷:۱۸۶–۹۵.

۱۴۳. اوی پی، لی وای، ژانگ زد، تائو اچ، لی زد، لیو دی. یک روش بهینه‌سازی برای مدل طبقه‌بندی تشخیص نفوذ مبتنی بر شبکه باور عمیق. IEEE Access. 2019;7:87593–605.

۱۴۴. اویس ک، خوشگفتار ت.م، وانگ دد. بررسی انتقال یادگیری. مجله کلان داده. 2016؛ 3(1):9.

۱۴۵. اوبتن آی، اچ، فرانک ای. داده‌کاوی: ابزارها و تکنیک‌های کاربردی یادگیری ماشین. مورگان کافمن؛ ۲۰۰۵.

۱۴۶. اوبتن آی، اچ، فرانک ای، تریگ ال، ای، هال ام، ای، هولمز جی، کانینگهام اس. جی. وکا: ابزارها و تکنیک‌های کاربردی یادگیری ماشین با پیاده‌سازی‌های جاوا. ۱۹۹۹.

127. وو سی سی، پن-لیانگ سی، پی-هونگ ال، شیانگ-یو وای. القای درخت تصمیم با تعداد محدودی از گره‌های برگ. Appl Intell. 2016;45(3):673–85.

128. وو ایکس، کومار وی، کوینلان جی آر، گوش جی، یانگ کیو، موتودا اچ. مک‌لاکلان جی جی، ان جی ای، لیو بی، فیلیپ اس وای و همکاران. 10 الگوریتم برتر در داده‌کاوی. Inform Syst. 2008;14(1):1–37.

۱۲۹. وشین وای، کونگ ال، لیو زد، چن وای، لی وای، ژو اچ، گائو ام، هو اچ، وانگ سی. روش‌های یادگیری ماشین و یادگیری عمیق برای امنیت سایبری. IEEE Access. 2018;6:35365–81.

130. ژو دی، یینگجی تی. بررسی جامع الگوریتم‌های خوشه‌بندی. مجله علمی داده آن. 2(2): 165–93؛ 2015.

131. زکی ام. جی. الگوریتم‌های مقیاس‌پذیر برای کاوش انجمنی. Data Eng. 2000;12(3):372–90.

132. زانلا ای، بویی ان، کاستلانی ای، وانجلیستا ال، زورزی ام. اینترنت اشیا برای شهرهای هوشمند. مجله اینترنت اشیا. IEEE. 2014;1(1):22–32.

۱۳۳. ژائو کیو، بوهمیک اس. اس. کاوش قوانین انجمنی: یک بررسی. سین-گاپور: دانشگاه فنی نانیانگ؛ ۲۰۰۳.

۱۳۴. ازنگ تی، شی دلیو، شو ال، هی ایکس، ژانگ وای، یو ام، یانگ جی، چن وای. چارچوبی مبتنی بر یادگیری ماشین برای شناسایی دیابت نوع ۲