



چالش‌های یادگیری ماشین: یک بررسی انتقادی

[†] انریکو باربیراتو [†]، * و آلیس گاتی

گروه ریاضی و فیزیک، دانشگاه کاتولیک قلب مقدس، ۲۵۱۳۳ برشا، ایتالیا؛ * alice.gatti@unicatt.it مکاتبات: enrico.barbierato@unicatt.it

این نویسندگان به طور مساوی در این اثر مشارکت داشتند.[†]

چکیده: مفهوم یادگیری تعابیر متعددی دارد، از کسب دانش یا مهارت گرفته تا ساخت معنا و توسعه اجتماعی. یادگیری ماشینی (ML) شاخه‌ای از هوش مصنوعی (AI) محسوب می‌شود و الگوریتم‌هایی را توسعه می‌دهد که می‌توانند از داده‌ها یاد بگیرند و قضاوت خود را با استفاده از روش‌های آماری اولیه به مشاهدات جدید تعمیم دهند. هزاره جدید شاهد گسترش شبکه‌های عصبی مصنوعی (ANNs) بوده است، نوعی فرمالیسم که قادر به دستیابی به دستاوردهای خارق‌العاده در مسائل پیچیده‌ای مانند بینایی کامپیوتر و تشخیص زبان طبیعی است. به طور خاص، طراحان ادعا می‌کنند که این فرمالیسم شباهت زیادی به نحوه عملکرد نورون‌های بیولوژیکی دارد. این اثر استدلال می‌کند که اگرچه یادگیری ماشینی دارای پایه ریاضی/ آماری است، اما نمی‌توان آن را به طور دقیق به عنوان یک علم در نظر گرفت. حداقل از دیدگاه روش‌شناختی. دلیل اصلی این است که الگوریتم‌های یادگیری ماشینی قدرت پیش‌بینی قابل توجهی دارند، اگرچه لزوماً نمی‌توانند توضیحی علی در مورد پیش‌بینی‌های به دست آمده ارائه دهند. به عنوان مثال، یک شبکه عصبی مصنوعی می‌تواند بر روی مجموعه بزرگی از اطلاعات مالی مصرف‌کننده آموزش داده شود تا اعتبار را پیش‌بینی کند. این مدل عوامل مختلفی مانند درآمد، سابقه اعتباری، بدهی، الگوهای هزینه و موارد دیگر را در نظر می‌گیرد. سپس یک امتیاز اعتباری یا تصمیمی در مورد تأیید اعتبار ارائه می‌دهد. با این حال، ماهیت پیچیده و چندلایه شبکه عصبی، درک اینکه مدل از کدام عوامل خاص یا ترکیبی از عوامل برای رسیدن به تصمیم خود استفاده می‌کند را تقریباً غیرممکن می‌کند. این عدم شفافیت می‌تواند مشکل‌ساز باشد، به خصوص اگر مدل اعتبار را رد کند و متقاضی بخواهد دلایل خاص این رد را بداند. ماهیت «جعبه سیاه» مدل به این معنی است که نمی‌تواند توضیح یا تفکیک روشنی از نحوه سنجش عوامل مختلف در فرآیند تصمیم‌گیری خود ارائه دهد. ثانیاً، این کار این باور را که یک ماشین می‌تواند به سادگی از داده‌ها، چه در حالت نظارت شده و چه بدون نظارت، فقط با اعمال روش‌های آماری یاد بگیرد، رد می‌کند. فرآیند یادگیری بسیار پیچیده‌تر است، زیرا نیاز به درک کامل یک توانایی یا مهارت آموخته شده دارد. از این نظر، پیشرفت‌های بیشتر در یادگیری ماشین، مانند یادگیری تقویتی و یادگیری تقلیدی، نشان‌دهنده شباهت‌های دلگرم‌کننده‌ای با مهارت‌های شناختی مشابه مورد استفاده در یادگیری انسان است.



نقل قول: Barbierato, E.; Gatti, A.

چالش‌های یادگیری ماشینی:

یک بررسی انتقادی. الکترونیک ۱۳، ۲۰۲۴

۴۱۶. <https://doi.org/10.3390/electronics13020416>

ویراستار علمی: آریا

گانگوپادیای

دریافت شده: ۴ دسامبر ۲۰۲۳

بازبینی‌اشده: ۵ ژانویه ۲۰۲۴

پذیرفته شده: ۱۷ ژانویه ۲۰۲۴

منتشر شده: ۱۹ ژانویه ۲۰۲۴



حق نشر: © ۲۰۲۴ متعلق به نویسندگان.

دارنده مجوز: MDPI، باز، سوئیس.

این مقاله یک مقاله با دسترسی آزاد است

تحت شرایط و ضوابط توزیع شده است

شرایط کریتیو کامنز

مجوز انتساب (<https://creativecommons.org/licenses/by/>)

(CC BY) (<https://creativecommons.org/licenses/by/>)

۴۰۷).

کلمات کلیدی: یادگیری ماشینی؛ روش علمی؛ یادگیری تقلیدی؛ نورون‌های آینه‌ای

۱. مقدمه

مفهوم یادگیری به هیچ وجه یک تفسیر منحصر به فرد ندارد، زیرا ادبیات علمی دیدگاه‌های مختلفی را ارائه می‌دهد، از رویکردهای آموزشی گرفته تا فلسفی، حتی شامل جامعه‌شناسی یا علوم پایه. به عنوان مثال، طبق گفته بلوم [1]، یادگیری کسب دانش یا مهارت است ("یادگیری یک تغییر نسبتاً دائمی در پتانسیل رفتاری است که در نتیجه تمرین یا تجربه تقویت شده رخ می‌دهد")، در حالی که طبق گفته جاناسن [2]، یادگیری ساخت معنا است ("یادگیری فرآیندی است که افراد بر اساس تجربیات خود معانی را می‌سازند"). نویسندگانی مانند ویگوتسکی [3] یادگیری را یک پدیده اجتماعی می‌دانند که از تعاملات پویا بین فرد و محیط اطراف سرچشمه می‌گیرد. به طور مشابه، پیاژه [4] یادگیری را علاوه بر نیاز به کسب اطلاعات، به رشد اجتماعی مرتبط می‌داند. از آنجایی که این فرآیند مستلزم تبادل اجتماعی شدید است، جارویس [5] ادعا می‌کند که این امر به زمان یا مکان مربوط نمی‌شود، بلکه یک فعالیت مداوم است.

یادگیری ماشین به دنبال بهره‌برداری از الگوریتم‌های تحت نظارت یا بدون نظارت است که می‌توانند یک موضوع خاص را یاد بگیرند. وظیفه (برای مثال، طبقه‌بندی یا خوشه‌بندی) از یک مجموعه داده. تکنیک اول نیاز به یک مجموعه داده شامل مشخصات نمونه‌هایی از یک متغیر هدف تحت مطالعه دارد؛ متغیرهای باقی‌مانده، پیش‌بینی‌کننده نامیده می‌شوند. تکنیک اخیر، برای مثال، شامل موارد زیر است: خوشه‌بندی مجموعه داده‌ها، که در خروجی دو یا چند خوشه داده را برمی‌گرداند، که نقاط آنها عبارتند از بر اساس فاصله مکانی و در نهایت، بر اساس شباهت گروه‌بندی می‌شوند. موارد دیگر یادگیری بدون نظارت شامل نقشه‌های خودسازمانده (SOMs)، تحلیل مؤلفه‌های اصلی (PCA) و ... می‌شود. و غیره. یک الگوریتم آموزشی، مجموعه‌ای از مشاهدات شناخته‌شده را به عنوان ورودی دریافت می‌کند، که به زیرمجموعه‌های «آموزش» (TR) و «آزمون» (TS) تقسیم می‌شود. ۸۰٪ و ۲۰٪ مقدار اولیه) سپس الگوریتم روی TR آموزش داده می‌شود تا زمانی که بتواند با دقت قابل قبولی به وظیفه خود عمل کند. عملکرد. در مرحله دوم، توانایی پیش‌بینی الگوریتم در برابر ... آزمایش می‌شود. مجموعه داده «آزمایشی». محققان یادگیری ماشین ادعا می‌کنند که یک الگوریتم زمانی یک وظیفه را یاد گرفته است که می‌تواند قضاوت خود را هنگام بررسی مشاهدات جدیدی که بخشی از آن نبوده‌اند، تعمیم دهد. مجموعه داده اصلی. به طور رسمی‌تر، تعیین اینکه آیا یک مدل یادگیری ماشینی «یاد گرفته» است یا خیر بستگی به زمینه خاص و اهداف مدل دارد. با این حال، برخی معیارهای کلی می‌تواند برای ارزیابی اینکه آیا یک مدل با موفقیت یاد گرفته است، مطابق جدول 1 در نظر گرفته شود.

جدول 1. معیارهای یادگیری مدل یادگیری ماشین.

معیار	توضیحات
دقت	این مدل باید بتواند پیش‌بینی‌ها یا طبقه‌بندی‌های دقیقی روی داده‌های دیده نشده انجام دهد. این بدان معناست که مدل باید فراتر از داده‌های آموزشی که در معرض آن قرار گرفته است، تعمیم یابد.
تعمیم‌پذیری	مدل نباید بیش از حد به داده‌های آموزشی وابسته باشد و باید بتواند روی داده‌های ... عملکرد خوبی داشته باشد. منابع مختلف یا با توزیع‌های متفاوت.
استحکام	مدل باید در برابر نویز و داده‌های پرت مقاوم باشد و به راحتی توسط الگوریتم‌های متخاصم فریب نخورد. مثال‌ها
تفسیرپذیری	این مدل باید قابل فهم و توضیح باشد و به ما اجازه دهد بفهمیم که چگونه تصمیمات خود را می‌گیرد و شناسایی سوگیری‌ها یا محدودیت‌های بالقوه.
کارایی	این مدل باید بتواند آموزش ببیند و پیش‌بینی‌های کارآمدی انجام دهد، به خصوص برای مجموعه داده‌های بزرگ یا پیچیده.
ارتباط	این مدل باید با وظیفه مورد نظر مرتبط باشد و به مشکل یا سوال خاص مطرح شده بپردازد.
تازگی	این مدل باید بینش‌ها یا راه‌حل‌های جدیدی ارائه دهد که قبلاً شناخته شده یا در دسترس نبوده‌اند.
تأثیر	این مدل باید تأثیر مثبتی بر دنیای واقعی داشته باشد، چه با حل یک مشکل، چه با بهبود یک فرآیند، یا در حال تصمیم‌گیری.
مقیاس‌پذیری	توانایی مدل در حفظ عملکرد با افزایش اندازه مجموعه داده‌ها.
انصاف	اطمینان از اینکه این مدل، تعصب ناعادلانه علیه گروه‌های خاص ایجاد یا تقویت نمی‌کند.
	قابلیت استقلال برای اتکال یا یادگیری از داده‌های آموزشی که به‌طور کلی در دسترس نیستند یا می‌توانند با مدل و خروجی‌های آن تعامل داشته باشند.
	پایبندی به استانداردهای قانونی و اخلاقی، به ویژه در حوزه‌های حساسی مانند مراقبت‌های بهداشتی یا مالی.
	ارزیابی تأثیر زیست‌محیطی آموزش و استقرار مدل، مانند مصرف انرژی.
	اطمینان از اینکه مدل در برابر حملات مقاوم است و داده‌های حساس را افشا نمی‌کند.

تکرارپذیری، توانایی سایر محققان یا متخصصان برای بازآفرینی مدل و دستیابی به نتایج مشابه.

شبکه‌های عصبی مصنوعی (ANNs) در چند دهه اخیر به طور گسترده مورد استفاده قرار گرفته‌اند طیف گسترده‌ای از کاربردها، به ویژه در زمینه‌های بینایی کامپیوتر، زبان طبیعی پردازش و رباتیک (به [6-8]مراجعه کنید) معماری اصلی - ANN حداقل در نسخه اولیه طرح پیشنهادی - [9] تا حدودی مبتنی بر نحوه عملکرد نورون‌های بیولوژیکی است. پس از انجام برخی مراحل اولیه مشکلات در شبیه‌سازی عملکرد XOR بولی، [10] شبکه‌های عصبی مصنوعی (برای مثال، به [11]مراجعه کنید) مسیر تاریخی) به فرمالیسم‌های پیشرفته‌تری مانند کانولوشن تکامل یافته‌اند شبکه‌های عصبی (CNN) مورد دوم معمولاً در زمینه بینایی کامپیوتر به کار می‌رود، برای مثال، برای تشخیص نمادهای دست‌نویس. مدل‌های ارتباطی پیشرفته‌تر به ... اشاره دارند. به حافظه بلند مدت-کوتاه مدت (LSTM) که با توانایی به خاطر سپردن تقویت می‌شوند

توالی ورودی‌هایشان. در نتیجه، آنها با حفظ متن یک جمله یا حتی پیش‌بینی سری‌های زمانی و پیش‌بینی الگوهای داده، در تشخیص متن نوشتاری انسان [12] موفق بودند (به [13] مراجعه کنید).

این مقاله ادعاهای زیر را ارائه می‌دهد: • بحث در مورد ماهیت نوآورانه تکنیک‌های یادگیری ماشین باید با احتیاط در نظر گرفته شود، زیرا برخی از تکنیک‌های به کار گرفته شده نسبتاً قدیمی هستند و معمولاً از حوزه آمار سرچشمه می‌گیرند.


• بحث در مورد اینکه یادگیری ماشینی به عنوان علم در نظر گرفته می‌شود، کاملاً درست نیست، زیرا برخی از مهم‌ترین مدل‌های یادگیری ماشینی (یعنی شبکه‌های عصبی مصنوعی) فاقد قابلیت‌های توضیحی هستند، اگرچه قدرت پیش‌بینی قدرتمندی را حفظ می‌کنند؛ • اصطلاح «یادگیری ماشینی» این مفهوم را بیش از حد بزرگ می‌کند. اگرچه مدل‌های یادگیری ماشینی برای انجام وظایف خاص آموزش دیده‌اند، اما هیچ مدرکی وجود ندارد که نشان دهد مدل نوعی درک از پدیده مورد مطالعه دارد. این با جوهره خود یادگیری در تضاد است، زیرا انسان‌ها معمولاً با ایجاد درک جزئی یا حتی کامل از مهارت موجود، انجام یک کار را یاد می‌گیرند. به طور کلی درست نیست که دانش ارائه شده توسط یک مدل یادگیری ماشینی مؤثر باشد، زیرا داده‌های مورد استفاده برای آموزش مدل ممکن است نامتعادل، جانبدارانه یا ناکافی باشند تا به مدل اجازه دهند آنچه را که آموخته است تعمیم دهد.

•

• از سوی دیگر، تکنیک‌های نوآورانه یادگیری ماشین، مانند یادگیری تقویتی (RL) یا حتی یادگیری تقلیدی (IL) شباهت‌هایی با روش‌های یادگیری مورد استفاده توسط انسان در علوم شناختی دارند.

مخاطب این اثر، محققان یادگیری ماشین و مهندسان کامپیوتر هستند. با این حال، هسته اصلی بحث برای فیلسوفان علم و محققان معرفت‌شناسی اهمیت ویژه‌ای دارد. به طور خاص، این مقاله با هدف کمک به گفتگوی جاری در مورد مبانی معرفت‌شناختی و جایگاه علمی یادگیری ماشین، به بررسی انتقادی مبانی اصلی، محدودیت‌ها و دیدگاه‌های فعلی آن می‌پردازد.

این مقاله به شرح زیر سازماندهی شده است. بخش ۲ مهم‌ترین مدل‌های ارتباطی یادگیری ماشین را فرموله می‌کند. بخش ۳ جایگاه معرفت‌شناختی یادگیری ماشین را بررسی می‌کند و تحلیلی از کاستی‌های آن ارائه می‌دهد. بخش ۴ به بررسی کارهای مرتبط می‌پردازد. در نهایت، بخش ۵ این کار را نتیجه‌گیری می‌کند و برخی از خطوط کارهای آینده را پیشنهاد می‌دهد. شکل ۱ نمایش بصری از ساختار کار را ارائه می‌دهد.




شکل ۱. نمایش بصری ساختار اثر.

۲. پارادایم‌های یادگیری ماشین این بخش مهم‌ترین پارادایم‌های مرتبط با فرآیند یادگیری در هوش مصنوعی را فرموله می‌کند.

تکامل مداوم حوزه یادگیری ماشین منجر به معرفی الگوها و روش‌های مستقل دیگری شده است. در طیف یادگیری ماشین، یادگیری تقلیدی (IL)، یادگیری تقویتی (RL)، یادگیری نظارت‌شده (SL)، یادگیری بدون نظارت (UL)

و یادگیری نیمه‌نظارتی (SSL) به عنوان حوزه‌های محوری تحقیق برجسته هستند. آنها ویژگی مشترکی در توانمندسازی ماشین برای یادگیری از طریق یک مدل دارند، اما در نحوه انجام عملیات یادگیری متفاوت هستند. فراتر از این تعاریف اساسی، چشم‌انداز تحقیقات هوش مصنوعی شامل مجموعه‌ای غنی از روش‌شناسی‌ها مانند یادگیری خودنظارتی، یادگیری فعال، یادگیری انتقالی، یادگیری از راه دور، یادگیری جمعی، یادگیری بیزی، یادگیری ساختاریافته، یادگیری سلسله‌مراتبی، یادگیری ویژگی، یادگیری متریک و یادگیری مداوم است. هر یک از این پارادایم‌ها سهم متمایزی در هدف کلی توانمندسازی سیستم‌های محاسباتی برای استخراج بینش، تصمیم‌گیری و سازگاری با سناریوهای متنوع دارند. شکل ۲ رابطه بین هوش مصنوعی، یادگیری ماشینی و پارادایم‌های اصلی پیشرفته یادگیری ماشینی را که در این مقاله مورد تجزیه و تحلیل قرار گرفته‌اند، نشان می‌دهد.



شکل ۲. رابطه بین هوش مصنوعی، یادگیری ماشینی و الگوهای اصلی یادگیری ماشینی پیشرفته.


۲.۱. یادگیری تقلیدی یادگیری تقلیدی (IL) شامل یک یادگیرنده است که با بازتولید رفتار مشاهده شده در محیط، پاسخ‌ها را تولید می‌کند. ژنگ و همکاران [14] طبقه‌بندی کاربردها و چالش‌ها را پیشنهاد می‌کنند. مدل استاندارد IL شامل تعامل بین عناصر اصلی زیر است: یک عامل، محیط، یک معلم و یک سیاست. عامل (یعنی یادگیرنده) اطلاعاتی را برای آموزش خود به دست می‌آورد. این مدل از دو روش اصلی برای یادگیری یک سیاست در مورد اقدامات آینده خود استفاده می‌کند: (i) یادگیری از یک معلم از طریق نمایش یا (ii) یادگیری از تجربه (استفاده از یک عامل پاداش یا جریمه برای ارزیابی پیشرفت آن).

صرف نظر از روش یادگیری، عامل باید هم نمایش و هم محیط را مشاهده کند تا دانش لازم برای فرآیند تصمیم‌گیری بعدی خود را کسب کند. یادگیرنده IL اغلب از چندین مؤلفه مکانی تشکیل شده است و بنابراین، داده‌های آن شامل مختصات هر دو مؤلفه و اتصالات آنها است که به طور بالقوه شامل محدودیت‌های مکانی نیز می‌شود. محیط شامل مجموعه‌ای متناهی و گسسته از حالت‌های تصادفی، $S = \{s_1, s_2, \dots, s_n\}$ است که در آن هر حالت نشان دهنده وضعیت عامل (موقعیت در محیط، اطلاعات اتصالات آن و وضعیت یک هدف) است. عامل با مجموعه‌ای گسسته از اقدامات موجود $\{a_1, a_2, \dots, a_n\}$ مشخص می‌شود و برای دستیابی به یک هدف مشخص، در محیط تعامل می‌کند. هدف فرآیند یادگیری، توسعه یک سیاست صحیح است. مورد دوم با نگاشت بین حالت s و اقدام a برای دستیابی به یک هدف (یعنی رفتار مطلوب یا خروجی صحیح) نشان داده می‌شود. عامل از این سیاست برای تصمیم‌گیری در مورد اینکه پس از وارد کردن حالت واقعی s_i محیط، باید کدام اقدام a_i را انجام دهد، استفاده می‌کند. یادگیری از طریق نمایش معلم با یک جفت (s_i, d_{a_i}) کار می‌کند، که در آن حالت s_i برداری از ویژگی‌ها در آن لحظه است و عمل d_{a_i} عمل انجام شده توسط نمایش دهنده (یعنی معلم) است.

یادگیری از طریق تجربه با یک پاداش (یا جریمه، در صورت منفی بودن) پس از انجام عمل a_i کار می‌کند. این یادگیری با یک تاپل (s_i, a_i, r_i, s_{i+1}) از حالت ورودی s_i عمل انجام شده a_i پاداش اعطا شده r_i برای ارزیابی تصمیم و حالت جدید s_{i+1} از محیط کار می‌کند.

تفاوت اصلی بین دو نوع یادگیری، گنجاندن یک معلم یا یک پاداش در مدل است. در هر دو مورد، فرآیند یادگیری شامل ثبت الگوها و روابط درون داده‌ها است که به عامل اجازه می‌دهد در سناریوهای مشابه آینده تصمیمات آگاهانه‌ای بگیرد. گنجاندن یک معلم، راهنمایی صریح ارائه می‌دهد، در حالی که پاداش...

یادگیری مبتنی بر یادگیری ماشینی (IL) بر بازخوردهای تبعی از محیط متکی است و بر سازگاری و استقلال عامل در اصلاح قابلیت‌های تصمیم‌گیری خود تأکید دارد. عمل خروجی، برداری از بخش‌هایی از عامل است که باید برای تغییر وضعیت محیط مطابق با سیاست تصمیم‌گیری آموخته‌شده، جایجا شود. شکل ۳ شمایی از تنظیمات مدل IL را نشان می‌دهد. یادگیرنده (یعنی عامل) توسط محیط احاطه شده است و از اطلاعات ارائه شده از نمایش‌دهنده (یعنی معلم) و وضعیت s_i از محیط به عنوان ورودی، برای خروجی یک عمل a_i استفاده می‌کند. سپس این فرآیند تکرار می‌شود. تاکاپوکی و همکارانش [15] مشاهده می‌کنند که معلم اغلب انسان است، که IL را به بهترین انتخاب برای انتقال دانش از انسان‌ها به ربات‌ها تبدیل می‌کند. IL در سیستم‌های کنترل خودکار به طور بهینه عمل می‌کند و مسائل با ابعاد بالا به طور کارآمد حل می‌شوند. همانطور که حسین و همکارانش [16] بیان کرده‌اند، یکی از کاربردهای برجسته IL شامل آموزش ربات‌هایی است که اقدامات مختلفی مانند رانندگی وسایل نقلیه را انجام می‌دهند. در این زمینه، یک ربات از چندین مفصل متحرک تشکیل شده است و بردار حالت s_i مشخصات آنها را قبل از اجرای هر عملی در بر می‌گیرد. برداری که نشان دهنده تغییر حالت بعدی است، s_{i+1} ، مشخصات جدید این مفاصل را پس از انجام اعمال در بر می‌گیرد. علاوه بر این، نویسندگان تأکید می‌کنند که علیرغم اینکه IL در سناریوهایی که سایر الگوهای ML با چالش مواجه می‌شوند، عملکرد برتر نشان می‌دهد، اما بدون محدودیت نیست. به عنوان مثال، (i) نتایج با عملکرد بالا محدود به محیط‌های خاص وظیفه هستند؛ (ii) اثربخشی به شدت به کیفیت نمونه‌های ارائه شده وابسته است؛ (iii) راه‌حل‌های بهینه محلی بیشتر از راه‌حل‌های بهینه جهانی حاصل می‌شوند؛ (iv) مسائل مربوط به نمایش سیاست، جریمه‌هایی را هم بر کارایی داده و هم بر کارایی محاسباتی تحمیل می‌کنند.




شکل ۳. چارچوب یادگیری تقلیدی: نمایش بصری فرآیند IL.

۲.۲. یادگیری تقویتی یادگیری تقویتی (RL) شامل یک یادگیرنده است که باید کشف کند کدام اقدامات (یا گروه‌های بعدی اقدامات) را برای رسیدن به هدف به حداکثر رساندن پاداش عددی تعیین شده انجام دهد. RL با جستجوی آزمون و خطا و مراحل پاداش تأخیری مشخص می‌شود.

مدل استاندارد یادگیری تقویتی شامل تعامل بین یک عامل، محیط، یک سیاست، یک پاداش و یک تابع ارزش است. محیط شامل مجموعه‌ای متناهی و گسسته از حالت‌های تصادفی، $S = \{s_1, \dots, s_n\}$ است. علاوه بر این، عامل با مجموعه‌ای گسسته از اقدامات موجود، $A = \{a_1, \dots, a_n\}$ نشان داده می‌شود. عامل، یادگیرنده است، زیرا از طریق تصمیم خود در مورد اینکه در هر مرحله کدام عمل را انجام دهد، هدف مشخصی را دنبال می‌کند. عامل و محیط به هم متصل هستند، زیرا عامل در محیط قرار دارد و با آن تعامل می‌کند (با تغییر حالت خود). عامل، حالت فعلی s_i محیط را به عنوان ورودی دریافت می‌کند. بسته به عملی که می‌تواند بالاترین پاداش r_i را بازگرداند، عامل بر اساس آن رفتار می‌کند و یک خروجی (یعنی عمل a_i) تولید می‌کند. وضعیت آینده محیط به حالت فعلی داده شده و عمل انتخاب شده بستگی دارد. پاداش r_i به عنوان سیگنالی از محیط به عامل پس از هر تعامل عمل می‌کند و کوشش‌دهنده خوبی عمل انجام شده در یک حالت خاص است. در یادگیری تقویتی، کانبلینگ و همکارانش [17] الگوریتم‌ها را تحلیل

برای جستجوهای سیستماتیک آزمون و خطا برای کشف ترکیب‌های موفق از اقداماتی که پاداش تجمعی را به حداکثر می‌رسانند (یعنی، میزان مورد انتظار تقویت را به حداکثر می‌رسانند). تابع ارزش، که با $V(s)$ نشان داده می‌شود، پاداش تجمعی مورد انتظار را از یک حالت معین s به بعد نشان می‌دهد. هدف عامل، به حداکثر رساندن این پاداش تجمعی مورد انتظار با انتخاب اقداماتی است که منجر به مقادیر بالاتر تابع ارزش می‌شوند. خوبی عملکرد مدل را می‌توان بر اساس مقادیر نهایی تابع ارزش در حالت‌های مختلف ارزیابی کرد. شکل ۴ شمایی از تنظیمات مدل یادگیری تقویتی (RL) را نشان می‌دهد. یادگیرنده (یعنی عامل) توسط محیط احاطه شده است و از حالت s_i و پاداش r_i خود به عنوان ورودی برای خروجی یک عمل a_i استفاده می‌کند. سپس این فرآیند تکرار می‌شود. با وجود نقش حیاتی یادگیری تقویتی در کاربردهای مختلف، دارای برخی اشکالات عمده است که بر عملکرد آن تأثیر منفی می‌گذارد.


کاسپر و همکارانش [18] مسئله بازخورد انسانی ورودی را بررسی می‌کنند و اظهار می‌دارند که چالش‌هایی در مورد بازخورد انسانی، مدل پاداش و سیاست وجود دارد. انسان‌ها نمی‌توانند وظایف دشوار را به خوبی ارزیابی کنند و به راحتی گمراه می‌شوند. تابع پاداش نمی‌تواند بدون ایجاد سوگیری، انسان‌های مختلف از جوامع مختلف را به طور منحصر به فرد نشان دهد. در نهایت، یک سیاست به درستی توسعه یافته می‌تواند هدف اشتباهی را دنبال کند، زمانی که هدف واقعی در واقعیت با عوامل دیگر مرتبط است. لی [19] یک طبقه‌بندی گسترده ارائه می‌دهد که کاربردهای متنوع یادگیری تقویتی (RL) را در سناریوهای دنیای واقعی تشریح می‌کند. به طور خاص، دوورشاک و همکارانش [20] رابطه بین یادگیری تقویتی و اتوماسیون طراحی را بررسی می‌کنند و نتیجه می‌گیرند که امکان‌سنجی، تلاش آموزشی و قابلیت انتقال یادگیری تقویتی نتایج دلگرم‌کننده‌ای را نشان می‌دهد.



شکل ۴. چارچوب یادگیری تقویتی: نمایش بصری از فرآیند یادگیری تقویتی.

۳.۲. یادگیری نظارت‌شده یادگیری نظارت‌شده (SL) یک الگوی یادگیری ماشینی است که در آن الگوریتم با یک مجموعه داده برچسب‌گذاری‌شده وارد می‌شود. یکی از ویژگی‌های بارز این روش، ارائه مشاهدات و خروجی‌های مطلوب مربوط به یادگیرنده است. مدل بر روی جفت‌های ورودی-خروجی، که با (x_i, y_i) نشان داده می‌شوند، آموزش داده می‌شود، که در آن x_i ورودی و y_i خروجی مطلوب مربوطه است. هدف اصلی یادگیری نظارت‌شده، ایجاد نداشت بین ورودی و خروجی است که پیش‌بینی دقیق داده‌های دیده نشده در آینده را امکان‌پذیر می‌کند. این الگوریتم دقت پیش‌بینی خود را با استفاده از یک تابع زیان ارزیابی می‌کند و اختلاف بین نتایج پیش‌بینی‌شده و برچسب‌های واقعی را کمی‌سازی می‌کند. تابع زیان $L(\hat{y}, y)$ نشان‌دهنده میزان انحراف مدل از مقادیر واقعی است، که در آن $\hat{y}$ نشان‌دهنده خروجی پیش‌بینی‌شده و y نشان‌دهنده برچسب واقعی است. فرآیند یادگیری شامل تنظیم مکرر پارامترهای الگوریتم برای به حداقل رساندن اختلاف بین پیش‌بینی‌های آن و برچسب‌های واقعی است. وقتی خطا، که توسط تابع زیان کمی‌سازی می‌شود، به آستانه قابل قبولی برسد، مدل به اندازه کافی آموزش دیده تلقی می‌شود و بنابراین قادر به تعمیم و پیش‌بینی دقیق نتایج برای نمونه‌های داده جدید و دیده نشده است. شکل ۵ شمایی از تنظیمات مدل SL را نشان می‌دهد. یادگیرنده داده x_i را به عنوان ورودی دریافت می‌کند و خروجی $\hat{y}_i$ را تولید می‌کند. خروجی از طریق محاسبه تابع زیان با مقدار واقعی y_i مقایسه می‌شود.

$(y_i, \hat{y}_i)$ اسپس این فرآیند تکرار می‌شود. همانطور که [21] y_i نشان می‌دهد، SL در وظایف طبقه‌بندی عملکرد فوق‌العاده‌ای دارد. SL به ویژه برای وظیفه آموزش NNAها مناسب است، زیرا آنها به دانش بازیابی شده از داده‌های ورودی (یعنی به مقادیر واقعی موجود خروجی‌ها) بسیار وابسته هستند. [22] Mehlig وظایف طبقه‌بندی حل شده از طریق NNAهای آموزش دیده با استفاده از مجموعه داده‌های برجسب‌گذاری شده وارد شده به SL را بررسی می‌کند. فرآیند یادگیری پرسپترون شامل تنظیم وزن‌ها و بایاس‌های مدل بر اساس تابع زیان است. خروجی یک پرسپترون که در آن مشاهدات و وزن‌ها وارد می‌شوند از طریق یک تابع فعال‌سازی تولید می‌شود. در نتیجه، فرآیند یادگیری شامل تنظیم وزن‌ها و بایاس‌های پرسپترون‌ها برای به حداقل رساندن مقدار تابع زیان است. همانطور که توسط Liu و همکاران [23] برجسته شده است، موفقیت SL در حوزه‌های متنوعی از جمله بازیابی اطلاعات، داده‌کاوی، بینایی کامپیوتر، تشخیص گفتار، بیوانفورماتیک، شیمی‌انفورماتیک و تجزیه و تحلیل بازار گسترش می‌یابد. با این حال، نویسندگان هشدار می‌دهند که دستیابی به خطای آموزش کم، لزوماً عملکرد بهینه را در طول آزمایش تضمین نمی‌کند، زیرا به طور حتم به تعمیم‌پذیری نیاز است و هدف آن جلوگیری از کم‌پرازش و بیش‌پرازش است. یکی از محدودیت‌های اصلی، نیاز آن به داده‌های برجسب‌گذاری شده در طول مرحله ورودی است که مستلزم جفت ورودی‌ها و خروجی‌های متناظر برای آموزش مدل است. برای کاهش این محدودیت، یادگیری نیمه‌نظارتی (SSL) و یادگیری بدون نظارت (UL) گزینه‌هایی را ارائه می‌دهند که به ترتیب به برجسب‌های خروجی کمتر یا بدون برجسب به عنوان ورودی برای آموزش نیاز دارند.



شکل ۵. چارچوب یادگیری نظارت‌اشده: نمایش بصری فرآیند یادگیری ماشینی (SL).

۲.۴. یادگیری بدون نظارت یادگیری بدون نظارت (UL) فرض می‌کند که یادگیری از طریق داده‌های بدون دسته‌بندی وارد شده به یک الگوریتم رخ می‌دهد. الگوی بدون نظارت با یافتن الگوها، روابط، گروه‌بندی و ساختارها در داده‌های ورودی بدون هیچ راهنمایی کار می‌کند.

بنابراین، داده‌های ورودی $X = \{x_1, x_2, \dots, x_n\}$ هستند و الگوریتم باید به طور مستقل نمایش‌های معنادار (یعنی الگوها یا روابط پنهان) را در داده‌ها شناسایی کند.

نعیم و همکارانش [24] توضیح می‌دهند که UL ماشین‌ها را هوشمندتر می‌کند، زیرا آنها را قادر می‌سازد تا با استفاده از مدل‌هایی که روندها و الگوها را تشخیص می‌دهند و بر اساس آنها تصمیم‌گیری می‌کنند، به طور مستقل یاد بگیرند. کاربردهای قابل توجه UL مربوط به خوشه‌بندی و کاهش ابعاد است.

خوشه‌بندی یک مجموعه داده به معنای تقسیم داده‌ها به خوشه‌ها (یعنی گروه‌ها) است به طوری که نمونه‌های مشابه x_i گروه‌بندی شوند. در یک مدل خوشه‌بندی، $C = \{c_1, c_2, \dots, c_k\}$ نشان‌دهنده مجموعه خوشه‌ها است که در آن هر زیرمجموعه‌ای از X است. هدف این الگوریتم به حداقل رساندن یک تابع هدف است که اغلب شامل واریانس درون خوشه‌ای یا معیاری از شباهت است. از نظر ریاضی، به صورت زیر بیان می‌شود


$$D(x, \mu_i) = \sum_{i=1}^k x_i^2 D(x, \mu_i) \quad (1)$$

در $D(x, \mu_i)$ یغیاریغاصخوشه‌ای است. μ_i مرکز ابعاد، هدف نمایش داده‌ها در فضایی با ابعاد کمتر و در عین حال حفظ ویژگی‌های اساسی آن است. هدف، یافتن یک تابع نگاشت است.

که خطای بازسازی (یعنی عدم تشابه بین نقاط داده اصلی و نسخه‌های جدید آنها) را به حداقل می‌رساند.

$$\sum_{i=1}^n \|x_i - f(x_i)\|^2 \quad (2)$$

شکل 6 شمایی از تنظیمات مدل UL را نشان می‌دهد. یادگیرنده داده‌های x_i را به عنوان ورودی دریافت می‌کند و یک خروجی C (به عنوان مثال، خوشه‌ها) تولید می‌کند که معیار ارزیابی طراحی شده را برآورده می‌کند. یکی از مزایای قابل توجه استفاده از الگوریتم‌های UL مناسب بودن ذاتی آنها برای مدیریت داده‌های بدون ساختار است. بسیاری از الگوریتم‌های UL به طور خاص برای پیمایش و استخراج الگوهای معنادار از مجموعه داده‌هایی که فاقد برچسب‌های از پیش تعریف شده یا ساختارهای سازمان‌یافته هستند، طراحی شده‌اند. این سازگاری، UL را به ویژه در سناریوهایی که داده‌ها سازماندهی نشده‌اند، مؤثر می‌کند و به این الگوریتم‌ها اجازه می‌دهد تا ساختارها، روابط یا خوشه‌های اساسی را بدون نیاز به نظارت صریح تشخیص دهند.




شکل 6. چارچوب یادگیری بدون نظارت: نمایش بصری فرآیند UL.

۲.۵. یادگیری نیمه‌نظارتی

یادگیری نیمه‌نظارتی (SSL) یک شکل ترکیبی است که UL و SL را با هم ترکیب می‌کند، زیرا داده‌های ورودی ترکیبی از زوج‌های فقط ورودی و ورودی-خروجی هستند. در شرایطی توصیه می‌شود که SL مورد نیاز است، اما به دست آوردن یک مجموعه داده کامل امکان‌پذیر نیست (برای مثال، برای مسائل پرهزینه). باز هم، هدف یادگیری الگویی برای طبقه‌بندی داده‌های موجود در آینده است. علاوه بر داده‌های بدون برچسب $X = \{x_1, x_2, \dots, x_n\}$ ، هدف یادگیری الگویی برای طبقه‌بندی داده‌های موجود در آینده است. $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ارائه می‌شود. برخی اطلاعات نظارتی (یعنی داده‌های برچسب‌گذاری شده) [25] X-Chapelle اهمیت SSL را تأکید می‌کنند که این امر برای یادگیری از داده‌های بدون برچسب و داده‌های برچسب‌گذاری شده استفاده برای افزایش قابل توجه دقت پیش‌بینی، به مقدار زیادی داده ورودی نیاز است. در عوض، یک مزیت این است که وجود داده‌های بدون برچسب به بهبود تعمیم‌پذیری و عملکرد مدل کمک می‌کند. شکل 7 شمایی از تنظیمات مدل SSL را نشان می‌دهد. یادگیرنده داده x_i را به عنوان ورودی دریافت می‌کند و خروجی $\hat{y}_i$ را تولید می‌کند. خروجی از طریق محاسبه تابع زیان $L(y_i, \hat{y}_i)$ با مقدار واقعی y_i (در صورت وجود) مقایسه می‌شود. سپس این فرآیند تکرار می‌شود. توجه داشته باشید که خط حقیقت پایه نقطه‌چین است، زیرا اکثر مشاهدات با خروجی مورد انتظار خود وارد نمی‌شوند.

۲.۶. مقایسه الگوهای پیشنهادی یادگیری ماشین

الگوهای یادگیری ماشینی مورد بررسی، اگرچه تفاوت‌های عمده‌ای نیز دارند، اما برخی ویژگی‌های مشترک را نیز به اشتراک می‌گذارند.



شکل 7. چارچوب یادگیری نیمه‌نظارتی: نمایش بصری از فرآیند SSL.

در یادگیری تقویتی (RL) تمرکز بر آموزش یک عامل برای تصمیم‌گیری در یک محیط معین است. عامل با انجام اقدامات و دریافت پاداش یا جریمه یاد می‌گیرد و از این طریق یک استراتژی یا سیاست برای به حداکثر رساندن پاداش‌های تجمعی در طول زمان تدوین می‌کند. این روش به ویژه در سناریوهایی که نیاز به تعادل بین اکتشاف و بهره‌برداری دارند، مانند بازی‌های درون بازی (مانند شطرنج یا گو)، نوبری وسایل نقلیه خودران، مؤثر است. رباتیک و سیستم‌های توصیه‌گر. یادگیری تقویتی به داده‌های برچسب‌گذاری‌شده نیاز ندارد؛ در عوض، به ... متکی است. بر اساس بازخورد پاداش از محیط. از سوی دیگر، SL بر یادگیری تابعی متمرکز است که ورودی‌ها را به خروجی‌ها نگاشت می‌کند. این رویکرد برای کارهایی مانند تصویرسازی مناسب است.

و تشخیص گفتار، پیش‌بینی آب و هوا و تشخیص پزشکی، که در آن هدف این است که خروجی را برای یک ورودی جدید بر اساس تابع آموخته شده پیش‌بینی کنید. اثربخشی SL تا حد زیادی به کمیت و کیفیت داده‌های برچسب‌گذاری‌شده موجود برای آموزش بستگی دارد. UL با تمرکز بر شناسایی الگوها یا ساختارها در داده‌های بدون برچسب، از این الگوها فاصله می‌گیرد. داده‌ها، بدون برچسب‌های نتیجه صریح برای هدایت فرآیند یادگیری، الگوریتم‌های UL به دنبال ... هستند.

داده‌ها را به روشی معنادار سازماندهی کنید. این شکل از یادگیری در موارد مختلفی مفید است. کاربردها، از جمله تحلیل سبد بازار، توالی‌یابی ژن، تحلیل شبکه‌های اجتماعی، و سازماندهی کتابخانه‌های اسناد گسترده، که در آن الگوهای اساسی درون داده‌ها باید شناسایی شوند. SSL تعادلی بین نظارت‌شده و نظارت‌نشده برقرار می‌کند. یادگیری. این امر به ویژه زمانی مفید است که مقدار محدودی از داده‌های برچسب‌گذاری شده افزوده شده وجود داشته باشد با مقدار بیشتری از داده‌های بدون برچسب. با ترکیب عناصر SL و SSL، UL می‌تواند دقت یادگیری را بهبود بخشد. این رویکرد اغلب در سناریوهایی مانند وب پیاده‌سازی می‌شود.

طبقه‌بندی محتوا، ترجمه زبان و تحلیل گفتار، که در آن به دست آوردن حجم زیادی مجموعه داده‌های برچسب‌گذاری شده می‌تواند چالش‌برانگیز یا بسیار پرهزینه باشد. جدول 2 مقایسه‌ای بین UL، IL، RL و SL را گزارش می‌دهد. این جدول به صراحت بیان نمی‌کند داده‌های مربوط به SSL را نشان می‌دهد، زیرا ترکیبی از UL و SL است.

۲.۷ مدل‌های زبان بزرگ

ظهور و تکامل مدل‌های زبانی بزرگ (LLM) مانند GPT-3 در یادگیری ماشین پیشرفته، نشان‌دهنده یک تغییر الگو در درک زبان طبیعی است. و تولید. این مدل‌ها که بر روی پیکره‌های گسترده‌ای از داده‌های متنی آموزش دیده‌اند، نشان می‌دهند توانایی بی‌سابقه‌ای در پردازش و تولید زبان انسانی. این قابلیت پیامدهای گسترده‌ای در حوزه‌های مختلف [26, 27] از نظر درک زبان، MLL معیارهای جدیدی را در وظایفی مانند تحلیل احساسات، طبقه‌بندی موضوع،

و تفسیر متنی. معماری‌های یادگیری عمیق (DL) آنها را قادر می‌سازد تا درک کنند ویژگی‌های ظریف زبان، آنها را در درک زمینه، کنایه و حتی ... ماهر می‌کند. ارجاعات فرهنگی در متن. این امر کاربردهای قابل توجهی در زمینه‌هایی مانند نظارت بر رسانه‌های اجتماعی، تحلیل بازار و مطالعات فرهنگی دارد، که در آن‌ها درک ظرافت‌های انسانی اهمیت دارد. ارتباط بسیار مهم است. در مورد تولید زبان، LLM ها مهارت نشان داده اند

در خلق متنی منسجم و مرتبط با متن، از کمک در نگارش گرفته تا تولید محتوای خلاقانه، آنها در برنامه‌های جدید مانند تولید اخبار مورد استفاده قرار می‌گیرند. مقالات، نوشتن شعر و حتی اسکریپت نویسی برای دستیاران مجازی. این قابلیت باز شده است راه‌های جدید در تولید محتوا، که در آن توانایی تولید محتوای متنوع و پیچیده متن بسیار ارزشمند است. علاوه بر این، سازگاری LLMها در مدیریت سبک‌های مختلف زبانی و قالب‌ها قابل توجه هستند. از گزارش‌های رسمی گرفته تا مکالمات غیررسمی، این مدل‌ها می‌توانند خروجی‌های خود را متناسب با سبک‌های مختلف زبانی تنظیم می‌کنند و آنها را به ابزارهایی همه‌کاره در زمینه‌های مختلف تبدیل می‌کنند. مانند خدمات مشتری، جایی که آنها می‌توانند به طور طبیعی و جذاب با کاربران تعامل داشته باشند. در حوزه آموزشی، LLMها با ارائه آموزش‌های شخصی‌سازی‌شده، چشم‌انداز را متحول می‌کنند. تجربیات یادگیری. آنها می‌توانند توضیحاتی ارائه دهند، مشکلات را حل کنند و به صورت تعاملی عمل کنند گفتگوی آموزشی، آنها را به دارایی‌های ارزشمندی در پلتفرم‌های یادگیری دیجیتال تبدیل می‌کنند. با این حال، با این پیشرفت‌ها، چالش‌ها و مسئولیت‌هایی نیز به همراه می‌آید. مسائلی مانند سوگیری داده‌ها، ملاحظات اخلاقی در تولید خودکار محتوا و تأثیر بالقوه آن بر مشاغل در زمینه‌های مرتبط با محتوا، حوزه‌های تحقیق و بحث مداوم هستند. تضمین مسئولیت‌پذیری استفاده و بهبود مستمر این مدل‌ها برای بهره‌برداری مثبت از پتانسیل آنها بسیار مهم است. MLLها نقطه عطف مهمی در یادگیری ماشینی هستند و ...

مرزهایی که ماشین‌ها می‌توانند بفهمند و به زبان انسان بیان کنند. همانطور که آنها همچنان در حال تکامل هستند، انتظار می‌رود تأثیر آنها افزایش یابد و تعامل بین آنها را تغییر شکل دهد. انسان و فناوری.

جدول ۲. مقایسه‌ی SL، UL، IL و RL.

اس ال	این	یو ال	آر ال	جانبه
نگاشت ورودی به خروجی	تقلید از متخصص رفتار	کشف موارد پنهان سازها	سیاست بهینه	هدف یادگیری
برجسب‌گذاری شده جفت‌های ورودی-خروجی	تظاهرات، جفت‌های حالت-عمل	داده‌های خام بدون برجسب	سیگنال‌های حالت و پاداش	داده‌های ورودی
بدون تعامل	مشاهده تظاهرات	تصمیم‌گیری متوالی بدون تعامل صریح		تعامل با محیط زیست
خروجی صحیح برجسب‌ها	متخصص تظاهرات، پاداش‌ها	معیارهای ارزیابی یا معیارها	سیگنال‌های پاداش	سیگنال بازخورد
تشخیص الگو	تقلید و سیاست یادگیری	خوشه‌بندی، ابعاد کاهش	اکتشاف-استخراج و یادگیری سیاست	مکانیسم کلید
به حداقل رساندن خطا	یادگیری از متخصص رفتار	خودسازماندهی	آزمون و خطا	رویکرد آموزشی
طبقه بندی، رگرسیون	انتقال مهارت و تقلید	کشف الگو	تصمیم‌گیری متوالی	کاربردپذیری
تشخیص تصویر، تشخیص گفتار	خودمختار وسایل نقلیه، رباتیک	خوشه‌بندی، ابعاد کاهش	بازی سازی، رباتیک	نمونه‌هایی از کاربردها

۳. بحث

اگرچه مسائل مربوط به تعصب، انصاف و هوش مصنوعی قابل توضیح در یادگیری ماشینی کاملاً شناخته شده هستند. جامعه، پیامدها و چالش‌های آنها با پیشرفت در فناوری تکامل می‌یابد و کاربردها. این بخش با توجه به پیشرفت‌های اخیر، موارد جدید و ...، این مسائل را مجدداً بررسی می‌کند. یافته‌های تحقیقاتی و فناوری‌های نوظهور، نشان می‌دهند که چگونه این نگرانی‌های همیشگی ... آشکار شدن. علاوه بر این، لازم است بر ضرورت بحث مداوم تأکید شود در مورد این مسائل در جامعه یادگیری ماشینی. این واقعیت که این مسائل به خوبی شناخته شده‌اند، ... از اهمیت آنها کم نمی‌شود؛ گفتگوی مداوم برای توسعه شیوه‌های بهتر، به‌روزرسانی سیاست‌ها و آموزش تازه‌واردان به این حوزه بسیار مهم است. از این نظر، این بخش این مسائل را برای مخاطبان گسترده‌تر، شاید غیرمتخصص، قابل فهم یا مرتبط می‌سازد.

پیامدهای سوگیری، انصاف و قابلیت توضیح در یادگیری ماشین فراتر از جنبه‌های فنی است. جامعه به بخش‌هایی مانند سیاست‌گذاری، امور حقوقی و ادراک عمومی. علاوه بر این، مهم است که جایگاه معرفت‌شناختی ML را روشن کنیم، چه چیزی بدیع است و چه چیزی ... از رشته‌های دیگر گرفته شده است.

۳.۱ سهم نه چندان جدید یادگیری ماشین

یادگیری ماشینی عمدتاً از روش‌های آماری یا حتی از سایر حوزه‌های علمی استفاده می‌کند (برای برای مثال، خوشه‌بندی داده‌ها ابتدا در انسان‌شناسی توسط بواس [28] پیشنهاد شد و سپس موردادک [29] برای شناسایی الگوهای فرهنگی و درک روابط بین گروه‌های فرهنگی مختلف). دسترسی اخیر به حجم عظیمی از داده‌ها با موارد بیشتری همراه شده است سخت‌افزار قدرتمند و مقرون‌به‌صرفه، به محققان اجازه داد تا از داده‌های آماری تلفیقی بهره‌برداری کنند. روش‌ها از دیدگاهی جدید با پیروی از این جهت، ML ترکیبی از مبانی نظری تاریخی را در بر می‌گیرد. و پیشرفت‌های معاصر. در حالی که این حوزه به داده‌های آماری به‌خوبی تثبیت‌شده متکی است اصولی که به اواخر قرن هجدهم برمی‌گردد، اهمیت معاصر آن از ... ناشی می‌شود. ادغام این نظریه‌های کلاسیک با روش‌های بدیع و بی‌سابقه قابلیت‌های محاسباتی. الگوریتم‌های بنیادی، مانند رگرسیون خطی و نزدیکترین همسایه‌های K، بر اهمیت پایدار مفاهیم آماری کلاسیک تأکید می‌کنند.

در نتیجه، نوآوری ML عمدتاً در پذیرش شبکه‌های عصبی مصنوعی پیشرفته است. فرمالیسم‌ها (به جدول ۳ مراجعه کنید).

جدول 3. مدل‌های یادگیری ماشین به ترتیب زمانی.

توضیحات	سال	مدل
اصول رگرسیون خطی، یک رویکرد آماری بنیادی این تکنیک، در قرن هجدهم میلادی پایه‌گذاری شد.	اواخر قرن هجدهم (روش حداقل مربعات)	رگرسیون خطی
مفهوم تحلیل مؤلفه‌های اصلی به سال‌ها پیش برمی‌گردد. اوایل قرن بیستم، و رسماً توسط کارل معرفی شد پیرسون در سال ۱۹۳۳	۱۹۳۳ (رسمی)	تحلیل مؤلفه‌های اصلی (پی سی ای)
مفاهیم شبکه عصبی به دهه 1940 میلادی برمی‌گردد. معرفی پرسپترون. ظهور مجدد شبکه‌های عصبی شبکه‌هایی با DL در حدود دهه ۲۰۱۰ رخ دادند که توسط ... تسهیل شدند. پیشرفت در قدرت محاسبات و دسترسی به داده‌ها.	دهه ۱۹۴۰	شبکه‌های عصبی (پرسپترون)
پایه‌های طبقه‌بندی‌کننده Naive Bayes در ... گذاشته شد. دهه ۱۹۵۰، و از آن زمان به طور گسترده در وظایف طبقه‌بندی مورد استفاده قرار گرفته است.	دهه ۱۹۵۰ میلادی	بیز ساده
الگوریتم K-NN اگرچه مانند امروز رسمی نشده است، اما ویژگی‌های خاص خود را دارد. ریشه در دهه 1950 دارد. این طرح بیشتر در الگو استفاده شد شناسایی و طبقه‌بندی در دهه‌های بعدی.	دهه ۱۹۵۰ میلادی	K-نزدیکترین همسایه (K-NN)
K-means یک الگوریتم خوشه‌بندی بنیادی است که در ... توسعه یافته است. دهه ۱۹۵۰ داده‌ها را بر اساس میانگین به k خوشه مجزا تقسیم می‌کند. فاصله تا مراکز ثقل.	دهه ۱۹۵۰ میلادی	خوشه‌بندی K-means
خوشه‌بندی سلسله مراتبی که در دهه ۱۹۵۰ توسعه یافت، درختی از ... ایجاد می‌کند. خوشه‌ها با ادغام خوشه‌های کوچک‌تر در خوشه‌های بزرگ‌تر یا تقسیم خوشه‌های بزرگ‌تر	دهه ۱۹۵۰ میلادی	خوشه‌بندی سلسله مراتبی
اقتباسی از خوشه‌بندی k-means و k-medians که از میانه‌ها استفاده می‌کند به جای وسیله‌ای که می‌تواند برای داده‌های پرت، پایداری ایجاد کند مجموعه داده‌ها.	۱۹۵۰	خوشه‌بندی k-مدیا
اولین و ساده‌ترین نوع شبکه عصبی مصنوعی که توسط ... ابداع شد. فرانک روزنبلات.	۱۹۵۷	پرسپترون
مدل‌های پنهان مارکوف در دهه ۱۹۶۰ توسط ... معرفی شدند. لئونارد ای. باوم و دیگران. در درجه اول برای کاربردهایی در تشخیص گفتار.	دهه ۱۹۶۰	مدل‌های پنهان مارکوف (HMM)

الکترونیک ۴۱۶، ۱۳، ۲۰۲۴		۳۰ از ۱۱۲
جدول ۱۳. ادامه.		
توضیحات	سال	مدل
مفهوم درخت‌های تصمیم در دهه ۱۹۶۰ معرفی شد، با توسعه الگوریتم‌هایی مانند ID3 (تکرار شونده) دوبخشی‌ساز (۳نوشته‌ی راس کوینلان.	دهه ۱۹۶۰	درخت‌های تصمیم‌گیری
این شبکه که در دهه ۱۹۸۰ محبوبیت یافت، از ... استفاده می‌کند. الگوریتم پس‌انتشار برای آموزش، که برای یادگیری عمیق (DL) بسیار مهم است.	دهه ۱۹۷۰	شبکه پس‌انتشار
روش Mean Shift که در سال ۱۹۷۵ توسعه یافت، یک روش خوشه‌بندی ناپارامتری است. تکنیکی که برای یافتن ماکزیمم‌های یک تابع چگالی استفاده می‌شود.	۱۹۷۵	میانگین جابجایی
EM که در سال ۱۹۷۷ معرفی شد، یک روش تکراری است که برای یافتن ... برآوردهای حداکثر درستنمایی در مدل‌های آماری، به‌ویژه در حضور متغیرهای پنهان	۱۹۷۷	حداکثرسازی انتظارات (EM)
NNC ها که توسط یان لکان پیشگام شده‌اند، در پردازش داده‌ها با ... سرآمد هستند. توپولوژی شبکه‌ای، مانند تصاویر.	شبکه عصبی کانولوشن دهه ۱۹۸۰ (سیانان)	
طراحی شده برای تشخیص الگوها در توالی داده‌ها، مانند متن یا سری‌های زمانی.	شبکه عصبی بازگشتی (RNN) دهه ۱۹۸۰	
فرمول‌بندی ماشین‌های بردار پشتیبان برای طبقه‌بندی و وظایف رگرسیون توسط ولادیمیر واپنیک و همکارانش معرفی شد. همکاران در دهه ۱۹۹۰	دهه ۱۹۹۰	ماشین‌های بردار پشتیبان (SVM)
DBSCAN که در سال ۱۹۹۶ معرفی شد، یک خوشه‌بندی مبتنی بر چگالی است. الگوریتمی که نقاطی را که به طور فشرده در کنار هم قرار گرفته‌اند، گروه‌بندی می‌کند، علامت‌گذاری نقاط پرت در مناطق کم‌چگال‌تر.	۱۹۹۶	اسکن پایگاه داده
یک نوع RNN پیشرفته، قادر به یادگیری بلندمدت وابستگی‌ها، توسط سب هوکرایتر و یورگن معرفی شدند اشمیدهورر	حافظه کوتاه مدت بلند ۱۹۹۷ (LSTM)	
خوشه‌بندی طیفی، که در دهه ۲۰۰۰ محبوبیت پیدا کرد، از ... استفاده می‌کند. مقادیر ویژه یک ماتریس شباهت برای کاهش ابعاد قبل از خوشه‌بندی در ابعاد کمتر	دهه ۲۰۰۰	خوشه‌بندی طیفی
الگوریتم جنگل تصادفی توسط لئو بریمن در سال ۱۹۹۴ پیشنهاد شد. ۲۰۰۱ گسترش مفهوم درخت‌های تصمیم‌گیری.	۲۰۰۱	جنگل تصادفی
مفهوم تقویت گرادیان، پایه و اساس الگوریتم‌ها مانند AdaBoost و XGBoost، توسط جروم فریدمن پیشنهاد شد در سال ۲۰۰۱.	۲۰۰۱	ماشین‌های تقویت‌کننده گرادیان
طبق پیشنهاد ایان گودفلو، شبکه‌های مولد تخصصی (GAN) برای تولید داده استفاده می‌شوند، به ویژه در وظایف تولید تصویر.	۲۰۱۴	شبکه مولد تخصصی (گان)
در مقاله «توجه، تنها چیزی است که نیاز دارید» معرفی شده است. ترانسفورماتورها پردازش زبان طبیعی را متحول کردند.	۲۰۱۷	شبکه‌های ترانسفورماتور

قدرت پیش‌بینی یکی از جنبه‌های کلیدی روش‌های یادگیری ماشین است. بهبود دقت پیش‌بینی مدل‌های یادگیری ماشین، حوزه‌ای پویا است که در آن چندین استراتژی در هم تنیده وجود دارد. در هسته بهبود مدل‌های یادگیری ماشینی، تمرکز بر کیفیت و کمیت داده‌ها قرار دارد. مجموعه داده‌های با کیفیت بالا، مرتبط و جامع، بستری را تشکیل می‌دهند که بر اساس آن، اقدامات مؤثر مدل‌ها ساخته می‌شوند. برای تکمیل این امر، مهندسی ویژگی و انتخاب نقش حیاتی ایفا می‌کنند، زیرا شناسایی تأثیرگذارترین ویژگی‌ها می‌تواند به طور قابل توجهی بر پیش‌بینی‌پذیری یک مدل تأثیر بگذارد. قدرت، پیچیدگی و معماری خود مدل نیز بسیار مهم است. در حالی که موارد بیشتر مدل‌های پیچیده، مانند شبکه‌های عصبی عمیق‌تر، می‌توانند الگوهای پیچیده در داده‌ها را ثبت کنند، یک تعادل ظریف برای جلوگیری از بیش‌برازش. در این زمینه، روش‌های گروهی، که ترکیب پیش‌بینی‌ها از چندین مدل، به عنوان یک رویکرد قدرتمند برای دستیابی به پیش‌بینی‌های دقیق‌تر و قوی‌تر. بهینه‌سازی هایپرپارامتر یکی دیگر از حوزه‌های کلیدی است تمرکز. با تنظیم دقیق ابرپارامترهای مدل از طریق تکنیک‌هایی مانند جستجوی شبکه‌ای، جستجوی تصادفی، و بهینه‌سازی بیزی، بهبودهای قابل توجهی در عملکرد می‌توانند ایجاد کنند. این امر با الگوریتم‌های پیشرفته، به‌ویژه در یادگیری ماشینی (DL)، تکمیل می‌شود.

استانداردهای جدیدی را در حوزه‌های مختلف مانند پردازش تصویر، تجزیه و تحلیل داده‌های متوالی و پردازش زبان طبیعی تعیین می‌کنند. یادگیری انتقالی، که در آن مدلی که برای یک کار آموزش دیده است برای کار دیگری تطبیق داده می‌شود، به ویژه در سناریوهایی که داده‌های برچسب‌گذاری شده محدود هستند، مؤثر است. تکنیک‌های منظم‌سازی مانند dropout و منظم‌سازی L1/L2 نیز برای جلوگیری از بیش‌برازش به کار گرفته می‌شوند و قابلیت‌های تعمیم مدل را روی داده‌های جدید افزایش می‌دهند. مفهوم یادگیری و سازگاری در زمان واقعی، که در آن مدل‌ها به طور مداوم به‌روزرسانی می‌شوند و با داده‌های جدید سازگار می‌شوند، به دلیل توانایی‌اش در بهبود دقت پیش‌بینی در طول زمان، مورد توجه قرار می‌گیرد.

در نهایت، اتخاذ رویکردهای میان‌رشته‌ای که بینش‌ها و تکنیک‌هایی از حوزه‌هایی مانند آمار، علوم شناختی و فیزیک را در بر می‌گیرد، منجر به توسعه مدل‌های یادگیری ماشین نوآورانه و دقیق‌تر می‌شود. برای مثال، به [Zewe \(https://news.mit.edu/\)](https://news.mit.edu/) مراجعه کنید. [۲۰۲۳/بهبود-مدل‌های-یادگیری-ماشین-قابلیت-3120](#)، در ۵ ژانویه ۲۰۲۴ بازدید کرد، که تکنیکی برای تعیین مقدار عدم قطعیت مؤثر در مدل‌های یادگیری ماشین توسعه داد.

این روش که نیازی به آموزش مجدد مدل یا داده‌های اضافی ندارد، از یک مدل همراه ساده‌تر (متامدل) برای کمک به مدل اصلی در تخمین عدم قطعیت استفاده می‌کند. این رویکرد بر عدم قطعیت داده‌ها و مدل تمرکز دارد و به تصمیم‌گیری بهتر و اعتماد به پیش‌بینی‌های مدل کمک می‌کند.

۳.۲. یادگیری ماشین و روش علمی

روش علمی، چارچوبی نظام‌مند و دقیق برای بررسی جهان طبیعی فراهم می‌کند. این یک فرآیند چرخه‌ای است که شامل مشاهده، تدوین فرضیه، آزمایش، تحلیل داده‌ها و نتیجه‌گیری می‌شود. فرضیه‌های تدوین‌شده، توضیحات آزمایشی هستند که سعی در توضیح پدیده‌های مشاهده‌شده دارند. در نتیجه، فرضیه‌ها از دانش موجود، اصول علمی و استدلال منطقی الهام می‌گیرند.

فرضیه‌های خوب تعریف‌شده، خاص، قابل آزمایش و ابطال‌پذیر هستند، به این معنی که می‌توان اشتباه بودن آنها را از طریق آزمایش ثابت کرد. آزمایش، آزمون روش علمی است. این فرآیند آزمایش فرضیه‌ها در برابر شواهد تجربی است. آزمایش‌ها با دقت کنترل می‌شوند، متغیرها را جدا می‌کنند و سوگیری‌ها را به حداقل می‌رسانند تا از قابلیت اطمینان نتایج اطمینان حاصل شود. داده‌های خام جمع‌آوری‌شده از آزمایش‌ها تحت تجزیه و تحلیل و تفسیر دقیق قرار می‌گیرند. دانشمندان از تکنیک‌های آماری، مدل‌های ریاضی و ابزارهای تجسم برای استخراج معنا از داده‌ها، شناسایی روندها، الگوها و همبستگی‌ها استفاده می‌کنند. تجزیه و تحلیل داده‌ها بینش‌های مهمی در مورد اعتبار فرضیه‌ها ارائه می‌دهد. بر اساس تجزیه و تحلیل داده‌های تجربی، می‌توان اعتبار فرضیه‌ها را نتیجه گرفت. اگر داده‌ها از فرضیه‌ها پشتیبانی کنند، نتیجه‌گیری‌ها توضیحات موقت برای پدیده‌های مشاهده‌شده ارائه می‌دهند. با این حال، اگر داده‌ها با فرضیه‌ها مغایرت داشته باشند، نتیجه‌گیری‌ها منجر به رد یا اصلاح آنها می‌شود و تحقیقات بیشتر را برمی‌انگیزد. روش علمی یک فرآیند خطی نیست؛ بلکه یک چرخه تکرارشونده از مشاهده، تدوین فرضیه، آزمایش، تجزیه و تحلیل داده‌ها و شکل‌گیری نتیجه‌گیری است. با ظهور شواهد جدید، نظریه‌های موجود اصلاح می‌شوند و فرضیه‌های جدیدی تدوین می‌شوند که منجر به پیشرفت مداوم دانش علمی می‌شود. جوهره روش علمی در عینیت، دقت و ماهیت خوداصلاحی آن نهفته است. این فرآیندی است که شک، تردید و تفکر انتقادی را در بر می‌گیرد و تضمین می‌کند که دانش علمی نه مبتنی بر جزم یا باورهای شخصی، بلکه مبتنی بر شواهد تجربی و استدلال منطقی است.

می‌توان استدلال کرد که یادگیری ماشین را می‌توان امتدادی از روش علمی، به ویژه در استفاده از آزمایش فرضیه مبتنی بر داده و پالایش تکراری آن، در نظر گرفت. الگوریتم‌های یادگیری ماشین بر روی حجم وسیعی از داده‌ها آموزش داده می‌شوند، که از آنها الگوها را استخراج کرده و پیش‌بینی می‌کنند. این فرآیند شبیه تأکید روش علمی بر مشاهده، تدوین فرضیه و آزمایش است. علاوه بر این، مدل‌های یادگیری ماشین به طور مداوم بر اساس عملکردشان بر روی داده‌های جدید ارزیابی و پالایش می‌شوند که منعکس کننده ماهیت تکراری روش علمی است. با در دسترس قرار گرفتن داده‌های جدید، مدل‌های یادگیری ماشین می‌توانند برای بهبود دقت و تعمیم‌پذیری خود به‌روزرسانی شوند. هوش مصنوعی و یادگیری ماشین به طور فزاینده‌ای در اکتشافات علمی [30] ادغام می‌شوند و به دانشمندان در تولید فرضیه، طراحی آزمایش و جمع‌آوری داده‌ها کمک می‌کنند. این مقاله مواردی را برجسته می‌کند که در آنها هوش مصنوعی به طور قابل توجهی در زمینه‌هایی مانند ریاضیات محض و زیست‌شناسی مولکولی پیشرفت کرده است و قدرت پیش‌بینی و توانایی هدایت شهود انسان را در چالش‌های پیچیده علمی نشان می‌دهد. بوگ و همکاران [31] نقش ... را بررسی می‌کنند.

یادگیری ماشین به عنوان یک ابزار بهینه‌سازی که توسط رایانه‌های دیجیتال اجرا می‌شود و اینکه چگونه استفاده روزافزون از آن نشان‌دهنده تغییر از اهداف علمی سنتی توضیح به سمت تشخیص الگو و پیش‌بینی است. این مقاله پیامدهای این تغییر را برای توضیح علمی و جهت‌گیری‌های بالقوه آینده یادگیری ماشین در تحقیقات علمی بررسی می‌کند. در نهایت، بوخولز و همکارانش [32] برخی از بینش‌های مربوط به استفاده از مدل‌های یادگیری ماشین به عنوان روشی برای علم خارج از حوزه‌های موفقیت سنتی را مورد بحث قرار می‌دهند. این مقاله بحثی را در مورد چگونگی هماهنگی یادگیری ماشین با سایر روش‌های علمی، گذار از مدل‌های توضیحی به مدل‌های پیش‌بینی‌کننده، و نحوه کاربرد آن در حوزه‌های مختلف علمی مانند آلفا فولد در پیش‌بینی تاخوردگی پروتئین آغاز می‌کند.

مخالفان این دیدگاه معتقدند که یادگیری ماشینی رویکردی متمایز برای کشف دانش ارائه می‌دهد و از چندین جهت با روش علمی سنتی متفاوت است. اگرچه یادگیری ماشینی در تشخیص الگو و پیش‌بینی برتری دارد، اما اغلب نمی‌تواند توضیحات علی برای الگوهای مشاهده شده ارائه دهد. ماهیت «جعبه سیاه» بسیاری از مدل‌های یادگیری ماشینی، درک مکانیسم‌های اساسی پیش‌بینی‌های آنها را چالش‌برانگیز می‌کند. علاوه بر این، الگوریتم‌های یادگیری ماشینی اغلب بر اساس داده‌هایی آموزش می‌بینند که ممکن است حاوی سوگیری‌ها یا اشتباهاتی باشند که می‌تواند منجر به پیش‌بینی‌های جانبدارانه یا اشتباه شود. تشخیص و حذف این سوگیری‌ها، به‌ویژه در مدل‌های پیچیده، می‌تواند دشوار باشد. جدول ۴ برخی از مهم‌ترین شباهت‌های بین روش علمی و یادگیری ماشینی را خلاصه می‌کند.

جدول ۴. مقایسه‌ای بین روش علمی و جنبه‌های یادگیری ماشینی.

میلی لیتر	روش علمی	جنبه
پیش‌بینی‌ها یا طبقه‌بندی‌ها را بر اساس الگوهای مشاهده‌شده در داده‌ها انجام دهید	جهان طبیعی را درک کنید و اصول اساسی آن را کشف کنید	هدف
داده‌محور، با تمرکز بر الگوها و همبستگی‌های تجربی	مبتنی بر داده، اما با تأکید قوی بر درک نظری و توضیحات علی	رویکرد
تحلیل آماری، داده‌کاوی، الگوریتم‌های یادگیری ماشین و تشخیص الگو	مشاهده، آزمایش، آزمون فرضیه، مدل‌سازی ریاضی و تحلیل دقیق	روش‌ها
دقت پیش‌بینی، تعمیم‌پذیری، تفسیرپذیری و استحکام	دقت پیش‌بینی، تکرارپذیری، ابطال‌پذیری و قدرت توضیحی	ارزیابی
ممکن است همیشه قادر به ارائه توضیحات علی نباشد، اما می‌تواند بینش‌هایی در مورد همبستگی‌ها و الگوها ارائه دهد	تلاش می‌کند تا توضیحات علی برای مشاهدات ارائه دهد پدیده‌های توضیحی	
فرآیند تکراری آموزش، ارزیابی و اصلاح، هدایت‌شده توسط در دسترس بودن داده‌ها و بهینه‌سازی عملکرد	فرآیند تکراری مشاهده، آزمون فرضیه و اصلاح، که توسط درک نظری و شواهد تجربی هدایت می‌شود	تکرار
محدود به کیفیت و کمیت داده‌ها، سوگیری‌های ذاتی در داده‌ها و پیچیدگی مسائل دنیای واقعی	محدود به دامنه درک انسان و توانایی طراحی و اجرای آزمایش‌های معنادار	محدودیت‌ها
پیش‌بینی‌های کارآمد و دقیق را در حوزه‌های پیچیده، از جمله چارچوبی قوی برای کشف روابط علی و معلولی و درک جهان طبیعی فراهم می‌کند. برنامه‌های کاربردی در مراقبت‌های بهداشتی، مالی و فناوری، امکان‌پذیر می‌کند.		نقاط قوت
ضروری برای درک اصول اساسی حاکم بر جهان و تصمیم‌گیری‌های آگاهانه در مورد جهان اطرافمان نقش حیاتی در حل مشکلات دنیای واقعی و پیشبرد نوآوری در زمینه‌های مختلف ایفا می‌کند.		ارتباط

اینکه آیا شاخه‌ای از علم که نمی‌تواند یک واقعیت را به صورت علی توضیح دهد اما می‌تواند واقعیت‌ها را پیش‌بینی کند، همچنان می‌تواند علم تلقی شود یا خیر، به تعریف خاص علم مورد استفاده بستگی دارد. یک تعریف محدود از علم ممکن است ایجاب کند که همه توضیحات علمی علی باشند، به این معنی که آنها باید مکانیسم‌های اساسی ایجاد پدیده‌های مشاهده شده را توضیح دهند. طبق این تعریف، شاخه‌ای از علم که نتواند توضیحات علی ارائه دهد، علم واقعی محسوب نمی‌شود. با این حال، تعریف وسیع‌تری از علم می‌تواند توضیحات غیرعلی را نیز در نظر بگیرد، مادامی که مبتنی بر شواهد تجربی و روش‌شناسی دقیق باشند. طبق این تعریف، شاخه‌ای از علم که می‌تواند حقایق را پیش‌بینی کند، حتی اگر نتواند آنها را به صورت علی توضیح دهد، همچنان می‌تواند علم محسوب شود. به عنوان مثال، هواشناسی می‌تواند آب و هوا را با درجه بالایی از دقت پیش‌بینی کند، اما نمی‌تواند به طور کامل ...

مکانیسم‌های پیچیده‌ای که الگوهای آب و هوایی را هدایت می‌کنند. با این حال، هواشناسی هنوز یک علم محسوب می‌شود زیرا پیش‌بینی‌های آن مبتنی بر شواهد تجربی و روش‌شناسی دقیق است.

۳.۳. امروزی بر استقرا

در معرفت‌شناسی، استقراء به عنوان شیوه‌ای از استدلال مطرح می‌شود که به قلمرو کلیات می‌پردازد و اصول یا الگوهای فراگیر را از مجموعه‌ای از مشاهدات یا نمونه‌های خاص استخراج می‌کند. این رویکرد استقرایی از جزئی به کلی حرکت می‌کند و به دنبال تشخیص حقایق گسترده‌تر از شواهد تجربی است. با این حال، همانطور که توسط فیلسوف دیوید هیوم مشاهده شده است، اساس استقراء پیچیدگی‌های منطقی ذاتی را در خود جای داده است. وضعیت فردی را در نظر بگیرید که در طول زندگی خود فقط با قوهای سفید مواجه شده است. استقراء او را مجبور می‌کند تا یک نتیجه‌گیری کلی را مطرح کند: همه قوها سفید هستند. این استنتاج، که از مواجهه‌های مکرر با قوهای سفید استخراج شده است، سپس تعمیم داده می‌شود تا کل قوها، چه مشاهده شده و چه مشاهده نشده، را در بر بگیرد. با این حال، اعتبار این نتیجه‌گیری بر این فرض استوار است که نمونه‌های آینده، مشاهدات گذشته را منعکس می‌کنند. از نظر فلسفی، این چالش به عنوان "مسئله استقراء" که توسط هیوم بیان شده است، آشکار می‌شود. صرف مشاهده قوهای سفید به طور قطعی تضمین نمی‌کند که همه قوها، از جمله آن‌هایی که هنوز حضور ما را مزین نکرده‌اند، رنگ یکسانی داشته باشند. فرآیند استقرایی مبتنی بر این فرض است که آینده آینه گذشته است، مفهومی که عنصری از عدم قطعیت را وارد می‌کند.

استقرای ریاضی به عنوان یک عنصر بنیادی در قلمرو ... عمل می‌کند.

اثبات‌های ریاضی، که تثبیت دقیق ادعاهای جهان‌شمول را از طریق مشاهدات محدود تسهیل می‌کنند. اصل استقرای ریاضی در ساختار دو مرحله‌ای آن، متشکل از یک حالت پایه و مرحله استقرایی، خلاصه شده است. حالت اول یک مرحله اساسی است که مستلزم تأیید اعتبار گزاره برای کوچکترین عنصر در مجموعه تعیین شده است. به عنوان مثال، برای اثبات این ادعا که هر عدد زوج را می‌توان به صورت مجموع دو عدد صحیح متوالی نشان داد، باید این ادعا را برای کوچکترین عدد زوج، یعنی ۲، اعتبارسنجی کرد. مرحله استقرایی مستلزم نشان دادن این است که گزاره برای هر عدد طبیعی پس از حالت پایه معتبر باقی می‌ماند. برای برون‌یابی گزاره عدد زوج فوق‌الذکر، ضروری است که نشان دهیم اگر هر عدد زوجی که با n نشان داده می‌شود، بتواند به صورت مجموع دو عدد صحیح متوالی بیان شود، آنگاه عدد بعدی آن، که با $n + 2$ نشان داده می‌شود، می‌تواند به همان روش بیان شود. بررسی فلسفی استقرای ریاضی، نقاط قوت و محدودیت‌های ذاتی آن را آشکار می‌کند. از یک سو، چارچوب دقیقی برای استخراج حقایق جهانی از مشاهدات محدود فراهم می‌کند، کاری که از طریق استدلال قیاسی به تنهایی غیرقابل انجام است. توانایی تعمیم از موارد خاص، جنبه‌ای محوری از کاوش و کشف ریاضی را تشکیل می‌دهد.

در حوزه استدلال استقرایی، شناخت یک اصل معرفت‌شناختی اساسی از اهمیت فوق‌العاده‌ای برخوردار است: نتیجه حاصل از یک استدلال استقرایی، حتی زمانی که خود مقدمات به طور قابل اثباتی دقیق باشند، ضرورت ذاتی برای صدق ندارد. برخلاف استدلال قیاسی، که در آن صدق مقدمات به طور واضح صدق نتیجه را تضمین می‌کند، استدلال استقرایی چنین اطمینان مطلق را ارائه نمی‌دهد. این عدم قطعیت معرفت‌شناختی از ماهیت استنتاج استقرایی ناشی می‌شود که به تعمیم از موارد خاص برای تدوین یک گزاره گسترده‌تر وابسته است. برون‌یابی یک ادعای کلی مبتنی بر جزئیات مشاهده‌شده، ذاتاً عنصری از استدلال احتمالاتی را به جای ضرورت منطقی معرفی می‌کند.

به این ترتیب، صحت نتیجه‌گیری همچنان منوط به این فرض است که نمونه‌های آینده با مشاهدات گذشته همسو خواهند بود - فرضی که ذاتاً مستعد شک است. از نظر فلسفی، این ویژگی استدلال استقرایی، تمایز بین توجیه و حقیقت را برجسته می‌کند. در حالی که استدلال‌های استقرایی می‌توانند توجیهی قابل قبول برای یک نتیجه‌گیری بر اساس شواهد موجود ارائه دهند، حقیقت نتیجه‌گیری را نمی‌توان به طور قطعی تضمین کرد، زیرا مبتنی بر این فرض غیرقابل تأیید است که آینده با الگوهای گذشته مطابقت خواهد داشت.

علاوه بر این، استقرا عینی نیست. نتیجه‌گیری‌های استدلال‌های استقرایی مبتنی بر قضاوت‌های ذهنی در مورد وزن شواهد است. سناریویی را در نظر بگیرید که در آن

شخصی چند رستوران را در یک شهر جدید امتحان کرده و بر اساس تجربیات ذهنی خود نتیجه گرفته است که همه رستوران‌های آن شهر باید غذاهای استثنایی ارائه دهند. قضاوت فرد در مورد کیفیت رستوران‌های نمونه، اساس یک استنتاج استقرایی را تشکیل می‌دهد که به تمام رستوران‌های دیگر شهر تعمیم می‌یابد. در این مورد، نتیجه‌ای که گرفته می‌شود - یعنی اینکه همه رستوران‌های شهر غذاهای استثنایی ارائه می‌دهند - به شدت به قضاوت‌های ذهنی وابسته است. ارزیابی فرد از «استثنایی» ذاتاً ذهنی است و تحت تأثیر سلیقه‌ها، ترجیحات و تجربیات شخصی قرار دارد. وزنی که به نمونه محدود رستوران‌ها اختصاص داده شده است، ممکن است به طور دقیق تنوع یا تفاوت در کیفیت آشپزی در کل شهر را نشان ندهد.

ذهنیت‌گرایی در ارزیابی شواهد زمانی آشکار می‌شود که در نظر بگیریم فرد دیگری با سلیقه‌ها یا تجربیات متفاوت ممکن است از مجموعه‌ای متفاوت از رستوران‌ها بازدید کند و به نتیجه‌گیری متضادی در مورد کیفیت کلی غذاخوری‌های شهر برسد. این مثال نشان می‌دهد که چگونه استدلال استقرایی، به ویژه هنگامی که مبتنی بر ارزیابی‌های ذهنی باشد، می‌تواند منجر به نتیجه‌گیری‌هایی شود که فاقد عینیت هستند و ممکن است به طور جهانی قابل اجرا نباشند.

استقراء به عنوان یک مفهوم بنیادی در حوزه یادگیری ماشین، به ویژه در مراحل اولیه آن، عمل می‌کند، زیرا زیربنای فرآیند یادگیری الگوها و پیش‌بینی از داده‌ها است. الگوریتم‌های یادگیری ماشین برای تعمیم از نمونه‌های مشاهده شده و پیش‌بینی یا تصمیم‌گیری در مورد نمونه‌های دیده نشده، به استقراء متکی هستند. این رویکرد به ویژه هنگام برخورد با داده‌های پیچیده و بدون ساختار که در آن برنامه‌نویسی صریح ممکن است چالش برانگیز باشد، ارزشمند است. یک نمونه قابل توجه از یک الگوریتم یادگیری ماشین مبتنی بر استقراء، الگوریتم درخت تصمیم است. درخت‌های تصمیم به صورت بازگشتی داده‌ها را بر اساس ویژگی‌ها تقسیم می‌کنند و یک ساختار درخت مانند ایجاد می‌کنند که در آن هر گره نشان دهنده یک تصمیم بر اساس یک ویژگی خاص است.

این الگوریتم این قوانین تصمیم‌گیری را از داده‌های آموزشی برچسب‌گذاری‌شده می‌آموزد و آن را قادر به پیش‌بینی کلاس یا نتیجه نمونه‌های جدید و دیده نشده می‌کند. مثال دیگر، الگوریتم K-نزدیک‌ترین همسایه (K-NN) است که پیش‌بینی‌ها را بر اساس کلاس اکثریت نقاط داده K-نزدیک‌ترین در فضای ویژگی انجام می‌دهد. در این حالت، الگوریتم الگوهای را از روابط بین نقاط داده القا می‌کند و به آن اجازه می‌دهد نمونه‌های جدید را بر اساس نزدیکی آنها به نمونه‌های موجود طبقه‌بندی کند. علاوه بر این، ماشین‌های بردار پشتیبان (SVM) دسته‌ای از الگوریتم‌ها هستند که مرزهای تصمیم‌گیری را با به حداکثر رساندن حاشیه بین کلاس‌های مختلف در فضای ویژگی یاد می‌گیرند. MVSها، در اصل، به فرآیند استقرایی تعمیم از داده‌های آموزشی برای طبقه‌بندی نقاط داده جدید متکی هستند.

در زمینه یادگیری ماشین دقیق، که در درجه اول شامل یادگیری الگوها از داده‌ها برای پیش‌بینی یا تصمیم‌گیری است، مفهوم استقراء همچنان یک جنبه اساسی است.

استدلال استقرایی، یا تعمیم از نمونه‌های خاص برای پیش‌بینی در مورد نمونه‌های جدید، در ذات فرآیند یادگیری مدل‌های یادگیری ماشینی است. مدل‌های یادگیری ماشینی برای تشخیص الگوها و روابط درون داده‌ها طراحی شده‌اند و این تشخیص معمولاً شامل استنتاج استقرایی است که الگوهای مشاهده شده به نمونه‌های دیده نشده تعمیم داده می‌شوند. مثال‌هایی که قبلاً ارائه شد، مانند درخت‌های تصمیم، نزدیک‌ترین همسایه‌های K و ماشین‌های بردار پشتیبان، همگی برای پیش‌بینی به استدلال استقرایی متکی هستند. توجه به این نکته مهم است که ماهیت یادگیری ماشینی به گونه‌ای است که مدل‌ها از داده‌ها یاد می‌گیرند و این فرآیند یادگیری ذاتاً شامل تعمیم است. جوهره یادگیری ماشینی، ثبت الگوهای اساسی در داده‌ها برای پیش‌بینی در مورد نمونه‌های جدید و دیده نشده است. اگر یک مدل یادگیری ماشینی از نوعی استقراء یا تعمیم استفاده نکند، برای پیش‌بینی معنادار در مورد داده‌های جدید با مشکل مواجه خواهد شد.

۳.۴. مسئله‌ای توضیح اگرچه برخی مدل‌ها مانند رگرسیون چندجمله‌ای و درخت‌های تصمیم‌گیری به دلیل شفاف بودن و امکان تعیین وزن متغیر پیش‌بینی‌کننده در پیش‌بینی یک متغیر هدف، «جعبه سفید» در نظر گرفته می‌شوند، برخی دیگر از فرمالیسم‌ها، مانند شبکه‌های عصبی مصنوعی و جنگل‌های تصادفی، «جعبه سیاه» در نظر گرفته می‌شوند. توضیح و تفسیر هر دو نقش مهمی در رابطه با مسئله‌ای ارائه توضیحات علی در مدل‌های یادگیری ماشینی دارند.

توضیح به فرآیند شفاف‌سازی یا ارائه یک گزارش قابل فهم از چگونگی دستیابی به یک تصمیم یا نتیجه خاص توسط یک مدل هوش مصنوعی اشاره دارد. این شامل شکستن ...

پیش‌بینی‌ها یا تصمیمات پیچیده مدل را به عبارات قابل فهم برای کاربران یا ذینفعان تبدیل می‌کند. هدف اصلی توضیح در هوش مصنوعی قابل توضیح (XAI) افزایش شفافیت، اعتماد و پاسخگویی است. ارائه توضیحات واضح به کاربران، به ویژه کسانی که درک عمیقی از یادگیری ماشین ندارند، کمک می‌کند تا بفهمند که چرا یک مدل پیش‌بینی یا تصمیم خاصی را گرفته است. از سوی دیگر، تفسیر، در زمینه XAI، شامل درک و فهم عملکرد داخلی یک مدل یادگیری ماشین است. این امر به کشف ویژگی‌ها، متغیرها یا الگوهای می‌پردازد که به طور قابل توجهی در پیش‌بینی‌های مدل نقش دارند. تفسیر با بررسی مکانیسم‌های داخلی مدل هوش مصنوعی، فراتر از توضیح سطحی می‌رود. این امر به دانشمندان و محققان داده کمک می‌کند تا در مورد نحوه پردازش اطلاعات توسط مدل و اینکه کدام ویژگی‌ها در تصمیم‌گیری آن مؤثر هستند، بینش کسب کنند. هم توضیح و هم تفسیر به هدف کلی XAI، یعنی شفاف‌تر، قابل فهم‌تر و پاسخگوتر کردن سیستم‌های هوش مصنوعی، کمک می‌کنند.

در حالی که توضیح، کاربران نهایی و ذینفعان را هدف قرار می‌دهد، تفسیر اغلب دغدغه دانشمندان داده و محققانی است که به دنبال بهبود استحکام و قابلیت اطمینان مدل‌های یادگیری ماشین هستند. مزایای XAI متعدد است: (۱) افزایش اعتماد و شفافیت، زیرا می‌تواند با شفاف‌تر و قابل فهم‌تر کردن سیستم‌های هوش مصنوعی برای انسان‌ها، به افزایش اعتماد به آنها کمک کند؛ (۲) بهبود تصمیم‌گیری، زیرا می‌تواند با ارائه بینش در مورد نحوه عملکرد سیستم‌های هوش مصنوعی به انسان‌ها در تصمیم‌گیری بهتر کمک کند؛ (۳) کاهش سوگیری، زیرا XAI می‌تواند با آسان‌تر کردن شناسایی و اصلاح سوگیری‌ها در داده‌ها و الگوریتم‌ها، به کاهش سوگیری در سیستم‌های هوش مصنوعی کمک کند؛ و در نهایت، (۴) افزایش ایمنی XAI می‌تواند با آسان‌تر کردن شناسایی و کاهش خطرات، به افزایش ایمنی سیستم‌های هوش مصنوعی کمک کند.

۳.۵. درک مسئله‌ای توضیح: یک مثال عملی

مثال زیر با هدف روشن کردن مسئله اساسی ایجاد تعادل بین توضیح‌پذیری و دقت، یعنی ارزیابی اهمیت یک مدل دقیق در برابر ارزش مدلی که انگیزه نتایج به‌دست‌آمده را توضیح می‌دهد، ارائه شده است.

مثال زیر پایگاه داده MNIST (موسسه ملی استاندارد و فناوری اصلاح‌شده) (cvg.foundry.com/mnist) را در نظر می‌گیرد. (دسترسی در ۲۸ نوامبر ۲۰۲۳). این مجموعه شامل ۷۰,۰۰۰ تصویر متشکل از ارقام دست‌نویس است.


هر ورودی از مجموعه داده‌ها یک تصویر 28×28 پیکسلی است که رقمی بین ۰ تا ۹ را نشان می‌دهد. شکل ۸ نمونه‌ای از محتوای مجموعه داده‌ها را گزارش می‌دهد. هر تصویر دارای یک برچسب مرتبط است که رقم موجود را نشان می‌دهد. به طور خاص، X شامل تصاویر ورودی است و Y برچسب‌های مرتبط را در خود جای داده است. به عنوان مثال، تصویر اول X_0 حاوی رقم دست‌نویس ۵ است و بنابراین مقدار برچسب جفت‌شده آن Y_0 برابر با ۵ است.



شکل ۸. نمونه خاکستری از محتوای مجموعه داده MNIST.

هدف این است که بتوانیم محتوای تصویر را برای بازتولید متنی آن تشخیص دهیم. وظیفه طبقه‌بندی مورد نیاز - که منجر به ایجاد زوج‌ها (تصویر ورودی، برچسب خروجی) می‌شود - می‌تواند به روش‌های مختلفی انجام شود، که شامل مدل‌های جعبه سفید و جعبه سیاه می‌شود. برای مقایسه، یک الگوریتم خوشه‌بندی جعبه سفید (k-means) و یک شبکه عصبی مصنوعی جعبه سیاه (به طور خاص یک CNN انتخاب شده‌اند).

شکل ۹ عملکرد هر دو الگوریتم k-means (در سمت چپ) و CNN (در سمت راست) را نشان می‌دهد. در برنامه مورد نظر.



شکل ۹. طرحواره‌هایی از عملکرد k-means (در سمت چپ) و CNN (در سمت راست).


الگوریتم K-means یک الگوریتم خوشه‌بندی پارتیشن‌بندی است که معمولاً برای گروه‌بندی نقاط داده به خوشه‌های مجزا بر اساس شباهت‌هایشان استفاده می‌شود. این الگوریتم قوانین واضح و صریحی برای اختصاص نقاط داده به خوشه‌ها ارائه می‌دهد. به طور خاص، بینش‌های قابل فهمی در مورد فرآیند خوشه‌بندی ارائه می‌دهد و نمایشی قابل فهم و تفسیر از مکانیسم‌های تصمیم‌گیری خود را تقویت می‌کند. علاوه بر این، این الگوریتم به طور تکراری با به حداقل رساندن مجموع مربعات فواصل بین نقاط داده و مرکز خوشه‌های مربوطه، تخصیص خوشه‌ها را اصلاح می‌کند.

یک CNN ساختار پیچیده‌ای است که از چندین لایه و پارامترهای متعدد ساخته شده است. معماری آن با چیدمان سلسله مراتبی لایه‌ها (شامل لایه‌های کانولوشن، لایه‌های ادغام و لایه‌های کاملاً متصل) مشخص می‌شود که هر کدام هدف متمایزی را دنبال می‌کنند (مثلاً تشخیص الگوها، ادغام نمونه‌های کوچک، کاهش ابعاد، کاهش پیچیدگی محاسباتی و ...). لایه‌های کاملاً متصل، ویژگی‌های سطح بالا را از لایه‌های قبلی ادغام می‌کنند و به مدل اجازه می‌دهند تا بر اساس نمایش‌های آموخته‌شده، پیش‌بینی‌هایی انجام دهد. روابط و الگوهای آموخته‌شده توسط NNCها اغلب به راحتی قابل تشخیص یا توضیح با اصطلاحات انسانی نیستند. این عدم شفافیت، چالش‌هایی را در ... ایجاد می‌کند.

منطق پشت پیش‌بینی‌های شبکه را نشان می‌دهد و قابلیت تفسیر و اعتمادپذیری مدل را در زمینه‌های خاص محدود می‌کند.

پس از وارد کردن مجموعه داده‌ها برای آموزش هر دو مدل، مرحله آزمایش بعدی انجام شد. نتیجه در نمودار نشان داده شده در شکل ۱۰ نشان داده شده است. واضح است که CNN از نظر دقت عملکرد بهتری نشان داده و در هر دو آموزش و آزمایش به امتیازات بالایی دست یافته است (به مقدار ۱، بالاترین مقدار قابل دستیابی نزدیک می‌شود). در مقابل، K-means تنها نیمی از دقت CNN را نشان داد که نشان‌دهنده کارایی نسبتاً پایین‌تر آن در طبقه‌بندی تصویر است. از نقطه نظر دقت، CNN به عنوان انتخاب ارجح ظاهر می‌شود. با این حال، شایان ذکر است که K-means شفافیت کاملی در فرآیند تصمیم‌گیری خود ارائه می‌دهد و بینش‌هایی در مورد نحوه استخراج نتایج ارائه می‌دهد، ویژگی‌ای که CNN ندارد.

در نتیجه، استفاده از CNN قدرت پیش‌بینی دقیقی را فراهم می‌کند، اگرچه درک دلیل پیش‌بینی‌های خاص می‌تواند پیچیده یا حتی غیرممکن باشد.



شکل ۱۰. نموداری که دقت به دست آمده در طول دوره‌های آموزشی را برای هر دو مدل در مراحل آموزش و اعتبارسنجی نشان می‌دهد.

۳.۶. توضیح پشتیبانی‌اشده توسط مدل‌های کمکی

ادغام چارچوب‌های توضیحی با مدل‌های جعبه سیاه در یادگیری ماشین، مانند شبکه‌های عصبی عمیق، گامی اساسی در جهت افزایش قابلیت تفسیر آنها است و یکی از روش‌های مؤثر برای دستیابی به این هدف، استفاده از درخت‌های تصمیم‌گیری است. این ادغام در درجه اول از روش‌های مستقل از مدل مانند [33] LIME یا [34] SHAP استفاده می‌کند که برای ایجاد مدل‌های ساده و قابل تفسیر طراحی شده‌اند که به صورت محلی پیش‌بینی‌های یک مدل پیچیده را تقریب می‌زنند. این فرآیند شامل استفاده از درخت‌های تصمیم برای تقلید از مرز تصمیم‌گیری مدل جعبه سیاه برای موارد خاص است، بنابراین توضیح روشنی برای پیش‌بینی‌های فردی ارائه می‌دهد. جدا از تقریب‌های محلی، تمرکز بر تقریب‌های سراسری نیز وجود دارد. این شامل توسعه مدل‌های ساده‌تر مانند درخت‌های تصمیم برای درک رفتار کلی مدل پیچیده است، تکنیکی که به عنوان تقطیر مدل شناخته می‌شود. چالش اصلی در اینجا متعادل کردن سادگی درخت تصمیم برای تضمین قابلیت تفسیر در عین حفظ پیچیدگی کافی برای انعکاس دقیق رفتار مدل جعبه سیاه است. تجزیه و تحلیل اهمیت ویژگی یکی دیگر از جنبه‌های حیاتی است، به ویژه در روش‌های گروهی مانند جنگل‌های تصادفی. درخت‌های تصمیم‌گیری می‌توانند در شناسایی ویژگی‌هایی که مدل پیچیده برای پیش‌بینی مهم می‌داند، کمک کنند. با این حال، تفسیر محتاطانه این نتایج مهم است، زیرا اهمیت ویژگی لزوماً به معنای علت نیست. استخراج قانون رویکرد دیگری است که در آن قوانین تصمیم‌گیری برای تقریب فرآیند تصمیم‌گیری مدل جعبه سیاه ایجاد می‌شوند. پیچیدگی این قوانین می‌تواند متفاوت باشد و اغلب بین سادگی قوانین برای تفسیرپذیری و پیچیدگی آنها در ثبت نکات ظریف رفتار مدل، بده‌بستان وجود دارد. ملاحظات اخلاقی و عملی نیز نقش مهمی در

در این زمینه، تضمین شفافیت و اعتماد به سیستم‌های هوش مصنوعی، به ویژه در حوزه‌های حساسی مانند مراقبت‌های بهداشتی یا مالی، از اهمیت بالایی برخوردار است. علاوه بر این، با افزایش تقاضاهای نظارتی برای تصمیمات هوش مصنوعی قابل توضیح، این تکنیک‌ها نه تنها از نظر قابلیت استفاده، بلکه برای اهداف انطباق نیز ضروری می‌شوند.

در [35] نویسندگان بر روی یک چارچوب مدل-آگنوستیک که برای ارائه توضیحاتی برای مدل‌های بینایی طراحی شده است، تمرکز می‌کنند و روش‌های پیشرفته مختلف را برای توضیح هر دو مدل‌های بینایی (ViTs) و NNCها ارزیابی می‌کنند. هسیجا و همکاران [36] نگاهی جامع به روش‌های مختلف مورد استفاده در هوش مصنوعی قابل توضیح ارائه می‌دهند و بر نحوه تفسیر مدل‌های جعبه سیاه در حوزه‌های مختلف تمرکز می‌کنند. در حالی که تان و همکاران [37] توضیحات افزایشی جهانی را برای مدل‌های غیرافزایشی بررسی می‌کنند و بر چالش‌ها و ملاحظات مربوط به توضیح مدل‌های جعبه سیاه تمرکز می‌کنند. در نتیجه، می‌توان گفت که استفاده از درخت‌های تصمیم‌گیری برای جفت کردن چارچوب‌های توضیحی با مدل‌های جعبه سیاه، گامی مهم به سوی هوش مصنوعی مسئولانه است. این رویکرد نه تنها شفافیت این مدل‌ها را افزایش می‌دهد، بلکه تعادلی بین دقت پیش‌بینی آنها و توانایی ارائه بینش‌های قابل فهم در فرآیندهای تصمیم‌گیری آنها ایجاد می‌کند. این تعادل کلید استقرار مسئولانه هوش مصنوعی در بخش‌های مختلف است.

۳.۷ هوش مصنوعی قابل توضیح در مطالعات سرطان‌شناسی

به طور سنتی، مدل‌های یادگیری ماشین در انکولوژی بر تجزیه و تحلیل‌های پیش‌بینی‌کننده، مانند شناسایی احتمال بدخیم بودن تومور بر اساس داده‌های تصویربرداری، متمرکز بوده‌اند. با این حال، استنتاج علی به این مدل‌ها اجازه می‌دهد تا فراتر از همبستگی‌های صرف بروند و به علل اساسی بپردازند. به عنوان مثال، مدل‌ها ممکن است با در نظر گرفتن عوامل ژنتیکی یا محیطی، تشخیص دهند که چرا برخی تومورها به درمان‌ها پاسخ متفاوتی می‌دهند. یکی از مهمترین تأثیرات استنتاج علی در یادگیری ماشین، پیشرفت پزشکی شخصی‌سازی شده است.

با درک مکانیسم‌های سببی پشت پاسخ بیمار به درمان، یادگیری ماشینی می‌تواند به توسعه درمان‌های متناسب برای هر بیمار کمک کند، که به طور بالقوه اثربخشی درمان را افزایش داده و عوارض جانبی را کاهش می‌دهد. مدل‌های سببی همچنین نقش مهمی در درک پیشرفت بیماری دارند. آن‌ها می‌توانند داده‌های طولی بیمار را تجزیه و تحلیل کنند تا عواملی را که منجر به پیشرفت بیماری می‌شوند شناسایی کنند و در نتیجه به استراتژی‌های مداخله زودهنگام کمک کنند. در توسعه دارو، استنتاج سببی می‌تواند یک تغییر دهنده بازی باشد. این روش می‌تواند با درک مسیرهای سببی سلول‌های سرطانی، درمان‌های جدید بالقوه یا اهداف دارویی را شناسایی کند و منجر به توسعه داروهای مؤثرتر شود. علاوه بر این، استنتاج سببی می‌تواند به کاهش سوگیری‌ها در مدل‌های سنتی یادگیری ماشینی کمک کند، که گاهی اوقات سوگیری‌های موجود در داده‌های آموزشی را تکرار می‌کنند. با شناسایی و اصلاح این سوگیری‌ها، مدل‌ها دقیق‌تر و منصفانه‌تر می‌شوند. گذار از مدل‌های پیش‌بینی‌کننده به مدل‌های توضیحی در یادگیری ماشینی برای سرطان‌شناسی بسیار مهم است. مدل‌های توضیحی بینش‌هایی در مورد اینکه چرا برخی از درمان‌ها مؤثر هستند یا چرا برخی از بیماران نتایج بهتری دارند، ارائه می‌دهند و در نتیجه فرآیند تصمیم‌گیری را برای پزشکان بهبود می‌بخشند. توانایی مدل‌های استنتاج علی در ادغام منابع داده متنوع، از جمله عوامل ژنتیکی، محیطی و سبک زندگی، درک جامع‌تری از سرطان ارائه می‌دهد. این ادغام نه تنها برای درمان، بلکه برای سیاست‌گذاری و برنامه‌ریزی مراقبت‌های بهداشتی نیز بسیار مهم است و تخصیص مؤثر منابع را تضمین می‌کند.

ادبیات اخیر شاهد نمونه‌های قابل توجهی در این راستا است، به عنوان مثال، Lagemann و همکارانش [38] یک مدل عصبی را بررسی می‌کنند که شبکه‌های عصبی کانولوشن و گراف را ترکیب می‌کند. هدف این کار درک روابط علی در مسائل زیست‌پزشکی با ابعاد بالا است که یک حوزه حیاتی در تحقیقات سرطان‌شناسی است. این مطالعه بر چالش‌ها و روش‌های یادگیری روابط علی تحت شرایط داده‌های محدود تأکید می‌کند، که اغلب در تحقیقات بیولوژیکی و پزشکی رایج است. ML می‌تواند [39] در طبقه‌بندی و پیش‌بینی پاسخ‌های درمانی در سرطان‌های با منشأ اولیه ناشناخته به کار گرفته شود. به طور خاص، نویسندگان پیشرفت قابل توجهی را که در استفاده از داده‌های ژنومی و هوش مصنوعی برای بهبود تشخیص و برنامه‌های درمانی برای چنین سرطان‌هایی حاصل شده است، برجسته می‌کنند. کار Buijsman که در [40]، Synthese ارائه شده است، به جنبه وسیع‌تری از توضیحات علی مشتق شده از مدل‌های ML می‌پردازد. اگرچه منحصر به سرطان‌شناسی متمرکز نیست، اما بینش‌های ارزشمندی در مورد چگونگی کمک استنتاج علی در ML به درک علمی ارائه می‌دهد، که در زمینه بیماری‌های پیچیده‌ای مانند سرطان ضروری است. در نهایت، Chu و همکارانش [41] پیشرفت‌های حاصل شده در زمینه علی را بررسی می‌کنند.

تخمین اثر. این مقاله چالش‌های پیش روی این حوزه و جهت‌گیری بالقوه آینده را مورد بحث قرار می‌دهد، که به درک اثرات درمان و پیامدهای بیمار در انکولوژی بسیار مرتبط است.

باید توجه داشت که ادغام استنتاج علی در یادگیری ماشینی فقط یک پیشرفت فنی نیست؛ بلکه یک تغییر الگو در سرطان‌شناسی است. این امر امکان‌اتی را برای درمان و تحقیقات سرطان مؤثرتر، شخصی‌سازی‌شده‌تر و آگاهانه‌تر فراهم می‌کند و باور قبلی مبنی بر اینکه یادگیری ماشینی برای این حوزه مناسب نیست را به چالش می‌کشد.

۳.۸. مسائل مربوط به سوگیری و انصاف داده‌ها

عدالت داده‌ها در یادگیری ماشینی به رفتار عادلانه با گروه‌های مختلف در داده‌های مورد استفاده برای آموزش مدل‌های یادگیری ماشینی اشاره دارد. [42] این مفهوم بر اطمینان از این امر تمرکز دارد که داده‌های مورد استفاده برای آموزش مدل، نماینده‌ی گروه‌ها باشند و به نفع یا به ضرر هیچ گروه خاصی نباشند. نمونه‌ای از مسئله‌ی عدالت داده‌ها را می‌توان به عنوان مجموعه داده‌ای که برای آموزش یک مدل استخدام شامل کاندیداهای عمدتاً مرد استفاده می‌شود، توصیف کرد. این مدل ممکن است هنگام ارزیابی کاندیداهای زن عملکرد خوبی نداشته باشد. دستیابی به عدالت داده‌ها شامل ایجاد تعادل و نمایندگی کافی از گروه‌های مختلف است.

با توجه به زمینه، این مطالعه احتمالاً روش‌ها و چارچوب‌هایی را برای شناسایی و کاهش سوگیری‌ها در محتوای روزنامه‌نگاری بررسی می‌کند. این امر برای ارتقای بی‌طرفی و انصاف در گزارش اخبار ضروری است، که برای حفظ اعتماد و اعتبار در رسانه‌های جمعی بسیار مهم است. کاربرد علوم داده و تکنیک‌های تحلیلی در این حوزه، نشان‌دهنده تقاطع یادگیری ماشینی، مطالعات رسانه‌ای و اخلاق است.

سوگیری می‌تواند بر مجموعه داده‌های مورد استفاده برای آموزش یک مدل یادگیری ماشینی تأثیر بگذارد. [43] سوگیری‌ها در داده‌ها می‌توانند به اشکال مختلفی بروز کنند، از جمله (i) سوگیری انتخاب زمانی که گروه‌های خاصی ممکن است کمتر از حد واقعی نشان داده شوند یا از مجموعه داده‌ها حذف شوند، (ii) سوگیری برچسب‌گذاری، زمانی که خطاها یا سوگیری‌هایی در فرآیند برچسب‌گذاری رخ می‌دهد، (iii) سوگیری اجتماعی، که منعکس‌کننده تعصبات تاریخی یا اجتماعی علیه گروه‌های جمعیتی خاص است؛ و در نهایت، (iv) سوگیری نمونه، زمانی که مجموعه داده‌ها ممکن است به طور دقیق جمعیت وسیع‌تر را نشان ندهد. به عنوان مثال، یک سیستم تشخیص چهره که به دلیل کم بودن تعداد افراد در داده‌های آموزشی، در قومیت‌های خاص عملکرد ضعیفی دارد، نشان‌دهنده سوگیری است. مثال دیگر، یک الگوریتم استخدام است که کاندیداهایی با پیشینه‌های تحصیلی خاص را ترجیح می‌دهد و منجر به تبعیض علیه دیگران می‌شود. سوگیری در یادگیری ماشینی می‌تواند در مراحل مختلف فرآیند توسعه و استقرار وجود داشته باشد. این سوگیری اغلب از داده‌های سوگیرانه مورد استفاده برای آموزش مدل‌ها سرچشمه می‌گیرد. اگر داده‌های آموزشی حاوی سوگیری‌های تاریخی باشند یا نابرابری‌های اجتماعی را منعکس کنند، مدل ممکن است این سوگیری‌ها را یاد بگیرد و تداوم بخشد. علاوه بر این، سوگیری می‌تواند از طریق انتخاب ویژگی‌ها، طراحی الگوریتم و حتی فرآیند برچسب‌گذاری داده‌های آموزشی ایجاد شود. سوگیری می‌تواند از طریق حلقه‌های بازخورد منتشر شود، زیرا پیش‌بینی‌های سوگیرانه ممکن است نابرابری‌های موجود را تقویت و تشدید کنند. سوگیری در داده‌ها یک مسئله فراگیر است، زیرا مجموعه داده‌ها اغلب سوگیری‌ها و نابرابری‌های موجود در جامعه را منعکس می‌کنند. سوگیری‌های تاریخی و اجتماعی می‌توانند در حوزه‌های مختلف، از جمله عدالت کیفری، ریشه داشته باشند (برای مثال، به مورد [44] COMPAS اشتغال، [45] مراقبت‌های بهداشتی [46] و امور مالی [47] مراجعه کنید).

داده‌های جانبدارانه می‌توانند ناشی از تبعیض تاریخی، کلیشه‌های فرهنگی یا نابرابری‌های سیستماتیک باشند که منجر به کم‌نمایی یا نادرس‌تی گروه‌های خاص می‌شود. جدول 5 انواع اصلی سوگیری را خلاصه می‌کند.

توضیحات	تعصب
سوگیری انتخاب: برخی از گروه‌ها ممکن است کمتر از حد واقعی نمایش داده شده باشند یا از مجموعه داده‌ها حذف شده باشند.	
سوگیری در برچسب‌گذاری خطاها یا سوگیری‌ها در فرآیند برچسب‌گذاری می‌توانند باعث ایجاد بی‌دقتی شوند.	
سوگیری اجتماعی: سوگیری‌ها یا اجتماعی علیه گروه‌های جمعیتی خاص است.	
مجموعه داده‌ها ممکن است به طور دقیق نماینده جمعیت وسیع‌تر نباشد.	سوگیری نمونه

تعصب در یادگیری ماشینی می‌تواند به طور قابل توجهی اعتماد را از بین ببرد. وقتی کاربران درک می‌کنند که یک سیستم نتایج ناعادلانه یا جانبدارانه‌ای تولید می‌کند، اعتماد به فناوری را تضعیف می‌کند. عدم اعتماد می‌تواند منجر به مقاومت در برابر پذیرش راه‌حل‌های هوش مصنوعی، به ویژه در زمینه‌های حیاتی مانند مراقبت‌های بهداشتی، مالی و عدالت کیفری شود. این مشکل واقعاً جدی است. تعصب کنترل نشده می‌تواند تداوم یابد.

و نایربرای‌های اجتماعی را تشدید می‌کنند و منجر به نتایج تبعیض‌آمیز می‌شوند. علاوه بر این، سیستم‌های هوش مصنوعی مغرضانه ممکن است منجر به آسیب در دنیای واقعی شوند، بر زندگی افراد تأثیر بگذارند و نایربرای‌های سیستمی را تقویت کنند. اگر به طور مؤثر به آن پرداخته نشود، فقدان انصاف و شفافیت در سیستم‌های هوش مصنوعی می‌تواند به طور بالقوه منجر به شک و تردید عمومی، بررسی نظارتی و کاهش اعتماد عمومی و نهادی شود. اگرچه ممکن است زمستان جدیدی در هوش مصنوعی ایجاد نکند، اما می‌تواند مانع پذیرش مسئولانه و گسترده فناوری‌های هوش مصنوعی شود. بنابراین، تلاش‌ها برای کاهش تعصب، تضمین انصاف و افزایش شفافیت در یادگیری ماشین برای توسعه پایدار و اخلاقی آن بسیار مهم است. رازا و همکاران. [48] بر موضوع حیاتی تشخیص تعصب و انصاف در مقالات خبری تمرکز دارند. این تحقیق به ویژه در عصر رسانه‌های دیجیتال، جایی که محتوای اخبار می‌تواند تأثیر قابل توجهی بر افکار عمومی و دیدگاه‌های اجتماعی داشته باشد، مرتبط است. در [49] همین نویسندگان، در اثری متفاوت، یک چارچوب جامع هوش مصنوعی را پیشنهاد می‌کنند که اصول مهندسی نرم‌افزار را با انصاف در یادگیری ماشین، به ویژه برای کاربردهای مراقبت‌های بهداشتی، ترکیب می‌کند. این چارچوب برای بهبود مدولار بودن، قابلیت نگهداری و مقیاس‌پذیری طراحی شده است. این مرحله با شناسایی بازیگران کلیدی و نقش‌های آنها آغاز می‌شود و بر اهمیت درک کاربران برای ارائه جهت برای چارچوب تأکید دارد. در ادامه، تجزیه و تحلیل الزامات انجام می‌شود که در آن مشکلات موجود در مراقبت‌های بهداشتی که نیاز به رسیدگی دارند، همراه با الزامات خاص انصاف، با در نظر گرفتن پیامدهای اخلاقی، قانونی و اجتماعی، شناسایی می‌شوند. جمع‌آوری داده‌ها یک گام حیاتی است که بر جمع‌آوری نمونه‌های داده متنوع و نماینده ضمن تضمین حریم خصوصی و امنیت داده‌ها تمرکز دارد. در پیش‌پردازش داده‌ها، از بهترین شیوه‌ها برای پاکسازی و نرمال‌سازی داده‌ها استفاده می‌شود و تکنیک‌های پیش‌پردازش انصاف برای به حداقل رساندن سوگیری‌ها پیاده‌سازی می‌شوند. انتخاب ویژگی و مهندسی شامل شناسایی ویژگی‌های مرتبط و استفاده از دانش دامنه برای ایجاد ویژگی‌های معناداری است که به انصاف کمک می‌کنند. مرحله انتخاب و آموزش مدل، اصول مهندسی نرم‌افزار را در نظر می‌گیرد و از تکنیک‌های انصاف در پردازش در طول آموزش مدل استفاده می‌کند. سپس عملکرد مدل با استفاده از معیارهای استاندارد و خاص انصاف ارزیابی می‌شود و پس از آن تنظیم فرآیند و اعمال تکنیک‌های انصاف پس از پردازش برای اصلاح پیش‌بینی‌ها انجام می‌شود. در نهایت، مدل در یک محیط تولید مستقر و به طور مداوم پایش می‌شود و به بهترین شیوه‌های مهندسی نرم‌افزار پایبند است.

ارزیابی منظم مدل روی داده‌های جدید برای اطمینان از بی‌طرفی و تعمیم‌پذیری آن در طول زمان مهم است. بازخورد کاربر نیز در اعتبارسنجی رویکرد چارچوب بسیار مهم است و نقش علوم تجربی را در مهندسی نرم‌افزار برجسته می‌کند.

۳.۹. علم و شبه‌علم

علم و شبه‌علم با روش‌شناسی‌ها، اصول و اعتبار ادعاهایشان از هم متمایز می‌شوند. دقت در تعریف هر مفهوم برای درک ویژگی‌های متمایز آنها بسیار مهم است. علم تلاشی سیستماتیک و تجربی است که با هدف کسب دانش در مورد جهان طبیعی از طریق مشاهده، آزمایش و تدوین فرضیه‌های قابل آزمایش انجام می‌شود. این علم بر یک رویکرد روش‌شناختی دقیق، که اغلب به عنوان روش علمی از آن یاد می‌شود، متکی است که شامل (۱) جمع‌آوری داده‌ها و مشاهده پدیده‌های طبیعی؛ (۲) ارائه توضیحی قابل آزمایش و ابطال‌پذیر برای پدیده‌های مشاهده شده؛ (۳) انجام آزمایش‌های کنترل‌شده برای آزمودن فرضیه؛ (۴) تجزیه و تحلیل نتایج برای نتیجه‌گیری؛ (۵) قرار دادن یافته‌ها در معرض بررسی دقیق و اعتبارسنجی توسط جامعه علمی است. ویژگی‌های کلیدی تلاش‌های علمی شامل شواهد تجربی، ابطال‌پذیری، تکرارپذیری و تعهد به اصلاح نظریه‌ها بر اساس شواهد جدید است. دانش علمی موقتی است و با تکامل درک ما، در معرض اصلاح قرار می‌گیرد. در مقابل، از سوی دیگر، شبه‌علم به فعالیت‌ها، باورها یا ادعاهایی اشاره دارد که به عنوان علمی ارائه می‌شوند اما فاقد روش‌شناسی دقیق و مبنای تجربی تحقیق علمی اصیل هستند. ویژگی‌های شبه‌علم شامل موارد زیر است: (۱) فقدان شواهد تجربی یا اتکا به شواهد روایی به جای مشاهده سیستماتیک؛ (۲) ابطال‌ناپذیری، زیرا نظریه‌های شبه‌علمی اغلب به گونه‌ای ساخته می‌شوند که آنها را در برابر ابطال یا رد مصون می‌کند؛ (۳) ایده‌های شبه‌علمی معمولاً فاقد بررسی و اعتبارسنجی توسط جامعه علمی گسترده‌تر از طریق فرآیندهای بررسی همتا هستند؛ (۴) اتکا به حکایات، زیرا شبه‌علم اغلب به جای جمع‌آوری سیستماتیک داده‌ها، به توصیفات یا داستان‌های شخصی متکی است؛ (۵) پایداری باور با وجود تناقضات

شواهد و عدم سازگاری با اطلاعات جدید. نمونه‌هایی از شبه‌علم شامل طالع‌بینی، هومیوپاتی و ادعاهای مختلف ماوراءالطبیعه است. توجه به این نکته مهم است که اصطلاح «شبه‌علم» لزوماً به معنای فریب عمدی نیست؛ افراد ممکن است به دلیل سوگیری‌های شناختی یا عدم درک اصول علمی، صادقانه به ایده‌های شبه‌علمی اعتقاد داشته باشند.

اگرچه یک مدل یادگیری ماشینی جانبدارانه ممکن است خروجی‌هایی تولید کند که منعکس‌کننده یا حتی تقویت‌کننده تعصبات موجود (مانند نژادپرستی و تبعیض جنسی) باشد، اما دست‌هبندی چنین مدلی به عنوان شبه‌علم، ساده‌انگاری بیش از حد خواهد بود. تعصبات در مدل‌های یادگیری ماشینی را می‌توان از طریق تجزیه و تحلیل دقیق، ارزیابی مجدد داده‌ها و بهبود الگوریتم‌ها شناسایی و کاهش داد. آن‌ها وابسته به زمینه هستند و می‌توان آن‌ها را به داده‌ها و فرآیندهای مربوطه ردیابی کرد. اگرچه یادگیری ماشینی یک علم طبیعی سنتی به معنای فیزیک یا شیمی نیست، اما با تحقیقات علمی مشترکات دارد. این علم شامل آزمایش فرضیه، آزمایش و فرآیندهای اعتبارسنجی است، اگرچه تأکید اغلب بر دقت پیش‌بینی به جای توضیحات علی است.

۳.۱۰ یادگیری عمیق، یادگیری بین‌رشته‌ای و یادگیری انسانی

یادگیری تقویتی و یادگیری انسانی مبتنی بر تنبیه و جبران، در اصول بنیادی یادگیری از طریق بازخورد از طریق سیستم پاداش و جریمه، شباهت‌هایی دارند.

الگوریتم‌های یادگیری تقویتی (RL) بر اساس یک حلقه بازخورد عمل می‌کنند که در آن یک عامل بر اساس اقدامات خود، بازخوردی را به شکل پاداش یا جریمه دریافت می‌کند. الگوریتم یاد می‌گیرد که رفتار خود را بهینه کند تا پاداش‌های تجمعی را در طول زمان به حداکثر برساند. انسان‌ها اغلب از طریق یک مکانیسم بازخورد مشابه یاد می‌گیرند. تجربیات یا نتایج مثبت شبیه پاداش‌ها هستند و تکرار رفتارهای خاص را تشویق می‌کنند، در حالی که تجربیات یا پیامدهای منفی به عنوان مجازات عمل می‌کنند و از اقدامات نامطلوب جلوگیری می‌کنند. از سوی دیگر، یادگیری تقویتی شامل چالش اختصاص اعتبار به اقدامات گذشته است که به نتایج فعلی کمک می‌کنند. الگوریتم باید بفهمد کدام اقدامات منجر به پاداش یا جریمه شده‌اند، حتی اگر از نظر زمانی از نتیجه دور باشند. به طور مشابه، انسان‌ها اغلب نیاز دارند عواقب، چه مثبت و چه منفی، را به اقدامات خاص انجام شده در گذشته نسبت دهند. این درک، تصمیم‌گیری‌های آینده را برای تکرار اقدامات موفق یا اجتناب از موارد مرتبط با نتایج منفی آگاه می‌کند. جالب اینجاست که مدل‌های یادگیری تقویتی اغلب نیاز دارند دانش به دست آمده در یک زمینه را تعمیم دهند تا در موقعیت‌های جدید و نادیده عملکرد خوبی داشته باشند، برخلاف انسان‌هایی که ظرفیت تعمیم‌پذیری را نشان می‌دهند و درس‌های آموخته شده از یک حوزه را برای تصمیم‌گیری آگاهانه در موقعیت‌های جدید یا مرتبط به کار می‌برند.

می‌توان توازی مشابهی را بین IL و یادگیری انسان برقرار کرد. نورون‌های آینه‌ای، واحدهای عصبی تخصصی هستند که ویژگی متمایزی را نشان می‌دهند. فعال شدن آنها نه تنها در طول اجرای یک عمل خاص توسط یک فرد، بلکه با مشاهده انجام یک عمل مشابه توسط فرد دیگر نیز رخ می‌دهد.

این ویژگی متمایز پاسخ دوگانه، نقش محوری نورون‌های آینه‌ای را در درک و تفسیر اعمال دیگران نشان می‌دهد و در نتیجه، تشدید همدلانه با حالات و نيات عاطفی آنها را تسهیل می‌کند. شناسایی نورون‌های آینه‌ای در قشر پیش‌حرکتی میمون (PMC) توسط ریزولاتی و همکارانش [50,51] در اوایل دهه ۱۹۹۰ چشم‌انداز درک ما از بسترهای عصبی شناخت اجتماعی را متحول کرد. تحقیقات بعدی، وجود نورون‌های آینه‌ای را در مناطق مختلف مغزی، از جمله شکنج پیشانی تحتانی (IFG)، ناحیه حرکتی تکمیلی (SMA) و اینسولا اثبات کرده‌اند. فرض بر این است که فعال شدن نورون‌های آینه‌ای در طول مشاهده اعمال، از پدیده‌ای به نام "تشدید حرکتی" ناشی می‌شود. این مکانیسم مستلزم شبیه‌سازی اعمال مشاهده شده در سیستم حرکتی انسان است و فعالیت عصبی مشابه فعالیتی را که در صورت اجرای عمل مشاهده شده ایجاد می‌شود، منعکس می‌کند. این فرآیند شبیه‌سازی، درک نیت و هدف زیربنایی عمل مشاهده شده را ایجاد می‌کند و در نتیجه، پاسخ‌های همدلانه و تعاملات اجتماعی را تسهیل می‌کند. نورون‌های آینه‌ای در طیف گسترده‌ای از فرآیندهای شناختی اجتماعی، شامل زمینه‌های تحقیقاتی مختلف، نقش دارند. نقش نورون‌های آینه‌ای از تفاسیر مختلف پشتیبانی می‌کند [52] به عنوان مثال، آنها درک اهمیت و هدف اعمال مشاهده شده را تقویت می‌کنند و توانایی ... را فراهم می‌کنند.

نتایج احتمالی چنین اعمالی را پیش‌بینی می‌کنند. به همین ترتیب، آنها کسب مهارت‌ها و رفتارهای جدید را از طریق یادگیری مشاهده‌ای تسهیل می‌کنند و افراد را قادر می‌سازند تا اعمال نشان داده شده توسط دیگران را تقلید و اتخاذ کنند. نورون‌های آینه‌ای با تسهیل تشدید عاطفی مشترک با دیگران، و تقویت درک بهتر از احساسات و دیدگاه‌های آنها، به طور قابل توجهی در تجربه همدلی نقش دارند. علاوه بر این، آنها می‌توانند در نظریه ذهن، ظرفیت نسبت دادن حالات ذهنی به خود و دیگران، نقش داشته باشند و از این طریق درک باورها، نیات و خواسته‌های افراد دیگر را ممکن سازند.

در واقع، علیرغم حوزه‌ها و مکانیسم‌های مختلف درگیر، شباهت‌های قابل توجهی بین IL در حوزه یادگیری ماشین و یادگیری تقلیدی در علوم شناختی وجود دارد (به [53] مراجعه کنید).

هر دو حوزه از مفهوم یادگیری از رفتار مشاهده‌شده بهره می‌برند، البته با روش‌ها و اهداف متمایز. اولاً، IL شامل آموزش یک مدل با مشاهده نمایش‌های یک کار انجام‌شده توسط یک متخصص است. مدل یاد می‌گیرد که از اعمال و رفتار متخصص تقلید کند. به طور مشابه، افراد اعمال دیگران را به عنوان بخشی از فرآیند یادگیری اجتماعی مشاهده و تقلید می‌کنند. ثانیاً، انتقال دانش در هر دو حوزه اعمال می‌شود. IL امکان انتقال دانش از یک عامل آگاه (نمایش‌دهنده) به یک عامل یادگیری را فراهم می‌کند و دومی را قادر می‌سازد تا بدون قوانین صریح برنامه‌ریزی‌شده، مهارت‌ها را کسب کند. از سوی دیگر، تقلید در توسعه شناختی به افراد اجازه می‌دهد تا با مشاهده و تکرار رفتارهای دیگران در محیط اجتماعی خود، دانش را منتقل کرده و مهارت‌های جدید کسب کنند.

سوم، IL اغلب شامل یادگیری ضمنی است، که در آن الگوریتم یادگیری، الگوها و استراتژی‌ها را از نمایش‌های مشاهده‌شده بدون آموزش صریح استخراج می‌کند. در عین حال، کودکان -برای مثال- در یادگیری تقلیدی ضمنی شرکت می‌کنند، زیرا بدون آموزش صریح، اعمال را در محیط خود مشاهده و تکرار می‌کنند. با این حال، شباهت‌های دیگری نیز وجود دارد.

برای مثال، مدل‌های IL می‌توانند با تغییرات محیط سازگار شوند و رفتارهای آموخته‌شده خود را به موقعیت‌های جدید و نادیده تعمیم دهند. برخلاف افراد که می‌توانند رفتارهای آموخته‌شده را با زمینه‌های مختلف سازگار کنند و مهارت‌های کسب‌شده از طریق تقلید را به موقعیت‌های مختلف تعمیم دهند. AL همچنین در توسعه عامل‌های هوشمند اجتماعی بسیار مهم است و به آنها اجازه می‌دهد تا به طور مؤثر با انسان‌ها و سایر عامل‌ها تعامل داشته باشند و در محیط‌های مبهم یا پیچیده که نگاشت بین اعمال و نتایج ساده نیست، به خوبی در برابر چالش‌ها واکنش نشان دهند.

۴. کارهای مرتبط

این بخش، دیدگاه‌های مختلفی را در مورد جنبه‌های روش‌شناختی یادگیری ماشینی در بر می‌گیرد. این بخش در سه زیربخش بیان شده است که به بررسی (۱) دیدگاه یادگیری ماشینی به عنوان یک علم لادری، (۲) اصرار بر اعتبارسنجی روش علمی به کار رفته توسط یادگیری ماشینی، و در نهایت (۳) مشارکت‌های موفق در یادگیری ماشینی به عنوان یک علم در سایر رشته‌ها می‌پردازد. یک زیربخش اختصاصی، اصالت مشارکت حاضر در مورد ادبیات علمی را بررسی می‌کند.

۴.۱. یادگیری ماشین به عنوان علم لادری مسئله تفسیرپذیری در حوزه یادگیری ماشین بیش از پیش ضروری شده است، اگرچه تعریف روشنی از این اصطلاح به هیچ وجه روشن نیست. به عنوان مثال، کریشنان [54] ادعا می‌کند که تفسیر در چارچوب سیستم‌های یادگیری ماشین به روشن‌سازی یا ارائه اطلاعات به صورت قابل فهم اشاره دارد. در این حوزه، تفسیرپذیری رسماً به عنوان ظرفیت توضیح یا ارائه اطلاعات به شیوه‌ای قابل فهم برای انسان تعریف می‌شود. در یک چارچوب دقیق، شفافیت مدل با امکان‌سنجی یک فرد برای تأمل همزمان در کل مدل، همانطور که توسط لیپتون و همکاران [55] پیشنهاد شده است، با تأکید ویژه بر ماهیت فراگیر این شفافیت، مشخص می‌شود. جنبه ثانویه شفافیت شامل دسترسی به توضیحات شهودی برای هر مؤلفه مدل، از جمله ورودی‌ها، پارامترها و محاسبات است. در بازنمایی که به عنوان "شفاف" شناخته می‌شود، حالت‌های یک سیستم به شیوه‌ای که قابل بررسی، تحلیل، تفسیر و درک صریح توسط انسان باشد، به تصویر کشیده می‌شوند. علاوه بر این، گذار بین این حالت‌ها توسط قوانینی که دارای ویژگی‌های تفسیری مشابهی هستند، مشخص می‌شود.

ناپولتانی و همکاران [56] در مورد نقش ریاضیات محاسباتی که با توجه به رشته‌های جدید مانند ژنومیک، تکنیک‌های کلان داده و علم داده تغییر کرده است، تجدید نظر می‌کنند. نویسندگان چهار روش‌شناسی را برای روشن شدن رویکرد یادگیری ماشینی معرفی می‌کنند، یعنی (i) الگوی ریزآرایه، (ii) برتری پدیده‌های تاریخی، (iii) مفهوم‌سازی فرآیندهای توسعه‌ای، و در نهایت، (iv) اصل اجبار. در مورد الگوی ریزآرایه، محققان معتقدند که حجم بالایی از داده‌ها در مورد یک پدیده، که به موقع مورد پرسش قرار می‌گیرند، می‌تواند بینش معناداری در مورد خود پدیده ارائه دهند. نویسندگان اظهار می‌کنند که در الگوی ریزآرایه، راه‌حل‌ها از طریق یک فرآیند خودکار برازش داده‌ها به مدل‌هایی عاری از هرگونه درک ساختاری ذاتی فراتر از حل فوری مسئله، به دست می‌آیند. به این معنا، آنها نظریه "علم اگنوستیک" را تدوین می‌کنند. برتری پدیده‌های تاریخی توسط مفهوم چشم‌انداز تناسب اندام (نمایشی استعاری از رابطه بین ساختار ژنتیکی موجودات زنده و توانایی آنها برای بقا و تولید مثل در یک محیط خاص) پشتیبانی می‌شود و به نویسندگان این امکان را می‌دهد که استنباط کنند که بازه زمانی برای گذار از یک فرآیند بهینه‌سازی محلی به فرآیند بهینه‌سازی دیگر در توسعه چنین پدیده‌هایی، به طور قابل توجهی طولانی‌تر از زمان مورد نیاز برای خود فرآیندهای بهینه‌سازی است. به گفته نویسندگان، مفهوم‌سازی فرآیندهای توسعه‌ای را می‌توان با در نظر گرفتن نظریه تکامل، که نشان می‌دهد چگونه یک چارچوب کیفی می‌تواند درک کمی ایجاد کند، درک کرد. علیرغم ماهیت غیر ریاضی و عدم پیش‌بینی‌های کمی، ساختار منطقی ذاتی و چارچوب مفهومی این نظریه به عنوان سنگ بنای تحقیقات بیولوژیکی عمل کرده و از زمان آغاز آن، توسعه مدل‌های ریاضی خاص را تقویت کرده است. در نهایت، اصل اجبار شامل این مفهوم است که تکنیک‌های متمایز مختلف، که برای اعمال مفاهیم ریاضی پیشرفته در مسائل تجربی توسعه یافته‌اند، می‌توانند تحت یک دیدگاه روش‌شناختی مشترک متحد شوند. این دیدگاه حول ایده اعمال سیستماتیک ایده‌ها و روش‌های ریاضی بر روی داده‌ها می‌چرخد. در نتیجه، طبق گفته ناپولتانی و همکارانش، مفهوم پدیده‌های تاریخی و اصل اجبار، عمدتاً در چارچوب مجموعه داده‌های گسترده مرتبط به نظر می‌رسند، بنابراین وابستگی عمیقی به الگوی ریزآرایه نشان می‌دهند. بیان پدیده‌های تاریخی ذاتاً تمرکز را از حالت‌های پدیده‌ها به سمت فرآیندهای توسعه‌ای که باعث ایجاد آنها می‌شوند، تغییر می‌دهد. ناپولتانی و همکارانش [57] به بررسی این موضوع که از اصل اجبار الهام گرفته شده است، پرداخته‌اند. نویسندگان ادعا می‌کنند که روش‌های بهینه‌سازی متعددی را می‌توان به عنوان نمونه‌ای از مفهوم اجبار در نظر گرفت. این امر حتی در مواردی که مدل‌های دقیق و معتبر یک پدیده وجود ندارند یا نمی‌توانند کاربرد این تکنیک را اثبات کنند، رخ می‌دهد. به طور خاص، مفهوم اجبار در روش‌های بهینه‌سازی ازدحام ذرات و مدل‌سازی مبتنی بر بهینه‌سازی مسائل پردازش تصویر نشان داده شده است. از این مشاهدات، یک اصل قابل اجرا برای روش‌های کلی تجزیه و تحلیل داده‌ها، به نام «اصل برانت» استخراج می‌شود. این اصل فرض می‌کند که الگوریتمی که به حالت پایدار در خروجی خود دست می‌یابد، به طور مؤثر یک مشکل را حل کرده یا نیاز به جایگزینی دارد. در نهایت، فرض بر این است که سیستم‌های بیولوژیکی و پدیده‌هایی که از اصول کلی مورفوژنتیک پیروی می‌کنند، زمینه‌ای طبیعی برای کاربرد این اصل هستند.

نظریه تحلیل داده‌ها به عنوان «علم اگنوستیک» توسط ناپولتانی و همکارانش [58,59] بیشتر مورد بررسی قرار گرفته است. آنها معتقدند که علم داده، رویکردی منسجم و نوآورانه به چالش‌های تجربی است که در وسیع‌ترین معنای خود، به درک پدیده‌ها کمک نمی‌کند. در ریاضی‌سازی نوین ذاتی علم داده، تکنیک‌های ریاضی بر اساس ارتباط آنها با یک مسئله خاص انتخاب نمی‌شوند؛ بلکه از طریق فرآیند «اجبار» به کار گرفته می‌شوند. این شامل کاربرد روش‌های ریاضی برای یک مسئله خاص صرفاً بر اساس ظرفیت آنها در سازماندهی مجدد داده‌ها برای تجزیه و تحلیل بعدی و غنای ذاتی ساختار ریاضی آنها است. به طور خاص، ما معتقدیم که درک جامعی از شبکه‌های عصبی DL در چارچوب روش‌های بهینه‌سازی اجباری پدیدار می‌شود. در نهایت، ما به بررسی گسترده‌تر در مورد مناسب بودن روش‌های علم داده در حل مسئله می‌پردازیم. استدلال ما تأکید می‌کند که این تحقیق نباید به عنوان تلاشی برای همبستگی بین پدیده‌ها و راه‌حل‌های خاص تولید شده توسط روش‌های علم داده تعبیر شود. در عوض، تمرکز

در مورد روشن کردن ساختار داخلی روش‌های علم داده از طریق اشکال دقیق درک است.

۴.۲. مباحث پیرامون اعتبار یک روش علمی در یادگیری ماشینی

رویکردهای روش‌شناختی در تحقیقات یادگیری ماشینی را می‌توان با دقت بیشتری بررسی کرد. به عنوان مثال، مرجع [60] شکاف بین شیوه‌های فعلی یادگیری ماشینی و روش علمی سنتی، به ویژه در زمینه‌های تدوین فرضیه و آزمایش آماری را برجسته می‌کند. نویسندگان معتقدند که تحقیقات یادگیری ماشینی اغلب فاقد دقت سیستماتیک موجود در سایر رشته‌های علمی است. آنها طرفدار گنجاندن روش‌های علوم تجربی در یادگیری ماشینی، از جمله طرح‌های آزمایشی کنترل‌شده، قابل تکرار و قابل تأیید، هستند. آنها استدلال می‌کنند که این امر نه تنها علم بنیادی یادگیری ماشینی را بهبود می‌بخشد، بلکه کیفیت و قابلیت اطمینان تحقیقات کاربردی یادگیری ماشینی را نیز افزایش می‌دهد. از زاویه‌ای متفاوت، کرن و همکاران [61] بررسی می‌کنند که چگونه هوش مصنوعی (AI) می‌تواند به درک علمی کمک کند. این مقاله یک چارچوب فلسفه علم برای ارزیابی نقش هوش مصنوعی در درک علمی ارائه می‌دهد و سه بُعد را که هوش مصنوعی می‌تواند در آنها نقش داشته باشد، شناسایی می‌کند: به عنوان یک میکروسکوپ محاسباتی، به عنوان منبع الهام و به عنوان یک عامل درک. هر بُعد از طریق مثال‌های مختلف بررسی می‌شود و پتانسیل هوش مصنوعی برای آشکار کردن بینش‌های علمی جدید، الهام بخشیدن به ایده‌های جدید و توسعه بالقوه درک علمی جدید به صورت مستقل را برجسته می‌کند. این مقاله بر تمایز بین کشف علمی و درک تأکید می‌کند و نقش هوش مصنوعی را در پیشرفت دانش علمی برجسته می‌سازد.

ون کالستر و همکارانش [62] در مورد اهمیت کالیبراسیون الگوریتم‌های پیش‌بینی در تصمیم‌گیری بالینی بحث می‌کنند. کالیبراسیون‌های نادرست می‌تواند منجر به انتظارات نادرست و تصمیمات گمراه‌کننده شود و بر نیاز به مدل‌های پیش‌بینی که برای جمعیت و محیط خاص به خوبی کالیبره شده باشند، تأکید می‌کنند. ناهمگونی جمعیت‌های بیمار و تغییر پویایی مراقبت‌های بهداشتی، نظارت و به‌روزرسانی مداوم مدل‌ها را ضروری می‌سازد.

هدف کلی، افزایش اثربخشی تحلیل‌های پیش‌بینی‌کننده در تصمیم‌گیری مشترک و مشاوره بیمار است.

واروکاکس و همکارانش [63] مجموعه‌ای جامع از دستورالعمل‌ها را برای پیاده‌سازی و ارزیابی مؤثر یادگیری ماشینی در حوزه تصویربرداری پزشکی ارائه می‌دهند. این کار بر نیاز حیاتی به یکپارچگی داده‌ها تأکید می‌کند و بر جداسازی داده‌های آزمایشی از همان ابتدا برای جلوگیری از نشت داده‌ها تأکید دارد. این سند همچنین بر لزوم داشتن یک روش‌شناسی کاملاً تعریف‌شده برای انتخاب ابرپارامترهای مدل، ضمن اجتناب از استفاده از داده‌های آزمایشی در این فرآیند، تأکید می‌کند. نویسندگان همچنین بر اهمیت داشتن یک مجموعه داده آزمایشی به اندازه کافی بزرگ برای اطمینان از معناداری آماری توصیه می‌کنند و صدها یا در حالت ایده‌آل هزاران نمونه را با معیارهای عملکرد پشتیبانی‌شده توسط فواصل اطمینان توصیه می‌کنند.

این مقاله از استفاده از مجموعه داده‌های متنوع که به طور دقیق ناهمگونی بیمار و بیماری را در چندین موسسه منعکس می‌کنند، حمایت می‌کند و طیف وسیعی از جمعیت‌شناسی و وضعیت بیماری را در بر می‌گیرد. نویسندگان خواستار مقایسه‌های پایه قوی هستند که نه تنها شامل تکنیک‌های پیشرفته یادگیری ماشین، بلکه روش‌های بالینی سنتی نیز باشد. آنها همچنین بر نیاز به بحث انتقادی در مورد تغییرپذیری نتایج، با در نظر گرفتن عناصر تصادفی و منابع داده، تأکید می‌کنند. علاوه بر این، پیشنهاد می‌شود از معیارهای کمی متنوعی برای ثبت جنبه‌های مختلف مشکل بالینی، پیوند دادن آنها به شاخص‌های عملکرد بالینی مرتبط و تصمیم‌گیری آگاهانه در مورد بده بستان بین تشخیص‌های نادرست و خطاها استفاده شود. علاوه بر این، توصیه می‌شود بینش‌های کیفی گنجانده شود و گروه‌هایی که بیشترین تأثیر را از این کاربرد می‌پذیرند، در طراحی معیارهای ارزیابی دخیل شوند.

بوتیلیر و همکاران [64] تعادل بین تحقیقات تجربی و اکتشافی در حوزه یادگیری ماشینی، به ویژه در یادگیری عمیق (DL)، را بررسی می‌کنند. نویسندگان بر اهمیت تحقیقات تجربی در ایجاد یک پایگاه دانش قوی و تضمین پیشرفت علمی پایدار تأکید می‌کنند.

برعکس، تحقیقات اکتشافی به دلیل نقش آن در گسترش افق تحقیق با یافته‌های جدید ارزشمند است. با این حال، توجه به تمرکز بیش از حد بر هر یک از این دو رویکرد مهم است، زیرا می‌تواند منجر به پایه‌های غیرمستحکم شود یا با محدود کردن اکتشاف، مانع پیشرفت شود. انتقادات اخیر در روش‌شناسی یادگیری ماشینی ذکر شده است و بر لزوم درک تعادل بین این دو روش تحقیق تأکید می‌شود. نویسندگان از مثال هنجار دسته‌ای در یادگیری ماشینی برای نشان دادن اهمیت تحقیقات اکتشافی و تجربی استفاده می‌کنند.

نشان می‌دهد که هم‌افزایی بهتر بین این دو می‌تواند منجر به توسعه کارآمدتر و منطقی‌تر در این زمینه شود.

۴.۳. یادگیری ماشین به عنوان یک علم

تیاگالینگام و همکارانش [65] با تأکید بر اهمیت معیارسنجی در این حوزه، از این دیدگاه که یادگیری ماشینی می‌تواند به عنوان یک علم در نظر گرفته شود، حمایت می‌کنند. این مقاله چالش‌ها و رویکردهای موجود در توسعه معیارهای یادگیری ماشینی علمی را مورد بحث قرار می‌دهد و نشان می‌دهد که چگونه این معیارها برای ارزیابی و بهبود الگوریتم‌های یادگیری ماشینی در کاربردهای علمی ضروری هستند.

این مقاله بر نیاز به روش‌های سیستماتیک، تکرارپذیر و قابل تأیید برای ارزیابی تکنیک‌های یادگیری ماشین، که اصول کلیدی در تحقیقات علمی هستند، تأکید می‌کند. این رویکرد برای سنجش در یادگیری ماشین با روش علمی همسو است و آزمایش، ارزیابی و بهبود دقیق الگوریتم‌ها را بر اساس داده‌های تجربی و آزمایش‌های کنترل‌شده پیشنهاد می‌کند.

در [66] محققان تشویق می‌شوند تا استفاده از کاربردهای هوش مصنوعی در آموزش ریاضی را بررسی کنند و بر ارائه راهنمایی‌های شخصی‌سازی‌شده به دانش‌آموزان و بررسی تأثیرات روش‌های یادگیری مبتنی بر هوش مصنوعی تمرکز کنند. یک رویکرد نوآورانه شامل استفاده از داده‌کاوی آموزشی (EDM) برای بررسی عواملی است که بر نتایج دانش‌آموزان و رابطه بین رفتارها و عملکرد دانش‌آموزان تأثیر می‌گذارند. پیاده‌سازی هوش مصنوعی در دوره‌های ریاضی پیشرفته، مانند هندسه، توپولوژی و ریاضیات کاربردی، و همچنین در برنامه‌های بین رشته‌ای مانند STEM می‌تواند بسیار مفید باشد. همچنین نیاز به درک چگونگی کمک هوش مصنوعی به گروه‌های کم‌تأمین‌ده در آموزش ریاضی، از جمله معلمان و دانش‌آموزان دبیرستانی، وجود دارد. فراتر از تجزیه و تحلیل کمی، روش‌های تحقیق کیفی برای جمع‌آوری بازخورد دانش‌آموزان در مورد یادگیری به کمک هوش مصنوعی و بررسی ادراکات آنها مهم است.

توسعه محیط‌های یادگیری تطبیقی در ریاضیات از طریق همکاری بین متخصصان آموزش، فناوری آموزشی و علوم کامپیوتر، یکی دیگر از حوزه‌های کلیدی است. ادغام فناوری‌های مدرن هوش مصنوعی مانند یادگیری عمیق (DL) که ابزارهایی مانند تشخیص تصویر و صدا را ارائه می‌دهند، می‌تواند مزایای منحصر به فردی مانند کمک به دانش‌آموزان کم‌بینا را فراهم کند.

گنجاندن هوش مصنوعی در آموزش ریاضیات، ماهیت علمی آن را برجسته می‌کند. این رویکرد شامل تحقیق و آزمایش سیستماتیک است که برای روش علمی اساسی است. داده‌کاوی آموزشی (EDM) بر نقش هوش مصنوعی در تجزیه و تحلیل داده‌ها، یک فرآیند علمی کلیدی، تأکید دارد. کاربرد میان‌رشته‌ای هوش مصنوعی در ریاضیات پیشرفته و دوره‌های STEM ادغام آن با سایر زمینه‌های علمی را برجسته می‌کند و تطبیق‌پذیری علمی آن را نشان می‌دهد.

توسعه محیط‌های یادگیری تطبیقی از طریق همکاری بین متخصصان در رشته‌های مختلف، هوش مصنوعی را به عنوان یک ذینفع و کمک‌کننده به دانش علمی نشان می‌دهد. استفاده از فناوری‌های پیشرفته مانند یادگیری عمیق و تشخیص تصویر در آموزش، نشان‌دهنده نوآوری علمی مداوم در هوش مصنوعی است. علاوه بر این، به‌کارگیری روش‌های تحقیق کیفی و کمی در مطالعه تأثیر هوش مصنوعی، تعهد به دقت علمی را نشان می‌دهد. در نهایت، ظرفیت هوش مصنوعی برای پرداختن به چالش‌های پیچیده آموزشی، مانند بار شناختی و اضطراب یادگیری، نقش آن را در حل مسائل علمی نشان می‌دهد. در مجموع، این جنبه‌ها نشان می‌دهند که هوش مصنوعی ریشه عمیقی در اصول و روش‌های علمی دارد و جایگاه آن را به عنوان یک رشته علمی قوی تأیید می‌کند.

داگلاس و همکاران [67] کاربرد یادگیری ماشینی را در علوم نظری مورد بحث قرار می‌دهند و نشان می‌دهند که چگونه روش‌های یادگیری ماشینی، از جمله روش‌هایی که به داده‌های مصنوعی متکی هستند، در زمینه‌هایی مانند ریاضیات و فیزیک نظری مورد استفاده قرار می‌گیرند. این ادغام یادگیری ماشینی در حوزه‌های علمی سنتی، اعتبار علمی و پتانسیل آن را برای پیشرفت زمینه‌های مختلف مطالعاتی نشان می‌دهد. اورمزد و همکاران [68] تأثیر یادگیری ماشینی را در حوزه علمی بررسی می‌کنند. این مقاله مثال‌های مختلفی را ارائه می‌دهد که در آن‌ها یادگیری ماشینی برای درک پدیده‌های پیچیده، مانند تجزیه و تحلیل داده‌های نویزی و مطالعه چشم‌انداز ساختاری ویروس‌ها، به کار گرفته شده است. این نشان می‌دهد که چگونه یادگیری ماشینی نه تنها یک ابزار، بلکه یک رویکرد علمی است که به درک و کشف عمیق‌تر در علم کمک می‌کند.

۴.۴. مشارکت‌های این اثر

این اثر، با توجه به ادبیات موجود، مروری انتقادی بر مبانی یادگیری ماشین ارائه می‌دهد و بر اتکای آن بر استدلال استقرایی و زیر سوال بردن ظرفیت این حوزه برای یادگیری واقعی تمرکز دارد. این مقاله به طور منحصر به فردی پذیرش سنتی ... را نقد می‌کند.

استدلال استقرایی در یادگیری ماشین، نگرانی‌های فلسفی در مورد قابلیت اطمینان و اعتبار نتایج حاصل از نمونه‌های خاص به قوانین کلی را برجسته می‌کند. این موضوع با مباحث فلسفی در مورد «مسئله استقراء» همسو است و این فرض اساسی را که دقت بالا در تشخیص الگو معادل یادگیری واقعی است، به چالش می‌کشد. علاوه بر این، این مقاله به تمایز ظریف بین جنبه‌های قدیمی و جدید یادگیری ماشین می‌پردازد. این مقاله یک تحلیل تاریخی انتقادی ارائه می‌دهد و مبنای آماری روش‌هایی مانند یادگیری نظارت شده را از پیشرفت‌های جدیدتر مانند شبکه‌های عصبی کانولوشن (CNN)، شبکه‌های حافظه کوتاه مدت بلند مدت (LSTM) و مدل‌های زبانی بزرگ (LLM) متمایز می‌کند. این رویکرد به درک عمیق‌تر از تکامل یادگیری ماشین کمک می‌کند و روشن می‌کند که چگونه پیشرفت‌های معاصر بر اساس روش‌های سنتی ساخته می‌شوند یا از آنها فاصله می‌گیرند. علاوه بر این، بررسی این اثر در مورد آنچه که نوآوری در تکنیک‌های یادگیری ماشین را تشکیل می‌دهد، به بحث‌های جاری در مورد ماهیت نوآوری در این زمینه کمک می‌کند. این مقاله، دیدگاهی بنیادی ارائه می‌دهد که بررسی می‌کند آیا پیشرفت‌های اخیر در یادگیری ماشین، نشان‌دهنده‌ی پیشرفت‌های واقعی هستند یا صرفاً پیشرفت‌های تدریجی یا اقتباس‌هایی از تکنیک‌های موجود از سایر رشته‌ها. در مجموع، این مقاله از یک دیدگاه انتقادی و فلسفی، که کمتر در ادبیات جریان اصلی یادگیری ماشین دیده می‌شود، بهره می‌برد که اغلب بر پیشرفت تکنولوژیکی و الگوریتمی تأکید دارد. این دیدگاه ارزشمند است زیرا محققان و متخصصان را تشویق می‌کند تا قابلیت‌ها و مسیر توسعه‌ی یادگیری ماشین را به طور انتقادی ارزیابی کنند.

۵. نتیجه‌گیری

برخلاف هوش مصنوعی که زمستان‌های مکرری را تجربه کرد (یعنی دوره‌هایی که اعتبار این رشته به طرز چشمگیری تا حد تعلیق بودجه‌های تحقیقاتی کاهش یافت)، یادگیری ماشین همچنان پابرجاست. با این حال، چالش‌های مختلف باعث می‌شوند مسیر آن همیشه خطی نباشد. اولاً، رویکرد معرفت‌شناختی بنیادی آن - استقراء - در تولید استنتاج‌های معتبر کاملاً صحیح نیست. ثانیاً، برخی از مدل‌های یادگیری ماشین از فقدان مکانیسم‌های توضیح علی رنج می‌برند که ارزیابی وضعیت علمی آنها را دشوار می‌کند و بر اعتماد کاربران متخصص (مانند انکولوژیست‌ها یا معامله‌گران بازار) تأثیر می‌گذارد. ثالثاً، مسائلی مانند سوگیری و انصاف داده‌ها تأثیر زیادی بر مدل‌های یادگیری ماشین می‌گذارد و درک فرهنگی و اجتماعی از یادگیری ماشین و به طور کلی از هوش مصنوعی را تضعیف می‌کند. با این حال، این نقص‌ها را می‌توان با روش‌ها و تکنیک‌هایی که توسط ادبیات علمی ارائه شده است، کاهش داد. به عنوان مثال، چارچوب‌های توضیحی را می‌توان با "مدل‌های سیاه" با استفاده از درخت‌های تصمیم‌گیری یا رگرسیون‌های چندجمله‌ای جفت کرد. به طور مشابه، وجود سوگیری را می‌توان با الگوریتم‌های پیش‌پردازش، حین پردازش و پس‌پردازش شناسایی و کاهش داد. جالب‌تر اینکه، به نظر می‌رسد تکنیک‌هایی مانند یادگیری تقویتی (RL) و یادگیری القایی (IL) شباهت بیشتری را در نحوه یادگیری مدل‌های یادگیری ماشینی و انسان‌ها نشان می‌دهند، که احتمالاً به معنای وجود یک پایه نظری قوی‌تر برای هوش مصنوعی به طور کلی است.

مشارکت‌های نویسندگان: تحقیق، AG؛ نگارش - پیش‌نویس اصلی، EB و AG؛ نگارش - بررسی و ویرایش، EB همه نویسندگان نسخه منتشر شده از دست‌نوشته را خوانده و با آن موافقت کرده‌اند.

بودجه: این تحقیق هیچ بودجه خارجی دریافت نکرده است.

بیانیه دسترسی به داده‌ها: قابل اجرا نیست.

تضاد منافع: نویسندگان هیچگونه تضاد منافی را اعلام نمی‌کنند.

منابع

۱. بلوم، لیسانس؛ انگلهارت، دکترای پزشکی؛ فرست، ای‌جی؛ هیل، دبلیو اچ؛ کرائول، دکتر، طبقه‌بندی اهداف آموزشی: طبقه‌بندی اهداف آموزشی. کتابچه راهنمای I: حوزه شناختی؛ شرکت دیوید مکی: نیویورک، نیویورک، ایالات متحده آمریکا، ۱۹۵۶.
۲. جاناسن، دی اچ؛ روهبر-مورفی، ال. نظریه فعالیت به عنوان چارچوبی برای طراحی محیط‌های یادگیری سازنده‌گرا. آموزش. مجله توسعه فناوری، [CrossRef] 1999, 47, 61-79.
۳. وینگوتسکی، ال. اس؛ کول، ام. ذهن در جامعه: توسعه فرآیندهای روانشناختی عالی؛ انتشارات دانشگاه هاروارد: کمبریج، ام‌ای. آمریکا، ۱۹۷۸.
پیاره، جی. تکامل فکری از نوجوانی تا بزرگسالی. هوم، دو. [CrossRef] ۱۹۷۲, ۱۵, ۱-۱۲.
جاریس، پ. کتابچه راهنمای بین‌المللی رولج برای یادگیری مادام‌العمر؛ رولج: لندن، انگلستان، ۲۰۰۹.
۶. گاولیکوفسکی، ج. تاسی، CRN؛ علی، م. لی، جی. هامت، ام. فنگ، جی. کروسپه، آ. تربیل، آر. یونگ، پی. روزچر، آر. و همکاران نظرسنجی از عدم قطعیت در شبکه‌های عصبی عمیق. [CrossRef] Artif. Intell. Rev. 2023, 56, 1513-1589.
۷. کریچن، ام. شبکه های عصبی کانولوشنال: یک بررسی. [CrossRef] Computers 2023, 12, 151.

۸. کاسر، س.؛ واکز-سالازار، ل. آی.؛ میولی، م.؛ توپفر، ک. پتانسیل‌های شبکه عصبی برای شیمی: مفاهیم، کاربردها و چشم‌اندازها. دیجیت. دیسکاو. [CrossRef] 2023, 2, 28-58.

۹. روزنیلات، اف. آزمایش‌های شبیه‌سازی پرسپترون. مجموعه مقالات [CrossRef] 1960, 48, 301-309. IRE

۱۰. آمینسکی، امال؛ پاپرت، اس‌ای. پرسپترون‌ها؛ ویرایش گسترده؛ انتشارات ام‌آی‌تی: کمبریج، ام‌اس، ایالات متحده، ۱۹۸۸.

۱۱. آوردن، ک.؛ تسالیامانیس، گ.؛ کراس، ای.؛ راجرز، ت. شبکه‌های عصبی مصنوعی. در کتاب «یادگیری ماشین در مدل‌سازی و شبیه‌سازی: روش‌ها و کاربردها»؛ اشپرینگر: برلین/هایدلبرگ، آلمان، ۲۰۲۳؛ صفحات ۸۵-۱۱۹.

۱۲. اخورانا، د.؛ کولی، ا.؛ خاطر، ک.؛ سینگ، س. پردازش زبان طبیعی: وضعیت فعلی، روندها و چالش‌های فعلی. چندرسانه‌ای. ابزارها، کاربرد. [CrossRef] 2023, 82, 3713-3744.

۱۳. اکومار، ب.؛ یاداو، ن. یک مدل ترکیبی جدید با ترکیب β SARMA و LSTM برای پیش‌بینی سری‌های زمانی. Appl. Soft Comput. 2023, ۱۳۴, ۱۱۰۱۹. [CrossRef]

۱۴. اژنگ، ب.؛ ورما، س.؛ ژو، ج.؛ تسانگ، آی. دلیو، چن، ف. یادگیری تقلیدی: پیشرفت، طبقه‌بندی‌ها و چالش‌ها. IEEE Trans. Neural شبکه. یادگیری. سیستم. ۲۰۲۲؛ دسترسی زودهنگام. [CrossRef]

۱۵. اوسا، ت.؛ جارجین، ج.؛ نیومن، گ.؛ بگتل، ج.ا.؛ آبیل، پ.؛ پیتز، ج. یک دیدگاه الگوریتمی در مورد یادگیری تقلیدی. یافت شد. ربات ترندز. [CrossRef] 2018, 7, 1-179.

۱۶. احسین، الف.؛ جابر، م.م.؛ الیان، ای.؛ جین، س. یادگیری تقلیدی: بررسی روش‌های یادگیری. ACM Comput. Surv. 2017, 50, ۲۱. [مرجع متقابل]

۱۷. Kaelbling, L.P. 17. لیمتن، ام‌ال. Moore, A. W. Reinforcement Learning: A Survey. جی آرتیف. هوشمند [CrossRef] Res. 1996, 4, 237-285.

۱۸. کاسپر، س.؛ دیویس، س.؛ شی، س.؛ گیلبرت، ت.ک.؛ شور، ج.؛ راندو، ج.؛ فریدمن، ر.؛ کورباک، ت.؛ لیندنر، د.؛ فریر، پ.؛ و همکاران. مسائل حل نشده و محدودیت‌های اساسی یادگیری تقویتی از بازخورد انسانی. arXiv 2023, arXiv:2307.15217.

۱۹. الی، وای. کاربردهای یادگیری تقویتی. arXiv 2019, arXiv:1908.06973.

20. دوروشاک، اف. دیتزه، اس. ویتمن، ام. شلیج، بی. Wartzack, S. Reinforcement Learning for Engineering Design Automation. اطلاعات مهندسی پیشرفته. [CrossRef] 2022, 52, 101612.

۲۱. آبودله، تی. انواع الگوریتم‌های یادگیری ماشین. در پیشرفت‌های جدید در یادگیری ماشین؛ فناوری اطلاعات: ریکا، کرواسی؛ شانگهای، چین. [CrossRef] ۲۰۱۰.

۲۲. مهلیگ، ب. یادگیری ماشینی با شبکه‌های عصبی: مقدمه‌ای برای دانشمندان و مهندسان؛ انتشارات دانشگاه کمبریج: کمبریج، ماساچوست، ایالات متحده آمریکا. [CrossRef] ۲۰۲۱.

۲۳. لیو، کیو. وو، وای. یادگیری تحت نظارت. در دایره‌المعارف علوم یادگیری؛ اشپرینگر: بوستون، ماساچوست، ایالات متحده آمریکا. [CrossRef] ۲۰۱۲.

۲۴. نعیم، س.؛ علی، ع.؛ انام، س.؛ احمد، م.م. یک الگوریتم یادگیری ماشین بدون نظارت: بررسی جامع. مجله بین‌المللی. سامانه رقیمی محاسباتی. [CrossRef] 2023, 13, 911-921.

۲۵. چاپل، او.؛ شولکوف، ب.؛ زین، آ. (ویراستاران) یادگیری نیمه‌نظارتی؛ مجموعه محاسبات تطبیقی و یادگیری ماشینی؛ MIT انتشارات: لندن، انگلستان، ۲۰۱۰.

۲۶. ژاؤ، دلیو ایکس؛ ژو، کی. لی، جی.؛ تانگ، تی.؛ وانگ، ایکس.؛ هو، وای.؛ مین، وای.؛ ژانگ، بی.؛ ژانگ، جی.؛ دونگ، زد.؛ و همکاران. بررسی مدل‌های زبانی بزرگ. 2023, arXiv:2303.18223, arXiv

۲۷. یومن، اس. آر. هشت نکته که باید در مورد مدل‌های زبانی بزرگ بدانید. arXiv 2023, arXiv:2304.00612.

۲۸. مولر-ویل، س. داده‌ها، فراداده‌ها و داده‌های الگو: چگونه فرانتس بواس داده‌های آنتروپومتریک را بسیج کرد، ۱۸۹۰ و پس از آن. در داده‌ها سفرهایی در علوم؛ اشپرینگر: چام، سوئیس، ۲۰۲۰؛ ص ۲۶۵.

۲۹. مرداک، جی‌پی، ساختار اجتماعی؛ شرکت مک‌میلان: نیویورک، نیویورک، ایالات متحده آمریکا، ۱۹۴۹.

30. وانگ، اچ. فو، تی. دو، ی. گائو، دلیو. هوانگ، ک. لیو، ز. چندک، پ. لیو، اس. ون کاتویک، پی. دیک، ا. و همکاران کشف علمی در عصر هوش مصنوعی. نیچر [CrossRef] ۲۰۲۳, ۶۲۰, ۴۷-۶۰.

۳۱. بوگه، اف. جی؛ پوزنیک، ام. یادگیری ماشینی و آینده‌ی تبیین علمی. مجله‌ی عمومی فلسفه. [CrossRef] ۲۰۲۱, ۵۲, ۱۷۱-۱۷۶.

۳۲. بوخهولز، او.؛ گروت، تی. پیش‌بینی و تبیین با مدل‌های یادگیری ماشین: علوم اجتماعی به عنوان سنگ محک. مطالعه. تاریخ. فلسفه. علمی. [CrossRef] 2023, 102, 60-69.

۳۳. ریبریو، ام‌تی؛ سینگ، اس.؛ گسترین، سی. «چرا باید به شما اعتماد کنم؟» توضیح پیش‌بینی‌های هر طبقه‌بندی‌کننده. در مجموعه مقالات بیست و دومین کنفرانس بین‌المللی ACM SIGKDD در مورد کشف دانش و داده‌کوی، نیویورک، نیویورک، ایالات متحده آمریکا، ۱۷-۱۳ اگوست ۲۰۱۶؛ صفحات ۱۱۴۴-۱۱۳۵.

۳۴. لوندبرگ، اس. ام؛ لی، اس. آی. رویکردی یکپارچه برای تفسیر پیش‌بینی‌های مدل. در مجموعه مقالات پیشرفت‌ها در سیستم‌های پردازش اطلاعات عصبی ۳۰: کنفرانس سالانه سیستم‌های پردازش اطلاعات عصبی ۲۰۱۷-۲۰۱۷، کالیفرنیا، ایالات متحده آمریکا، ۲۴ تا ۲۹ دسامبر ۲۰۱۷.

۳۵. بارکان، او.؛ اشیر، ی.؛ اشل، آ.؛ الیشا، ی.؛ کونیگستین، ن. یادگیری توضیح دادن: چارچوبی مدل-اگنوستیک برای توضیح دادن مدل‌های جعبه سیاه. arXiv 2023, arXiv:2310.16584.

36. حسیجا، وی. چامولا، وی. ماهاپاترا، ا. سینگل، ا. گوئل، دی. هوانگ، ک. اسکاراداپن، اس. اسپینلی، آی. محمود، م. حسین، ع. تفسیر مدل‌های جعبه سیاه: مروری بر هوش مصنوعی قابل توضیح. Cogn. Comput. 2023, 1-30. [CrossRef]

۳۷. اتان، س.؛ هوکر، گ.؛ کخ، پ.؛ گوردو، آ.؛ کاروانا، ر. ملاحظات هنگام یادگیری توضیحات افزایشی برای مدل‌های جعبه سیاه. ماخ. یادگیری. [CrossRef] 2023, 1-27.

۳۸. لاگمن، ک.؛ لاگمن، س.؛ تاشلر، ب.؛ موکرچی، س. DL ساختارهای علّی در ابعاد بالا تحت محدودیت‌های داده. نات. ماخ هوشمند [CrossRef] 2023, 5, 1306-1316.

۳۹. مون، آی.؛ لویکولو، جی.؛ باکا، اس. سی.؛ شول، ال. ام.؛ کهل، کی. ال.؛ هاست، ام. جی.؛ لیو، دی.؛ شراگ، دی.؛ گوسف، ای. یادگیری ماشین برای طبقه‌بندی مبتنی بر ژنتیک و پیش‌بینی پاسخ به درمان در سرطان با منشأ اولیه ناشناخته. مجله پزشکی ملی. ۲۰۲۳, ۲۹, ۲۰۵۷-۲۰۶۷.

[مرجع متقابل]

۴۰. بویجسمن، س. توضیحات علمی علیّ از یادگیری ماشین. [CrossRef] *Synthese* 2023, 202, 202.

۴۱. چو، ز؛ لی، س. تخمین اثر علیّ: پیشرفت‌های اخیر، چالش‌ها و فرصت‌ها. در یادگیری ماشین برای استنتاج علیّ؛

اشپرینگر؛ چم، سوئیس، ۲۰۲۳: صفحات ۷۹–۱۰۰

۴۲. کاتون، س.؛ هاس، س. انصاف در یادگیری ماشین: یک نظرسنجی. [CrossRef] *ACM Comput. Surv.* 2020.

۴۳. محرابی، ن.؛ مورستار، ف.؛ ساکسنا، ن.؛ لزمان، ک.؛ گالستیان، ا. بررسی سوگیری و انصاف در یادگیری ماشین. *ACM Comput.*

سروی. [CrossRef] *(CSUR)* 2021, 54, 115.

44. Lagioia, F. 44. روائی، آر. سارتور، جی. عدالت الگوریتمی از طریق برابری گروهی؟ مورد، COMPAS-SAPMOC. AI Soc. 2023.

[CrossRef] ۳۸, ۴۵۹–۴۷۸.

۴۵. هاوزر، کی.ای. آیا هوش مصنوعی می‌تواند مشکل تنوع در صنعت فناوری را حل کند: کاهش نويز و سوگیری در تصمیم‌گیری‌های استخدامی.

استن. تک. ال. ریویو. ۲۰۱۹, ۲۲, ۲۹۰.

۴۶. میوانولا، ب.؛ تیریلی، س. فراتر از تعصب و تبعیض: بازتعریف اصل اخلاق هوش مصنوعی در مورد انصاف در الگوریتم‌های یادگیری ماشینی مراقبت‌های بهداشتی. انجمن هوش مصنوعی.

[CrossRef] ۲۰۲۳, ۳۸, ۵۴۹–۵۶۳.

۴۷. لی، وای.؛ لو، ال.؛ لیانگ، سی.؛ ما، اف. نقش سوگیری مدل در پیش‌بینی نوسانات: شواهدی از بازارهای سهام ایالات متحده. China Finance.

[CrossRef] *Rev. Int.* 2023, 13, 140-155.

۴۸. رضا، س.؛ رچی، دی‌جی؛ دینگ، سی. تعصبات: تشخیص تعصبات و تضمین انصاف در مقالات خبری. مجله بین‌المللی علوم داده. تحلیل. ۲۰۲۲, ۱–۲۱.

[مرجع متقابل]

۴۹. رضا، س.؛ پور، پ. او.؛ بشیر، س. آر. انصاف در یادگیری ماشینی با برابری در مراقبت‌های بهداشتی تلافی می‌کند. arXiv 2023, arXiv:2305.07041.

۵۰. ریزولاتی، جی.؛ سینیگالیا، سی. مغزهای آینده‌ای: چگونه دیگران را از درون درک می‌کنیم؛ انتشارات دانشگاه آکسفورد؛ آکسفورد، انگلستان، ۲۰۲۳.

۵۱. فیگوئیرودو، ال. اف؛ لانس، ام. ای؛ ماتپاس، سی.؛ گومز، ام. ام؛ ناردی، ای. نورون آینده‌ای: سی سال پس از کشف آن. براز. جی.

روانپزشکی [CrossRef] ۲۰۲۳, ۴۵, ۲۹۸–۳۰۲.

۵۲. گفّی، دی. تجسم عقلانیت: تفسیر فلسفی شناخت تجسم‌یافته. فلسفه ۲۰۲۳, ۱۳, ۷۸–۹۱.

۵۳. هوا، جی.؛ زنگ، ال.؛ لی، جی.؛ جو، زی. یادگیری برای یک ربات: یادگیری تقویتی عمیق، یادگیری تقلیدی، یادگیری انتقالی. حسگرها

[CrossRef] ۲۰۲۱, ۲۱, ۱۲۷۸.

۵۴. کریشنان، م. علیه تفسیرپذیری: بررسی انتقادی مسئله تفسیرپذیری در یادگیری ماشین. فلسفه. فناوری.

[CrossRef] ۲۰۲۰, ۳۳, ۴۸۷–۵۰۲.

۵۵. لپیوتون، زد.سی. افسانه‌های تفسیرپذیری مدل: در یادگیری ماشین، مفهوم تفسیرپذیری هم مهم است و هم ...

لغزنده. صف [CrossRef] *2018*, 16, 31-57.

۵۶. ناپولتانی، د.؛ پانزا، م.؛ استروپا، دی. سی. آیا کلان‌داده کافی است؟ تأملی بر نقش در حال تغییر ریاضیات در کاربردها.

نه. آمریکایی. ریاضی. انجمن. [CrossRef] *2014*, 61, 485-490.

۵۷. ناپولتانی، د.؛ پانزا، م.؛ استروپا، د. سی.، بهینگی اجباری و اصل برانت. در ریاضیات به عنوان یک ابزار: ردیابی نقش‌های جدید

ریاضیات در علوم؛ اشپرینگر؛ چام، سوئیس، ۲۰۱۷: صفحات ۲۳۳–۲۵۱.

۵۸. ناپولتانی، د.؛ پانزا، م.؛ استروپا، دی. سی. علم آگنوستیک. به سوی فلسفه‌ای برای تحلیل داده‌ها. یافته. علمی. ۲۰۱۱, ۱۶, ۱–۲۰.

[مرجع متقابل]

59. ناپولتانی، د.؛ پانزا، م.؛ استروپا، دی. ساختار آگنوستیک روش‌های علم داده. arXiv 2021, arXiv:2101.12150.

۶۰. فورد، جی. زد؛ پاگانینی، ام. روش علمی در علم یادگیری ماشین. arXiv 2019, arXiv:1904.10922.

61. کزن، م. پلیس، ر. Guo, SY؛ الدیقی، م. Cervera-Lierta, A.؛ فریدریش، پ. دوس پاسوس گومز، جی. هاسه، اف. جینیج، ا. نیگام، ع. و همکاران درک علمی با هوش مصنوعی نات. کشیش

فیزیک. [CrossRef] *2022*, 4, 761-769.

62. ون کالستر، بی. مک‌لرنون، دی.جی. ون اسمدن، م. وینتز، ال. اشتایبرگ، E.W. کالینز، کالیبراسیون PBGS: پاشنه آشیل

تحلیل‌های پیش‌بینی‌کننده. [CrossRef] *BMC Med.* 2019, 17, 230. [پاب‌مد]

۶۳. واروکو، جی.؛ چلیجینا، وی. یادگیری ماشین برای تصویربرداری پزشکی: شکست‌های روش‌شناختی و توصیه‌هایی برای آینده. [CrossRef] *NPJ Digit. Med.* 2022, 5, 48. [پاب‌مد]

۶۴. بوتیلیر، ایکس.؛ لورن، سی.؛ وینسنت، پی. تحقیقات تکرارناپذیر، تکرارپذیر هستند. در مجموعه مقالات کنفرانس بین‌المللی یادگیری ماشینی (PMLR)، لانگ بیج، کالیفرنیا، ایالات متحده آمریکا،

تا ۱۵ ژوئن ۲۰۱۹: صفحات ۷۳۴–۷۴۵

۶۵. تیاگالینگام، جی.؛ شانکار، ام.؛ فاکس، جی.؛ هی، تی. معیارهای علمی یادگیری ماشین. مجله فیزیک ملی، [CrossRef] ۲۰۲۲, ۴, ۴۱۳–۴۲۰.

۶۶. هوانگ، جی‌جی؛ تو، وای‌اف. نقش‌ها و روندهای پژوهشی هوش مصنوعی در آموزش ریاضیات: یک نگاشت کتاب‌سنجی

تحلیل و بررسی سیستماتیک. ریاضیات [CrossRef] *2021*, 9, 584.

۶۷. داگلاس، MR. یادگیری ماشین به عنوان ابزاری در علوم نظری. [CrossRef] *Nat. Rev. Phys.* 2022, 4, 145–146.

۶۸. اورمزد، آ. علم در عصر یادگیری ماشین. مجله فیزیک ملی. [CrossRef] ۲۰۲۰, ۲, ۳۴۲–۳۴۳.

سلب مسئولیت/یادداشت ناشر: اظهارات، نظرات و داده‌های موجود در تمام نشریات صرفاً متعلق به نویسنده (گان) و مشارکت‌کننده (گان) است و نه MDPI و/یا ویراستار(گان).

MDPI و/یا ویراستار(گان) مسئولیت هرگونه آسیب به افراد یا اموال ناشی از هرگونه ایده، روش، دستورالعمل یا محصولی که در محتوا به آن اشاره شده است را از خود سلب می‌کنند.