



یادگیری ماشین: مدل‌ها، چالش‌ها و مسیرهای تحقیق

طلا طلایی خویی * و نعیمه کعبوش^{1b}

دانشکده علوم کامپیوتر و مهندسی برق، دانشگاه داکوتای شمالی، گرند فورکس، داکوتای شمالی ۵۸۲۰۲ ایالات متحده آمریکا؛ *
tala.talaeikhoei@und.edu naima.kaabouch@und.edu مکاتبات:

چکیده: تکنیک‌های یادگیری ماشین به عنوان یک نیروی تحول‌آفرین ظهور کرده‌اند و حوزه‌های کاربردی مختلف، به ویژه امنیت سایبری را متحول کرده‌اند. توسعه کاربردهای بهینه یادگیری ماشین نیازمند ادغام فرآیندهای متعدد، مانند پیش‌پردازش داده‌ها، انتخاب مدل و بهینه‌سازی پارامترها است. در حالی که بررسی‌های موجود این تکنیک‌ها را روشن کرده‌اند، اما عمدتاً بر حوزه‌های کاربردی خاص متمرکز بوده‌اند. شکاف قابل توجهی که در مطالعات فعلی وجود دارد، فقدان یک مرور کلی جامع از معماری یادگیری ماشین و مراحل اساسی آن در حوزه امنیت سایبری است. برای پرداختن به این شکاف، این بررسی مروری جامع بر مطالعات فعلی در یادگیری ماشین ارائه می‌دهد که تکنیک‌های قابل اجرا در هر حوزه‌ای را پوشش می‌دهد. مدل‌ها به چهار دسته طبقه‌بندی می‌شوند: نظارت‌شده، نیمه‌نظارت‌شده، بدون نظارت و یادگیری تقویتی. هر یک از این دسته‌ها و مدل‌های آنها شرح داده شده است. علاوه بر این، این بررسی پیشرفت‌های فعلی مربوط به پیش‌پردازش داده‌ها و تکنیک‌های تنظیم فرآیند را مورد بحث قرار می‌دهد. علاوه بر این، این بررسی شکاف‌های تحقیقاتی و چالش‌های کلیدی که حوزه امنیت سایبری با آن مواجه است را شناسایی و بررسی می‌کند. با تجزیه و تحلیل این شکاف‌ها، ما برخی از مسیرهای تحقیقاتی امیدوارکننده را برای آینده پیشنهاد می‌کنیم.

در نهایت، این نظرسنجی با هدف ارائه یک منبع ارزشمند برای محققانی که علاقه‌مند به یادگیری در مورد یادگیری ماشین هستند، به آن‌ها بینش‌هایی برای تقویت نوآوری و پیشرفت در حوزه‌های کاربردی متنوع ارائه می‌دهد.

کلمات کلیدی: هوش مصنوعی؛ پیش‌پردازش داده‌ها؛ یادگیری ماشین؛ یادگیری نظارت‌شده؛ یادگیری نیمه‌نظارت‌شده؛ تکنیک‌های بهینه‌سازی؛ یادگیری تقویتی؛ یادگیری بدون نظارت



منبع: طلایی خویی، ت.؛ کعبوش،

ن. یادگیری ماشین: مدل‌ها، چالش‌ها و مسیرهای تحقیقاتی.

اینترنت آینده ۲۰۲۳، ۱۵، ۳۳۲. <https://doi.org/10.3390/fi15100332>

ویراستار آکادمیک: ماسیمو کافارو

دریافت شده: ۸ سپتامبر ۲۰۲۳

بازبینی‌شده: ۲۵ سپتامبر ۲۰۲۳

پذیرفته شده: ۱۳ اکتبر ۲۰۲۳

منتشر شده در: ۱۹ اکتبر ۲۰۲۳



حق نشر: © ۲۰۲۳ متعلق به نویسندگان.

دارنده مجوز MDPI، باز، سوئیس.

این مقاله یک مقاله با دسترسی آزاد است

تحت شرایط و ضوابط توزیع شده است

شرایط کریتیو کامنز

مجوز انتساب (CC BY) licenses/by/

(CC BY) (<https://creativecommons.org/>)

۴۰۷).

۱. مقدمه

برنامه‌های یادگیری ماشین (ML) اخیراً کاربرد گسترده‌ای در حوزه‌های مختلف، از جمله امنیت سایبری پیدا کرده‌اند [1]. این برنامه‌های امنیت سایبری به طور گسترده در سیستم‌های تحقیقاتی و تجاری پذیرفته شده‌اند و خود را به عنوان اجزای ضروری تثبیت کرده‌اند [2,3]. ساخت یک برنامه یادگیری ماشین امن و تأثیرگذار، کاری پیچیده و زمان‌بر است. این کار نیاز به داده‌های با کیفیت بالا و انتخاب یک مدل مناسب دارد که می‌تواند از طریق تنظیم فرآیند به معماری بهینه دست یابد [4]. هنگام ساخت یک مدل یادگیری ماشین موفق، عوامل متعددی باید در نظر گرفته شوند. برای توسعه یک برنامه یادگیری ماشین امنیتی موفق، مرحله اولیه شامل جمع‌آوری سیگنال‌های خام و تولید یک مجموعه داده است. با این حال، این فرآیند اغلب با چالش‌هایی مانند ناسازگاری‌ها، جانپ‌ها و افزونگی‌ها مواجه می‌شود که می‌تواند منجر به نتایج نادرست شود [5-7]. بنابراین، استفاده از تکنیک‌های مناسب پیش‌پردازش داده‌ها در توسعه هر برنامه یادگیری ماشین موفق ضروری می‌شود [8,9]. مرحله دوم انتخاب یک مدل یادگیری ماشین است. این مدل‌های یادگیری ماشین را می‌توان به چهار دسته طبقه‌بندی کرد: نظارت‌شده، نیمه‌نظارت‌شده، بدون نظارت‌شده و یادگیری تقویتی. مدل‌های نظارت‌شده از یک مجموعه داده برچسب‌گذاری‌شده برای فرآیند آموزش استفاده می‌کنند تا به خروجی‌های مطلوب دست یابند [3]. در مقابل، مدل‌های بدون نظارت با استفاده از مجموعه داده‌های بدون برچسب و بدون هیچ نظارتی آموزش داده می‌شوند. مدل‌های نیمه‌نظارت‌شده ترکیبی از مدل‌های نظارت‌شده و بدون نظارت هستند که مدل را با استفاده از تعداد کمی آموزش می‌دهند.

نمونه‌های برجسته‌گذاری شده و تعداد زیادی نمونه‌های بدون برجسته [4,5] در حالی که مدل‌های یادگیری تقویتی بر اساس پاداش دادن به اقدامات مطلوب یا تنبیه رفتارهای نامطلوب آموزش داده می‌شوند. در چنین مدل‌هایی، عامل تلاش می‌کند تا محیط را تفسیر کند، عمل کند و از طریق آزمون و خطا یاد بگیرد [6-8].

مرحله بعدی، حصول اطمینان از دستیابی مدل آموزش‌دیده به بهینه است. مدل‌های یادگیری ماشین شامل پارامترهای زیادی هستند. این پارامترها باید با استفاده از تکنیک‌های تنظیم فرایارامتری بهینه شوند [9-15]. یک تکنیک تنظیم فرایارامتری، الگوریتمی است که بهترین پارامترهای یک مدل یادگیری ماشین را با بهترین عملکرد پیدا می‌کند. نمونه‌هایی از این تکنیک‌های تنظیم شامل الگوریتم‌های ژنتیک، جستجوی تصادفی و جستجوی شبکه‌ای [13] است. به عنوان مثال، در کار شرح داده شده در [14]، نویسندگان از یک تکنیک تنظیم، یک تخمین‌گر پارزن با ساختار درختی، برای بهینه‌سازی پارامترهای چندین مدل مبتنی بر تقویت، مانند تقویت تطبیقی، تقویت دسته‌بندی و تقویت گرادیان، استفاده کردند. نمونه‌هایی از پارامترهایی که باید بهینه شوند، تعداد تخمین‌گر و یادگیری هستند. تعداد تخمین‌گرها نشان دهنده تعداد درختان در جنگل است، در حالی که نرخ یادگیری نشان می‌دهد که مدل با چه سرعتی یاد می‌گیرد. تعداد تخمین‌گرها و نرخ یادگیری پس از اعمال تکنیک تنظیم تخمین‌گر پارزن با ساختار درختی، به ترتیب روی 100 و 0.29 تنظیم شدند.

نتایج شبیه‌سازی، بهبودهای نمای در عملکرد این مدل‌های IML انتخاب‌شده را در نتیجه بهینه‌سازی پارامترهای آنها با استفاده از تکنیک تنظیم فرایارامتر نشان داد.

مطالعه دیگری [16] از جستجوی شبکه‌ای برای بهبود عملکرد چندین مدل یادگیری ماشین سنتی و گروهی، یعنی K نزدیکترین همسایه، نیز ساده، جنگل تصادفی و انباشتگی در تشخیص نفوذ در شبکه هوشمند استفاده کرد. نمونه‌هایی از ابرپارامترها تعداد همسایه‌ها، وزن و اندازه برگ‌های مورد استفاده در مدل K نزدیکترین همسایه هستند. تعداد همسایه‌ها به تعداد نزدیکترین همسایه‌ها در رویه رأی‌گیری که در مدل K نزدیکترین همسایه رخ می‌دهد اشاره دارد. در حالی که وزن در این مدل به وزن‌های داده شده به نزدیکترین نقطه K با استفاده از تابع هسته اشاره دارد. اندازه برگ‌ها حداقل تعداد نقاط را در یک گره مدیریت می‌کند و به طور موثر تعادل بین هزینه پیمایش گره و هزینه تخمین فاصله force-brute را تنظیم می‌کند. نتایج آنها با استفاده از پارامترهای بهینه شده بهبود قابل توجهی را نشان داد.

فرآیند تنظیم هایپرپارامتر به دلیل انواع مختلف هایپرپارامتر (گسسته، دسته‌بندی‌شده و پیوسته) که باید برای هر مدل بهینه شوند، در انواع مختلف مدل‌های یادگیری ماشین به طور قابل توجهی متفاوت است [16-19]. این فرآیند را می‌توان از طریق آزمایش دستی یا بهینه‌سازی خودکار انجام داد. با این حال، آزمایش دستی با محدودیت‌های متعددی همراه است، از جمله مشکلات در برخورد با پارامترهای متعدد [20]، مدل‌های پیچیده، ارزیابی‌های گسترده و پرهزینه و تعاملات غیرخطی هایپرپارامتر [17]. در نتیجه، بهینه‌سازی خودکار هایپرپارامتر به عنوان یک راه حل عملی برای کاربردهای دامنه متعدد ظهور کرده است [18,21,22]. هدف اصلی بهینه‌سازی خودکار هایپرپارامتر، ساده‌سازی مؤثر فرآیند تنظیم هایپرپارامتر است [23,24] با استفاده از این تکنیک‌ها، عملکرد مدل می‌تواند به طور قابل توجهی بهبود یابد و در عین حال نیاز به تلاش‌های انسانی را کاهش دهد. در نتیجه، مدل‌ها می‌توانند پیش‌بینی‌های دقیقی انجام دهند و عملکرد آنها با استفاده از معیارهای عملکرد [9,19,25] تجزیه و تحلیل شود.

در این بررسی، هدف ما ارائه مروری بر تکنیک‌های اخیر مربوط به کل فرآیند یادگیری ماشین، شامل پیش‌پردازش داده‌ها، مدل‌ها و رویکردهای بهینه‌سازی است. ما کاوشی عمیق در مورد مدل‌های مختلف یادگیری ماشین امنیتی، از جمله یادگیری تحت نظارت، نیمه‌نظارتی، بدون نظارت و یادگیری تقویتی ارائه می‌دهیم.

علاوه بر این، برخی از چالش‌ها و مسیرهای تحقیقاتی بالقوه در حوزه یادگیری ماشین را تجزیه و تحلیل می‌کنیم. به طور خلاصه، دستاوردهای اصلی این مقاله به شرح زیر است:

* بحث مختصری در مورد پیش‌پردازش داده‌ها؛ * طبقه‌بندی دقیق مدل‌های یادگیری نظارت‌شده، نیمه‌نظارت‌شده، بدون نظارت و تقویتی؛ * مطالعه تکنیک‌های بهینه‌سازی شناخته‌شده؛ * چالش‌های یادگیری ماشین در حوزه امنیت سایبری.

این نظرسنجی به شرح زیر سازماندهی شده است. ابتدا، در بخش 2، نظرسنجی‌های منتشر شده مرتبط در حوزه یادگیری ماشین را مورد بحث قرار می‌دهیم. سپس، در بخش 3، مدل‌های یادگیری ماشین موجود را مورد بحث قرار می‌دهیم. بخش 4 مراحل مختلف یادگیری ماشین را مورد بحث قرار می‌دهد و چندین رویکرد موجود در هر مرحله را خلاصه می‌کند. بخش 5 چالش‌های فعلی و جهت‌گیری‌های آینده را بررسی می‌کند. در نهایت، بخش 6 نتیجه‌گیری ارائه می‌دهد.

۲. کارهای مرتبط و روش تحقیق

تعدادی از نظرسنجی‌های مربوط به یادگیری ماشین در حوزه‌های مختلف، از جمله امنیت سایبری، در طول دهه گذشته منتشر شده‌اند. جدول 1 مروری بر برخی از این نظرسنجی‌ها با موضوعات پوشش داده شده و پوشش داده نشده ارائه می‌دهد. همانطور که در این جدول نشان داده شده است، برخی از این نظرسنجی‌ها فقط بر یک یا دو دسته یادگیری خاص متمرکز بوده‌اند. به عنوان مثال، در [26-30] نویسندگان چندین مدل یادگیری تحت نظارت را که در کاربردهای مختلف اعمال شده‌اند، بررسی کرده و مفاهیم اساسی در یادگیری ماشین را بررسی کرده‌اند. علاوه بر این، نویسندگان [26] چندین تکنیک ابرپارامتر و اهمیت آنها را در توسعه سیستم‌های یادگیری ماشین موفق تجزیه و تحلیل کرده‌اند. سایر نظرسنجی‌ها بر یادگیری بدون نظارت یا تقویتی متمرکز بوده‌اند. به عنوان مثال، نویسندگان [31] تجزیه و تحلیل جامعی از مدل‌های بدون نظارت ارائه داده‌اند، در حالی که نویسندگان [32] بر اهمیت مدل‌های نیمه نظارتی تأکید کرده‌اند و بحث مختصری در مورد این مدل‌ها ارائه داده‌اند. در مقابل، نویسندگان [33] صرفاً بر معماری سخت‌افزاری مدل‌های یادگیری تقویتی تمرکز کرده‌اند و مروری بر رویکردهای مختلف یادگیری تقویتی با تأکید بر پیاده‌سازی سخت‌افزاری آنها ارائه داده‌اند.

سایر نظرسنجی‌ها رویکردهای مختلف یادگیری را مقایسه کرده‌اند. نمونه‌هایی از چنین نظرسنجی‌هایی را می‌توان در [34-37] یافت، جایی که نویسندگان مدل‌های شناخته‌شده‌ی تحت نظارت و بدون نظارت را مورد بحث قرار داده‌اند و نقاط قوت و محدودیت‌های مربوط به آنها را برجسته کرده‌اند. در [38] نویسندگان مدل‌های یادگیری ماشین را به سه دسته اصلی، بدون نظارت، تحت نظارت و یادگیری تقویتی طبقه‌بندی کرده‌اند و شرح مفصلی از این دسته‌ها را به طور خاص در زمینه معماری کامپیوتر و طراحی سیستم ارائه داده‌اند. در [39] نویسندگان همچنین مقایسه‌ای از سه مدل مختلف یادگیری ماشین ارائه داده‌اند: مدل‌های تحت نظارت، بدون نظارت و نیمه نظارت. در [40] نویسندگان بر مقایسه مدل‌های خود، نیمه نظارت و بدون نظارت برای طبقه‌بندی تصاویر تمرکز کرده‌اند. نویسندگان [41-45] همچنین مدل‌های مختلف یادگیری ماشین، یعنی الگوریتم‌های یادگیری تحت نظارت، نیمه نظارت، بدون نظارت و تقویتی را مورد بحث قرار داده‌اند. این نظرسنجی‌ها بر حوزه‌های خاصی مانند شبکه‌سازی تعریف‌شده توسط نرم‌افزار و اینترنت اشیا متمرکز بوده‌اند.

با این حال، بررسی‌های موجود در منابع [26-45] بر روی هر چهار نوع مدل یادگیری ماشین، به ویژه در حوزه تحقیقات امنیت سایبری که بر بسیاری از انواع شبکه‌ها، از جمله 5G/6G، سیستم‌ها/وسایل نقلیه هوایی بدون سرنشین، اینترنت اشیا، وسایل نقلیه هوشمند و شبکه‌های حسگر بی‌سیم تأثیر می‌گذارد، تمرکز نکرده‌اند. در تمام این زمینه‌های تحقیقاتی، سیستم‌ها از اینترنت برای ارتباط استفاده می‌کنند که مستعد حملات سایبری است. علاوه بر این، این مطالعات [26-45] سایر مراحل حیاتی یادگیری ماشین، مانند تکنیک‌های پیش‌پردازش داده‌ها و تنظیم فرآیند را پوشش ندادند. در این مقاله، ما یک بررسی در مورد یادگیری ماشین، روش‌های پیش‌پردازش داده‌ها و رویکردهای تنظیم فرآیند ارائه می‌دهیم.

علاوه بر این، ما یک طبقه‌بندی برای مدل‌های طبقه‌بندی یادگیری ماشین پیشنهاد می‌کنیم که مدل‌های یادگیری نظارت‌شده، بدون نظارت، نیمه‌نظارت‌شده و تقویتی را پوشش می‌دهد. هدف ما از طریق این طبقه‌بندی، ارائه درک جامعی از چشم‌انداز متنوع مدل‌های یادگیری ماشین به خوانندگان است. به طور خلاصه، این بررسی با ارائه یک منبع جامع که پیش‌پردازش داده‌ها، تکنیک‌های یادگیری ماشین و تنظیم فرآیند را روشن می‌کند، قصد دارد به این شکاف‌ها در مطالعات موجود بپردازد.

ارائه درک جامع از کاربردهای یادگیری ماشین به خوانندگان

حوزه‌های مختلف، مانند امنیت سایبری.

جدول ۱. فهرست مقالات مروری مرتبط.

سال مرجع	نکات برجسته مطالعه	پوشش یادگیری ماشینی			پوشش پیش‌پردازش داده‌ها و تنظیم هایپرپارامتر	تفاوت‌های نظارت یادگیری	تفاوت‌های نظارت یادگیری
		پیش از تاریخ پردازش	تفاوت‌های نظارت یادگیری	تفاوت‌های نظارت یادگیری			
[34]	۲۰۲۱	مدل‌های شناخته‌شده‌ای یادگیری عمیق را شرح می‌دهد، اصول و ویژگی‌های آنها.					
[41]	۲۰۱۹	بر یادگیری ماشینی محدود تمرکز دارد. تکنیک‌هایی که فقط توسط نرم‌افزار تعریف شده‌اند شبکه سازی.					
[39]	۲۰۲۲	مسائل شناخته شده در این زمینه را بررسی می‌کند. طرح‌های سیستمی که می‌توانند با استفاده از آنها حل شوند تکنیک‌های یادگیری ماشین.					
[26]	۲۰۲۱	شرح مفصلی از چند مورد ارائه می‌دهد. مدل‌های نظارت‌شده و بهینه‌سازی آنها تکنیک‌ها.					
[32]	۲۰۲۱	مروری بر نیمه نظارتی ارائه می‌دهد. تکنیک‌های یادگیری ماشین با آنها الگوریتم‌های موجود.					
[38]	۲۰۲۲	آخرین پیشرفت‌ها، چالش‌ها و ... را ارائه می‌دهد. محدودیت‌های مدل‌های نظارت‌شده در حوزه تحلیل ریسک دریایی					
[33]	۲۰۲۲	بررسی معماری سخت‌افزاری الگوریتم‌های یادگیری تقویتی					
[28]	۲۰۲۲	الگوریتم موجود برای شبکه‌های بی‌اسیم را ارائه می‌دهد. شبکه‌های حسگر و توصیف شبکه‌های موجود چالش‌های استفاده از چنین تکنیک‌هایی					
[29]	۲۰۱۶	بیشتر موارد شناخته شده تحت نظارت را شرح می‌دهد. الگوریتم‌های حل مسائل طبقه‌بندی					
[35]	۲۰۱۹	توصیفی از نظارت‌شده‌های شناخته‌شده ارائه می‌دهد و مدل‌های بدون نظارت					

جدول، ادامه.

نقشه نظارتی یادگیری	پوشش یادگیری ماشینی	پوشش پیش‌پردازش داده‌ها و تنظیم‌های پیرامون یادگیری	نکات برجسته مطالعه	سال مرجع	پیش از تاریخ پردازش	
					پیش از تاریخ پردازش	پیش از تاریخ پردازش
[36]	۲۰۲۱	عمیقاً تحت نظارت و بدون نظارت را مورد بحث قرار می‌دهد. مدل‌های یادگیری برای تشخیص نفوذ سیستم‌ها.				
[37]	۲۰۲۱	بررسی‌های موجود تحت نظارت و بدون نظارت تکنیک‌ها در شبکه هوشمند				
[40]	۲۰۲۱	الگوریتم‌های شناخته‌شده برای تصویر را توضیح می‌دهد طبقه بندی ها.				
[31]	۲۰۲۲	یادگیری عمیق بدون نظارت را نشان می‌دهد مدل‌ها را مدل‌سازی کرده و چالش‌های آنها را خلاصه می‌کند.				
[42]	۲۰۲۳	تکنیک‌های مصرف انرژی را مورد بحث قرار می‌دهد آینده				
[43]	۲۰۲۰	بررسی تکنیک‌های مختلف یادگیری ماشین در حوزه امنیت از اینترنت اشیا.				
[44]	۲۰۲۰	یک طبقه‌بندی از یادگیری ماشینی پیشنهاد می‌دهد تکنیک‌هایی در امنیت اینترنت چیزها.				
[38]	۲۰۱۹	بررسی طبقه‌بندی یادگیری ماشینی مدل‌های موجود در سیستم‌های تشخیص نفوذ				
[45]	۲۰۲۲	تکنیک‌های یادگیری ماشین را در کنترل صنعتی ارائه می‌دهد. سیستم‌ها.				
[30]	۲۰۲۲	طبقه‌بندی تشخیص نفوذ را پیشنهاد می‌دهد سیستم‌هایی برای مدل‌های نظارت‌شده				

همان طواری که قولاً و غیرش در تقویدلی اها هر یک گیرین ما دشمنه اما بنظر قانون اشد چه لیدم بنظر طایفه بد کرد نظر ارباب و اشد غیره می نویسن اشد یک از

```
graph TD; A[Classification of Machine Learning Models] --> B[Supervised Learning]; A --> C[Semi-supervised Learning]; A --> D[Unsupervised Learning]; A --> E[Reinforcement Learning]; B --> B1[Decision-based]; B --> B2[Tree-based]; B --> B3[Distance-based]; B --> B4[Linearization-based]; B --> B5[Neural Network-based]; B --> B6[Ensemble-based]; C --> C1[Inductive-based]; C --> C2[Transductive-based]; D --> D1[Clustering-based]; D --> D2[Dimensionality Reduction-based]; D --> D3[Neural Network-based]; E --> E1[Model free-based]; E --> E2[Model-based];
```

۱. یادگیری تحت نظارت

[illegible]

در دو مرحله [56].

آموزش مدل: هدف از این آموزش شناسایی بارها و راه‌های برای به دست آوردن یک نتیجه خاص است که می‌تواند به طور دقیق رابطه بین X و y را برقرار کند. در اینجا، y یک متغیر عددی است که می‌خواهیم آن را پیش‌بینی کنیم. برای رسیدن به چنین هدفی، یک مجموعه داده آموزشی $N = \{x_i | y_i\}$ با نمونه‌هایی از x و y استفاده می‌شود.

۲) افزایش دقت پیش‌بینی، به ویژه در محیط‌های با کمبود داده. (1)


سازگاری آنها با روابط پیچیده و توانایی جلوگیری از بیش‌پرازش از طریق رگولاتور - که در آن PO پارامتر بهینه است، و یک عبارت منظم‌سازی برای جریمه کردن مدل است. نقاط قوت بیشتری هستند. با این حال، مدل‌های بزرگی می‌توانند از نظر محاسبات، پیچیده‌یابی و مسائل بیش‌پرازش، اجتناب کنند، و به عنوان پارامتر، تعریف می‌شوند.

لزام‌آور، به ویژه برای مدل‌های پیچیده یا مجموعه داده‌های بزرگ. علاوه بر این، ذهنیت در بهینه‌سازی.

انتخاب پیشین‌ها ممکن است باعث ایجاد سوگیری شود و تفسیر نتایج می‌تواند برای پیش‌بینی غیر مدل چالش‌برانگیز باشد؛ پس از انجام آموزش مدل و انتخاب پارامترهای بهینه متخصصان مسائل مربوط به مقیاس‌پذیری همچنین ممکن است با مجموعه داده‌های گسترده ایجاد شود، که مستلزم محاسبات دقیق است، از ورودی داده شده می‌توان خروجی مربوطه را به صورت زیر بدست آورد

از آن فوآند پیش بینی یا استنتاج نامیده می‌شود. دقت پیش بینی روی یک زنجره نهان، مارکوف، نیز

برای گواهی بهر همانطور که قرار می‌دهیم، مجموعه داده آزمایش Dt را می‌توان برای ارزیابی عملکرد مدل محاسبه کرد. [57]

[illegible]

بدل‌های برای یک کار خوب قوی برای مدیریت عدم قطعیت ارائه می‌دهند و بیش‌اینی‌های جامع را با استفاده از توزیع‌های احتمال

یجاد سلسله مراتبی از قوانین اگر-آنگاه برای تقسیم ویژگی‌ها در مجموعه داده آموزشی. ابهام اساسی، که یک مزیت مهم است. علاوه بر این، آنها را ادغام قبلی برتری دارند.

دانش، افزایش دقت سنجش، به ویژه در محیط‌های با کمبود داده.

سازگاری با روابط پیچیده و توانایی جلوگیری از بیش‌برازش از طریق منظم‌سازی، از نقاط قوت دیگر هستند. با این حال،

مدل‌های بیزی می‌توانند از نظر محاسباتی پیچیده باشند،

به خصوص برای مدل‌های پیچیده یا مجموعه داده‌های بزرگ. علاوه بر این، سلیقه‌ای بودن در انتخاب اولویت‌ها ممکن است باعث ایجاد سوگیری شود، و تفسیر نتایج می‌تواند برای افراد غیرمتخصص چالش‌برانگیز باشد. مسائل مربوط به مقیاس‌پذیری نیز ممکن است با مجموعه داده‌های گسترده ایجاد شود، که مستلزم بررسی دقیق است.

منابع محاسباتی.

در این مطالعه، ما هفت مدل مبتنی بر پیازی تحت نظارت، یعنی چند جمله‌ای‌ها را مورد بحث قرار می‌دهیم.

بیز ساده، زنجیره پنهان مارکوف، بیز ساده گاوسی، بیز ساده برنولی، مکمل

بسیار ساده، طبقه‌بندی‌کننده فرآیند گاوسی، و برآوردهای تک‌واستگی میانگین.

در مدل‌های مبتنی بر درخت، بیش‌ازپس‌ها با ساخت یک ساختار درخت‌مانند با استفاده از ... ایجاد می‌شوند.

سلسله مراتبی از قوانین اگر-آنگاه برای تقسیم‌بندی ویژگی‌ها در مجموعه داده‌های آموزشی. عناصر اساسی

شاخه‌ها و گره‌های یک درخت می‌توانند ریشه، داخل یا برگ باشند. بارتیشن‌ها

می‌توان بر اساس معیارهای مختلف، یعنی آنتروپی، شاخص جینی، خطای طبقه‌بندی، افزایش اطلاعات، نسبت افزایش و معیارهای دوگانه‌ی [58] انتخاب کرد. مدل‌های مبتنی بر درخت مزایای متعددی مانند دقت بالا و سهولت تفسیر بدون هیچ گونه پیش‌پردازش بیش از حد داده‌ها را ارائه می‌دهند. این مدل‌ها، همانطور که در شکل 2 نشان داده شده است، شامل چندین مدل نظارت شده، از جمله درخت طبقه‌بندی و رگرسیون، قطعه گردنی 4/5، قطعه گردنی 5/0، دوبخشی‌کننده تکراری، 3 تشخیص خودکار تعامل کای-اسکوئر و درخت تصمیم‌گیری هوفدینگ هستند.

یادگیری مبتنی بر نمونه، یادگیری مبتنی بر حافظه، به گروهی از تکنیک‌های یادگیری ماشین اشاره دارد که می‌توانند با داده‌های دیده نشده سازگار شوند و معمولاً برای پردازش داده‌های بلادرنگ استفاده می‌شوند. این روش‌ها از مفاهیم الگوریتم بهینه‌سازی نزدیکترین همسایه برای طبقه‌بندی یا پیش‌بینی داده‌ها استفاده می‌کنند. الگوریتم‌های مبتنی بر حافظه عمدتاً از ساده‌ترین چارچوب یادگیری مبتنی بر نمونه، یعنی مبتنی بر نمونه (IB1) پیروی می‌کنند که شامل سه تابع اصلی، یعنی تابع شباهت، به‌روزرسانی توصیف مفهوم و تابع طبقه‌بندی است. [59] این الگوریتم‌ها، بر اساس توصیف توابع قبلی، به مقدار زیادی حافظه برای ذخیره داده‌ها نیاز دارند. مدل‌های مبتنی بر حافظه، پردازش را تا زمانی که یک نمونه جدید طبقه‌بندی یا پیش‌بینی شود، به تأخیر می‌اندازند که به عنوان الگوی یادگیری تنبل شناخته می‌شود. یادگیری تنبل این مزیت را دارد که تابع هدف را به صورت محلی و متفاوت برای هر نمونه جدید تخمین می‌زند. [60, 61] در نتیجه، روش‌های مبتنی بر نمونه انعطاف‌پذیری زیادی دارند و گزینه‌های متعددی در طراحی توابع هدف دارند. آنها اغلب برای ساخت مدل‌های نمونه آزمایشی استفاده می‌شوند که شامل پنج تکنیک هستند، یعنی همسایه شعاعی، همسایه‌های نزدیک، K ماشین بردار پشتیبان، C ماشین بردار پشتیبان خطی و ماشین بردار پشتیبان nnu، همانطور که در شکل 2 نشان داده شده است.

مدل‌های مبتنی بر منظم‌سازی، الگوریتم‌های یادگیری حیاتی هستند که برای برآزش مناسب یک تابع روی مجموعه آموزشی و جلوگیری از مشکلات بیش‌برآزش با اضافه کردن اطلاعات اضافی به مدل‌ها استفاده می‌شوند. [62] در این مدل‌ها، یک عبارت جریمه اضافی، اطلاعات اضافی، در تابع خطا برای تنظیم مدل‌ها و کنترل تابع نوسانی اضافه می‌شود. [63] کاهش مقدار خطا، روش انقباض نامیده می‌شود و جنبه اصلی تکنیک مبتنی بر منظم‌سازی است. تابع انقباض ممکن است منجر به کاهش واریانس شود که در مجموعه داده‌های بزرگ بسیار مؤثر است، به خصوص زمانی که داده‌ها از یک محیط با ابعاد بالا هستند. [64] مدل‌های مبتنی بر منظم‌سازی را می‌توان به طبقه‌بندی‌کننده رنج، انقباض مطلق حداقل و عملگر انتخاب، شبکه الاستیک، یک قانون، قانون صفر، نزول گرادیان تصادفی، طبقه‌بندی‌کننده‌های تهاجمی غیرفعال، رگرسیون لجستیک، تحلیل تفکیک خطی، تحلیل تفکیک درجه دوم، طبقه‌بندی‌کننده گام به گام و ستون فقرات رگرسیون تطبیقی چند متغیره، همانطور که در شکل 2 نشان داده شده است، طبقه‌بندی کرد.

شبکه‌های عصبی، که به عنوان شبکه‌های عصبی مصنوعی (ANN) نیز شناخته می‌شوند، زیرمجموعه مهمی از تکنیک‌های یادگیری ماشین هستند که از مغز انسان الهام گرفته شده‌اند. این تکنیک‌ها می‌توانند به طور مؤثر در طبقه‌بندی، خوشه‌بندی، تشخیص الگو و پیش‌بینی‌ها مورد استفاده قرار گیرند. پتانسیل بالای چنین تکنیک‌هایی، ارائه پردازش با سرعت بالا در پیاده‌سازی موازی است. NNAها به دلیل نرخ بالای خودآموزی، سازگاری، تحمل خطا و ویژگی‌های غیرخطی این تکنیک‌ها، به طور گسترده برای تقریب توابع جهانی برای پارادایم‌های عددی مختلف استفاده می‌شوند. [65, 66] تقریب تابع جهانی به این اشاره دارد که چگونه یک شبکه عصبی می‌تواند هر تابعی را که در آموزش و اعتبارسنجی آن استفاده می‌شود، تقریب بزند. علاوه بر این، این تکنیک‌ها در مقایسه با تکنیک‌هایی با ورودی‌های بزرگ، آسان برای استفاده و دقیق‌تر هستند. [67] شبکه‌های عصبی تحت نظارت را نیز می‌توان به چهار دسته طبقه‌بندی کرد: پرسپترون چند لایه، شبکه‌های عصبی کانولوشن، شبکه‌های عصبی عمیق و شبکه‌های عصبی بازگشتی، همانطور که در شکل 2 نشان داده شده است.

تکنیک‌های یادگیری ماشین مبتنی بر گروه، که به عنوان سیستم‌های طبقه‌بندی کننده ضرب‌کننده نیز شناخته می‌شوند، چندین یادگیرنده را برای حل یک مسئله آموزش داده و ادغام می‌کنند. در این تکنیک‌ها، ظرفیت تعمیم یک یادگیرنده گروهی به طور کلی قوی‌تر از یک یادگیرنده انفرادی است. [68, 69] اگرچه این نظریه بیشتر برای یادگیرنده‌های ضعیف صادق است، اما یادگیرنده‌های سنتی قوی نتایج عملکرد بهتری ارائه می‌دهند. علاوه بر این، مدل‌های گروهی معمولاً زمانی که تنوع بین یادگیرنده‌های پایه ترکیبی وجود دارد، نتایج بهتری ارائه می‌دهند. [70] این مدل‌ها مزایای متعددی از جمله واریانس کم، عملکرد بالا و حذف نویز و داده‌های مغرضانه را ارائه می‌دهند. علاوه بر این، این مدل‌ها مقاوم هستند که می‌توانند پراکندگی یا

پراکندگی پیش‌بینی‌ها، علیرغم مزایای این مدل‌ها، آنها با چندین مورد سروکار دارند کاستی‌ها، از جمله فقدان سادگی و قابلیت توضیح، تعمیم‌پذیری و بالا بودن زمان پیش‌بینی [71]

مدل‌های مبتنی بر گروه به سه نوع مختلف طبقه‌بندی می‌اشوند: کیسه‌ای (bagging)، تقویتی (boosting) و انباشت، همانطور که در شکل 3 نشان داده شده است. مدل Bagging که به عنوان تکنیک تجمیع بوت‌استرپ شناخته می‌شود، می‌تواند واریانس را به حداقل برساند و در نتیجه پیش‌بینی را بهبود بخشد [71، 72]. مدل‌های تقویتی از یک تکنیک تکرار متوالی برای ترکیب چندین فرد ضعیف استفاده می‌کنند.

زبان‌آموزان را به یک زبان‌آموز قوی با عملکرد بهتر تبدیل می‌کند. برای تولید خروجی این یادگیرنده قوی، رابطه‌ای مبتنی بر میانگین وزنی یا رأی‌گیری بین ... برقرار می‌شود. یادگیرنده‌های پایه با توزیع‌های مختلف [73] در نهایت، پشته‌سازی، که به عنوان تعمیم پشته شناخته می‌شود، نوع دیگری از تکنیک یادگیری جمعی است که شامل ناهمگن می‌شود. یادگیرنده‌های ضعیف، مدل‌های پشته‌ای ممکن است مزایایی مانند افزایش استحکام و بهبود عملکرد را ارائه دهند [74]. این تکنیک‌ها عملکرد بالاتر را تضمین می‌کنند.

در مقایسه با هر مدل مشارکتی واحد، جدول 2 ویژگی‌ها را ارائه می‌دهد، مزایا و معایب این تکنیک‌های طبقه‌بندی نظارت‌شده.

جدول 2. ویژگی‌ها، محدودیت‌ها و نقاط قوت دسته‌بندی‌های طبقه‌بندی [56-74]

معایب	مزایا	ویژگی‌ها	طبقه‌بندی دسته بندی
توانایی تعمیم‌پذیری؛ هزینه‌ها؛ ظرفیت ادغام موارد قبلی؛ دشواری در تفسیر؛ پیچیدگی؛ مجموعه داده‌های کوچک مفید است.		• برخورد با داده‌های نامشخص.	بیزی-مبتنی بر
• تعمیم‌پذیری؛ • مستعد بیش‌برازش (overfitting)؛ • غیر مستقیم؛ • دشواری در تفسیر؛ • مجموعه داده‌های بزرگ.			مبتنی بر درخت
• قدرت محاسباتی بالا؛ هزینه‌ها؛ حافظه گران‌قیمت کاربرد.	• ظرفیت انطباق با شرایط جدید و داده‌های بلادرنگ؛ قابلیت تغییر شباهت تابع برای هر نمونه در هر مرحله پیش‌بینی؛ فرایند آموزش سریع.	• سازگاری با شرایط جدید و داده‌های بلادرنگ.	مبتنی بر نمونه
• کاهش واریانس مدل بدون افزایش سوگیری؛ کاهش مشکلات بیش‌برازش؛ خطای بایاس بالا.	سادگی؛ کارایی محاسباتی.	منظم سازی تخمین ضریب به سمت صفر؛ تعمیم.	مبتنی بر منظم‌سازی
• نیاز به مجموعه داده‌های بزرگ؛ قدرت محاسباتی بالا؛ قدرت؛ طبیعت جعبه سیاه؛ مستعد بیش‌برازش (overfitting).	قابلیت تشخیص تمام موارد ممکن تعاملات بین پیش‌بینی‌کننده‌ها متغیرها؛ در دسترس بودن آموزش‌های متعدد فرآیندها؛ نرخ بالای تطبیق پذیری.	ذخیره اطلاعات در کل شبکه؛ حافظه توزیع‌شده؛ قابلیت موازی سازی پردازش.	عصبی مبتنی بر شبکه
• زمان استنتاج بالا؛ عدم سادگی؛ عدم تعمیم.	• واریانس کم؛ عملکرد بالا؛ حذف نویز و داده‌های مغرضانه.	• ترکیب چندگانه زبان‌آموزان	مبتنی بر گروه

```
graph TD; A[Ensemble Learning Models] --> B[Bagging-based]; A --> C[Boosting-based]; A --> D[Stacking-based]; B --> B1[Bagging Classifier]; B --> B2[Voting Classifier]; B --> B3[Random Forest]; B --> B4[Extra Tree Classifier]; B --> B5[Isolation Forest]; C --> C1[Gradient Boosting]; C --> C2[Adaptive Boosting]; C --> C3[Extreme Gradient Boosting]; C --> C4[Light Gradient Boosting]; C --> C5[Categorical Gradient Boosting]; C --> C6[Brown Boosting]; C --> C7[Logit Boosting]; D --> D1[Auto-Encoder]; D --> D2[Boltzmann]; D --> D3[Belief Neural Network]; D --> D4[Generative Adversarial Neural Network];
```

The diagram illustrates the classification of Ensemble Learning Models into three main categories: Bagging-based, Boosting-based, and Stacking-based. Each category further branches into specific models or techniques.

- Ensemble Learning Models**
 - Bagging-based**
 - Bagging Classifier
 - Voting Classifier
 - Random Forest
 - Extra Tree Classifier
 - Isolation Forest
 - Boosting-based**
 - Gradient Boosting
 - Adaptive Boosting
 - Extreme Gradient Boosting
 - Light Gradient Boosting
 - Categorical Gradient Boosting
 - Brown Boosting
 - Logit Boosting
 - Stacking-based**
 - Auto-Encoder
 - Boltzmann
 - Belief Neural Network
 - Generative Adversarial Neural Network

۳.۲. یادگیری نیمه نظارتی


در ادامه مفاهیم ریاضی اصلی مدل‌های یادگیری نیمه‌نظارتی آمده است.

در مدل‌های نیمه‌تطارتی، مجموعه نمونه‌های آموزشی به صورت $(X_i, Y_i) \quad X_i \in \mathbb{R}^d$ تعریف می‌شود. در این مدل‌ها، هر نمونه از یک فضای ویژگی با ابعاد d تشکیل شده است. هدف از این مدل‌ها، یافتن یک تابع f است که بتواند به درستی خروجی Y_i را بر اساس ورودی X_i پیش‌بینی کند. این مدل‌ها معمولاً برای داده‌های خطی غیرقابل جداسازی استفاده می‌شوند. برای بهبود عملکرد این مدل‌ها، می‌توان از تکنیک‌های مختلفی مانند استفاده از لایه‌های پنهان، استفاده از توابع فعال‌سازی غیرخطی، استفاده از روش‌های بهینه‌سازی پیشرفته و استفاده از داده‌های بیشتر استفاده کرد.

پیش‌بینی مدل: هنگامی که مدل با پارامترهای بهینه آموزش داده شد، دقت یادگیرنده‌ها را روی نمونه‌های داده آزمایشی پیش‌بینی می‌کند، که در مقایسه با یادگیرنده‌هایی که از داده‌های برچسب‌گذاری شده استفاده می‌کنند، از آن فراتر می‌رود.

مدل‌های نیمه‌نظارتی عموماً بسط مستقیم مدل‌های نظارت‌شده در نظر گرفته می‌شوند. این مدل‌ها را می‌توان به مدل‌های مبتنی بر استقراء و مبتنی بر انتقال تقسیم کرد، همانطور که در شکل ۴ نشان داده شده است. جدول ۳ ویژگی‌ها، مزایا و معایب این مدل‌ها را شرح می‌دهد. مدل‌های مبتنی بر استقراء می‌توانند برای هر شیء در ورودی پیش‌بینی ایجاد کنند.

مدل‌های انتقالی دسته دیگری از مدل‌های یادگیری نیمه‌نظارتی هستند که برادر هستند، در حالی که نمونه‌های داده بدون برچسب هستند. این روش‌ها معمولاً برای طبقه‌بندی و رگرسیون استفاده می‌شوند. برای مثال، در یک مدل انتقالی، داده‌های بدون برچسب می‌توانند به عنوان داده‌های هدف استفاده شوند، در حالی که داده‌های دارای برچسب به عنوان داده‌های منبع استفاده می‌شوند. این روش‌ها معمولاً برای بهبود عملکرد مدل‌ها در وظایف یادگیری بدون برچسب استفاده می‌شوند. در این روش، داده‌های بدون برچسب به عنوان داده‌های هدف استفاده می‌شوند، در حالی که داده‌های دارای برچسب به عنوان داده‌های منبع استفاده می‌شوند. این روش‌ها معمولاً برای بهبود عملکرد مدل‌ها در وظایف یادگیری بدون برچسب استفاده می‌شوند.



حدول، 3. ونڱ ٻاها، محدوديتاها و نقاط قوت مڊا ٻاها، نمه نظارت، [76-81]

نقطه ضعف	مزیت	ویژگی‌ها	رده بندی
از همین مدل همیشه استفاده کرد	پیش‌بینی‌های جدید	مدلی تولید می‌کند که می‌تواند ایجاد کند	القای- مبتنی بر
در آموزش و پیش‌بینی موارد جدید نمونه‌های داده	نمونه‌ها مستقل از نمونه‌های قدیمی	پیش‌بینی‌ها برای هر نمونه در فضای ورودی	مبتنی بر ترانسداکتیو
عدم تمایز بین الگوریتم‌های انتقال در یک شیوه نظارت شده	هیچ تفاوتی بین مراحل آموزش و آزمایش	نقاط قوت پیش‌بینی‌کننده محدود به اشیایی که در طول پردازش می‌شوند مراحل آموزش	

مدل‌های انتقالی دسته دیگری از مدل‌های یادگیری نیمه‌نظارتی هستند که برای کل فضای ورودی مدلی ایجاد نمی‌کنند. این مدل‌ها بین ... و ... تفاوتی قائل نمی‌اشوند. مراحل آموزش و آزمایش. آنها به طور گسترده بر اساس الگوریتم‌های مبتنی بر گراف انجام می‌شوند. رویکردی که در آن نمونه‌های داده از طریق نمودارها به هم متصل می‌اشوند و داده‌های آنها رشد می‌کنند. با لیه‌های گراف. [79] این مدل‌های مبتنی بر گراف (مولد، منیفولد و حداکثر حاشیه) با سه مرحله سروکار دارد، یعنی ساخت نمودار، وزن‌دهی، و استنتاج. [80] در ساخت گراف، از مجموعه داده‌های ورودی برای تولید گراف استفاده می‌شود. که در آن گره‌ها نشان می‌دهند نمونه‌های داده از طریق لبه به هم متصل شده‌اند. [79, 81] در وزن‌دهی گراف، یال‌ها وزن‌دهی می‌شوند تا شباهت جفتی بین نمونه‌های داده نشان داده شود. در نمودار استنتاج، نمودار برای برجسته کردن برجسته‌ها در مقایسه با داده‌های بدون برجسته اعمال می‌شود. نمونه‌ها. جزئیات بیشتر در مورد این مدل‌ها و ویژگی‌ها را می‌توان در [80] یافت.

۳.۳ یادگیری بدون نظارت

روش‌های یادگیری ماشین بدون نظارت، خروجی‌های بدون برچسب را با استفاده از ... تجزیه و تحلیل و خوشه‌بندی می‌کنند. مجموعه‌ای از ورودی‌ها. خوشه‌بندی نمونه‌ها به طور گسترده برای کشف الگوها، ساختارها، و داده‌های پنهان استفاده می‌شود.

یا دانش داده در مجموعه داده‌های بدون برچسب [24،57] موارد زیر مفاهیم ریاضی هستند.

از مدل‌های بدون نظارت

یک مدل یادگیری ماشین بدون نظارت، یک تابع پارامتری θ است که

بدون خروجی، در این مدل، داده‌های ورودی به ... اشاره دارند.

یک فضای برداری d بعدی است. داده‌ها باید

به طور دقیق آموزش داده شده تا برچسب داده را که مشخص نیست، پیش‌بینی کند. مراحل بدون نظارت مدل‌ها به شرح زیر توصیف می‌شوند.

آموزش مدل: این فرآیند شامل شناسایی پارامترهای بهینه است.

که می‌تواند به یافتن دقیق‌تر الگویی بین نمونه‌های داده و خروجی‌های آنها کمک کند. بنابراین،

ن

یک تابع f از X به Y را می‌توان به صورت زیر نوشت:

برای محاسبه تفاوت بین ورودی‌های داده و خروجی‌ها تعریف شده است. هدف آموزش

مدل‌های بدون نظارت، کاهش تابع زیان در مجموعه آموزشی و دستیابی به

نتایج بهینه.

پیش‌بینی مدل: پس از آموزش مدل و زمانی که پارامترهای بهینه تعیین شدند

اگر داده‌های ورودی را به مدل ارائه دهیم، مدل می‌تواند خروجی‌ها را پیش‌بینی کند. در اینجا می‌توان برای ارزیابی محاسبه کرد.

عملکرد مدل.

مدل‌های بدون نظارت را می‌توان به مدل‌های مبتنی بر خوشه، مبتنی بر کاهش ابعاد و مبتنی بر شبکه عصبی تقسیم کرد، همانطور که در شکل 5 نشان داده شده است.

این مدل، داده‌ها را بر اساس ویژگی‌ها و شباهت‌هایشان، در دسته‌هایی گروه‌بندی می‌کند و

آنها را با هم خوشه‌بندی می‌کند. این گروه قادر به یافتن زیرگروه‌های همگن در


داده‌های داده شده، و نتایج آنها می‌تواند برای گروه‌بندی مشاهدات (ویژگی‌ها) به بخش‌های مجزا استفاده شود.

گروه‌ها. این گروه‌ها به تفسیر و ارزیابی داده‌ها کمک می‌کنند. این روش‌ها عبارتند از

معمولاً پیاده‌سازی آنها آسان است؛ با این حال، پیچیدگی آنها بالاست [75]. همانطور که در شکل 5 نشان داده شده است،

شبکه‌های عصبی تخصصی، به عنوان مثال، شبکه‌های عصبی باور، از جمله مدل‌های مبتنی بر خوشه‌بندی و شبکه‌های عصبی شامل K-میانگین، K-میانگین، و K-میانگین. جدول 4 خوشه‌بندی کاراکتری، فاکتورگیری ماتریس غیر منفی و خوشه‌بندی مکانی مبتنی بر چگالی را فهرست می‌کند.

لیست شبکه‌ها، محدودیت‌ها و نقاط قوت این مدل‌ها.



شکل ۵. مروری بر مدل‌های یادگیری بدون نظارت.

مدل‌های یادگیری بدون نظارت، به کاهش ابعاد و تعداد ویژگی‌ها در یک مجموعه داده اشاره دارند.

که به صورت ستون نمایش داده می‌شوند. در یادگیری بدون نظارت، چنین مدل‌هایی با هدف کاهش

طبقه‌بندی

ویژگی‌ها

تعداد ویژگی‌ها در آموزش و آزمایش. مدل‌هایی مانند این می‌توانند روابط را خلاصه کنند

دسته بندی

بین نمونه‌هایی با تعداد ابعاد کاهش یافته. استفاده از این رویکردها تسهیل می‌کند

مبتنی بر خوشه

داده‌های دسته‌بندی نشده را به گروه‌های مشابه تقسیم می‌کند؛

• پیاده سازی آسان.

تعداد ویژگی‌ها را در روز داده شده کاهش می‌دهد.

مبتنی بر کاهش ابعاد

• کاهش زمان و ذخیره سازی.

• از دست رفتن داده‌ها.

تجسم و پیش‌پردازش مجموعه داده‌های پیچیده. مدل‌های مبتنی بر کاهش ابعاد می‌توانند زمان و فضای ذخیره‌سازی را کاهش دهند، اگرچه ممکن است با از دست دادن داده‌ها مواجه شوند. [75] همانطور که در شکل 5 نشان داده شده است، این دسته‌ها شامل نقشه‌های خودسازماندهی، تحلیل مؤلفه‌های اصلی، مقیاس‌بندی چندبعدی و تحلیل مؤلفه‌های مستقل هستند.

دسته دیگری از مدل‌های بدون نظارت، مدل‌های مبتنی بر شبکه عصبی هستند که به هر دو دسته مدل‌های تحت نظارت و بدون نظارت تعلق دارند. این مدل‌ها می‌توانند تعاملات بین پیش‌بینی‌کننده‌ها را شناسایی کنند و از سازگاری بالایی برخوردارند. با وجود این مزایا، آن‌ها به مجموعه داده‌های عظیمی برای پردازش نیاز دارند و تمایل زیادی به بیش‌برازش دارند. علاوه بر این، مدل‌های مبتنی بر شبکه عصبی معمولاً با قدرت محاسباتی بالایی مواجه هستند. رمزگذارهای خودکار، شبکه‌های عصبی مولد تخصصی، بولتزمن و شبکه‌های عصبی باور، از جمله مدل‌های بدون نظارت مبتنی بر شبکه عصبی هستند، همانطور که در شکل 5 نشان داده شده است. جدول 4 ویژگی‌ها، محدودیت‌ها و نقاط قوت این مدل‌ها را فهرست می‌کند.

جدول 4. ویژگی‌ها، محدودیت‌ها و نقاط قوت مدل‌های بدون نظارت. [74,75]

معایب	مزایا	ویژگی‌ها	رده بندی
* پیچیدگی زیاد.	* پیاده سازی آسان.	داده‌های دسته‌بندی نشده را به گروه‌های مشابه تقسیم می‌کند؛	مبتنی بر خوشه
* از دست رفتن داده‌ها.	* کاهش زمان و ذخیره سازی.	تعداد ویژگی‌ها را در مجموعه داده داده شده کاهش می‌دهد؛	مبتنی بر کاهش ابعاد
* نیاز به مجموعه داده‌های عظیم؛ * قدرت محاسباتی بالا؛ * تمایل به بیش‌برازش (overfitting).	* می‌تواند تعاملات بین متغیرهای پیش‌بینی‌کننده را تشخیص دهد؛ در دسترس بودن فرآیندهای آموزشی متعدد؛ * سازگاری بالا.	• الهام از مغز انسان.	مبتنی بر شبکه عصبی

۳.۴. یادگیری تقویتی مدل‌های یادگیری تقویتی (RL) یکی دیگر از دسته‌های یادگیری ماشینی هستند که یک عامل را برای یادگیری در یک محیط تعاملی با دریافت بازخورد از تجربیات و اقدامات خود آموزش می‌دهند. یادگیری تقویتی، مدل‌ها را آموزش می‌دهد تا اقدامات بهینه را در یک محیط یاد بگیرند تا حداکثر پاداش را دریافت کنند. این اقدامات بهینه را می‌توان از طریق تعامل با یک محیط و پاسخ‌های آنها انجام داد. در غیاب ناظر، یادگیرنده باید توالی اقدامات خود را به طور مستقل بررسی کند، که پاداش‌ها را به حداکثر می‌رساند. [82] مزایای یادگیری تقویتی شامل توانایی آنها در مدیریت محیط‌های پویا و پیچیده است که آنها را برای کارهایی مانند کنترل رباتیک و بازی مناسب می‌کند. آنها همچنین در سناریوهایی با بازخورد پراکنده یا تأخیری عالی هستند. با این حال، آنها اغلب به آموزش گسترده نیاز دارند و ممکن است با فضاهای حالت با ابعاد بالا مشکل داشته باشند.

علاوه بر این، تعریف یک تابع پاداش مناسب می‌تواند چالش برانگیز باشد، و پاداش‌های ضعیف طراحی شده ممکن است منجر به رفتار غیربهینه شوند. علاوه بر این، استراتژی‌های اکتشاف باید به دقت متعادل شوند تا از آزمون و خطای بیش از حد جلوگیری شود. به طور کلی، یک عامل تلاش می‌کند تا چالش‌های تصمیم‌گیری را از طریق مدل‌سازی فرآیند تصمیم‌گیری مارکوف (MDP) به صورت متوالی یاد بگیرد. در یک گام زمانی، عامل مشاهده‌ای از محیط $P_t \rightarrow P$ دریافت می‌کند، که در آن P فضای حالت را نشان می‌دهد و عامل می‌تواند بر اساس واکنش محیط، رفتاری $R(P_t) \rightarrow B_t$ را انتخاب کند. در این زمینه، $B(P_t)$ مجموعه تمام اقدامات ممکن حالت P_t است. سپس، عامل پاداش R_{t+1} را دارد. سپس، حالت P_{t+1} و پاداش R_{t+1} به حالت قبلی P_t و رفتار B_t بستگی دارند. در طول فرآیند یادگیری، عامل همچنین یاد می‌گیرد که پاداش‌های تجمعی را که به عنوان بازده پاداش مورد انتظار E_t نشان داده شده است، با استفاده از نرخ تنزیل γ با استفاده از معادله زیر [83] به حداکثر برساند:

$$k=0 \gamma^k R_{t+k} + \gamma^k V_t - V_{t-1} \quad (2)$$

بر اساس ماهیت مسئله، مانند طبقه‌بندی، رگرسیون یا خوشه‌بندی. پس از انتخاب مدل، مرحله آموزش آغاز می‌شود که در طی آن مدل با تنظیم مکرر پارامترهای خود برای به حداقل رساندن یک معیار خطای از پیش تعریف شده، الگوها و روابط موجود در داده‌ها را یاد می‌گیرد.

این مرحله شامل تقسیم مجموعه داده‌های داده شده به مجموعه‌های آموزشی و اعتبارسنجی برای ارزیابی عملکرد مدل است.

پس از آموزش، مدل با استفاده از یک مجموعه داده آزمایشی جداگانه برای ارزیابی توانایی تعمیم‌پذیری آن، مورد ارزیابی قرار می‌گیرد. اگر عملکرد مدل معیارهای مورد نظر را برآورده کند، می‌توان آن را برای کاربردهای امنیتی دنیای واقعی پی‌گیری کرد. فرآیندهای یادگیری ماشینی با یک چرخه مداوم از پالایش و تکرار که بر روی مدل‌ها انجام می‌شود، برای دستیابی به دقت و استحکام بالاتر مشخص می‌شوند و آنها را به ابزاری ضروری برای حل مسائل پیچیده در حوزه‌های مختلف تبدیل می‌کنند. برای بحث مختصر در مورد این مراحل، مروری بر پیش‌پردازش داده‌ها، رویکردهای تنظیم و معیارهای ارزیابی ارائه شده است.

4.1. پیش‌پردازش داده‌ها یکی از عوامل کلیدی اصلی در توسعه یک سیستم یادگیری ماشین موفق، در دسترس بودن و کیفیت مجموعه داده‌ها و معیارهای مورد استفاده است. [15,49] با این حال، جمع‌آوری داده‌ها در زمینه‌های مختلف می‌تواند چالش‌های متعددی را ایجاد کند، از جمله دشواری در ایجاد مجموعه داده‌های واقعی به دلیل ایمنی، [48] امنیت، [50] حریم خصوصی [48,50,101] و سایر نگرانی‌ها. برای پرداختن به این موضوع، مطالعات متعددی بر شناسایی شرایط نادر و شبیه‌سازی مجموعه داده‌ها برای کشف الگوهای ضروری داده‌ها متمرکز شده‌اند [15,51-53,101-109]. تضمین عملکرد بهینه مدل‌های یادگیری ماشین نیازمند مجموعه داده‌های با کیفیت بالا است و پیش‌پردازش داده‌ها را به گامی حیاتی در فرآیند یادگیری ماشین تبدیل می‌کند. در مرحله پیش‌پردازش، داده‌های خام به فرمت عملی تبدیل می‌شوند. علاوه بر این، مجموعه داده‌ها اغلب حاوی نقص‌هایی مانند ناسازگاری، افزونگی، نویز و مقادیر از دست رفته هستند [54] که می‌توانند بر عملکرد مدل تأثیر بگذارند. بنابراین، مراحل پردازش مناسب برای افزایش کیفیت و قابلیت اطمینان تصمیمات مدل مهم هستند. [55] پیش‌پردازش داده‌ها شامل کاهش داده‌ها، تبدیل داده‌ها، گسسته‌سازی، تمیز کردن داده‌ها و یادگیری نامتعادل برای آماده‌سازی داده‌ها برای یادگیری ماشین مؤثر است. [110]

جدول 6 خلاصه‌ای جامع از تکنیک‌های کلیدی پیش‌پردازش داده‌ها در فرآیندهای مختلف، از جمله تبدیل داده‌ها، پاکسازی، کاهش/افزایش، گسسته‌سازی و یادگیری نامتوازن، ارائه می‌دهد. تکنیک‌های تبدیل داده‌ها، داده‌ها را از یک قالب به قالب دیگر تبدیل می‌کنند. این امر از طریق دو تکنیک اصلی انجام می‌شود: نرمال‌سازی و استانداردسازی. پاکسازی داده‌ها شامل کارهایی مانند پر کردن مقادیر گم‌شده، مدیریت داده‌های نویزی و برخورد با داده‌های پرت است. در زمینه کاهش/افزایش داده‌ها، اطلاعات اضافی و نامربوط را می‌توان با استفاده از تکنیک‌هایی مانند استخراج ویژگی، انتخاب ویژگی و تولید نمونه شناسایی و حذف یا اضافه کرد. گسسته‌سازی رویکردی است که تعداد مقادیر داده‌ها را با تبدیل آنها به مجموعه‌ای کوچکتر از مقادیر گسسته کاهش می‌دهد.

در مواردی که توزیع کلاس نامتعادل است، تکنیک‌های یادگیری متعادل برای جلوگیری از عملکرد پایین بسیار مهم هستند. متعادل کردن توزیع کلاس از طریق تکنیک‌های کم نمونه‌گیری و بیش نمونه‌گیری حاصل می‌شود و بهترین نتایج عملکرد را تضمین می‌کند. [56,110-113]

جدول 6. خلاصه‌ای از مراحل پیش‌پردازش داده‌ها به همراه تکنیک‌های آنها. [15,31-56,101-113]

نکات برجسته	تکنیک	روش‌شناسی	پیش‌پردازش داده‌ها مراحل
داده‌های داده شده را استخراج کرده و آنها را به فرمت قابل استفاده تبدیل کنید	نرمال‌سازی بردار واحد	استانداردسازی و نرمال‌سازی	تبدیل داده‌ها
	حداکثر مقیاس عضلات شکم		
	اسکالر ترانسفورماتور کوانتایل		
	مقیاس‌بندی اسکالر مقاوم حداقل-حداکثر		
	اسکالر ترانسفورماتور قدرت		
	نرمال‌سازی بردار واحد		
	اسکالر استاندارد		

جدول ۶. ادامہ.

نکات برجسته	تکنیک	روش‌شناسی	پیش‌پردازش داده‌ها مراحل
از دست دادن کارایی، سوگیری شدید و پیچیدگی در مدیریت داده‌ها.	تحلیل کامل پرونده	جایگذاری مقادیر گم‌شده	تمیز کردن داده‌ها
	انتساب مکرر دسته‌ها		
	میانگین/میانگین انتساب		
	انتساب حالت		
	پایان انتساب دم		
	جایگذاری نزدیکترین همسایه		
	جایگذاری تکراری		
	جایگذاری عرشه گرم و سرد		
	انتساب اکتشافی		
	جایگذاری درون‌یابی		
جایگذاری مبتنی بر رگرسیون			
کاهش یا افزایش تعداد نمونه‌ها یا ویژگی‌هایی که در فرآیند آموزش مهم نیستند	پرداخت داده‌ها	درمان نویز	
	فیلترهای نویز		
	بسته بندی	انتخاب ویژگی	
	فیلتر		
	جاسازی شده		
	تحلیل مؤلفه‌های اصلی	استخراج ویژگی	کاهش/افزایش داده‌ها
	تحلیل تفکیکی خطی		
	تحلیل مؤلفه‌های مستقل		
	حداقل مربعات جزئی		
	کاهش ابعاد چند عاملی		
کاهش ابعاد غیرخطی			
رمزگذار خودکار			
تجزیه تانسور			
الگوریتم‌های تراکم	تولید نمونه		
			الگوریتم‌های تراکم
			الگوریتم‌های ویرایش
الگوریتم‌های ترکیبی			
از دست دادن اطلاعات، سادگی، خوانایی و فرآیند یادگیری سریع‌تر	گسسته‌سازی کای اسکوتر	مبتنی بر گسسته‌سازی	گسسته‌سازی
	گسسته‌سازی کارآمد		
نتایج ارزیابی واقعی را ارائه می‌دهد	کم‌نمونه‌گیری تصادفی	کم‌نمونه‌گیری	یادگیری نامتعادل
	لینک‌های تومک		
	نزدیکترین همسایه متراکم		
	ویرایش‌شده نزدیکترین همسایه		
	کم‌نمونه‌گیری نزدیک به خطا		
	نمونه‌گیری تصادفی بیش از حد	نمونه‌برداری بیش از حد	
	تکنیک نمونه‌گیری بیش از حد مصنوعی اقلیت		
	مصنوعی تطبیقی		
	تکنیک نمونه‌گیری بیش از حد اقلیت مصنوعی		
	مرزی		

۴.۲. رویکردهای تنظیم عملکرد مدل‌های یادگیری ماشین به ویژگی‌های مهندسی‌شده یا تنظیمات ابرپارامترها متکی است [۸۹،۹۰]. ایجاد یک مدل یادگیری ماشین موفق نیازمند یک فرآیند پیچیده است که شامل شناسایی یک الگوریتم مناسب و استفاده از یک معماری بهینه با تنظیم ابرپارامترهای آن (PH) می‌شود. [۹۱-۹۵] این پارامترها می‌توانند مقادیر دسته‌بندی‌شده، گسسته و پیوسته باشند.

روش‌های تنظیم هایپرپارامتر می‌توانند دستی یا خودکار باشند. [96-100] تنظیم دستی به دلیل مدل‌های پیچیده یادگیری ماشین و تعاملات غیرخطی هایپرپارامتر، رویکردی ناکارآمد است. [15،101،102] با این حال، تکنیک‌های تنظیم خودکار، فرآیند تشخیص پارامترهای بهینه یک مدل را با استفاده از روش‌های بهینه‌سازی خاص سرعت می‌بخشند. چندین تکنیک تنظیم هایپرپارامتر وجود دارد. این انواع، همانطور که در جدول 7 نشان داده شده است، نقاط قوت و محدودیت‌های مختلفی دارند. [89،103]

جدول 7. ویژگی‌ها، مزایا و معایب رویکردهای تنظیم. [89،103-113]

متدهای هایپرپارامتر	نقاط قوت	
• فقط با ابرپارامترهای دسته‌بندی‌شده مؤثر است؛ • یافتن ابرپارامترها زمان زیادی می‌برد.	• ساده.	جستجوی شبکه‌ای
• به نتایج قبلی متکی نیست؛ • نمی‌تواند با آن عملکرد خوبی داشته باشد. • موازی‌سازی را انجام می‌دهد؛ • مونتر از جستجوی شبکه‌ای است. • هایپرپارامترهای شرطی		جستجوی تصادفی
• عملکرد ضعیف برای موازی سازی.	• نیازی به مقداردی اولیه خوب ندارد؛ • با انواع هایپرپارامترها به خوبی کار می‌کند.	الگوریتم ژنتیک
• تشخیص بهینه محلی؛ • پشتیبانی از ابرپارامترهای پیوسته.	• سرعت همگرایی سریع برای ابرپارامترهای پیوسته.	تکنیک‌های مبتنی بر گرادیان
• عملکرد ضعیف برای موازی سازی.	• سرعت همگرایی سریع برای ابرپارامترهای پیوسته.	بهینه‌سازی بیزی-فرآیند گاوسی
• در موازی‌سازی خوب عمل می‌کند؛ • با انواع ابرپارامترها به خوبی کار می‌کند. • به مقداردی اولیه خوبی نیاز دارد.		بهینه‌سازی ازدحام ذرات
• وابستگی‌های شرطی را حفظ کند؛ • با انواع وابستگی‌ها به خوبی کار کند. • تعمیم‌پذیری بالا؛ • توانایی بهینه‌سازی بیزی		
• بهینه‌سازی موازی؛ • رضایت بخشی ارائه نمی دهد.		هایپرband
• عملکرد ضعیف؛ • موازی‌سازی.		بهینه‌سازی بیزی-SMAC
• پیدا کردن ابرپارامترها در برخی سناریوها می‌تواند چالش‌برانگیز باشد؛ • یافتن پارامترهای تطبیقی ممکن است برای برخی موارد مناسب نباشد.	• به طور همزمان بهینه سازی می کند پارامترها را تعیین کرده و مدل را آموزش می‌دهد؛ • انعطاف‌پذیری مدل یادگیری ماشین را بهبود می‌بخشد؛ • پارامترهای تطبیقی را به جای ... پیدا می‌کند. • نسبت به یک مجموعه ثابت از ابرپارامترها.	مبتنی بر جمعیت

۴.۳. معیارهای ارزیابی

معیارهای ارزیابی برای بررسی عملکرد مدل‌های یادگیری ماشین ضروری هستند. این معیارها بسته به کاربرد و دسته مدل‌ها متفاوت هستند. به عنوان مثال،

مدل‌های یادگیری نظارت‌شده به معیارهای متفاوتی نسبت به مدل‌های یادگیری تقویتی نیاز دارند. در زیر شرح مختصری از رایج‌ترین معیارها و معادلات ریاضی آنها آمده است.

۴.۳.۱. معیارهای ارزیابی برای دقت یادگیری نظارت‌شده: این معیار، پیش‌بینی‌های صحیح انجام‌شده توسط یک مدل یادگیری ماشینی را نشان می‌دهد. این معیار، همانطور که در معادله (۶) ارائه شده است، محاسبه می‌شود، که در آن TP نشان‌دهنده مثبت واقعی، TN نشان‌دهنده منفی واقعی، FP نشان‌دهنده مثبت کاذب و FN نشان‌دهنده منفی کاذب است.

تبی پی + تی ان
(6)
$$\frac{TP + TN}{TP + TN + FP + FN} \times 100$$
تی پی + اف پی + تی ان

دقت: این عدد، تعداد مثبت‌های واقعی تقسیم بر تعداد کل مثبت‌های واقعی و مثبت‌های کاذب را نشان می‌دهد. این عدد را می‌توان با فرمول زیر محاسبه کرد:

تی پی
(7)
$$\frac{TP}{TP + FP} \times 100$$
تی پی + اف پی

فراخوانی (نرخ تشخیص): این معیار، تعداد نمونه‌های مثبت طبقه‌بندی‌شده‌ی صحیح را به تعداد کل نمونه‌های مثبت محاسبه می‌کند. این معیار، همانطور که در معادله (8) نشان داده شده است، می‌تواند توانایی مدل را در طبقه‌بندی نمونه‌های مثبت در میان سایر نمونه‌ها نشان دهد.

تی پی
(8)
$$\frac{TP}{TP + FN}$$
تی پی + اف پی

امتیاز F1: این معیار از فراخوانی و دقت مشتق شده است، که در آن دقت در معادله (7) تعریف شده است و فراخوانی توسط معادله (8) ارائه شده است. این معادله به صورت زیر است:

(9)
$$F1 = \frac{2TP}{2TP + FP + FN}$$

مساحت زیر منحنی مشخصه عملکرد گیرنده (AUC): مشخصه عملکرد گیرنده (ROC) می‌تواند بده‌ایستان بین حساسیت و ویژگی را در یک مدل یادگیری ماشینی تجسم کند. این منحنی به عنوان نموداری از نرخ مثبت واقعی (TPR) به نرخ مثبت کاذب (FPR) در نظر گرفته می‌شود. این معیار با استفاده از معادله (10) محاسبه می‌شود، که در آن x پارامتر متغیر AUC را نشان می‌دهد.

تی پی
(10)
$$\int_0^1 \text{TPR}(FPR) \, dFPR$$
تی پی + اف پی

نرخ هشدار کاذب: نرخ هشدار کاذب، نرخ مثبت کاذب، احتمال به صدا درآمدن یک هشدار کاذب است. این معیار را می‌توان با فرمول زیر محاسبه کرد:

تی پی
(11)
$$\frac{FP}{N}$$
تی ان + اف پی

نرخ تشخیص اشتباه: این نرخ، درصد نمونه‌های طبقه‌بندی‌شده‌ی اشتباه را نشان می‌دهد. این نرخ از رابطه‌ی زیر محاسبه می‌شود:

تی پی
(12)
$$\frac{FP + FN}{N}$$
تی پی + اف پی

میانگین خطای مطلق درصد: برای ارزیابی دقت مدل‌های پیش‌بینی استفاده می‌شود. این معیار، میانگین درصد اختلاف بین مقادیر پیش‌بینی‌شده و واقعی را محاسبه می‌کند.

تی پی
(13)
$$\frac{1}{N} \sum_{t=1}^N |F_t - A_t|$$
تی ان

که در آن، n تعداد دفعات جمع‌بندی تکرار است، At مقدار واقعی در زمان t را نشان می‌دهد و Ft مقدار پیش‌بینی‌شده در زمان t است.

زمان پردازش: این به زمان صرف شده برای آموزش، آزمایش و پیش‌بینی نتایج اشاره دارد. این می‌تواند نشان دهنده زمان مورد نیاز برای پیش‌بینی یا تجزیه و تحلیل سیگنال‌های مخرب در مقایسه با سیگنال‌های غیرمخرب باشد.

زمان آموزش به ازای هر نمونه: این به زمان صرف شده برای آموزش یک مدل روی یک نمونه واحد از مجموعه داده‌ها اشاره دارد. این مقدار زمان مورد نیاز برای پردازش و یادگیری از ویژگی‌ها و برچسب‌های یک نمونه منفرد در طول مرحله آموزش را نشان می‌دهد.

میزان استفاده از حافظه: این مقدار حافظه یا فضای ذخیره‌سازی است که یک مدل در کل فرآیند خود به آن نیاز دارد. این مقدار، نشان‌دهنده‌ی میزان منابع حافظه‌ی مورد استفاده برای ذخیره و پردازش پارامترهای مدل، محاسبات میانی و سایر داده‌های مرتبط است.

۴.۳.۲. معیارهای ارزیابی برای مدل‌های یادگیری بدون نظارت

امتیاز سیلوئت (Silhouette Score): این معیار، میزان شباهت هر نقطه داده در یک خوشه را با نقاط داده خوشه‌های همسایه محاسبه می‌کند. مقادیر بالاتر نشان می‌دهد که نقاط داده به خوبی خوشه‌بندی شده‌اند و جدایی واضحی دارند.

شاخص دیویس-بولدین: این شاخص میانگین شباهت بین هر خوشه و شبیه‌ترین خوشه‌های آن را محاسبه می‌کند. شاخص دیویس-بولدین پایین‌تر نشان‌دهنده خوشه‌بندی بهتر است و مقادیر کوچک‌تر نشان‌دهنده خوشه‌های فشرده‌تر و متمایزتر هستند.

شاخص کالینسکی-هاراباز: این شاخص نسبت واریانس بین خوشه‌ای به واریانس درون خوشه‌ای را ارزیابی می‌کند. مقادیر بالاتر نشان‌دهنده جداسازی بهتر بین خوشه‌ها هستند و دلالت بر این دارند که داده‌ها به خوبی خوشه‌بندی شده‌اند.

شاخص دان: این معیار، نسبت حداقل فاصله بین خوشه‌ای به حداکثر فاصله درون خوشه‌ای را ارزیابی می‌کند. شاخص دان بالاتر، خوشه‌بندی بهتری را نشان می‌دهد، زیرا فواصل کوچک‌تر درون خوشه‌ها و فواصل بزرگ‌تر بین خوشه‌ها را نشان می‌دهد.

اینرسی (مجموع مربعات درون خوشه‌ای): اینرسی، فاصله کل بین نقاط داده درون یک خوشه را محاسبه می‌کند. مقادیر پایین‌تر اینرسی، خوشه‌های متراکم‌تر و فشرده‌تری را نشان می‌دهند.

آماره شکاف: آماره شکاف، عملکرد الگوریتم خوشه‌بندی را با عملکرد خوشه‌بندی تصادفی مقایسه می‌کند. شکاف بزرگ‌تر نشان می‌دهد که خوشه‌بندی الگوریتم بهتر از تصادفی است.

شاخص رند تعدیل‌شده: این شاخص، شباهت بین برچسب‌های کلاس واقعی و برچسب‌های اختصاص داده شده توسط الگوریتم خوشه‌بندی را با در نظر گرفتن شانس اندازه‌گیری می‌کند. مقادیر بالاتر نشان‌دهنده توافق خوشه‌بندی بهتر هستند.

اطلاعات متقابل نرمال‌شده: این معیار، اطلاعات متقابل بین برچسب‌های کلاس واقعی و تخصیص‌های خوشه‌بندی را اندازه‌گیری می‌کند و برای در نظر گرفتن شانس، نرمال‌سازی شده است. اطلاعات متقابل نرمال‌شده بالاتر، نشان‌دهنده کیفیت خوشه‌بندی بهتر است.

همگنی، کامل بودن و معیار V: این سه معیار، همگنی، کامل بودن و میانگین هارمونیک آنها (معیار V) جنبه‌های مختلف کیفیت خوشه‌بندی را ارزیابی می‌کنند. همگنی میزان خلوص هر خوشه را نسبت به یک کلاس واحد محاسبه می‌کند.

کامل بودن، میزان خوب بودن انتساب همه نمونه‌های یک کلاس مشخص به یک خوشه را اندازه‌گیری می‌کند. معیار V همگنی و کامل بودن را در یک معیار واحد ترکیب می‌کند.

شکاف طیفی: شکاف طیفی، شکاف بین مقادیر ویژه یک شباهت را اندازه‌گیری می‌کند. ماتریس یا گراف لاپلاس. شکاف طیفی بزرگ‌تر نشان دهنده خوشه‌های متمایزتر است.

۴.۳.۳. معیارهای ارزیابی برای مدل‌های یادگیری نیمه‌نظارتی لگاریتم درست‌نمایی: در یادگیری نیمه‌نظارتی، که در آن از مدل‌های مولد مانند مدل‌های مخلوط گاوسی (GMM) یا خودرمزگذارهای تغییراتی (VAE) استفاده می‌شود، لگاریتم درست‌نمایی می‌تواند یک معیار حیاتی باشد. این معیار میزان موفقیت مدل در ثبت توزیع داده‌های زیربنایی را اندازه‌گیری می‌کند.

دقت شبه‌برچسب: در یادگیری نیمه‌نظارتی، شبه‌برچسب‌ها بر اساس پیش‌بینی‌های مدل به نقاط داده بدون برچسب اختصاص داده می‌شوند. دقت شبه‌برچسب، دقت این شبه‌برچسب‌ها را اندازه‌گیری می‌کند و بینشی در مورد میزان استفاده مدل از داده‌های بدون برچسب ارائه می‌دهد.

منظم‌سازی سازگاری: برخی از روش‌های یادگیری نیمه‌نظارتی از منظم‌سازی سازگاری به عنوان معیاری برای سنجش پایداری مدل با مقایسه پیش‌بینی‌ها روی نسخه‌های مختل‌شده از ورودی یکسان استفاده می‌کنند. سازگاری بالاتر نشان دهنده تعمیم‌پذیری بهتر است. معیارهای یادگیری فعال: در یادگیری نیمه نظارتی با یادگیری فعال، از معیارهایی مانند تراکم پرساوجو و تنوع پرساوجو استفاده می‌شود. تراکم پرساوجو میزان موفقیت مدل در انتخاب نقاط داده آموزنده برای برچسب‌گذاری را اندازه‌گیری می‌کند، در حالی که تنوع پرساوجو، تنوع نقاط داده انتخاب شده را ارزیابی می‌کند.

آنتروپی: آنتروپی، عدم قطعیت پیش‌بینی‌های مدل را اندازه‌گیری می‌کند. آنتروپی پایین‌تر نشان‌دهنده‌ی اطمینان بالاتر در پیش‌بینی‌ها است که می‌تواند معیار ارزشمندی در هنگام کار با داده‌های بدون برچسب باشد.

۴.۳.۴. معیارهای ارزیابی برای مدل‌های یادگیری تقویتی پاداش تجمعی (بازده): پاداش تجمعی که بازده نیز نامیده می‌شود، مجموع پاداش‌های دریافتی توسط عامل در طول یک توالی از اقدامات در یک قسمت است. این معیار، توانایی عامل را در به حداکثر رساندن اهداف بلندمدت خود اندازه‌گیری می‌کند.

پاداش میانگین: پاداش میانگین، مقدار مورد انتظار پاداش‌های دریافتی در هر گام زمانی یا در هر قسمت را محاسبه می‌کند. این معیار، معیاری از کارایی و اثربخشی عامل در دستیابی به اهدافش را ارائه می‌دهد.

مجموع پاداش‌های تخفیف‌دار: در برخی موارد، در نظر گرفتن پاداش‌های آینده با وزن‌های کمتر مهم است. مجموع پاداش‌های تخفیف‌دار، ضریب تخفیفی (گاما) را اعمال می‌کند تا به پاداش‌های فوری اهمیت بیشتری داده شود و در عین حال پیامدهای بلندمدت نیز در نظر گرفته شود. وظایف اپیزودیک در مقابل وظایف مداوم: بسته به وظیفه، ممکن است لازم باشد از روش‌های ارزیابی متفاوتی استفاده کنید. وظایف اپیزودیک برای هر قسمت، شروع و پایان مشخصی دارند، در حالی که وظایف مداوم به طور نامحدود ادامه می‌یابند. انتخاب معیار ارزیابی می‌تواند بر این اساس متفاوت باشد.

نرخ کاوش: کاوش در یادگیری تقویتی بسیار مهم است. ارزیابی نرخ کاوش عامل به تعیین اینکه آیا به طور مؤثر محیط را برای کشف سیاست‌های بهینه کاوش می‌کند یا اینکه در دام سیاست‌های غیربهبهینه گرفتار می‌شود، کمک می‌کند.

منحنی یادگیری: منحنی یادگیری، عملکرد عامل (مثلاً پاداش تجمعی) را در طول زمان رسم می‌کند و نشان می‌دهد که با چه سرعتی به یک سیاست بهینه یا نزدیک به بهینه همگرا می‌شود. به نظارت بر پیشرفت یادگیری کمک می‌کند.

همگرایی Q-value: در یادگیری Q و سایر روش‌های مبتنی بر مقدار، همگرایی Q-value را می‌توان ارزیابی کرد تا مشخص شود که آیا عامل یک تابع مقدار دقیق را یاد گرفته است یا خیر.

همگرایی سیاست: برای روش‌های مبتنی بر سیاست، مانند گرادین‌های سیاست یا REIN- FORCE همگرایی سیاست عامل می‌تواند ارزیابی شود تا مشخص شود که آیا یک سیاست بهینه یا نزدیک به بهینه پیدا کرده است یا خیر.

معیارهای موازنه اکتشاف-بهره‌برداری: معیارهایی مانند نرخ اکتشاف حریصانه اِپِسلون (ε)، اکتشاف بولتزمن یا UCB (محدوده اطمینان بالا) به ارزیابی میزان تعادل عامل بین اکتشاف (تلاش برای اقدامات جدید) و بهره‌برداری (انتخاب شناخته‌شده‌ترین اقدامات) کمک می‌کنند.

نرخ موفقیت: در وظایفی که هدف یا منظور خاصی وجود دارد (مثلاً رسیدن به یک هدف در یک هزارتو)، نرخ موفقیت درصد اپیزودهایی را اندازه‌گیری می‌کند که در آن‌ها عامل با موفقیت به هدف دست می‌یابد.

آنتروپی سیاست: آنتروپی سیاست، سطح عدم قطعیت در انتخاب اقدام عامل را کمی می‌کند. آنتروپی بالاتر نشان‌دهنده کاوش بیشتر است، در حالی که آنتروپی پایین‌تر نشان‌دهنده یک سیاست قطعی‌تر است.

زمان حل: این معیار، زمان یا تعداد گام‌هایی را که عامل برای حل مسئله طی می‌کند، اندازه‌گیری می‌کند. برای دستیابی به سطح از پیش تعریف‌شده‌ای از عملکرد یا حل یک کار، این به ارزیابی کارایی کمک می‌کند. کارایی نمونه: کارایی نمونه، سرعت یادگیری عامل از تعاملاتش با محیط را ارزیابی می‌کند و تعداد اپیزودها یا مراحل مورد نیاز برای رسیدن به سطح مشخصی از عملکرد را در نظر می‌گیرد.

جدول 8 معیارهای ارزیابی ممکن برای هر دسته یادگیری ماشینی را، همانطور که در بالا بحث شد، خلاصه می‌کند.

جدول 8. معیارهای ارزیابی برای مدل‌های یادگیری نظارت‌شده، نیمه‌نظارت‌شده، بدون نظارت و تقویتی .

نام متریک	دسته بندی
• دقت؛ فراخوانی؛ امتیاز ؛F1نرخ هشدار اشتباه؛ دقت؛ • سطح زیر منحنی • ؛(AUC)نرخ تشخیص اشتباه؛ • میانگین درصد خطای مطلق • زمان پردازش؛ • زمان پیش‌بینی؛ • اندازه حافظه؛ • زمان آموزش به ازای هر نمونه.	یادگیری تحت نظارت
• امتیاز سیلوئت؛ • شاخص دان؛ • اینرسی (مجموع مربعات درون خوشه‌ای) ؛ • آماره شکاف؛ • شاخص دیویس-بولدین؛ • شاخص رند تعدیل‌شده؛ • اطلاعات متقابل نرمال‌شده؛ • همگنی، کامل بودن و معیار • ؛Vشاخص کالینسکی-هاراباز؛ شکاف طیفی.	یادگیری بدون نظارت
• دقت؛ دقت؛ فراخوانی؛ امتیاز ؛ AUC • ؛F1نرخ هشدار اشتباه؛ • نرخ تشخیص اشتباه؛ • میانگین درصد خطای مطلق؛ • زمان پردازش؛ • زمان پیش‌بینی؛ • اندازه حافظه؛ • زمان آموزش به ازای هر نمونه؛ • درستی لگاریتمی؛ • دقت شبه‌برچسب؛ • • منظم‌سازی سازگاری؛ • معیارهای یادگیری فعال؛ • آنتروپی.	یادگیری نیمه نظارتی
• یاداش تجمعی (بازده)؛ • یاداش متوسط؛ • مجموع یاداش‌های تخفیف‌یافته؛ • وظایف اپیزودیک در مقابل وظایف مداوم؛ • نرخ کاوش؛ • منحنی یادگیری؛ • همگرایی مقدار ؛Qهمگرایی سیاست؛ • معیارهای موازنه کاوش-بهره‌برداری؛ • نرخ موفقیت؛ • آنتروپی سیاست؛ • زمان حل؛ • کارایی نمونه.	یادگیری تقویتی

۵. چالش‌ها و مسیرهای آینده

یادگیری ماشینی در سال‌های اخیر شاهد پیشرفت‌های چشمگیری بوده است. اما هنوز با چالش‌ها و جهت‌گیری‌های تحقیقاتی متعددی روبرو است. برخی از حوزه‌های برجسته تمرکز در جدول 9 نشان داده شده است.

جدول 9. چالش‌های فعلی در یادگیری ماشین. [114-125]

چالش‌ها	توضیحات
قابلیت تفسیر و توضیح	• معماری مدل پیچیده؛ • مدل‌های جعبه سیاه؛ • توضیحات کاربرپسند؛ ویژگی‌های قابل تفسیر؛ موازنه با عملکرد.
تعصب و انصاف	• سوگیری داده‌ها و الگوریتم‌ها؛ • بروز سوگیری‌های ناخواسته یا تبعیض علیه گروه‌های خاص؛ سوگیری‌ها در سیستم‌های پشتیبانی تصمیم‌گیری.
استحکام خصمانه	• مسمومیت داده‌های خصمانه؛ • محدودیت‌های محاسباتی و منابع؛ • پیچیدگی مدل داده؛ • حملات خصمانه و قابلیت انتقال آنها.
حریم خصوصی و امنیت	• محافظت از داده‌ها و مدل‌های کاربر در برابر نقض حریم خصوصی و حملات؛ • یادگیری فدرال امن و حریم خصوصی تفاضلی.
یادگیری تقویتی	• کارایی پایین؛ • پایداری پایین؛ • قابلیت تعمیم پایین؛ • بده بستان‌های اکتشاف-بهره‌برداری، یادگیری خارج از سیاست و یادگیری تقویتی ایمن.
محاسبات کوانتومی	• اهداف متناقض؛ • بهینه‌سازی چندمعیاره؛ • توسعه الگوریتم؛ • عدم تحذب؛ • فضاهای جستجوی با ابعاد بالا؛ • محدودیت‌های منابع محاسباتی.
مدل‌های چندمعیاره	• پیچیدگی بده بستان؛ • عدم تحذب؛ • ابعاد بالا؛ • مدل‌سازی ترجیحات؛ • منابع محاسباتی؛ قابلیت تفسیر؛ مقیاس‌پذیری.

قابلیت تفسیر و توضیح: مدل‌های یادگیری ماشین به دلیل پیچیدگی‌شان به عنوان جعبه سیاه در نظر گرفته می‌شوند. بنابراین، خروجی‌های آنها معمولاً قابل درک نیستند. بنابراین، تقاضای مبرمی برای درک و توضیح فرآیندهای تصمیم‌گیری آنها وجود دارد. دستیابی به قابلیت تفسیر و توضیح برای ایجاد اعتماد و تضمین بهترین کارایی حیاتی است. [114-122]

سوگیری و انصاف: الگوریتم‌های یادگیری ماشین از مجموعه داده‌های ساخته‌شده توسط انسان‌ها استفاده می‌کنند، بنابراین این مدل‌ها می‌توانند به‌طور ناخواسته سوگیری‌هایی را نشان دهند یا علیه گروه‌های خاص تبعیض قائل شوند. در نتیجه، کاهش بیش‌برازش و ارتقای انصاف در مدل‌های یادگیری ماشین از اهداف مهم تحقیقاتی هستند. این امر مستلزم توسعه روش‌هایی برای طبقه‌بندی

سوگیری‌ها، و همچنین طراحی الگوریتم‌هایی که انصاف را نشان می‌دهند و فاقد سوگیری در گروه‌های جمعیتی متنوع هستند [114-117].

استحکام در برابر حملات خصمانه: مدل‌های یادگیری ماشین در برابر حملات خصمانه آسیب‌پذیر هستند، که در آن تغییرات جزئی و نامحسوس در داده‌های ورودی می‌تواند منجر به طبقه‌بندی نادرست یا پیش‌بینی‌های اشتباه شود. تحقیقات به طور فعال بر ساخت مدل‌های قوی که در برابر حملات خصمانه مقاومت می‌کنند، متمرکز است. تکنیک‌هایی مانند آموزش خصمانه، تقطیر دفاعی و بهینه‌سازی مقاوم برای افزایش تاب‌آوری مدل به کار گرفته می‌شوند [117، 118].

حریم خصوصی و امنیت: افزایش استفاده از یادگیری ماشین در حوزه‌های حساس، نگرانی‌هایی را در مورد حریم خصوصی و امنیت ایجاد می‌کند. محافظت از داده‌ها و مدل‌های کاربر در برابر نقض حریم خصوصی و حملات، بسیار مهم می‌شود. جهت‌گیری‌های تحقیقاتی شامل توسعه تکنیک‌های یادگیری ماشین با حفظ حریم خصوصی مانند محاسبات چندجانبه امن، یادگیری فدرال و حریم خصوصی تفاضلی است [114-122].

یادگیری تقویتی: در برخی زمینه‌ها و موارد، داده‌های واقعی محدودی در دسترس است. برای مثال، در امنیت سایبری، داده‌های حاصل از حملات می‌توانند بسیار محدود باشند و در برخی موارد، انجام حملات برای به دست آوردن داده‌ها مجاز نیست. یادگیری تقویتی به چالش دسترسی محدود به داده‌ها می‌پردازد. با این حال، مدل‌های تقویتی موجود، کارایی کمتری نسبت به مدل‌های یادگیری ماشین مرسوم دارند. بنابراین، تلاش‌های تحقیقاتی بر افزایش کارایی، پایداری و قابلیت‌های تعمیم الگوریتم‌های یادگیری تقویتی متمرکز شده‌اند. مباحث شامل موازنه‌های اکتشاف-بهره‌برداری، یادگیری خارج از سیاست و یادگیری تقویتی ایمن است [115-122].

مدل‌های چندمعیاره: در چشم‌انداز به سرعت در حال تحول یادگیری ماشین، روندهای جدیدی برای افزایش قابلیت‌های تصمیم‌گیری و محاسباتی در حال ظهور هستند. به عنوان مثال، مدل‌های چندمعیاره در حال برجسته شدن هستند و فرآیندهای تصمیم‌گیری پیچیده‌تر و ظریف‌تری را امکان‌پذیر می‌سازند. این مدل‌ها را می‌توان برای در نظر گرفتن معیارها و اهداف چندگانه، اغلب متضاد، در نظر گرفت [123]. مدل‌های چندمعیاره در یادگیری ماشین شامل بهینه‌سازی فرآیندهای تصمیم‌گیری در زمانی هستند که چندین هدف متضاد برای بررسی وجود دارد، مانند هزینه، دقت و قابلیت تفسیر. توسعه الگوریتم‌های یادگیری ماشین که بتوانند این اهداف متضاد را مدیریت کنند و بین آنها به طور مؤثر تعادل برقرار کنند، همچنان یک چالش مهم است. رویکردهای رایج شامل تکنیک‌های بهینه‌سازی چندهدفه، کاوش جبهه پارتو و مدل‌سازی ترجیحات است. ادغام مؤثر این رویکردها در مدل‌های یادگیری ماشین به دلیل چندین مسئله، از جمله عدم تعادل، فضای جستجوی با ابعاد بالا و محدودیت‌های منابع محاسباتی، پیچیده است. پرداختن به این مشکلات برای ایجاد مدل‌های یادگیری ماشین چندمعیاره قوی که قادر به تصمیم‌گیری آگاهانه هستند و اهداف و ترجیحات متنوع را در کاربردهای دنیای واقعی متعادل می‌کنند، بسیار مهم است.

محاسبات کوانتومی: محاسبات کوانتومی نمایانگر یک مرز انقلابی در یادگیری ماشین است. محاسبات کوانتومی می‌تواند پتانسیل افزایش سرعت نمایی در حل وظایف پیچیده بهینه‌سازی و تشخیص الگو را ارائه دهد. با مهار اصول مکانیک کوانتومی، محاسبات کوانتومی ممکن است این حوزه را متحول کند، درهایی را به روی چالش‌های قبلاً غیرقابل عبور باز کند و مرزهای جدیدی را در یادگیری ماشین و تجزیه و تحلیل داده‌ها باز کند [124، 125]. محاسبات کوانتومی با بهره‌گیری از پدیده‌های کوانتومی مانند درهم‌تنه‌ی و درهم‌تنیدگی، نویدبخش حل مسائل پیچیده در یادگیری ماشین است. یکی از چالش‌های برجسته در یادگیری ماشین کلاسیک، حل مسائل بهینه‌سازی است و الگوریتم‌های کوانتومی مانند الگوریتم بهینه‌سازی تقریبی کوانتومی و حل‌کننده ویژه کوانتومی متغیر، پتانسیل همگرایی سریع‌تر بهینه‌سازی را نشان می‌دهند. علاوه بر این، مدل‌های یادگیری ماشین کوانتومی، مانند ماشین‌های بردار پشتیبان کوانتومی و شبکه‌های عصبی کوانتومی، با هدف ارائه مزایای کوانتومی نسبت به هم‌تایان کلاسیک در وظایفی مانند طبقه‌بندی و رگرسیون هستند. با این حال، محاسبات کوانتومی در یادگیری ماشین هنوز در مراحل ابتدایی خود است و با چالش‌هایی مربوط به تصحیح خطا، مقیاس‌پذیری سخت‌افزار و نیاز به طرح‌های رمزگذاری داده‌های کوانتومی روبرو است. با بالغ شدن این حوزه و پیشرفت فناوری‌های کوانتومی، محاسبات کوانتومی می‌تواند با مقابله کارآمدتر با چالش‌های پیچیده بهینه‌سازی و مدل‌سازی، کاندیدی بالقوه‌ای برای ایجاد انقلابی در یادگیری ماشین باشد.

این چالش‌ها و جهت‌گیری‌های تحقیقاتی تنها بخشی از چشم‌انداز وسیع یادگیری ماشینی را نشان می‌دهند. این چالش‌ها پیچیدگی یادگیری ماشینی را برجسته می‌کنند و محققان و متخصصان تلاش می‌کنند تا بر محدودیت‌ها غلبه کرده و قابلیت‌های این سیستم‌ها را ارتقا دهند. این حوزه همچنان به سرعت در حال تکامل است و این امر به دلیل ضرورت مقابله با این چالش‌ها و گسترش مرزهای آنچه با این مدل‌ها قابل دستیابی است، می‌باشد.

۶. نتیجه‌گیری

این مقاله خلاصه‌ای از کاربردهای امنیت سایبری یادگیری ماشین را برجسته می‌کند که شامل پیش‌پردازش داده‌ها، مدل‌ها و تکنیک‌های بهینه‌سازی قابل اجرا در حوزه‌های مختلف است. این بررسی مفاهیم اساسی، پیشرفت‌های فعلی، اجزای کاربردهای امنیت سایبری یادگیری ماشین و چالش‌های موجود را مورد بحث قرار می‌دهد. یکی از سهم‌های اصلی این بررسی، طبقه‌بندی مدل‌های یادگیری ماشین به چهار دسته است: نظارت‌شده، نیمه‌نظارت‌شده، بدون نظارت و یادگیری تقویتی. از طریق این طبقه‌بندی، ما طبقه‌بندی از پیشرفت‌های موجود در مدل‌های طبقه‌بندی یادگیری ماشین را بر اساس ویژگی‌های مشترک آنها معرفی می‌کنیم. تکنیک‌های بهینه‌سازی، تکنیک‌های ضروری در توسعه الگوریتم‌های یادگیری ماشین بهینه و موفق هستند و ما بحث مختصری در مورد این تکنیک‌ها ارائه می‌دهیم. علاوه بر این، چالش‌های باز و جهت‌های تحقیقاتی بالقوه را برای الهام بخشیدن به تلاش‌های تحقیقاتی عملی و آینده تشریح می‌کنیم.

مشارکت‌های نویسندگان: تحقیق، NK و TTK منابع، TTK نگارش TTK و - NK نگارش - بررسی و ویرایش، NK نظارت، NK مدیریت پروژه، NK تأمین بودجه. NK همه نویسندگان نسخه منتشر شده مقاله را خوانده و با آن موافقت کرده‌اند.

بودجه: این تحقیق توسط بنیاد ملی علوم (NSF) با شماره جایزه 2006674 تأمین مالی شده است.

بیانیه دسترسی به داده‌ها: قابل اجرا نیست.

تضاد منافع: نویسندگان هیچگونه تضاد منافی را اعلام نمی‌کنند.

منابع

۱.

سارکر، IH، یادگیری ماشین: الگوریتم‌ها، کاربردهای دنیای واقعی و مسیرهای تحقیقاتی. SN Comput. Sci. 2021، 2، 160.

[مرجع متقابل]

2. Vinuesa، R. عزیزپور، ح.، لیت، آی.، بلعام، م.، دیگنوم، وی.، دومیش، اس.، فلاندر، آ.، SD، Langhans، تنگمارک، م.، Nerini، FF نقش هوش مصنوعی در دستیابی به اهداف توسعه پایدار، نات. اشتراک. [CrossRef] 2020، 11، 233.

[پایان]

۳. الله، ز.؛ التورجمان، ف.؛ موستاردا، ل.؛ گالیاردی، ر. کاربردهای هوش مصنوعی و یادگیری ماشینی در شهرهای هوشمند.

مجله کامپیوتر. ارتباطات. [CrossRef] 2020، 154، 313-323.

۴. اورزانلی، آک.؛ یاپراکدال، اف.؛ بایسال، ام. روش‌ها و کاربردهای یادگیری عمیق برای سیستم‌های قدرت الکتریکی: یک بررسی جامع. مجله بین‌المللی انرژی، [CrossRef] ۲۰۲۰، ۴۴، ۷۱۳۶-۷۱۵۷.

5. ژائو، س.؛ بلایجرگ، ف.؛ وانگ، ه. مروری بر کاربردهای هوش مصنوعی برای الکترونیک قدرت. IEEE Trans. Power

الکترون. [CrossRef] 2021، 36، 4633-4658.

6. مامون، AA؛ سهیل، M.؛ محمد، N.؛ سانی، MSH؛ دپیتا، DR؛ حسین، E. مروری جامع بر تکنیک‌های پیش‌بینی بار با استفاده از مدل‌های پیش‌بینی تکی و ترکیبی. [CrossRef] 134911-134939. IEEE Access 2020، 8،

۷. مسعودی، م.؛ درویش، ا.؛ رفعت، س.س.؛ ابو-روب، ح.؛ تولیت، ه.ا.، محلی‌سازی تخلیه جزئی UHF در تابلهای برق عایق گاز: رویکرد مبتنی بر تقویت گرادیان. در مجموعه مقالات کنفرانس برق و انرژی کانزاس (IEEE 2020 KPEC)، کانزاس، ایالات متحده آمریکا، ۱۴-۱۳ ژوئیه ۲۰۲۰؛ صفحات ۵-۱۰.

۸. علی، اس.اس.؛ چوی، بی.جی. تکنیک‌های هوش مصنوعی پیشرفته برای شبکه‌های هوشمند توزیع‌شده: یک بررسی. الکترونیک [CrossRef] 2020، 9، 1030.

۹. یین، ل.؛ گائو، ک.؛ ژائو، ل.؛ ژانگ، ب.؛ وانگ، ت.؛ لی، س.؛ لیو، ه. مروری بر یادگیری ماشین برای نسل جدید توزیع هوشمند بار در سیستم‌های قدرت. [CrossRef] 2020، 88، 103372. Eng. Appl. Artif. Intell.

۱۰. اپنگ، س.؛ سان، س.؛ یائو، ی.د. بررسی طبقه‌بندی مدولاسیون با استفاده از یادگیری عمیق: نمایش سیگنال و پیش‌پردازش داده‌ها. در Neural Networks and Learning Systems: IEEE Transactions on ۲۰۲۱،

۱۱. آرجون، ی.؛ کابوش، ن. بررسی جامع حسگری طیف در شبکه‌های رادیویی شناختی: پیشرفت‌های اخیر، جدید

چالش‌ها و مسیرهای تحقیقاتی آینده. حسگرها [CrossRef] ۲۰۱۹، ۱۹، ۱۲۶.

۱۲. امنگ، تی.؛ جینگ، ایکس.؛ یان، زی.؛ پدریج، دبلیو. بررسی یادگیری ماشین برای تلفیق داده‌ها. [CrossRef] Inf. Fusion 2020، 57، 115-129.

۱۳. کاروالیو، دی‌وی؛ پریرا، ای‌ام؛ کاردوسو، جی‌اس. تفسیرپذیری یادگیری ماشین: بررسی روش‌ها و معیارها. الکترونیک ۲۰۱۹،

۸. ۸۳۲. [CrossRef]

14. خویی، ت. ت؛ اسماعیل، س.؛ کابوش، ن. مدل‌های مبتنی بر تقویت با بهینه‌سازی تخمین‌گر پارزن با ساختار درختی برای تشخیص حملات نفوذ به شبکه هوشمند. در مجموعه مقالات دوازدهمین کنفرانس سالانه محاسبات فراگیر، الکترونیک و ارتباطات سیار (UEMCON 2021) نیویورک، نیویورک، ایالات متحده آمریکا، 4-۱۰ دسامبر 2021؛ صفحات [CrossRef] 165-170.

۱۵. اهاتر، ف.؛ لوک، ج.؛ اشمیت-تیم، ل. فراتر از تنظیم دستی ابرپارامترها. هوش مصنوعی. ۲۰۱۵، ۲۹، ۳۳۷-۳۲۹.

[مرجع متقابل]

16. خویی، ت. ت؛ آیسو، گ.؛ هو، دلیو. سی؛ کابوش، ن. روش‌های یادگیری گروهی برای سیستم تشخیص نفوذ ناهنجاری در شبکه هوشمند. در مجموعه مقالات کنفرانس بین‌المللی IEEE در مورد فناوری اطلاعات الکتریکی (EIT)، مونت پلزن، میشیگان، ایالات متحده آمریکا، 15-14 مه 2021؛ صفحات [CrossRef] 129-135.

۱۷. اوبرت دو پویزو، سی.؛ میس، آر.؛ میسن، تی. در مورد قابلیت اطمینان سیستم‌های برنامه‌ریزی تولید مبتنی بر یادگیری تقویتی: الف بررسی تطبیقی. مجله هوش مصنوعی. [CrossRef] 2022, 33, 911-927.

۱۸. اموس، جی.؛ هانسل، کی.؛ عبدالصمد، اچ.؛ استارک، اس.؛ کلور، دی.؛ پیتز، جی. یادگیری تقویتی مقاوم: مروری بر مبانی و پیشرفت‌های اخیر. مآخ. یادگیری. دانش. اضافی. [CrossRef] 2022, 4, 276-315.

۱۹. الطیف، س.؛ کویاوهیتل، ج.؛ پرویز، ف.؛ شمشاد، ف.؛ علی، ح. اس.؛ کامبیرا، ای. بررسی یادگیری تقویتی عمیق برای کاربردهای مبتنی بر صدا. [CrossRef] Artif. Intell. Rev. 2022, 56, 2193-2240.

20. پاساح، آ.؛ کندر، د. یک مدل یادگیری عمیق سبک برای طبقه‌بندی تصاویر رادار روزنه مصنوعی. Ecol. Inform. 2023, ۷۷, ۱۰۲۲۸. [CrossRef]

21. فرانکن، ج. ولتینگ، ام. کاتزی، جی. کلونبورگ، جی. وریلن، تی. Rellermeyer, JS نظرسنجی در مورد یادگیری ماشینی توزیع شده. [CrossRef] ACM Comput. Surv. 2020, 53, 1-33.

۲۲. دارگان، س.؛ کومار، م.؛ آیگاری، م. ر.؛ کومار، گ. بررسی یادگیری عمیق و کاربردهای آن: الگویی جدید برای ماشین یادگیری. مهندسی روش‌های محاسباتی معماری. [CrossRef] 2020, 27, 1071-1092.

۲۳. پیتروپاکیس، ن.؛ پاناؤسیس، ای.؛ جیانتسوس، ت.؛ آناستازیادیس، ای.؛ لوکاس، جی. طبقه‌بندی و بررسی حملات علیه یادگیری ماشینی. مجله علوم کامپیوتر، ویرایش ۲۰۱۹، شماره ۳۴، شماره [CrossRef] ۱۰۰۱۹۹.

۲۴. وو، ایکس.؛ شیائو، ال.؛ سان، وای.؛ ژانگ، جی.؛ ما، تی.؛ هی، ال. بررسی نقش انسان در حلقه برای یادگیری ماشین. آینده. عمومی. محاسبات. سیستم. [CrossRef] ۲۰۲۲, ۱۳۵, ۳۶۴-۳۸۱.

۲۵. وانگ، کیو.؛ ما، وای.؛ ژائو، کی.؛ تیان، وای. بررسی جامع توابع زیان در یادگیری ماشین. مجله علوم داده. ۲۰۲۲, ۹, ۱۸۷-۲۱۲.

[مرجع متقابل]

۲۶. چوی، اچ.؛ پارک، اس. بررسی تکنیک‌های بهینه‌سازی عملکرد سیستم مبتنی بر یادگیری ماشین. علوم کاربردی. ۲۰۲۱, ۱۱, ۳۲۳۵.

[مرجع متقابل]

۲۷. راوسون، آ.؛ بریتو، م. بررسی فرصت‌ها و چالش‌های یادگیری ماشینی تحت نظارت در تحلیل ریسک دریایی. ترجمه. ویرایش [CrossRef] ۲۰۲۲, ۴۳, ۱۰۸-۱۳۰.

۲۸. احمد، ر.؛ وزیرعلی، ر.؛ ابوعین، ت. یادگیری ماشینی برای امنیت شبکه‌های حسگر بی‌سیم: مروری بر چالش‌ها و مسائل. حسگرها [CrossRef] 2022, 22, 4730. [پایامد]

۲۹. سینگ، آ.؛ تاکور، ن.؛ شارما، آ. مروری بر الگوریتم‌های یادگیری ماشین تحت نظارت. در مجموعه مقالات سومین کنفرانس بین‌المللی محاسبات برای توسعه پایدار جهانی (INDIACom) سال ۲۰۱۶، دهلی نو، هند، ۱۶ تا ۱۸ مارس ۲۰۱۶؛ صفحات ۱۳۱۰ تا ۱۳۱۵.

۳۰. عبدالله، ای. ای.؛ الیسا، دلیو.؛ اتوم، ای. اف. سیستم‌های تشخیص نفوذ با استفاده از تکنیک‌های یادگیری ماشینی نظارت‌شده: یک بررسی. Procedia Comput. علمی [CrossRef] 2022, 201, 205-212.

۳۱. دایک، هو. ژو، وای.؛ دویراستی، کی. کی. وو، کیو. یادگیری بدون نظارت مبتنی بر شبکه عصبی مصنوعی: مروری. در مجموعه مقالات کنفرانس بین‌المللی IEEE 2018 در مورد سیستم‌های سایبورگ و بیونیک ۲۵ (CBS)، ۱۷ اکتبر ۲۰۱۸؛ صفحات ۳۲۲ تا ۳۲۷.

۳۲. ون انگلن، جی. ای.؛ هوس، اچ. اچ. بررسی در مورد یادگیری نیمه نظارتی. مآخ. لرن. [CrossRef] ۲۰۲۰, ۱۰۹, ۳۷۳-۴۴۰.

۳۳. روتمن، م.؛ پورمن، م. بررسی معماری‌های خاص دامنه برای یادگیری تقویتی. IEEE Access 2022, ۱۰, ۱۳۷۶۷-۱۳۷۵۳. [CrossRef]

۳۴. دونگ، س.؛ وانگ، پ.؛ عباس، ک. بررسی یادگیری عمیق و کاربردهای آن. مجله علوم کامپیوتر، شماره ۲۰۲۰، صفحه ۴۰، صفحه [CrossRef] ۱۰۳۷۹.

۳۵. ری، س. مروری سریع بر الگوریتم‌های یادگیری ماشین. در مجموعه مقالات کنفرانس بین‌المللی یادگیری ماشین، کلان داده، ابر و محاسبات موازی (COMITCon)، ۱۹ فروردین، ۱۴ تا ۱۶ فوریه ۲۰۱۹؛ صفحات ۳۵ تا ۳۹.

۳۶. لانسکی، جی.؛ علی، س.؛ محمدی، م.؛ مجید، م. ک.؛ کریم، س. ه.؛ رشیدی، س.؛ حسین‌زاده، م.؛ رحمانی، ای. ام. سیستم‌های تشخیص نفوذ مبتنی بر یادگیری عمیق: یک بررسی سیستماتیک. [CrossRef] IEEE Access 2021, 9, 101574-101599.

۳۷. مسعودی، م.؛ ابو-روب، ح.؛ رفعت، س. س.؛ چیهی، آی.؛ اوسلاتی، ف. س. یادگیری عمیق در فناوری شبکه هوشمند: مروری بر پیشرفت‌های اخیر و چشم‌اندازهای آینده. [CrossRef] 9, 54558-54578. IEEE Access 2021,

۳۸. لایو، اچ.؛ لانگ، بی. روش‌های یادگیری ماشینی و یادگیری عمیق برای سیستم‌های تشخیص نفوذ: یک بررسی. علوم کاربردی. ۲۰۱۹، ۹، ۴۳۹۶. [CrossRef]

۳۹. ون، ن.؛ شی، وای. بررسی یادگیری ماشینی برای معماری و سیستم‌های کامپیوتری. ACM Comput. Surv. 2022, 55, 1-39.

[مرجع متقابل]

۴۰. شمارج، ل.؛ سانتاروسا، م.؛ شرودر، س. م.؛ کخ، ر. بررسی یادگیری نیمه‌نظارتی، خودنظارتی و بدون نظارت برای طبقه‌بندی تصویر پخش. [CrossRef] IEEE Access 2021, 9, 82146-82168.

۴۱. شی، جی.؛ یو، اف. آر.؛ هوانگ، تی.؛ شی، آر.؛ لیو، جی.؛ وانگ، سی.؛ لیو، وای. بررسی تکنیک‌های یادگیری ماشینی کاربردی در شبکه‌های نرم‌افزارمحور (SDN) مسائل و چالش‌های تحقیقاتی. در IEEE: IEEE Communications Surveys & Tutorials، نیویورک، نیویورک، ایالات متحده آمریکا، ۱۹-۲۰، جلد ۲۱، صفحات ۳۹۳-۴۳۰.

42. یانو، ز. لوم، ی. جانستون، ا.؛ Mejia-Mendoza, LM؛ ژو، ایکس. ون، ی. آسپور-گوزیک، ع. Sargent, EH؛ بگو، ماشین ZW یادگیری برای آینده‌ای با انرژی پایدار. [CrossRef] Nat. Rev. Mater. 2023, 8, 202–215.

۴۳. القفرادی، ام‌ای؛ محمد، ای.؛ العلی، ای‌کی؛ دو، ایکس.؛ علی، آی؛ گویازی، ام. بررسی روش‌های یادگیری ماشین و یادگیری عمیق برای امنیت اینترنت اشیا (IoT) در بررسی‌ها و آموزش‌های ارتباطات IEEE؛ IEEE؛ نیویورک، نیویورک، ایالات متحده آمریکا، ۲۰۲۰؛ جلد ۲۲، صفحات ۱۶۸۵–۱۶۴۶

۴۴. مسعود، س.؛ برادی، ا.؛ بخاری، س.؛ اچ. آر.؛ کوانگ، پی. تی. ای.؛ احمد، او. بی.؛ عطری، م. بررسی یادگیری ماشینی در اینترنت اشیا چیزها: الگوریتم‌ها، استراتژی‌ها و کاربردها. اینترنت اشیا [CrossRef] ۲۰۲۰، ۱۲، ۱۰۳۱۴.

۴۵. عمر، کارشناسی ارشد؛ جونجو، کنتاکی؛ جیلانی، ام‌تی؛ ماتور، ای‌پی. یادگیری ماشینی برای تشخیص نفوذ در سیستم‌های کنترل صنعتی: کاربردها، چالش‌ها و توصیه‌ها. مجله بین‌المللی کریت. زیرساخت. پروت. [CrossRef] ۲۰۲۲، ۳۸، ۱۰۰۵۱۶.

۴۶. فون روئدن، ل.؛ مایر، س.؛ گارکه، ج.؛ باوکهاگه، س.؛ شوکر، ج. یادگیری ماشینی آگاهانه -به سوی طبقه‌بندی یادگیری صریح ادغام دانش در جدیدترین فناوری‌ها و فرصت‌های موجود برای مراقبت‌های بهداشتی. 2019, 18, 19-20.

۴۷. وارینگ، جی.؛ لیندوال، سی.؛ اومتون، آر. یادگیری ماشینی خودکار: مروری بر جدیدترین فناوری‌ها و فرصت‌های موجود برای مراقبت‌های بهداشتی. مصنوعات، اطلاعات، پزشکی. [CrossRef] 2020, 104, 101822.

۴۸. وانگ، اچ.؛ ال‌وی، ال.؛ لی، ایکس.؛ لی، اچ.؛ لنگ، جی.؛ ژانگ، وای.؛ تامسون، وی.؛ لیو، جی.؛ ون، ایکس.؛ لو، جی. رویکرد مدیریت ایمنی برای تولید انسان‌محور در صنعت ۵.۰ مبتنی بر دوقلوی دیجیتال. مجله سیستم‌ها. [CrossRef] ۲۰۲۳، ۶۶، ۱–۱۲.

۴۹. روتر، آ.؛ میکالیاس، پ.؛ جونز، م.؛ گادپالی، و.؛ سامسی، س.؛ کپتر، ج. بررسی و معیارسنجی شتاب‌دهنده‌های یادگیری ماشین. در مجموعه مقالات کنفرانس محاسبات شدید با کارایی بالا، 2019 IEEE (HPEC) والتهام، ماساچوست، ایالات متحده آمریکا، ۲۴ تا ۲۶ سپتامبر ۲۰۱۹؛ صفحات ۹ تا ۹.

۵۰. کاور، ب.؛ دادخواه، س.؛ شعله، ف.؛ نت، ECP؛ شیونگ، پ.؛ اقبال، س.؛ لاموتان، پ.؛ ری، س.؛ قربانی، ع.ا. اینترنت اشیا (IoT) تکامل مجموعه داده‌های امنیتی: چالش‌ها و مسیرهای آینده. اینترنت اشیا [CrossRef] 2023, 22, 100780.

۵۱. پاولادا، آ.؛ راجی، آی‌دی.؛ بندر، ای‌ام.؛ دنتون، ای.؛ هانا، آ. داده‌ها و (مشکلات) آن: بررسی توسعه و استفاده از مجموعه داده‌ها در تحقیقات یادگیری ماشین. الگوها [CrossRef] ۲۰۲۱، ۲، ۱۰۳۳۶. [پاب‌امد]

۵۲. اسلیمان، هو؛ بنواد، س.؛ خویی، ت.؛ کابوش، ن. یک مدل یادگیری ماشین مبتنی بر تقویت نور برای تشخیص حملات جیمینگ فریبده بر روی پهپادها. در مجموعه مقالات دوازدهمین کارگاه و کنفرانس سالانه محاسبات و ارتباطات (CCWC) IEEE 2022 لاس وگاس، نوادا، ایالات متحده آمریکا، ۲۶ تا ۲۹ ژانویه ۲۰۲۲؛ صفحات ۳۳۳ تا ۳۳۸.

۵۳. منش، ام آر؛ کنی، جی.؛ هو، دلیو سی؛ دواکاتونی، وی کی؛ کابوش، ان. تشخیص حملات جعل GPS بر روی سیستم‌های هوایی بدون سرنشین. در مجموعه مقالات شانزدهمین کنفرانس سالانه ارتباطات و شبکه مصرف‌کننده (CCNC) IEEE لاس وگاس، نوادا، ایالات متحده آمریکا، ۱۴–۱۵ ژانویه ۲۰۱۹؛ صفحات ۱۰۶ تا ۱۰۶.

۵۴. شیریفانی، ک.؛ امینی، م. یادگیری ماشینی و یادگیری عمیق: مروری بر روش‌ها و کاربردها. مجله مهندسی فناوری اطلاعات جهان. ۲۰۲۳، ۱۰، ۳۸۹۷–۳۹۰۴.

۵۵. عبید، اچ.؛ اس؛ دهیاب، اس. ای؛ صبری، اس. اس. تأثیر تکنیک‌های پیش‌پردازش داده‌ها و کاهش ابعاد بر دقت یادگیری ماشین. در مجموعه مقالات نهمین کنفرانس سالانه فناوری اطلاعات، مهندسی الکترومکانیک و میکروالکترونیک (IMECON) ۲۰۱۹ جاپپور، هند، ۱۳ تا ۱۵ مارس ۲۰۱۹؛ صفحات ۲۷۹ تا ۲۸۳.

۵۶. لیو، ب.؛ دینگ، م.؛ شهام، س.؛ رهایو، دلیو.؛ لین، ز. وقتی یادگیری ماشین با حریم خصوصی تلافی می‌کند: یک بررسی و چشم‌انداز. ACM Comput. Surv. (CSUR) 2021, 54, 1-36. [CrossRef]

۵۷. سینگ، س.؛ گوپتا، پ. مطالعه تطبیقی الگوریتم درخت تصمیم ID3، cart و ID4.5 یک بررسی. مجله بین‌المللی علوم و فناوری پیشرفته (IAIST) ۲۰۱۴، ۲۷، ۹۷–۱۰۳.

۵۸. ژانگ، ام‌ال.؛ ژو، زی‌اچ. ML-KNN یک رویکرد یادگیری تنبل برای یادگیری چندبرچسبی. تشخیص الگو. ۲۰۰۷، ۴۰، ۲۰۳۸–۲۰۴۸.

[مرجع متقابل]

۵۹. موسوی، م. ت.؛ احمد، و.؛ جان، ک. ه.؛ فارس، ک. ب.؛ هوملز، د. م. در مورد آموزش طبقه‌بندی‌کننده‌های تابع پایه شعاعی. عصبی شبکه. [CrossRef] ۱۹۹۲، ۵، ۵۹۵–۶۰۳.

۶۰. ژو، جی.؛ گندمی، ای.؛ اچ.؛ چن، اف.؛ هولزنگر، ای. ارزیابی کیفیت توضیحات یادگیری ماشین: بررسی روش‌ها و متریک الکترونیک [CrossRef] 2021, 10, 593.

۶۱. جیانگ، ت.؛ فانگ، ه.؛ وانگ، ه. اینترنت وسایل نقلیه مبتنی بر بلاکچین: معماری شبکه توزیع‌شده و تحلیل عملکرد. مجله اینترنت اشیا [CrossRef] IEEE. 2019, 6, 4640-4649.

۶۲. جیا، دلیو.؛ دای، د.؛ شیائو، ایکس.؛ وو، اچ. آرنور؛ کاهش نویز مبتنی بر تنظیم توجه برای طبقه‌بندی رابطه نظارت از راه دور. در مجموعه مقالات پنجاه و هفتمین نشست سالانه انجمن زبان‌شناسی محاسباتی، فلورانس، ایتالیا، ۲۸ ژوئیه تا ۲ اوت ۲۰۱۹؛ صفحات ۳۹۹ تا ۴۰۸.

63. اپیودون، OI؛ Omolara, AE؛ محمد، ن.ا.؛ ارشد، ج. پیشرفته‌ترین کاربردهای شبکه عصبی مصنوعی: الف نظرسنجی. هلیون [CrossRef] ۲۰۱۸، ۴، e00938.

۶۴. ایزنودجن، ن.؛ لایز، س.؛ فرج، ا. یک رویکرد طبقه‌بندی جدید برای سخت‌افزار شبکه‌های عصبی: از تراشه‌های استاندارد تا سیستم‌های تعبیه‌شده روی تراشه. Artif. Intell. Rev. 2014, 41, 491–534. [CrossRef]

۶۵. وانگ، دی.؛ هی، اچ.؛ لیو، دی. کنترل بهینه هوشمند با یادگیری انتقادی برای یک سیستم جرثقیل سقفی غیرخطی. IEEE Trans. انفورماتیک صنعتی [CrossRef] ۲۰۱۸، ۱۴، ۲۹۳۲–۲۹۴۰.

۶۶. وانگ، اس‌سی. شبکه عصبی مصنوعی. در محاسبات میان‌رشته‌ای در برنامه‌نویسی جاوا؛ اشپرنگر؛ برلین/هایدلبرگ، آلمان، ۲۰۰۳؛ صفحات ۸۱–۱۰۰.

۶۷. آلباوی، س.؛ محمد، ت.ا.؛ الزاوی، س. درک یک شبکه عصبی کانولوشن. در مجموعه مقالات بین‌المللی کنفرانس مهندسی و فناوری (ICET) ایتالیا، ترکیه، ۲۱ تا ۲۳ آگوست ۲۰۱۷.

۶۸.خویی، تی. تی؛ اسلیمان، اچ. او؛ کابوش، ان. امنیت سایبری شبکه‌های هوشمند: حملات، تشخیص، تکنیک‌های مقابله و مسیرهای آینده. ارتباطات، شبکه. [CrossRef] 14, 119-170. 2022.

۶۹.گونتوری، اس. کی؛ سارکار، دی. مدل‌های یادگیری ماشین گروهی برای تشخیص سرقت انرژی. مجله سیستم‌های برق و قدرت، ۲۰۲۱ [CrossRef] ۱۹۲، ۱۰۶۹۰۴.

۷۰.چافی، م؛ بادر، ف.؛ پالیکوت، ج. افزایش پوشش در اینترنت اشیا با باند باریک با استفاده از یادگیری ماشین. در مجموعه مقالات کنفرانس ارتباطات و شبکه‌های بی‌سیم (WCNC)، 2018 IEEE بارسلونا، اسپانیا، ۱۸-۱۵ آوریل؛ ۲۰۱۸ صفحات ۱-۶.

71. بیطاس، ص. Michailidis, ET؛ وویوکاس، ن. د. کاناتاس، AG نظرسنجی در مورد تکنیک های یادگیری ماشینی برای ارتباطات مبتنی بر پهپاد. حسگرها [CrossRef] 19, 5170. 2019، [پابمد]

72. بنوس، ال. تاگاراکیس، A.C. دولیاس، جی. بروتو، آر. کاتریس، دی. بوچتیس، دی. یادگیری ماشینی در کشاورزی: جامع بررسی به‌روز شده. حسگرها [CrossRef] ۲۱، ۳۷۵۸. ۲۰۲۱.

73. Wagle, PP؛ رانی، س. کولیگی، س.ب. سومان، BH؛ پرامود، بی. کومار، پی. رغوان، س. شستری، کالیفرنیا؛ سانجی، HA؛ کومار، م. و همکاران سیستم امنیت شبکه گروهی مبتنی بر یادگیری ماشین. در پیشرفت‌های اخیر در هوش مصنوعی و مهندسی داده؛ اشپرنگر؛ برلین/هایدلبگ، آلمان، 2022؛ صفحات 3-15.

۷۴. ساتون، س-ادی، درخت‌های طبقه‌بندی و رگرسیون، دسته‌بندی و تقویت. هندب. آمار. ۳۰۳-۳۲۹، ۲۴، ۲۰۰۵.

۷۵. زادنوردیک، ل.؛ بسولد، تی. آر. تی؛ کوساک، ر. درس‌هایی از یادگیری نوزادان برای یادگیری ماشینی بدون نظارت. نات. ماخ. اینتل. [CrossRef] ۲۰۲۲، ۴، ۵۱۰-۵۲۰.

۷۶. خویی، ت.ت.؛ کابوش، ن. تحلیل مقایسه‌ای مدل‌های نظارت‌شده و نظارت‌شده برای تشخیص حملات روی سیستم‌های تشخیص نفوذ. اطلاعات [CrossRef] ۱۴، ۱۰۳. ۲۰۲۳.

۷۷. کومار، پ.؛ گوپتا، ج-پی؛ تریپاتی، ر. یک چارچوب تشخیص حمله سایبری مبتنی بر یادگیری جمعی و معماری مه-ابر برای شبکه‌های اینترنت اشیا پزشکی. مجله کامپیوتر. ارتباطات. [CrossRef] 166, 110-124. 2021.

۷۸. هادی، م؛ عبدل، ای-ام-اف؛ شوونکر، ف. یادگیری نیمه‌نظارتی. در کتابچه راهنمای پردازش اطلاعات عصبی؛ اشپرنگر؛ برلین/هایدلبگ، آلمان، ۲۰۱۳.

۷۹. السکن، ت.؛ متزن، ج. ه.؛ هاتر، ف. جستجوی معماری عصبی: یک بررسی. جی. ماخ. یادگیری. پژوهش. ۲۰۱۹، ۲۰، ۱-۲۱.

۸۰. لی، ی.؛ ژو، ج.؛ لی، م.؛ رن، ی.؛ ژانگ، ب. هموارسازی همسایه‌ها روی نمودارهای معلم برای یادگیری نیمه‌نظارتی. در مجموعه مقالات کنفرانس IEEE در مورد بینایی کامپیوتر و تشخیص الگو، لیک سیتی، یوتا، ایالات متحده آمریکا، ۱۸ تا ۲۲ ژوئن؛ ۲۰۱۸؛ صفحات ۸۸۹۶ تا ۸۹۰۵.

۸۱. پارک، س.؛ پارک، ج.؛ شین، س.؛ مون، آی. ترک تحصیل خصمانه برای یادگیری تحت نظارت و نیمه نظارت. در مجموعه مقالات سی و دومین کنفرانس AAAI در مورد هوش مصنوعی، نیواورلئان، لوئیزیانا، ایالات متحده آمریکا، ۲۲ تا ۲۷ فوریه؛ ۲۰۱۸؛ صفحات ۳۹۱۷ تا ۳۹۲۴.

۸۲. خویی، تی. تی؛ کابوش، ان. مدل تقویتی مبتنی بر یادگیری Q کپسولی برای سیستم تشخیص نفوذ در شبکه هوشمند. در مجموعه مقالات کنفرانس بین‌المللی IEEE در مورد فناوری اطلاعات الکتریکی (eIT)، رومئوویل، ایلینوی، ایالات متحده آمریکا، ۲۰-۱۸ مه؛ ۲۰۲۳؛ صفحات ۳۳۹-۳۴۳.

۸۳. پولیدوروس، ای. اس؛ نالپانتیدیس، ال. بررسی یادگیری تقویتی مبتنی بر مدل: کاربردهای آن در رباتیک. مجله هوش، ربات، سیستم. [CrossRef] ۱۷۳-۱۷۳، ۸۶، ۲۰۱۷.

۸۴. دگریس، ت.؛ پیلارسکی، پی-ام؛ ساتون، یادگیری تقویتی بدون مدل RS با عمل پیوسته در عمل. در مجموعه مقالات کنفرانس کنترل آمریکا (ACC) سال ۲۰۱۲، مونترال، QC، کانادا، ۲۹-۲۷ ژوئن؛ ۲۰۱۲؛ صفحات ۲۱۸۲-۲۱۷۷.

۸۵. کانو، دی.؛ هو، دلیو، ژائو، جی.؛ ژانگ، جی.؛ ژانگ، بی.؛ لیو، زی.؛ چن، زی.؛ بلابجرگ، اف. یادگیری تقویتی و کاربردهای آن در سیستم‌های قدرت و انرژی مدرن: مروری. مجله سیستم‌های قدرت، انرژی پاک، [CrossRef] ۱۰۴۲-۱۰۲۹، ۸، ۲۰۲۰.

۸۶. ژانگ، جی. ام؛ هارمن، ام؛ ما، ال.؛ لیو، وای. تست یادگیری ماشین: بررسی، چشم‌اندازها و افاق‌ها. در ترانکشن‌های IEEE در مورد مهندسی نرم‌افزار؛ IEEE نیویورک، نیویورک، ایالات متحده آمریکا، ۲۰۲۲؛ جلد ۴۸، صفحات ۳۶.

۸۷. صلاح‌الدین، ف.؛ کبوش، ن. تهدیدات امنیتی، تشخیص و اقدامات متقابل برای لایه فیزیکی در شبکه‌های رادیویی شناختی: الف نظرسنجی. انجمن فیزیک، [CrossRef] 101001, 39, 2020.

88. رامیرز، ج. یو، دلیو، Perrusquía, A. یادگیری تقویتی بدون مدل از تظاهرات کارشناسان: یک بررسی. آرتیف. هوشمند کشیش [CrossRef] ۳۲۱۱-۳۲۱۳، ۵۵، ۲۰۲۲.

۸۹. یانگ، ل.؛ شامی، ا. در باب بهینه‌سازی فرایارامتری الگوریتم‌های یادگیری ماشین: نظریه و عمل. نوروکامپیوتینگ ۲۰۲۰، [CrossRef] ۳۱۶-۲۹۵، ۴۱۵.

۹۰. ک.؛ مادیکونتا، پی.کی.آر؛ گادکالو، تی.آر؛ باتاچاریا، اس.؛ هگده، پی.؛ سینگ، اس. بهینه‌سازی انرژی برای ارتباطات سبز در اینترنت اشیا با استفاده از بهینه‌سازی هریس هاکس. در IEEE Transactions on Green Communications and Networking؛ نیویورک، نیویورک، ایالات متحده آمریکا، ۲۰۲۲؛ جلد ۶، صفحات ۶۹۴-۶۸۵.

۹۱. خدادادی، ن.؛ اسناسل، و.؛ میرجیلی، س. الگوریتم بهینه‌سازی حسابی پویا برای بهینه‌سازی خرپا تحت شرایط طبیعی محدودیت‌های فرکانسی. [CrossRef] 10, 16188-16208. 2022, IEEE Access

۹۲. کامینز، سی.؛ واستی، بی.؛ گوئو، جی.؛ کوی، بی.؛ انسل، جی.؛ گومز، اس.؛ جین، اس.؛ لیو، جی.؛ تیتاد، او.؛ استاینم، بی.؛ و همکاران. CompilerGym: محیط‌های بهینه‌سازی کامپایلر قوی و کارآمد برای تحقیقات هوش مصنوعی. در مجموعه مقالات سمپوزیوم بین‌المللی IEEE/ACM 2022 در مورد تولید و بهینه‌سازی کد (CGO)، سنوئل، جمهوری کره، ۲۲ تا ۲۶ آوریل؛ ۲۰۲۲؛ صفحات ۱۹۲ تا ۱۰۵.

۹۳. ژانگ، دلیو.؛ گو، ایکس.؛ تانگ، ال.؛ یین، وای.؛ لیو، دی.؛ ژانگ، وای. کاربرد الگوریتم‌های یادگیری ماشین، یادگیری عمیق و بهینه‌سازی در مهندسی ژئومهندسی و علوم زمین: بررسی جامع و چالش‌های آینده. [CrossRef] 17-1, 109, 2022, Gondwana Res.

۹۴. میتال، س.؛ وایشای، س. بررسی تکنیک‌های بهینه‌سازی یادگیری عمیق روی پردازنده‌های گرافیکی. مجله سیستم‌ها. آرج. [CrossRef] ۱۰۶۳۵، ۹۹، ۲۰۱۹.

۹۵. ژانگ، کیو.؛ یانگ، ال-تی.؛ چن، زی.؛ لی، پی. بررسی یادگیری عمیق برای کلان‌داده. [CrossRef] 157-146, 42, 2018, Inf. Fusion

96. اوایلاده، اونتاریو؛ ازوگوو، ای-ای-اس.؛ محمد، تی-آی-ای؛ ابوعلیگاه، ال. الگوریتم جستجوی بهینه‌سازی ابولا: یک الگوریتم جدید الهام‌گرفته از طبیعت الگوریتم بهینه‌سازی فراابتکاری. [CrossRef] 10, 16150-16177. 2022, IEEE Access

۹۷. بلنک، جی.؛ دب، کی. پیمو: بهینه‌سازی چندهدفه در پاتون. [CrossRef] 8, 89497-89509. 2020, IEEE Access

۹۸. کایانو، ک.؛ یو، ک.؛ کو، ب.؛ لیانگ، ج.؛ سونگ، ه.؛ یو، ک.؛ یک چارچوب بهینه‌سازی چندوظیفه‌ای تکاملی برای مسائل بهینه‌سازی چندهدفه مقید. [CrossRef] Comput. 2022, 26, 263–277. [IEEE Trans. Evol.](#)

۹۹. ریاض، م.؛ احمد، س.؛ حسین، ا.؛ نعیم، م.؛ محبت‌پوپا، ل. تکنیک‌های بهینه‌سازی احتمالاتی در سیستم قدرت هوشمند. انرژی‌ها [CrossRef] ۲۰۲۲, ۱۵, ۸۲۵.

۱۰۰. ایو، تی.؛ ژو، ا.ج. بهینه‌سازی فراپارامتری: مروری بر الگوریتم‌ها و کاربردها. arXiv 2020, arXiv:2003.05689.

۱۰۱. ایانگ، ایکس.؛ سونگ، زد.؛ کینگ، آی.؛ شو، زد. بررسی یادگیری عمیق نیمه‌نظارتی. [CrossRef] arXiv 2021, arXiv:2103.00550.

۱۰۲. اگیسسون، بی آر؛ راجرز، تی تی؛ ژو، ایکس. یادگیری نیمه نظارتی انسان. تاپ. کاگن. ساینس. [CrossRef] ۲۰۱۳, ۵, ۱۳۲–۱۷۲.

۱۰۳. انگوین، تی. تی؛ نگوین، ان. دی؛ نهاوندی، اس. یادگیری تقویتی عمیق برای سیستم‌های چندعاملی: مروری بر چالش‌ها، راه‌حل‌ها و کاربردها. [CrossRef] Cybern. 2020, 50, 3826–3839. [IEEE Trans.](#)

104. کنیز، ال. کارداریلی، جی سی. دی نونزیو، ال. فضولاری، ر. جیاردینو، دی. ری، م. اسپانو، اس. یادگیری تقویتی چند عاملی: الف بررسی چالش‌ها و کاربردها. علوم کاربردی. [CrossRef] 2021, 11, 4948.

۵. ادو، دبلیو.؛ دینگ، س. بررسی یادگیری تقویتی عمیق چندعاملی: از منظر چالش‌ها و کاربردها. مصنوع. اینتل. ویرایش [CrossRef] ۲۰۲۰, ۵۴, ۳۲۱۵–۳۲۳۸.

۱۰۶. اسالوان، د.؛ کانت، س.؛ پاریک، ه.؛ شارما، ر. چالش‌های یادگیری تقویتی در پروتز. Mater. Today Proc. 2022, 49, ۳۱۳۳–۳۱۳۶. [\[مرجع متقابل\]](#)

۱۰۷. انارخده، ام‌اس؛ چاترجی، اس.؛ گوش، اس. روندها و چالش‌ها در تکنیک‌های بهینه‌سازی برای بهره‌برداری و کنترل ریزشبکه‌ها -مروری. در مجموعه مقالات اولین کنفرانس بین‌المللی برق و انرژی ۲۰۱۲ در NERIST (ICPEN) نی‌رجولی، هند، ۲۸–۲۹ دسامبر ۲۰۱۲؛ صفحات ۱۰۷–۱۰۸.

۱۰۸. اخی، ت.ت؛ اسماعیل، س.؛ کبوش، ن. تکنیک‌های انتخاب پویا برای تشخیص حملات جعل GPS روی پهپادها. حسگرها ۲۰۲۲, ۲۲, ۶۶۲. [CrossRef]

۱۰۹. اخی، ت.ت؛ اسماعیل، س.؛ الشمايله، ک.؛ دوابهاکتونی، و.ک.؛ کابوش، ن. تأثیر مجموعه داده‌ها و پارامترهای مدل بر عملکرد یادگیری ماشین برای تشخیص حملات جعل GPS در وسایل نقلیه هوایی بدون سرنشین. علوم کاربردی. ۲۰۲۲, ۱۳, ۳۸۳. [\[مرجع متقابل\]](#)

۱۱۰. اخی، ت.ت؛ کابوش، ن. شبکه‌های عصبی با اتصال متراکم برای تشخیص حملات انکار سرویس در شبکه هوشمند برق. در مجموعه مقالات سیزدهمین کنفرانس سالانه محاسبات فراگیر، الکترونیک و ارتباطات سیار (UEMCON) IEEE نیویورک، نیویورک، ایالات متحده آمریکا، ۲۶ تا ۲۹ اکتبر ۲۰۲۲؛ صفحات ۲۰۷ تا ۲۱۱.

۱۱۱. خان، ا.؛ خان، ش.؛ سیف، م.؛ بتول، ا.؛ سهیل، ا.؛ خان، م.و. بررسی تکنیک‌های یادگیری عمیق برای تحلیل کووید-۱۹ و کاربرد آنها برای تشخیص امیکرون. مجله تحقیقات نظری. هنری. هوش. [CrossRef] ۲۰۲۳, ۱–۴۳.

۱۱۲. اگویینات، م.؛ ستورامان، اس. سی. بررسی جامع تکنیک‌های تشخیص بدافزار مبتنی بر یادگیری عمیق. علوم کامپیوتر. ویرایش. ۲۰۲۳, ۴۷, ۱۰۵۲۹.

۱۱۳. اقیصری، م.؛ ابراهیم‌زاده، ف.؛ رحیمی، م.؛ معظمی‌گودرزی، م.؛ لیو، ی.؛ پرامانیک، پ.ک.د.؛ هروی، م.ا.؛ مهبذیا، ا.؛ قادرزاده، م.؛ فیلی‌زاده، م.ر.؛ و همکاران. یادگیری عمیق: کاربردها، معماری‌ها، مدل‌ها، ابزارها و چارچوب‌ها: یک بررسی جامع. در CAAI Transactions on Intelligence Technology: IET: Stevenage, انگلستان, ۲۰۲۳.

۱۱۴. مورگان، دی.؛ جیکوبز، آر. فرصت‌ها و چالش‌های یادگیری ماشینی در علم مواد. سالنامه پژوهشی مواد. ۲۰۲۰, ۵۰, ۱–۱۳. [CrossRef]

۱۱۵. افون، کی. کی؛ ژانگ، دبلیو. آینده یادگیری ماشین در ژئوتکنیک. ارزیابی، مدیریت، مهندسی ریسک، مخاطرات جغرافیایی ۲۰۲۳, ۱۷, ۷–۲۲. [CrossRef]

۱۱۶. اکریشنام، ان.پی.؛ اشرف، ام‌اس؛ راجاگوپال، بی.آر؛ واتس، پی.؛ چاکراواری، دی.اس.کی؛ رافی، اس.ام. تحلیل روندهای فعلی، پیشرفت‌ها و چالش‌های یادگیری ماشینی (ML) و استخراج دانش: از MI تا هوش مصنوعی قابل توضیح. موسسه صلاحیت صنعتی-مدیریت تبلیغات بریتانیا ۲۰۲۲, ۵۸, ۵۴–۶۲.

117. لی، ز. یون، جی. ژانگ، آر. رجبی پور، ف. Srubar, WV, III؛ دایو، آی. Radli'nska, A. یادگیری ماشینی در علم بتن: کاربردها، چالش‌ها و بهترین شیوه‌ها. [CrossRef] NPJ Comput. Mater. 2022, 8, 127.

۱۱۸. حسین، ای. ا.ج؛ ابوهاشیم، زی.؛ الحسینی، ام.؛ محمد، دبلیو. ام. یادگیری ماشینی در قلمرو کوانتومی: جدیدترین فناوری، چالش‌ها و چشم‌انداز آینده. [CrossRef] Expert Syst. Appl. 2022, 194, 116512.

۱۱۹. خان، ت.؛ تیان، دبلیو.؛ ژو، گ.؛ ایلگر، س.؛ گونگ، م.؛ بویا، ر. مدیریت منابع با محوریت یادگیری ماشین (ML) در فضای ابری محاسبات: مروری بر مطالعات و مسیرهای آینده. مجله محاسبات شبکه‌ای. [CrossRef] 2022, 204, 103405.

۱۲۰. استرهویزن، جی.ای؛ گلداسمیت، بی.آر؛ لینیک، اس. یادگیری ماشینی قابل تفسیر برای تولید دانش در کاتالیز ناهمگن. نات. کاتال. [CrossRef] 2022, 5, 175–184.

۱۲۱. ابهارادیا، جی. پی.، استفاده از یادگیری ماشینی برای هوش تجاری پیشرفته. مجله بین‌المللی علوم کامپیوتر. ۲۰۲۳, ۷, ۱–۱۹.

۱۲۲. طلائی خویی، ت.؛ اولد سلیمان، ح.؛ کابوش، ن. یادگیری عمیق: مرور سیستماتیک، مدل‌ها، چالش‌ها و مسیرهای تحقیقاتی. در محاسبات عصبی و کاربردها؛ اشپرنگر؛ برلین/هایدلبرگ، آلمان، ۲۰۲۳؛ صفحات ۱۰۲۲–۱۰۲۳.

۱۲۳. ابن‌آمر، س.؛ بلعید، ف.؛ بنکرایم، ر.؛ رمدانی، ب.؛ گوسمی، ک. طبقه‌بندی و خوشه‌بندی چندمعیاره: یک روش کتاب‌اسنجی بررسی و دستور کار تحقیق. [CrossRef] Ann. Oper. Res. 2023, 325, 771–793.

۱۲۴. والدز، ف.؛ ملین، پ. مروری بر محاسبات کوانتومی و الگوریتم‌های یادگیری عمیق و کاربردهای آنها. Soft Comput. 2023، 27، ۱۳۲۳۶-۱۳۲۱۷. [CrossRef]

۱۲۵. افیهری، دلیو اف؛ ارجون، ی.؛ حسن الغازی، ه.؛ کبوش، ن.؛ ابو المجد، ای.بی. یک الگوریتم مبتنی بر بهینه‌سازی ازدحام ذرات برای تشخیص حمله شبیه‌سازی کاربر اولیه. در مجموعه مقالات هشتمین کارگاه و کنفرانس سالانه محاسبات و ارتباطات، (IEEE 2018 (CCWC)، لاس وگاس، نوادا، ایالات متحده آمریکا، ۱۰-۱۸ ژانویه ۲۰۱۸؛ صفحات ۸۲۷-۸۳۳

سلب مسئولیت/یادداشت ناشر: اظهارات، نظرات و داده‌های موجود در تمام نشریات صرفاً متعلق به نویسنده (گان) و مشارکت‌کننده (گان) است و نه MDPI و/یا ویراستار (گان). MDPI و/یا ویراستار (گان) مسئولیت هرگونه آسیب به افراد یا اموال ناشی از هرگونه ایده، روش، دستورالعمل یا محصولی که در محتوا به آن اشاره شده است را از خود سلب می‌کنند.